

摘要：

招商证券指出，AI产业链正出现罕见价格分裂：上游存储、光模块、电力设备因供给紧张持续涨价，下游Token却卷入降价潮。但价格越低、Token用量越大。市场交易重心正从资本开支扩张转向算力变现验证，2万亿算力基建落地中，国产芯片、电力与储能或成最硬主线。

AI产业链的定价逻辑正在分裂。上游的存储、CPU、光模块在涨价，下游的Token价格在竞争式下跌——两件事同时发生，且都有加速的迹象。

招商证券张夏在6月15日发布的策略周报中写道：“**当前AI产业链正经历一场罕见的结构性定价。上游算力资源价格因供给刚性约束持续通胀，下游Token消费价格因模型能力跃迁与市场竞争加剧持续通缩。**”

这不是一个简单的“AI还行不行”的问题。2023年至2025年，市场主要交易海外头部大厂和国内企业资本开支扩张的确定性；进入2026年，尤其是6月以后，交易开始分化：上游硬件涨价还能支撑盈利预期，下游应用则被追问——Token降价之后，算力能不能变成稳定现金流和利润。

问题在于，Token便宜了，用量会不会足够多，多到足以抵消单价下跌？

上游：供给跟不上，涨价是必然

上游通胀的直接导火索，是一场原材料涨价潮。

六氟化钨是典型案例。韩国供应商已通知三星、SK海力士，2026年度六氟化钨合同价格上调70%-90%。此前4月，日本关东电化等核心供应商也发出供应中断风险警告。财联社相关信息显示，中国99.999%纯度六氟化钨价格已至1670-1810元/kg，较去年同期523元/kg上涨232.7%。

电子布涨价也在推动上游行情。再往后看，存储、CPU、光模块等AI硬件也延续涨价趋势。


涨价能被市场快速交易，是因为它和EPS联系很直接。估值已经不低时，资金更愿意追逐盈利上修；而涨价逻辑清楚、数据容易跟踪，自然成为资金筛选AI上游标的的入口。

更中期的逻辑是供需错配。云厂商资本开支快速上行，带来对GPU、存储、光模块、PCB、供电电等产品的持续需求。但上游扩产有周期，供给无法立刻跟上。

测算中的全球Hyperscaler资本开支从2022年的1620亿美元、2023年的1540亿美元，升至2025年的4480亿美元，2026年预期为7570亿美元，2027年预期为9200亿美元。需求斜率太陡，上游价格就很难平稳。


三星和SK海力士在2026年4-5月财报及交流中都提到，AI驱动的存储短缺将持续至2027年及以后，部分核心客户已经提前锁定2027年产能。

图 6: 全球主要云厂商资本开支 (十亿美元)



资料来源: Bloomberg, 招商证券

图 7: 全球 Hyperscaler 资本开支历史与预期 (十亿美元)



资料来源: SEC Filing, Epoch AI, 招商证券

下游：价格跌了，但用量在爆炸

下游的Token价格确实在跌，而且跌得很快。

衡量全市场Token支出的Silicon Data LLM Token支出指数，自今年2月单边上涨后，近期出现首次明显回落——企业开始认为主流大模型的token定价还会继续下降，于是推迟采购。OpenAI正考虑大幅下调token收费，原因是要应对Anthropic的降价压力；腾讯云已宣布部分模型输入价格下调66.67%。

图 4: Silicon Data LLM Token 支出指数在近期出现明显回落



资料来源: Silicon Data, 招商证券

但与此同时，调用量在爆炸式增长。

经济学里有个“杰文斯悖论”——当某种资源效率提升、成本下降后，总需求往往不降反升，因为使用门槛降低会催生出更多新场景。这个规律在煤炭、电力、通信带宽上都发生过，现在轮到Token。

根据OpenRouter数据，截至2026年6月8日，全球周Token调用量已达36.1万亿，且仍在指数级增长。

国内的数字更直观：生成式AI用户数从2024年底的2.49亿增长至2025年中的5.15亿，增长约2倍；同期日均Token消费量则从约1000亿增长至2026年一季度的1.4万亿——增长约1400倍。用户涨了2倍，消耗量涨了1400倍，说明驱动增长的主要不是新用户，而是每个用户调用深度的提升，以及Agent类应用的快速渗透。

表 1: 国内 AI 用户规模增长与 token 消费量对比


时间	生成式 AI 用户 (亿)	日均 Token 消费量 (亿)
2024-12-31	2.49	1000
2025-06-30	5.15	
2025-12-31		1000000
2026-03-31		1400000
增长倍数	2x	1400x

资料来源: CNNIC《第 55 次中国互联网络发展状况统计报告》，国家数据局

中国厂商的低价策略在这场竞争里收效显著。全球调用量最多的模型是DeepSeek和腾讯混元，而非能力测评分数更高的海外旗舰。开源模型的Token调用权重到2025年后期已接近三分之一总使用量，大量开发者开始用DeepSeek、通义千问替代部分闭源API。

从投资角度看，决定AI产业收入空间的关键变量，不是单个Token的价格，而是Token总消费量的增速——只要后者持续高于前者下降的速度，产业整体收入规模就不会萎缩。

图 5：全球周 Token 调用量已经达到 36.1 万亿 Token



市场交易逻辑正在切换

2023-2025年，市场交易的是CAPEX扩张的确定性——只要大厂持续砸钱，上游硬件就有订单。

进入2026年6月，这个逻辑开始分裂。上游继续涨，下游开始卷，市场开始追问一个更难回答的问题：算力能否转化为可持续的现金流和利润？

上周A股盘面面对AI下游通缩给出了负面反馈。但从总量视角看，决定行业成长空间的关键不是单个Token价格，而是Token总消费量的增长速度。当需求增长持续快于价格下降速度，AI产业整体收入规模仍有望维持增长。

Anthropic 6月9日发布的Claude Fable 5是一个典型案例，说明顶级AI公司的战略重心正在发生变化。

Fable 5的能力已全面超越此前任何面向公众开放的模型，且在任务越长、越复杂的情况下，领先幅度越大。但定价比此前的Mythos Preview低了不止一半——输入10美元/百万token，输出50美元/百万token。

图 3：Claude Fable 5 的能力全面领先现有大模型

	Claude Mythos 5 / Fable 5	Claude Mythos Preview	Claude Opus 4.8	GPT 5.5	Gemini 3.1 Pro
Agentic coding SWE-Bench Pro	80.3%	77.8%	69.2%	58.6%	54.2%
Agentic coding FrontierCode (Diamond)	29.3% xhigh	—	13.4% xhigh	5.7% xhigh	—
Knowledge work GDPval-AA	1932	—	1890	1769	1314
Knowledge work vision GDPpdf	29.8% no tools	—	22.5% no tools	24.9% no tools	16.7% no tools
Spatial reasoning Blueprint-Bench 2	38.6%	—	14.5%	36.2%	26.5%
Tool use AutomationBench	17.4%	—	15.5%	12.9%	9.6%

资料来源：Anthropic，招商证券

这家公司没有在能力最强的时候拿最高的价，反而在定价上更激进。原因很简单：对于企业客户来说，测评跑第一已经不是最重要的事，能不能大规模、低成本地部署，才是。

2万亿算力投资，钱流向哪里

政策层面，2025年1月发布的《国家数据基础设施建设指引》明确了“十五五”期间的投入方向：据业界初步测算，数据基础设施每年吸引直接投资约4000亿元，带动未来五年投资规模约2万亿元。与此同时，本轮算力基建要求至少80%的AI芯片来自华为、寒武纪等国内供应商，英伟达和AMD被直接排除在外。

根据EPOCH AI测算，典型1GW AI数据中心前期资本支出约380亿美元。按2万亿元总投资拆解，各环节受益规模如下：

- GPU芯片：占比39%，对应约7800亿元——这是整个产业链弹性最大的部分
- 电力与供配电：占比21%，约4200亿元（发电机、变压器、UPS各约1000-1200亿元）
- 土地、楼体与机房工程：占比11%，约2200亿元
- 光模块、交换机、散热设施：各占4%，各约800亿元，合计占比12%

表 2：算力中心建设成本拆解

维度	细分项目	成本占比	按 2 万亿测算金额（单位：亿元）
算力核心硬件设施	GPU	39%	7800
	CPU	2%	400
	存储	5%	1000
	PCB 印刷电路板	1%	200
	服务器主板、背板、电源模块、机箱、整机柜集成	3%	600
高速网络与通信互联基础设施	交换机、路由器	4%	800
	光模块、光芯片	4%	800
	网卡	2%	400
	光纤	2%	400
电力和供配电基础设施	发电机	6%	1200
	变压器	5%	1000
	UPS/HVDC 不间断电源系统	5%	1000
	其余供电设施	5%	1000
数据中心配套设施	土地、楼体、机房工程、承重结构、装修和园区配套	11%	2200
	液冷、风冷、冷却塔、精密空调等散热设施	4%	800
	其余数据中心配套设施	2%	400
	合计	100%	20000

资料来源：EPOCH AI, Business Insider, 招商证券

按2万亿总投资测算，其中约7800亿元流向国产算力芯片，摊分5年，每年拉动超1500亿元的国产AI芯片需求。


国产化进度比很多人预想的快。2025年国产芯片整体市占率约41%，2026年上半年首次突破52%，已超过英伟达。华为昇腾是最大赢家，2025年出货81.2万张，占国产芯片总出货量近一半；阿里平头哥26.5万张位居第二；百度昆仑芯和寒武纪各约11.6万张。

2026年5月，中国信息安全测评中心首次将“人工智能训练推理芯片”列为单独评测类别，昇腾310/910、寒武纪真武M530/M890等9款产品获得I级认证，有效期三年。这一认证对政府、央企、电信等采购场景具有直接的指引意义。



图 10：国产芯片 2025 年出货量情况

■ 华为昇腾 ■ 阿里平头哥 ■ 百度昆仑芯 ■ 寒武纪 ■ 海光信息 ■ 沐曦股份 ■ 天数智芯 ■ 其它




资料来源：IDC，招商证券

电力，被低估的受益方向

算力基建的2万亿投资中，约4200亿元将带动电力、散热、网络设备等配套建设。

中国信通院数据显示，2025年全国算力中心用电量已达1960亿千瓦时，增速远超全社会用电量均值。国家能源局预计，“十五五”期间全国算力用电量年均新增1000亿千瓦时以上，到2030年预计达到8000亿千瓦时，届时将占全社会用电量约6%。

图 11：2021-2025 年全国算力中心用电量占比提升



资料来源：中国信通院，招商证券

“东数西算”和“算电协同”已明确为国家政策方向。逻辑是这样的：东部算力需求集中，西部风光水电丰富——算力向西迁移可以消纳绿电，同时“西电东送”仍然需要高效的输电设备。AI高密机柜对供电稳定性要求极高，高效节能变压器、高压直流供电系统的需求由此被直接拉动。

储能的逻辑也在改变。数据中心需要7×24小时不间断供电，储能既可以替代柴油发电机做应急备用，也可以作为一路主供电电源通过并网提供日常供电。截至2025年底，全国已建成投运新型储能装机达1.36亿千瓦/3.51亿千瓦时，较2024年底增长84%——AI基建正在成为储能新增需求的重要变量。

最后看三件事：价格、调用量、资本开支

这轮AI产业链分化，不适合只用“上游好、下游差”概括。

上游涨价要看能不能传导到盈利。材料、存储、光模块、供配电设备涨价，短期更容易被市场交易，但也要看扩产后供需是否缓和。

下游Token降价要看调用量。只要Token总消费量增速快于价格下降，AI产业整体收入规模仍有
机会增长。反过来，如果降价没有换来足够调用量，应用端压力会更明显。

算力基建要看CAPEX能不能落地。2万亿元数据基础设施投资、国产AI芯片替代、电力和储能配
套，是这条链条里最硬的抓手。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文
中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

119 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论