


摘要：

全球AI交易近期剧烈波动，主因是交易高度拥挤及二季度业绩期临近，市场等待新催化剂。中金构建的四维泡沫监测体系显示：AI需求（调用量、付费比例）持续增长，但高成本削弱收入兑现，导致云厂商现金流压力加大，需依赖外部融资。目前产业处于融资第一阶段向第二阶段切换，整体尚未呈现全面泡沫化特征。短期AI交易将走向“缩圈”和分化，关注算力瓶颈资产（美国AIDC/电力）及国产算力链。

7月以来，Meta计划出售算力的消息[1]导致此前高度拥挤的全球AI交易明显降温，海外算力链的韩国KOSPI（-9%）和A股创业板50（-6%）都明显回调（美元计价），但国产算力链如科创芯片和半导体设备展现出相对韧性，上半年国内外同步的AI交易也转向了分化和“缩圈”，这与我们在下半年展望《“殊途同归”的K型分化》中预期一致。

为何全球AI交易出现如此剧烈的波动、为什么又是现在？首先，美国AI交易从2023年开始就大体遵循“两个季度强、一个季度弱”的规律，且每次市场对泡沫的担忧都是在业绩期（如2025年10月、2024年8月）。此次从年初开始AI交易持续至今也快两个季度了、加上二季度业绩期临近，市场进入纠结期、等待新的催化剂也就不意外了，我们此前就多次提醒7-8月可能是AI交易的波动期。其次，海外AI链条的交易本就高度拥挤（《如何应对高拥挤资产？》），短期叙事层面的扰动足以触发资金获利了结，尤其是集齐了“散户多、高杠杆、高拥挤”的韩股，波动就更为显著（《韩股杠杆风险有多大？》）。

图表：美国AI交易从2023年开始就大体遵循“两个季度强、一个季度弱”的规律



资料来源：FactSet，中金公司研究部

但不管情绪和拥挤交易可能诱发的波动有多大，**决定科技交易走向的归根结底还是基本面和产业趋势**，就如同去年四季度市场同样担心AI泡沫、私募信贷风险和AI挤出就业一样，但一季度AI投资激增和toB业务突破迅速消解了这一担忧，只不过现在又回到类似的节点。**当前的关键问题是：1）算力供给的稀缺性是否被削弱？2）云厂商Capex是否阶段性冗余？3）已投出去的资本开支能否转化为足够的回报？**

实际上，2023年以来，AI的发展就是在“投资增加→担忧泡沫→产业突破→投资增加”这个循环中波折前行，因此面对无法提前预知的产业进展（如去年底市场对toB业务期待不大），在任何一个时间点简单的宣称有无泡沫都是静态且武断的，相比之下，倒不如构建动态监测泡沫的体系，更具有现实意义。

因此在本文，我们从需求、现金流、资金来源、外部约束四个维度构建泡沫的监测体系，捕捉产业趋势的边际变化，判断本轮调整究竟是短期交易出清，还是产业逻辑的彻底逆转。


如何构建泡沫监测体系？四个维度；需求和现金流决定“过剩”，资金来源和外部约束是压力信号

泡沫的本质不在于投资规模本身有多大，而在“过剩”二字，是否过剩则是相对需求和能力而言的（《AI“泡沫”走到哪一步了？》）。刻画需求和能力的方式是看需求转化为收入的程度、以及企业获取的现金流能否支撑投资。

基于这一逻辑，我们以需求和现金流衡量是否过剩，以资金来源和外部约束作为压力信号，构建四层AI泡沫监测体系，具体来看：

- **第一层看需求和收入：**验证AI需求的重点，已经从“有没有人用”转向“有多少人愿意付费使用、付费强度多高、以及ToB和ToC哪一类更容易快速形成稳定收入”。因此，**需求端关注模型能力、Token使用量、单位成本以及付费使用比例。**
- **第二层看现金流：**需求兑现后，应用端带来的收入增长能否转化为利润和经营现金流是第二层的关注重点。**如果AI收入形成的内生现金流足够覆盖持续扩张的资本开支，那么产业闭环仍成立；**否则，对外部融资的依赖也将持续上升，这也引出了第三层资金来源验证的必要性。
- **第三层看资金来源：**AI投资的资金目前仍主要来自龙头企业内生现金流和低成本债务，但需要观察其是否开始向外部、高成本的融资扩散。**可以追踪科技信用债的发行规模和融资成本、银行信贷、风险投资和IPO的热度。**如果资金开始向未上市企业、未盈利的上市公司或高杠杆主体倾斜，泡沫化的特征也或将进一步加大。
- **第四层看外部约束：**如社会对AI挤出就业的反对和由此导致的监管对AI分红、杠杆等问题的强化，**从“企业是否愿意投资”到观察“外部条件是否允许继续投资”。**外部约束不一定直接削弱需求，但会通过拉长建设周期、推高建设成本、放大社会影响等压低投资回报，企业也会被迫放缓投资节奏。

图表：我们从需求、商业化与现金流、资金来源、外部约束四个维度构建泡沫的监测体系




资料来源：Artificial Analysis，Open Router，Bloomberg，Sensor Tower，FactSet，OpenAI，Anthropic，中金公司研究部

1 如何刻画需求？调用量和付费说明需求不断增长，但成本削弱了收入兑现，反而说明需要更多投资

与新能源车、智能手机等硬件不同，AI的“使用”门槛更低，仅下载应用、发起对话或短期试用都可能被计入渗透率。因此，宏观层面的AI使用比例并不能反映真实的AI需求，需要沿着使用规模→付费比例→收入兑现的链条来逐层验证：1) 调用量决定需求基础，2) 付费比例决定了商业化程度，3) 最终收入还取决于单位Token价格和低价模型使用结构。


1) 首先，有没有量？AI需求是否产生了足够大的真实调用量？全球Token使用量年初以来增长超9倍，根据Open Router的统计，推理需求推动全球日均Token使用量由2026年初以来的6800亿快速增长至7万亿。与此同时，中美前沿模型能力的差距收窄尤其是价格优势明显，在近期Token成本过高的背景下，中国模型的使用量不断上升甚至领先全球，占比也由年初的20%升至当前的56%，美国模型使用量的占比反而由70%下行至37%，这也是近期Token支出下降的原因，不是因为调用减少，而是因为切换到相对便宜的模型。

图表：推理需求推动全球日均Token使用量由2026年初以来的6800亿快速增长至7万亿




资料来源：Open Router，中金公司研究部

图表：此前中国发布的DeepSeek R1、Kimi K2也阶段性追平甚至反超美国模型的得分



资料来源：Artificial Analysis，中金公司研究部

图表：中国模型的Token使用量占比也由年初的20%持续抬升至当前的56%




资料来源：Open Router，中金公司研究部

2) 其次，付不付费？有多少用户愿意为AI需求付费？ToB端需求兑现速度更快，美国企业付费比例升至55%，但集中在知识密度高、数字化基础好的行业。根据Ramp AI Index对美国7万家样本企业的信用卡和账单平台支付数据，美国企业对AI的付费比例由2026年初的47%升至


55%。其中，科技传媒（80%）和金融保险（74%）行业付费比例最高，这也是美国非农就业中IT与金融行业受AI冲击最为明显的原因，而制造业付费比例也在2025年底超过整体水平，酒店餐饮则相对偏低（31%），**表明AI真实的付费需求率先在能够嵌入 workflow、并较快形成效率回报的行业兑现。**不同模型的付费比例同样印证这一特征，得益于年初以来Claude Code等开发者工具在企业场景中使用提升，Anthropic的企业付费比例自2025年底的18%加速抬升至6月的42.4%，超过OpenAI成为当前美国企业付费比例最高的大模型公司；相比之下，侧重toC端的模型如Gemini则明显落后，也解释了港股大模型公司表现的差异。

图表： AI真实的付费需求率先在能够嵌入 workflow、并较快形成效率回报的行业兑现



资料来源：Ramp AI，中金公司研究部


图表： Anthropic的企业付费比例自2025年底的18%加速抬升至6月的42.4%



资料来源：OpenAI，Anthropic，中金公司研究部


3) 最后，收入转化效果如何？单位Token支出下降削弱了AI需求的收入兑现效果。按照市场真实用量加权计算，百万Token平均支出已经由5月中旬最高峰的2.8美元回落18%至2.31美元。不过需要强调的是，在总使用量和付费比例持续扩张的同时，单位支出下降本身并非负面信号，**这意味着新增需求正更多由流向更正在从高价格模型转向更经济的模型。**这一趋势也解释了中国模型使用量占比的快速反超，中美模型差距不断缩窄的背景下，Token价格成为用户选择模型的重要因素之一。中国模型中，DeepSeek（176美元）、Minimax（203美元）、Kimi K2（831美元）和GLM 5.2（933美元）的单位Token价格要远低于Claude Fable 5的6015美元和GPT 5.5的2818美元。

图表：真实用量加权的百万Token支出已经由5月中旬最高峰的2.8美元回落18%至2.31美元



资料来源：Bloomberg，中金公司研究部

图表：DeepSeek、Minimax、Kimi K2和GLM 5.2的单位Token价格远低于美国模型



资料来源：Artificial Analysis，中金公司研究部

综合来看，从第一层的需求角度看，目前AI需求呈现调用量快速增长、付费比例提升，但单位价格下降的特征，意味着AI需求基础和商业化程度都已显著提高，但高成本环境下，用户正更多转向低成本模型。换言之，AI需求尚未证伪，但收入进一步转化面临成本约束，这也意味着在当前算力供给和成本结构下，高性能模型的大规模使用仍然偏贵，后续反而还需要更多算力投资来释放需求。


2 现金流压力如何？收入加速转化但慢于支出，现金流压力增加，云厂商接近临界点

需求得到验证之后，下一步需要观察现金流能否支撑投资支出的强度。对Open AI和Anthropic等模型公司而言，重点在于用户付费和企业收入能否覆盖其算力成本；对于云厂商而言，则需要验证来自模型公司和企业客户的云业务收入能否覆盖其资本开支，进而加大外部融资需求。

1) 是否已转化为持续的收入？应用端看，模型公司商业化明显提速。Anthropic月均用户收入（ARPU）和付费用户占比显著抬升，由2025年底0.9美元增长207%至2026年5月2.76美元，付费用户占比也升至13%，从更完整收入口径看，Anthropic ARR由2025年底的90亿美元大幅升至470亿美元。OpenAI的ARPU和付费用户比例增速相对平稳，ARR由214亿美元小幅增至250亿美元。云厂商云业务也受算力需求提振而加速兑现，主要云厂商的云业务收入在2026年一季度突破1000亿美元，同比增长36%。彭博一致预期显示，云收入规模将继续加速增长，二季度


和三季度或分别突破1100亿美元和1200亿美元。不过，单位Token支出自5月以来的下降，可能会削弱收入转化的速度，这也是市场担心的原因。

图表：Anthropic ARR由2025年底的90亿美元大幅升至470亿美元



资料来源：Bloomberg，中金公司研究部

图表：主要云厂商的云业务收入在2026年一季度突破1000亿美元




资料来源：FactSet，中金公司研究部

2) 是否能覆盖支出？模型公司尚未将收入转化为稳定的现金流。Anthropic的ARR自2026年4月超过OpenAI，规模快速增长的背后是其收入结构的不同。Anthropic约85%的收入来自企业和开发者客户，OpenAI则恰好相反，85%来自个人订阅[2]。商业模式和定价权的差异也或将使得Anthropic更快将收入转化为现金流，OpenAI管理层预计2030年才能首次实现自由现金流转正[3]，但Anthropic预计2028年收入将达到700亿美元，同时实现170亿美元的正现金流[4]。


云厂商的现金流压力更多来自资本开支，目前已经基本耗尽。Hyperscaler五大云厂商自由现金流一季度同比收缩78%至95亿美元，市场预期三季度或转负，其中亚马逊和甲骨文的自由现金流一季度已耗尽，谷歌和微软则相对健康)。不过这一担忧从去年底以来就被反复交易，如果AI需求继续扩张，收入提升将缓解自由现金流的压力。同时，存量杠杆水平依然较低43%，短期不构成系统性的偿付压力。

图表：云厂商自由现金流一季度已经同比收缩78%至95亿美元，一致预期显示三季度或将转负



资料来源：FactSet，中金公司研究部

图表：2026年一季度五大云厂商的资本开支 vs. 经营性现金流的比例已经升至94%



资料来源：Bloomberg，中金公司研究部

综合来看，虽然模型公司和云厂商的收入都在加速兑现，但兑现速度受Token支出影响，也仍慢于投资支出，导致现金流的压力增加，进而需要更多外部资金支持，这也是市场的主要担心点，这也引出第三层对资金来源讨论的必要性。


3 钱从哪来、谁在给AI投资？由云厂商驱动的第一阶段逐步转向全社会融资的第二阶段

AI投资的钱从哪里来、谁在给AI投资，也是判断泡沫阶段的重要维度。过去两年，AI投资主要由云厂商依靠自有现金和经营性现金流。但随着资本开支持续增长，内生现金流覆盖能力接近临界点，需要依赖外部融资。外部融资增加并不等同于泡沫，在目前的融资成本和杠杆水平上，云厂商仍可以承受一段时间的外部融资增加。但若主要的融资主体由龙头企业大幅扩散到未盈利和商业模型不确定的公司，产业泡沫化的程度也会随之增加。

借鉴互联网泡沫的经验，产业融资经历了三个阶段：1) 第一阶段，电信运营商和大型科技企业90年代初启动移动网络基础设施投资，依靠经营现金流，类似这一轮的五大云厂商；2) 第二阶段，随着网景（Netscape）在1995年8月上市，融资由企业内部扩展至公开市场和更广泛的社会资本，同时1996年政府颁布《电信法》推动产业投资增长（《美国“泡沫”破裂了吗？与互联网泡沫的对比》），意味着资金来源扩散至全社会融资；3) 第三阶段，融资门槛显著下降，二级市场上市潮带动更多IPO资金入市，1998年后大量低盈利、负现金流甚至商业模式尚未验证的公司上市，产业的泡沫化逐步增加。


类比科网泡沫，目前处于第一阶段向第二阶段的转换期，仍由云厂商主导，但已经逐步转向全社会融资。云厂商作为本轮AI投资的起点，其资本开支主要投向基础层的数据中心以及配套设施，在美国龙头企业的AI产业链的投资规模中占据近八成。但现金覆盖能力的下降，增加了外部融资的规模。2026年以来，五大云厂商累计发行的信用债规模达到1320亿美元，已超过2025全年发行的930亿美元。但外部融资并非坏事，当前五大云厂商的ROIC（21%）显著高于其WACC（12%，图表12），表明现阶段企业仍有意愿加杠杆。信用市场虽未系统性收紧，但伴随信用债供给增加，五大云厂商5年期CDS均已边际抬升，其中甲骨文升幅最大超过40bp，亚马逊、谷歌和Meta次之，反映市场已经开始针对资本开支扩张、杠杆抬升以及投资回报的不确定性计入更高的风险溢价。

图表：五大云厂商的ROIC显著高于其WACC



资料来源：Bloomberg，中金公司研究部

图表：五大云厂商的5年期CDS已经边际抬升




资料来源：University of Florida，中金公司研究部

随着Anthropic和OpenAI推进上市，AI融资也将进入第二阶段。2025年7月生效的“大美丽法案”通过100%折旧、允许美国境内研发支出的当期扣除等优惠方式推动产业投资。同时，Anthropic和OpenAI上市，融资将逐步由战略投资者和私募资本，扩展至共同基金、养老金及居民等更广泛的投资者，更低成本的权益资金参与AI基础设施投资，也会部分“分担”云厂商的资本开支压力。

目前尚未到互联网革命时期的第三阶段。美国风投融资规模自2023年1690亿美元加速升至2025年的3400亿美元，2026年仅一季度风投融资规模就达到2670亿美元，相当于美股总市值0.3%，接近

1999-2000年水平。不过，当前资金高度集中在头部AI企业，并未广泛扩散至商业模式不稳定的初创企业。一季度OpenAI、Anthropic、xAI、Waymo和Databricks五笔融资金额合计占风投总额的73%[5]。作为对比，1999年高峰期有370家科技股上市，募集资金占52%，但其中实现盈利的公司仅占14%。

图表：1999年的高峰期有370家科技股上市，募集资金占52%，但实现盈利的公司仅占14%



资料来源：Haver，中金公司研究部


综合看，目前AI产业融资正由第一阶段向第二阶段切换，整体杠杆水平和信用风险相对健康，尚未呈现典型的泡沫化特征。如果后续融资行为进一步由当前的云厂商和模型龙头，扩散至高杠杆、负现金流甚至商业模式尚未验证的公司，也将成为判断泡沫化加剧的重要信号之一。

4 外部约束的压力？社会的反对与监管趋严，但现阶段AI的正面性足以抵消负面影响

正如我们在《AI时代与人口变局猜想》中提到的，AI变革有其两面性，在提升全要素生产率和拉动短期增长上有正面性，但也有短期人口减少和就业挤出的负面效应。随着算力和算法的发展，劳动的分配份额可能面临挤出，需要妥善应对好潜在的分配分化问题。但现阶段，AI投资不管是拉动增长还是提升效率都有很强的正面性，更不用说长期战略意义，因此政策仍有很强动力加大支持力度。但随着时间推移，就业挤出导致反对声音，投资引发的环境等现实问题，分配差异拉大导致的监管趋严，都会增加压力。

1) 初期就业冲击集中在科技和金融等高暴露行业。目前AI对就业的影响更多是结构性的，裁员人数中科技和金融相关行业占比约40%，过去三年美国IT行业净减少近45万人，但从整体上看影响并不显著，以科技为代表的就业人数占比自2023年的4.3%小幅回落至3.9%。**初期就业的挤出仍以高附加值和专业化工作为主（如程序员），但当机器人的加持对更广泛的标准化就业挤出加大后，社会的反对声音也可能会逐渐增加。**


图表：过去三年美国IT行业净减少近45万人



资料来源：U.S. Data Centers Tracker，中金公司研究部

2) 居民反对和地方审批已成为数据中心建设的约束。Blackstone旗下QTS在经历多年社区反对和诉讼后，于2026年7月终止弗吉尼亚Digital Gateway大型数据中心项目[6]，表明即使资金和需求充足，土地审批、环境影响及社会接受度仍可能导致项目延期甚至取消。目前美国1592个数据中心里面，与Digital Gateway类似的取消案例有62个。

图表：目前美国1592个数据中心里面，与Digital Gateway类似的取消案例有62个



资料来源：FactSet，中金公司研究部

3) 分配问题逐渐浮出水面，如AI“分红税”可能挤压资本开支空间。5月韩国政府官员提议[7]，通过对AI的相关收益征税向国民支付分红，该消息引发韩国股市剧烈震荡，投资者担心针对企业的“超额利润税”或挤压后续AI投资的空间。

虽然外部约束不会直接放大泡沫，但会抬高投资成本、延长项目建设周期、甚至可能打断企业继续投资的链条，尤其在市场对AI投资回报产生分歧时，上述因素都有可能加剧担忧，进一步放大对现金流耗尽和投资放缓的担忧。

后续AI交易将如何演变？短期走向“缩圈”和分化，新催化剂出现前关注“瓶颈资产”


综合四个维度的泡沫监测指标体系看，AI需求仍在快速兑现，但现阶段受制于成本，收入兑现速度慢于投资，导致现金流无法完全覆盖算力端的支出，引发了市场担忧；不过外部融资目前仍处于初期，资金来源和投资主体都相对健康，尚未呈现完全泡沫化的特征；外部约束有所增

加，但尚不足以抵消正面性。这与去年三四季度类似，即产业趋势尚未证伪，但原有催化已被充分定价，市场需要等待财报、模型升级等新的催化剂。

往前看，二季度业绩期间市场将维持观望，等待催化剂，大概率走向“缩圈”和分化抵御波动。如果新催化剂出现（例如二季度财报再度超预期，需求大幅增加，又或者新的业务模式突破，如toC业务），那么有望“复制”一季度情形，推动全球硬件行情再度扩散。

否则，在此之前，AI交易可能走向分化，更多关注短期确定性和“瓶颈资产”。1) 海外算力方向，相比短期存在变数的芯片，美国的约束更多在于算力交付、电力和数据中心建设，因此美国AIDC、电力设备等链条仍有支撑；2) 国产算力方向，中国的约束在高端芯片供给，故国产算力、科创芯片、半导体设备等自主可控方向韧性更强，同时模型能力的提升也增加了Token出海的机遇，也利好国产算力链的发展。

图表： AI交易可能走向分化，更多关注短期确定性和“瓶颈资产”



资料来源：Artificial Analysis, Open Router, Bloomberg, Sensor Tower, FactSet, OpenAI, Anthropic, 中金公司研究部

本文来源：[中金刘刚、杨萱庭](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

👍 75 ⭐ 收藏

分享到:

写评论

请发表您的评论

😊 表情 🖼️ 图片

发表评论