摘要：
字节跳动Seed的安全工作，正在从一个既有团队变成独立的组织单元。 10月13日，字节跳动Seed宣...

字节跳动Seed的安全工作，正在从一个既有团队变成独立的组织单元。

10月13日，字节跳动Seed宣布成立“Seed Model-Alignment & Preparedness”部门，由严林负责，向Seed负责人吴永辉汇报。原Responsible AI团队及部分Chat团队成员转入新部门。

部门负责模型规范、安全评估、对齐训练、防护系统和风险监控。“Alignment”指模型行为与人类意图和安全约束保持一致；“Preparedness”则指为模型能力继续提升后可能出现的风险做准备。

字节在部门目标中写入提升智能体模型安全能力，以及防范化学、生物、放射、核等前沿能力风险。安全评估将承担什么职责，评估结果能否影响模型和功能的开放，成为这次调整留下的核心问题。

原有安全团队，为何要重新编组

Seed此前已有Responsible AI团队。此次调整将原团队与部分Chat团队成员归入同一架构，两类人员的具体比例和分工尚未公开。

从新部门覆盖的职责看，字节试图把模型训练、评估与部署后的风险处置放到同一组织框架下；

模型规范和对齐训练属于研发环节，安全评估用于测试能力边界，防护系统和风险监控面向部署后的攻击、偏离与异常行为。

Seed近来的产品进展，为这种整合提供了现实场景。

今年6月，Seed发布Seed2.1，重点强调跨工具、跨环境的任务交付能力。

按照Seed官方介绍，该模型可处理文件、调用工具、完成代码实现和运行环境搭建等多步骤任务，并已在豆包、TRAE上线，通过火山方舟提供API。

模型只生成答案时，风险主要集中在回答内容。进入任务执行环节后，模型还要理解目标、选择工具、读取数据，并在外部系统中完成操作，风险也会随权限延伸。

模型可能误解用户意图，也可能受到网页、文档、邮件中恶意指令的干扰。工具权限设置过宽、上下文遭到投毒，都可能让一次模型偏差变成实际操作。

OWASP去年底发布的智能体应用十大安全风险，将目标劫持、工具滥用、身份与权限滥用、记忆与上下文投毒列为重点。这类风险发生在模型调用工具和访问外部系统的过程中，通常还需要权限控制、运行监测等机制配合。

字节将模型侧团队与部分Chat团队成员放入同一架构，或意在缩短测试、训练与产品上线之间的反馈链路，新部门能否参与模型发布评审，是否有权要求补充测试或暂停功能开放，公开资

料尚未披露。

独立部门提供了稳定的负责人和汇报线；

它能在多大程度上影响模型发布节奏，仍取决于评估流程、资源配置和处置权限。

大规模应用前，厂商需要证明什么

QuestMobile数据显示，今年6月，豆包活跃用户规模达到3.82亿。活跃用户不等同于智能体用户，却显示出字节拥有较大的AI应用入口。

Seed模型正在通过豆包、TRAE和火山方舟进入消费者、开发者和企业场景。模型能力向更多用户和更多工具开放后，安全问题会从研发问题进入产品和运营环节。

用户愿意让模型生成一段文本，未必愿意让它处理文件、接入企业内部系统或完成关键操作。后几类任务需要明确授权范围、操作记录和异常处置机制，企业客户尤其看重这些环节。

自动化程度越高，模型能够创造的价值越大；授权范围越广，发生错误后的代价也越高。安全能力会影响智能体能否进入高价值工作流。

监管要求已经落到具体操作。

今年5月，国家网信办等部门发布《智能体规范应用与创新发展实施意见》，要求用户对智能体自主决策享有知情权和最终决策权，智能体执行操作不得超出授权范围；

文件还提出行为围栏、攻击检测、权限管理、供应链安全和第三方评测等要求。

Seed新部门的职责与上述要求存在交集；

模型规范涉及行为边界，安全评估对应上线前测试，防护系统和风险监控面向运行时处置，监管并不能单独解释字节的组织调整，但智能体加速落地，正在把安全工作推向研发和产品的前端。

海外实验室已经开始把安全要求嵌入模型研发。

Anthropic的Responsible Scaling Policy将能力阈值与相应安全措施配对：当模型达到预设能力等级后，需升级部署与安全防护。它提供了一种可供参照的路径，模型能力提升后，安全要求也要同步升级。

对Seed而言，接下来需要公开的并非更多原则，而是更具体的机制：安全评估覆盖哪些模型和产品，第三方测试如何进入发布流程，发现高风险能力或异常行为后，评估结果如何影响上线决定。

字节已经把安全与对齐提到独立部门层级。安全评估能否进入模型发布链条，将决定这次调整最终的分量。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取



限免

28 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论