

摘要：

阿里开源Qwen 3.8 Flash-Next，采用125B MoE架构（激活约6B参数），支持262144 token上下文，训练成本大降，性能提升，价格仅为DeepSeek-V4-Flash的1/3。实测显示其能快速完成文案改写、会议纪要整理等办公任务。同期智谱也开源GLM-5.3-Flash，性能对标Claude Opus 4.8但价格更低，国产大模型价格战持续升级。

阿里千问新模型，又卷出了新水平。

他们发布并开源的Qwen 3.8 Flash-Next，不仅价格直接秒杀了DeepSeek-V4-Flash，而且刚发布便摘得了Huggingface榜首！



推上网友们也沸腾了，甚至还有工程师甩出实测视频直呼牛逼：

Qwen 3.8 Flash踏平了VRAM的门槛，数据中心级的长文本大模型，在消费级4090显卡上也能跑了！



Alok @analogalok · 7h

The VRAM barrier is officially dead.

VRAM 方面的限制已经不复存在了。

I just ran Qwen 3.8 Flash Next (MoE) 125B A6B with a 250,000 context window on a single 24GB RTX 4090.

我刚刚在一张 24GB 的 RTX 4090 显卡上运行了 Qwen 3.8 Flash Next (MoE) 125B A6B 版本。该模型使用了 250,000 的上下文窗口大小。

21 tokens/sec decode. 364 t/s prefill.

每秒可解码 21 个令牌。预填充速度为每秒 364 个令牌。

no mtp. no dflash. no kv cache quantization!

没有 MTP 功能。没有 DFlash 技术。也没有 KV 缓存量化功能！

We are running datacenter models on consumer @danielhanchen:

我们正在消费者的 @danielhanchen 设备上运行数据中心相关模型：

还有人已经兴冲冲地把它用到了工作中。

不到8分钟，它就跑完了涵盖Python编程、多表分析和研究报告生成的一整套 workflow：



Md Ismail Sojal  
@0x0SojalSec

Follow



在配备 64GB 内存的 MacBook M5 Max 上本地运行全新的 Qwen 3.8 Flash Next，速度流畅，达到 30 tok/s。完整的代理工作流程，包括网络搜索、Python 编程和多表研究报告，在 8 分钟内完成。

 公众号 · 量子位

宝塔特效也不在话下：



Wäsche  @WäscheNex1q · 10h



Say hello to the most beautiful and elaborate pagoda scene ever made.
3.8-flash setting a new standard

来欣赏有史以来最美丽、最精致的宝塔场景吧。3.8 级的特效效果堪称一流。

哇奥，真有这么炫？我们当然也得上手试试。



 公众号 · 量子位

每百万Tokens输入仅0.8元

Qwen3.8-Flash采用了**125B MoE架构**，每Token仅激活约**6B参数**，原生可支持**262144token**上下文，并可通过YaRN扩展至**1M token**。

同时，它也是Qwen4新架构的提前预演。

相比于Qwen 3.7 Plus，Qwen 3.8 Flash不光把激活参数砍到了1/3，训练成本也仅为其1/9，且通用、数学推理、编程等能力都更加强悍了。

更狠的是价格，Qwen 3.8 Flash**每百万Tokens输入仅0.8元**，输出**2.7元**，缓存命中**0.1元**，价格最低至DeepSeek-V4-Flash的**1/3**。



真是比拼多多砍一刀力度大多了（bushi



好吧好吧，既然价格已经卷到了这个份上，那咱也不客气了，直接上强度，用两个实测来探探Qwen 3.8 Flash在办公场景实际的干活能力吧。

实测一：为相机产品设计四种适配不同风格平台的文案

我们设计了一场“赛博文案挑战赛”，让Qwen 3.8 Flash在1元的额度内，将一份近万字的相机产品资料改写成小红书、微博、抖音和朋友圈文案，看看它究竟能完成多少项任务。

提示词如下：

提示词:

Role

你是一位精通多平台内容运营的资深数码文案专家,擅长将产品资料转化为符合各平台调性的高转化文案。

Task

请将下方【相机产品资料】改写为4个平台的发布文案:小红书、微博、抖音口播稿、朋友圈。

Constraints (关键! 节省 Token & 保证质量)

1. 严格基于资料事实, 禁止编造参数或功能
2. 每个平台文案独立输出, 用「===平台名===」分隔
3. 禁用"首先/其次/总之"等 AI 感连接词
4. 总输出控制在 1200 字以内 (避免超预算)
5. 每文案需包含: 正文 + 3 个精准标签/话题

Platform Style Guide

- 小红书: 闺蜜种草语气, emoji 密度适中, 突出使用场景痛点, 标题带数字/情绪钩子
- 微博: 前 20 字设悬念, @官方账号, 带#话题#, 引导评论区互动
- 抖音: 前 3 秒强冲突开场, 口语化短句, 标注[画面建议], 结尾留行动指令
- 朋友圈: 第一人称真实体验感, 不超过 6 行, 像朋友分享而非广告

发完提示词之后, 我就去公司茶水间打了个水, 全程不到2分钟。

回来一看, 四份不同平台的文案都已经全部写好了, 并且@对了品牌、风格、话题词条拿捏得准准的 (除了我不会那么发那么长的朋友圈之外hhh):

===小红书===

标题: 376g的佳能R50, 终于把“相机太重懒得带”治好了😄

白色机身+银色18-45套头, 颜值真的很奶油~

约2420万有效像素, 搭配DIGIC X, 日常拍人、拍猫狗、拍车都能识别追踪, 新手上手压力小很多。

视频最高4K 30p, 全高清还能到120p, 拍Vlog、日常记录都够用。

机身约376g, 含电池和存储卡, 包里随手塞, 出门没那么劝退。

但也要说真话:

机身没有传感器位移防抖, 套机镜头有IS光学防抖。

单卡槽、UHS-I卡, 拍得勤快记得及时备份。

官方标配不含存储卡、相机包、三脚架、备用电池, 别默认都有。

#佳能R50 #第一台微单 #白色相机

公众号 · 量子位

===微博===

376g白色微单, 拍猫还能追车?

佳能EOS R50白色套机整理: 约2420万有效像素, 全像素双核CMOS AF, 最多4503个对焦点位, 支持人物/动物/车辆与眼睛检测; 电子快门最高约15张/秒, 视频6K超采样4K 30p, 全高清最高约120p。套头RF-S18-45mm F4.5-6.3 IS STM带光学防抖, 机身约376g含电池卡。截图加补后价6449元, 优惠前7766元, 实际以结算页为准。你最想带它拍什么? @佳能中国

#佳能EOSR50# #新手微单# #Vlog相机#

公众号 · 量子位

===抖音口播稿===

别急着买相机，先搞清这台白色R50适不适合你！

[画面建议：白色机身上手特写→拍猫/拍人→镜头铭牌特写→参数卡弹出]

佳能EOS R50，白色机身约376g，含电池和存储卡。

约2420万有效像素，DIGIC X处理器。

支持人物、动物、车辆识别，还能检测眼睛。

最高约15张/秒电子快门，抓拍小孩、宠物有戏。

视频4K 30p，全高清最高120p，日常Vlog够用。

重点提醒：

机身没有传感器位移防抖，套头有IS光学防抖。

单卡槽，兼容UHS-I。

官方标配不含存储卡、相机包、三脚架、备用电池。

白色选项显示“下单送三年意外险”，承保方、适用范围、领取方式问商家。

想知道第一颗升级镜头怎么选？评论区告诉我，下期安排。

#佳能R50 #新手微单 #相机测评

公众号 · 量子位

===朋友圈===

白色R50拿在手里，真的会让人想出门拍照。

376g含电池和卡，拍人、拍猫、旅行记录都够轻。

4K 30p，全高清最高120p，日常Vlog很省心。

套头带IS光学防抖，但机身没有传感器位移防抖。

官方标配不含存储卡、相机包、三脚架、备用电池。

适合第一台APS-C微单，蹲活动价格再决定。

#佳能R50 #第一台微单 #轻量相机

公众号 · 量子位

不到2分钟肝完四份文案，“赛博打工人”的手速算是过关了。

但职场里真正让人头疼的，往往不是写文案，而是开完会之后谁来把一地鸡毛整理清楚。

于是，我们给它安排了第二份工作，考验它的实战办公能力。

实测二：把一场产品周会变成可执行方案

我们以“智能客服Agent V2.0 需求与技术评审会”为主题，原汁原味复刻了一份大家刚开完周会后可能会拿到的、同音错字多且穿插着琐碎闲聊的万字原始会议实录材料，并让Qwen3.8-Flash一次性完成了提取总结、整理表格和会后通知邮件三项工作。



[00:02:15] 小赵：张工，这没法加缓存啊，用户问的问题千奇百怪的，你怎么命中缓存？而且这次王姐要求那个“多轮对话状态管理”，就是说用户上一句说了“我要退款”，下一句说“那件红色的”，阿珍，就是Agent得知道“那件红色的”是指上一句的那个商品。这个上下文一长，偷啃，就是Token消耗就大，成本扛不住啊。

[00:02:48] 王姐：[打断] 哎小赵，你别跟我扯什么偷啃不偷啃的，我不管你们用什么技术，反正现在竞品，就是那个某某大厂，他们家的客服就能记住上下文，而且还能自动帮用户改地址。老板说了，这次V2.0必须得有这个功能，不然双十一的客诉率降不下来。

△图片由AI生成，“token”听成“偷啃”真是太有生活了

提示词如下：

Role

你是一个资深的 PMO（项目管理办公室）专家，擅长从嘈杂、非结构化的原始会议记录中提取关键信息，并输出专业的会议纪要和商务邮件。

Task

请阅读我提供的《智能客服 Agent_V2.0_会议实录.txt》，并**一次性**完成以下三项工作：

任务一：核心结论总结

提炼出本次会议达成的 5 条最核心的共识或决策。要求语言精炼，直击重点。

任务二：待办事项清单 (Action Items)

请整理一份详细的待办事项表格。表格必须包含以下列：

- 任务描述
- 负责人
- 截止时间/节点
- 优先级 (P0/P1/P2)

任务三：会后通知邮件

起草一封可以直接发送给所有参会者的正式邮件。邮件需包含会议背景、核心决议同步以及对各方待办事项的提醒，语气要专业且得体。

Constraints (严格遵守)

1. ****信息保真****：所有内容必须严格基于提供的转写稿。
2. ****处理缺失信息****：如果材料中未明确提及某项任务的“负责人”、“截止时间”或“优先级”，请务必在表格中填写 **“**待确认**”**，****绝对不要****根据推测自行补充或编造。
3. ****输出格式****：请按照【任务一】、【任务二】、【任务三】的顺序依次输出，使用 Markdown 格式排版。

默认模式下，不到4分钟，Qwen3.8-Flash就圆满完成了所有任务，且五条核心结论总结、表格分工内容均准确无误，邮件格式规范，收件人也与会议内容一一对应。

智能客服 Agent V2.0 需求与技术评审会·会议纪要

- 会议时间：2026-08-25 14:00 - 16:15
- 会议主题：智能客服 Agent V2.0 需求与技术评审（技术方案与排期对齐）
- 参会人员：老李（产品总监）、张工（后端架构）、王姐（业务运营）、小赵（算法）、陈哥（前端）、小刘（PMO / 记录）
- 会议目标：双十一前上线 V2.0，确定核心功能技术方案与排期
- 名词还原对照（转写口误已归一化）：阿珍 → Agent；瑞格 / 热狗 → RAG；偷晴 → Token；破木特 → Prompt；欢觉 → 幻觉；凡体宁 → Fine-tuning（微调）

【任务一】核心结论总结（5 条）

1. RAG 知识库技术路线确定：BGE-M3 + Milvus，先 INT8 量化跑 Baseline。
Embedding 模型升级为 BGE-M3；向量库选 Milvus（弃用 ES，向量检索性能不足）。Milvus 参数定档：`metric_type` 由 IP 改为 COSINE（BGE-M3 官方建议）、`nprobe` 由 16 调至 64——召回率 78% → 92%，延迟 15ms → 85ms，权衡结论为“召回率优先，85ms 延迟可接受”。基础架构部昨夜新增 1 张 A100（原 2 张 A10），显存满足 FP16；但因标注数据延期，先用 INT8 量化跑 baseline，数据到位再切全精度。风险点：A100 是否为长期分配尚未确认。
2. 多轮对话状态管理：双轨并行、以 A/B 测试定案，状态管理不全盘依赖大模型。
小赵先产出“纯大模型”baseline；张工同步评估状态机方案（关键实体如商品 ID / 订单号由界面点选采集 → 传后端存 Redis，大模型只负责话术生成，不承担状态管理），两方案做 A/B 测试对比。算法侧已提出小模型做意图识别的成本优化路径，但因幻觉风险（退款意图误判为催发货）被张工判定为高风险，未采纳为既定方案。

【任务二】待办事项清单（Action Items）

“说明：转写稿中未对任何任务给出优先级（P0/P1/P2）定义或指派，因此优先级列一律标注“待确认”，不作推测填充；同理，仅有工期估算而无明确交付日期的条目，截止时间标注“待确认”并在备注中保留原始估算。”

#	任务描述	负责人	截止时间 / 节点	优先级	备注（依赖-风险）
1	RAG 升级：Embedding 换 BGE-M3，先用 INT8 量化产出 baseline，标注数据到位后切 FP16	小赵	待确认（算法侧含微调、Prompt 调优预估 ≥4 周；节点受 #4 制约）	待确认	数据源：排期讨论；显存依赖 A100
2	多轮对话状态管理：产出纯大模型 baseline	小赵	待确认	待确认	上下文变长导致 Token 消耗与成本压力
3	评估“大模型 + 状态机”方案（前端点选采集商品ID/订单号 → 后端存 Redis，大模型仅生成话术），并与 #2 做 A/B 测试	张工	待确认	待确认	业务侧已否定重点点选交互，方案须兼顾“无感”体验
4	重新签约外包标注团队并推进进场	王姐	外包最快下周三进场（转写稿原文，未给具体日期）	待确认	合同未签完，原“本周内启动”目标已失效；#1/#2 的前置阻塞项
5	修复 Milvus schema 类型不匹配：user_id 由 VARCHAR(64) 对齐订单系统 INT，消除 type mismatch	待确认	今天内（2026-08-25 会议当日）	待确认	张工口头判定“必须今天修掉，否则联调无法进行”，但未点名执行人
6	提交 PR：Milvus metric_type IP → COSINE；nprobe 定为 64	张工	待确认	待确认	召回率 92% 延迟 85ms 的权衡已定档

【任务三】会后通知邮件

收件人：老李、张工、王姐、小赵、陈哥
抄送：基础架构部、运维（相关事项知会）
发件人：小刘（PMO）
主题：【会议纪要】智能客服 Agent V2.0 需求与技术评审会（2026-08-25）——核心决议与待办确认

各位同事，大家好：

感谢大家今日下午（14:00-16:15）参与智能客服 Agent V2.0 需求与技术评审会。本次会议围绕 V2.0 的技术路线、多轮对话方案、需求范围与排期进行了充分讨论并达成关键共识。现将核心决议与待办事项同步如下，请各责任人核对，如有出入请于 24 小时内回复本邮件指正。

一、会议背景

V2.0 须在双十一前上线（10 月 20 日封版），业务侧对现网 V1.0“答非所问、无法记忆上下文”的问题反馈集中，同时需对齐竞对已有的上下文记忆与地址修改能力，以及双十一天猫/淘宝场景下的客诉率与转化率考核要求。本次会议目标为锁定技术方案与交付排期。

二、核心决议同步

- RAG 升级：Embedding 模型切换至 BGE-M3，向量库采用 Milvus；参数定档 `metric_type = COSINE`、`nprobe = 64`（召回率 78% → 92%，延迟 15ms → 85ms，判定召回率优先）。
- 推理精度策略：基础架构部已新增 1 张 A100（原 2 张 A10），显存具备 FP16 条件；但因标注数据延后，算法侧先用 INT8 量化产出 baseline，数据到位后切换全精度。
- 多轮对话：采取双轨并行——算法侧先出纯大模型 baseline，后端侧评估“界面采集关键实体 + Redis 状态存储 + 大模型仅生成话术”的状态机方案，二者通过 A/B 测试择优；小模型意图识别路径因幻觉风险暂不采纳。
- 交互红线：整体追求“无感”体验，不以多层点选/卡片流程拦截用户；请求超限一律排队处理，不转人工。

三、待办事项与节点提醒			
序号	事项	负责人	节点
1	修复 Milvus schema <code>user_id</code> 类型不匹配 (VARCHAR(64) ↔ INT)	待确认	今日 (8/25) 内
2	外包标注团队合同与进场推进	王姐	最快下周三进场 (请同步确切日期)
3	BGE-M3 INT8 量化 baseline	小赵	待确认 (算法侧预估 ≥4 周)
4	纯大模型多轮对话 baseline	小赵	待确认
5	状态机方案评估 + A/B 测试设计	张工	待确认
6	Milvus <code>metric_type</code> → COSINE 提 PR	张工	待确认
7	压测 (150 QPS) 与限流排队策略落地	张工	待确认
8	协调运维搭建 Milvus 集群	老李	运维原述"下周"
9	确认 A100 长期分配归属	老李	待确认 (双十一前)
10	主动营销需求向管理层沟通延期	老李 (王姐配合)	待确认
11	流式输出接口文档补发 (钉钉)	张工	会后
12	V2.0 成本口径汇报 (约 0.03 元/会话)	老李	会后
13	前端多轮对话 UI 改造与流式输出 bug 修复	陈哥	预估 2 周, 依赖后端接口
14	审阅 Benchmark 附件与竞品截图合集, Prompt 调优重点覆盖标红 case	小赵	待确认

△部分测试结果图

甚至没有要求它，它也会自行贴心地给我们梳理出了会议中尚未讨论出结果的事项、方便我们下次开会继续讨论，be like：

附：本次未闭环事项（供下次会议议程）

- 双十一峰值 500 QPS 的承载方案与 150 QPS 压测目标之间的差距如何弥补（扩容、降级或限流兜底）。
- 成本模型的完整口径（服务器、带宽、人力、微调算力是否计入）与业务可接受上限。
- "无感体验"与"实体点选采集"之间的交互折中方案与验收标准。
- 主动营销若确定双十一后启动，推荐系统与数仓权限的责任归属与排期。
- 各任务优先级 (P0/P1/P2) 的正式定级。

而且到这一步，我的额度还没烧完哦！

啊哈哈这种不受限的感觉真是太爽了。

现在，Qwen 3.8 Flash已经在“千问办公”平台首发上线，API接口也已同步开放，大家可以去试试啦！

Qwen3.8-Max 首发上线 Token Plan 个人企业双版本享超值优惠低至 39 元起，夜间调用更优惠，高效开启 AI 生产力

千问AI平台

体验 模型 应用 探索 定价 文档 登录

Token Plan 重磅升级

个人版上线，团队版降价，更低成本畅享 Qwen3.8-Max 等先进模型，高效开启 AI 创作与开发

立即订阅 查看活动

Skills CLI

一键将技能折叠进你的 Agent 里

[让Agent 安装](#) [手动安装](#) [README](#)

根据 <https://platform.qianwen...>

公众号 · 量子位

One More Thing


国产大模型价格战打得更猛了。

就在Qwen 3.8 Flash开源的几乎同一时间，智谱也开源了GLM-5系列首个原生多模态模型**GLM-5.3-Flash**，也就是之前在网上爆火的“牛来”大模型Ox Alpha。

测评中，该模型的性能比肩Claude Opus 4.8，价格却砍到了GLM-5.3的1/10。

LLM Performance Evaluation

6 benchmarks: Terminal Bench 2.1, DeepSWE v1.1, Agents' Last Exam, AutomationBench v1.0.6, HLE w/ Tools, GDPVal-AA v2
■ GLM-5.3-Flash ■ GLM-5.2 ■ DeepSeek-V4-Vision-Exp ■ Claude Opus 4.8 ■ GPT-5.6 Terra ■ Gemini 3.7 Flash



而且GLM-5.3-Flash还慷慨地开放了为期两周的半价活动，这意味着，活动期内的GLM-5.3-Flash的价格仅为GLM-5.3的1/20，为Opus4.8的1/40。



此外，Qwen 3.8 Flash和GLM-5.3-Flash还有一个**共同点**，那就是他们这次都以超低的价格杀了DeepSeek-V4-Flash个措手不及（DeepSeek骂骂咧咧地走开了）：

三款模型 API 价格对比

单位：元 / 百万 Tokens

模型	计价条件	输入（缓存未命中）	输入（缓存命中）	输出
DeepSeek-V4-Flash	空闲时段	1.50	0.05	4.50
DeepSeek-V4-Flash	高峰时段	3.00	0.10	9.00
Qwen 3.8 Flash	标准价格	0.80	0.10	2.70
GLM-5.3-Flash	限时五折，两周	0.40	0.115	1.40
GLM-5.3-Flash	原价	0.80	0.23	2.80

- ① DeepSeek 高峰：北京时间 9:00—12:00、14:00—18:00，其余为空闲时段。
- ② DeepSeek 定价自 2026年8月17日 00:00 起生效。
- ③ GLM 五折优惠限时两周，具体起止日期未日期；缓存存储限时免费。
- ④ Qwen 未标注分时定价或优惠期限。

公众号 · 量子位

△DeepSeek-V4-Flash、Qwen 3.8 Flash、GLM-5.3-Flash价格对比图

没得说，太卷了。

本文来源：[量子位](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码 免费领取

VIP会员 · 7天畅读卡 | 大师课 · 入门串讲



限免

14 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论