

摘要：

工程化突围。



作者 | 周智宇

当全球市场在亚马逊与谷歌的财务余震中，反复拷问AI投入是否“见顶”以及自由现金流何时回归，这场军备竞赛正进入冷峻的淘汰赛。

这场竞赛里注定赢家寥寥，唯有在产出比的生死线上建立商业闭环，方能得到投资者青睐。

经历了“V型反转”的金山云对此感受颇深。从2024年9月低点时的每股2美元，到高点时超22美元/股，金山云的价值正在被市场重估。

2025年四季度，金山云交出了一份关键成绩单：营收27.6亿元再创历史新高，智算云收入9.3亿元再次攀升且占公有云收入比例已达49%；四季度，金山云再次实现调整后经营利润转正，相较于曾经动辄数亿元的亏损，这标志着公司在经历了长达三年的阵痛转型后，终于在“智算时代”叩响了盈利的大门。

金山云高级副总裁刘涛，这位在云行业深耕十余年的老将，在近期与华尔街见闻的独家对话中，复盘了这段惊险转型历程。

“我们经历过从最高峰股价掉下来的极度痛苦。”刘涛直言。

从2020年末峰值时每股近75美元，到2022年10月低点的1.77美元，金山云手中持有的现金价值甚至一度高于市值。资本市场给出的结论冷酷且决绝：市场预判他们会快速耗尽资金。

这并非金山云一家的困境，而是整个中国云行业在过去十年集体陷入的“规模陷阱”。在那个时代，估值的驱动力来自流量和营收规模，厂商们在CDN（内容分发网络）等基础设施红海里刺刀见红。金山云也曾一度陷入“投得越多，亏得越多”的恶性循环。



“这种逻辑曾是行业挥之不去的阴影。”刘涛直言，但公司的本质是要给股东挣钱，这种旧的发展模式也在2022年走向终点。

刘涛透露，他在2022年初接手公有云团队时的使命极其纯粹：不做亏钱生意。

他上任第一年，便清退了所有毛利为负的客户，这导致公有云业务营收和毛利都出现较大波动。但到了2025年，金山云公有云业务已实现节节攀升。

金山云的变革故事中，最关键的一章是关于“信仰”的博弈。面对ChatGPT引发的算力海啸，2023年4月，刘涛与管理层面临一个足以决定公司生死的决策：是否要在现金流极其紧张的情况下，投入数亿元组建大规模智算集群？

“这是一个可能把公司拖入绝境的决定，”刘涛回忆道，因为一旦交付失败，巨额折旧是当时公司也难以承受的。但CEO邹涛的一句话定下了基调：“要对AI有信仰，这就像蒸汽机时代来临。”最终，金山云在完全没有前人经验的领域，硬生生啃下了大规模集群组网这块工程硬骨头。

从现在来看，金山云管理层做了一个正确的决定。

眼下，中美科技巨头们仍在持续为算力开出巨额支票，但苛刻的投资者们却也开始用ROI来衡量每一笔支出的效果。

这也意味着，在算力军备赛持续的同时，智算云正逐步转向以“运营效率”为核心的下半场。

在金山云的视角里，智算云不再是简单的资源买卖，而是一场极限工程挑战。大规模智算集群极度脆弱，光模块故障率高达2‰，机器故障率达1%-2%，对于大规模集群而言，任何单点波动都可能引发连锁反应，导致整体训练任务中断。

为了应对这种损耗，金山云通过一系列硬核工程手段重塑了稳定性。

金山云构建了故障感知驱动的自愈系统，依托容器化调度和热备切换机制，将训练任务恢复时长压缩至20分钟以内，保障集群实际运行SLA稳定在99.9%以上；通过PD分离（预填充和解码分离）与KV Cache复用技术，在办公场景服务中实现了优于原厂方案的响应延时稳定性，有效提升推理侧的利润空间；将资源管理模式升级为“任务交付”导向，解决了智算时代训练任务易中断的痛点，显著提升了底层硬件的有效利用率。

展望2026年，刘涛认为真正的分水岭在于“应用”。相比于前途未卜的通用大模型混战，机器人与自动驾驶提供了更清晰的场景ROI。视频生成的实用化、VLA模型在机器人端的泛化，将让推理需求呈现指数级增长。

刘涛敏锐地察觉到，机器人公司大多擅长身体指令，但在云端工程、安全防护和数据闭环上几乎是赤手空拳。

金山云的策略是成为这个万亿赛道底层的“循环系统”：为头部公司提供从数据生产、存储到模型训练、仿真的全生命周期闭环；针对机器人可能被黑客控制的极端风险，构建端到端的安全防御，防止AI“大脑”被恶意劫持；通过极致的推理优化，让机器人端的响应像生物直觉一样快速准确。

“抢占了机器人场景的高地，就意味着拿到了重塑物理世界智能规则的终极船票。”刘涛预判，未来三到五年，机器人将从简单的捡袜子、捡毛巾的动作起步，逐步渗透进千家万户，而金山云要做的，是从这些企业出生开始，就成为它们原生依赖的云底座。



“不做大模型”是金山云在智算大潮中保持冷静的战略底线。

正因为不参与模型端的竞争，金山云得以在生态上保持极度的开放与纯粹。无论是“模型新贵”，还是生态内的大模型，都稳健地生长在金山云的智算底座之上。

刘涛认为，随着推理侧需求的指数级爆发，Token将成为类似水电的普惠资源，而云厂商的胜负手在于谁能以最低的工程代价输出最稳定的服务。

智算云的红利期不会永远持续，只有那些能解决极限工程难题、打通行业数据闭环的厂商，才能在潮水退去后依然立于潮头。

从股价1.7美元的谷底，到今天智算业务占比超过三分之一并带动全公司走向盈亏平衡，金山云的“V型反转”并非偶然。它本质上是一家成熟企业在深刻理解产业纵深后，对运营效率与商业本色的坚决回归。

这场关乎生产力主导权的竞赛，才刚刚进入最残酷、也最精彩的深水区。

刘涛和金山云正试图证明：一家云服务商如果足够尊重财务规律、愿意深耕工程细节，同时对技术趋势保持判断力，就有机会在AI浪潮中，完成从资源集成到价值共生的转变。

如何走出谷底

华尔街见闻：你在金山云十年了，云厂商也经历了从移动互联网到PC再到AI时代的演进。对你个人来说印象最深、或者最煎熬的一段时间是什么情况？

刘涛：最难忘也最痛苦的，其实就是“V字反转”的过程。2020年金山云上市，股价最高冲到75美元，估值一度达到170多亿美金。雷总（雷军）当时非常高兴，大家也觉得公司前途无量。

到了2021、2022年，资本市场不再以PS（市销率）来看待云公司，而是看PE（市盈率）和损益情况。我们的股价从75美金跌到了1.7美金。当时资本市场的评价非常刺耳，甚至出现“团队能力不足”、“现金价值高于市值”、“或将快速耗尽资金”等负面评价。

当时CDN业务处于负毛利状态，相当于公司为了维持规模，实际是在贴钱做业务。这种极度不健康的经营模式，让我们不得不痛定思痛，启动全面转型。

华尔街见闻：过去两年里，有没有哪个时刻或会议，让你觉得AI确实正在重构整个公司的逻辑？

刘涛：2021年，一家大模型初创客户对高性能算力的需求，比一些头部客户还要多。这让我们意识到，大模型公司对算力的需求，是截然不同的量级。后来，客户提出搭建大规模集群的需求，涉及金额巨大，对公司现金流构成了严峻考验。

我本身是技术出身，做事是很理性的。我问邹总（邹涛）：“干这个事儿，搞不好会把公司拖垮，咱干还是不干？”

邹涛当时的决定是：“熬夜干！”邹涛说：“你们要对AI有信仰，这是蒸汽机时代来了，未来的空间是无法想象的”。事实也证明了这个判断的前瞻性。

华尔街见闻：一线团队最直接的感受和心态变化是什么？大家讨论最聚焦的点在哪里？

刘涛：销售和技术团队的心态已经从“跟随”转向了“领先”的自信。



销售团队越打越有劲头，因为这种客户标杆效应是不断叠加的。要知道，在通算时代，我们和友商差距明显，一直处于被动跟随状态。

可进入AI时代，市场需求聚焦在智算网和存储领域，这正好是我们深耕且具备优势的赛道。

该抛弃对云的偏见了

华尔街见闻：投资人觉得云业务不是好生意，这种观点是否过时了？

刘涛：我认为这种观点存在误区，特别是在中国市场。

相比其他To B业务，云是极少数具备高可持续性的赛道。中国客户虽不习惯为纯软件付费，但愿意为硬件能力与技术服务买单。云的核心价值是用技术服务最大化释放硬件能力。

当前客户普遍强调成本控制，企业已不愿意承担自建基建团队的高昂成本。比如客户将设备托管在我们这里，我们只收一定比例的服务费，成本远低于企业自建运维。

当然，如果陷入无穷无尽的定制化项目，云业务确实难成好生意。但聚焦标准化、可规模化的运营型项目，云就是极具价值的优质赛道。

华尔街见闻：相比规模较大的友商，金山云最大的特色和竞争策略是什么？

刘涛：我们走的是“田忌赛马”的竞争策略。

作为规模较小的公司，我们不拼体量、不搞同质化竞争，而是以“性价比”和“贴身服务”打造差异化优势，提供更具竞争力的价格和更好的服务。就拿机器人赛道来说，面对客户需求，我会陪着SA、售后一起上门对接，全程跟进。客户只要提出合理需求，我们会全力以赴地解决。

这个赛道的客户，工程能力普遍偏弱，而强大的工程交付能力正是我们的长板，刚好能精准匹配他们的痛点。

这种“贴身肉搏”的深度服务，让我们在机器人赛道赢得了许多头部客户的认可和信赖，这一点连规模更大的友商都非常羡慕。

挖掘细分机遇

华尔街见闻：在选择客户时，都有哪些考虑？

刘涛：我们的选择逻辑非常清晰：聚焦能带来增量的赛道和客户。

传统云客户的预算逐年缩减，能持平就算不错。

智算领域的增长主要来自大模型，但仅靠这一个赛道还不够。因此，我们重点锁定了自动驾驶、机器人、AI for Science（科学智能）。

其中，自动驾驶是成熟赛道，我们的核心打法就是保持耐心，守机会。

机器人则是全新赛道。这里的公司多为科学家创业，擅长算法但缺少工程落地概念，这正是我们的机会。

科学智能领域，比如生物医药相关企业，这类公司本身发展很成熟，与他们合作，核心是比拼性价比，用更具优势的方案赢得认可。

华尔街见闻：自动驾驶和机器人客户在算力调度和工程落地中，你们解决了哪些具体的痛点？

刘涛：核心是解决算力调度与工程落地中的稳定性和数据闭环。

对于万卡集群而言，硬件故障难以避免。我们通过搭建故障感知机制、部署热备机技术，实现了节点故障后的快速自愈。一旦出现节点故障，20分钟内就能自动恢复训练任务，确保集群实际运行SLA稳定在99.9%以上。

针对办公场景，我们与集团共研了PD分离（预填充和解码分离）技术，显著降低了首字延迟（TTFT）。

同时，通过优化KV Cache的命中率和预充能力，即便在高并发场景下，也能保证推理稳定丝滑。

华尔街见闻：自动驾驶也在从VLA转向到大世界模型，数据吞吐压力非常大，这块是否有技术压力？

刘涛：压力确实非常大，核心痛点集中在数据的存储、处理与流转全流程。

自动驾驶领域的数据采集门槛低、增量惊人，轻松就能达到EB级。

为此，我们与客户深度协同打磨出了一套全流程数据闭环平台，涵盖数据脱敏、视频与点云融合处理、3D高斯建模等核心功能。

此外，车端算力受限于功耗瓶颈，未来可能会出现“端侧负责实时决策，云端运行宏观世界模型”的架构，这会带来巨大的云端推理需求。

华尔街见闻：机器人赛道的数据维度更多元，处理压力更大，我们在这个过程中能做好的核心服务是什么？

刘涛：我们的目标是“辅助客户聚焦核心算法，其余所有工程化、数据化相关的繁琐工作，全部交给我们”。

在数据采集与处理闭环上，我们提供从本地数据同步、云端标注、数据清洗到最终模型训练的全流程一体化平台。

虽然我们不直接开展数据标注业务，但我们会做好桥梁，整合并集成一系列高质量的数据定制和标注供应商。

这种“技术基座+生态整合”的模式，让我们能够像AWS一样实现上层服务的轻资产运营，同时牢牢锁定底层算力服务的粘性。

接下来几场硬仗

华尔街见闻：展望2026全年，“核心战役”是什么？

刘涛：核心聚焦于“大客户、深赛道、Token化”三大方向。



我们有三场关键战役：一是筑牢技术根基，确保在新一代硬件迭代背景下，大集群的可靠性和稳定性保持业界领先水平；二是深化赛道渗透，在机器人等垂直赛道持续强化全流程闭环服务能力，不仅满足现有客户需求，更主动挖掘并解决如系统安全漏洞等潜在痛点；三是激活增长新动能，深度运营Token业务。

华尔街见闻：除了Token业务，你还觉得哪些赛道有爆发潜力？

刘涛：我有两个比较看好的前瞻方向。

AI原生游戏，比如“指挥官模式”，玩家只指挥，剩下的AI队友听你的；或者具备情绪价值的AI陪玩。

代码生成SaaS是最确定的增量。企业因为隐私要求，不会用公版大模型，我们需要提供企业级的私有化代码生成服务，我们内部也已经在深度使用了。

华尔街见闻：小米金山生态在金山云收入占比持续提升，如何看待“独立第三方”的标签？

刘涛：生态是我们的优势之一，但不是我们的全部竞争力。

虽然小米金山生态的智算投入持续提升，但外部客户的订单增速更快，目前生态外客户的业务占比依然保持稳健。

从行业格局来看，云行业内Top 3到Top 5的企业都能实现良性发展，我们的核心优势在于，立足智算这一独特赛道，且已抢占先发先机，有望实现更快发展。

华尔街见闻：接下来金山云营收和利润的增长点在哪？

刘涛：这是一个分层贡献的结构。

一方面，通过为最优质的客户提供大集群供给，拉动营收和总利润额的绝对值增长，该板块虽然毛利率偏低，但业务根基稳健；另一方面，机器人赛道业务、中型客户以及AI Agent应用相关业务，是高利润率板块。此外，Token业务是未来的爆发点，目前其绝对规模虽然尚小，但增长速度迅猛，有望成为增长引擎。

2026年，我们将继续朝着“经营利润转正”的目标前进。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时 0 元领

* 同一用户免费领取一次

扫码 免费领取



限免

👍 42

★ 收藏

分享到:  

写评论

请发表您的评论



