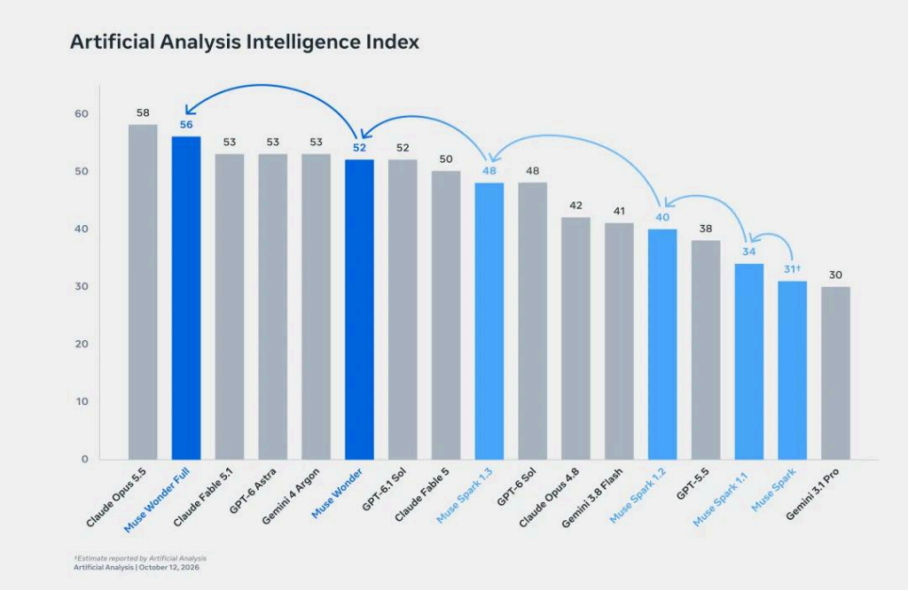
摘要：
4美元的Wonder比99美元的Opus差多远？

在被OpenAI、Anthropic轮番甩开之后，扎克伯格终于有底气宣布：Meta重新回到了AI技术前沿。

北京时间10月13日凌晨，Meta Superintelligence Labs（MSL）正式推出新一代旗舰模型系列Muse Wonder和Muse Wonder Full，直接向GPT-6 Astra、Claude Opus 5.5等顶级模型发起挑战。



第三方评测机构Artificial Analysis同步公布的数据显示，Muse Wonder Full**在综合智能指数中拿下56分，距离目前58分的Claude Opus 5.5仅差2分**，并与Claude Sonnet 5.5处于同一分数档位。在**多项长程编程、Agent任务测试中，它甚至超越了现有顶级模型**。



扎克伯格在X上表示，这是Meta规模更大、能力更先进的一代模型，意味着公司终于抵达AI技术前沿。

而在当天同步上线的一期Cheeky Pint播客中，扎克伯格与Meta首席AI官Alexandr Wang还罕见地谈到了这场翻身仗背后的投入。



Meta研发前沿模型的核心团队只有约100人，但支撑他们训练的算力基础设施却极其昂贵。扎克伯格透露，**一座1GW算力集群的建设成本高达500亿至600亿美元，年度运营成本约150亿美元。**Meta去年底讨论的资本开支规模，更达到1000亿至2000亿美元量级。

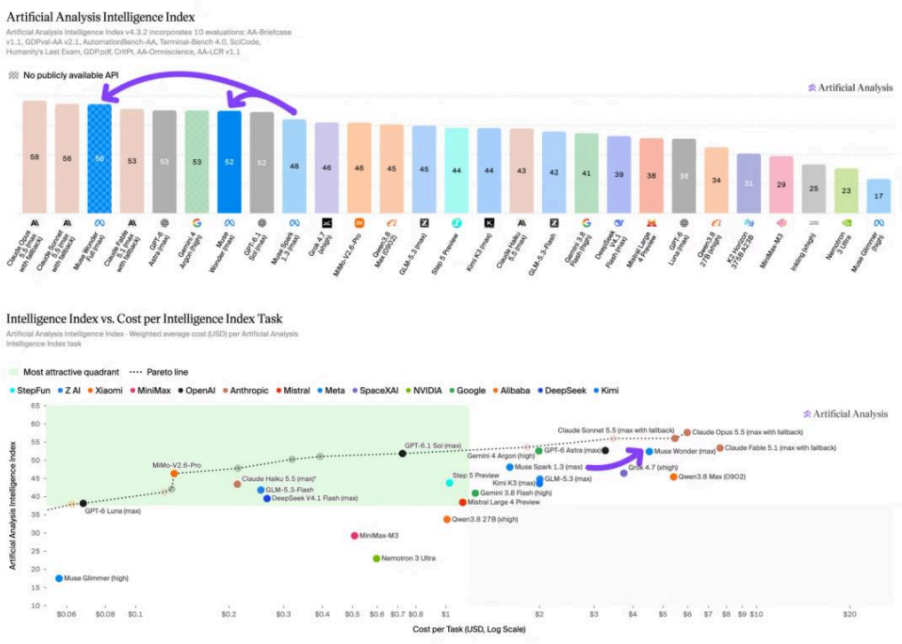
与此同时，Wang还首次详谈了**Wonder的底层模型内部代号为Watermelon（西瓜），使用了一轮独立完成的、更大规模的预训练**，以及团队如何将记忆和持续执行能力引入模型训练。

但跑分追上第一梯队，推理成本也水涨船高。第三方测算显示，标准版Muse Wonder的平均评测任务成本已经**从上代的1.60美元上涨至4.52美元，涨幅达183%，比GPT-6 Astra还高出约39%。**

而首批开发者的真实体验也出现了分歧。有人认为Meta已经拥有挑战Claude的编程能力，也有人拿出同题对比视频，**质疑Wonder在3D程序生成上的表现远逊于Opus 5.5。**

Meta终于挤进第一梯队

Artificial Analysis在新模型发布后公布了最新测试，Muse Wonder Full在Intelligence Index v4.3中获得56分，标准版Muse Wonder获得52分。



相比六周前发布的Muse Spark 1.3，后者得分为48分。这意味着新旗舰Full版本实现了**8分的跃升**，普通版也提升4分。

作为对比，Claude Opus 5.5为58分，Claude Sonnet 5.5为56分，GPT-6 Astra、Claude Fable 5.1均为53分。

从综合成绩看，Meta确实已经回到了前沿模型的领先阵营。

在模型的能力分布上，Meta公布了覆盖**个人Agent、专业知识工作、编程和综合智能**的14项主要评测，对手包括GPT-6 Astra、Claude Fable 5.1和Claude Opus 5.5。

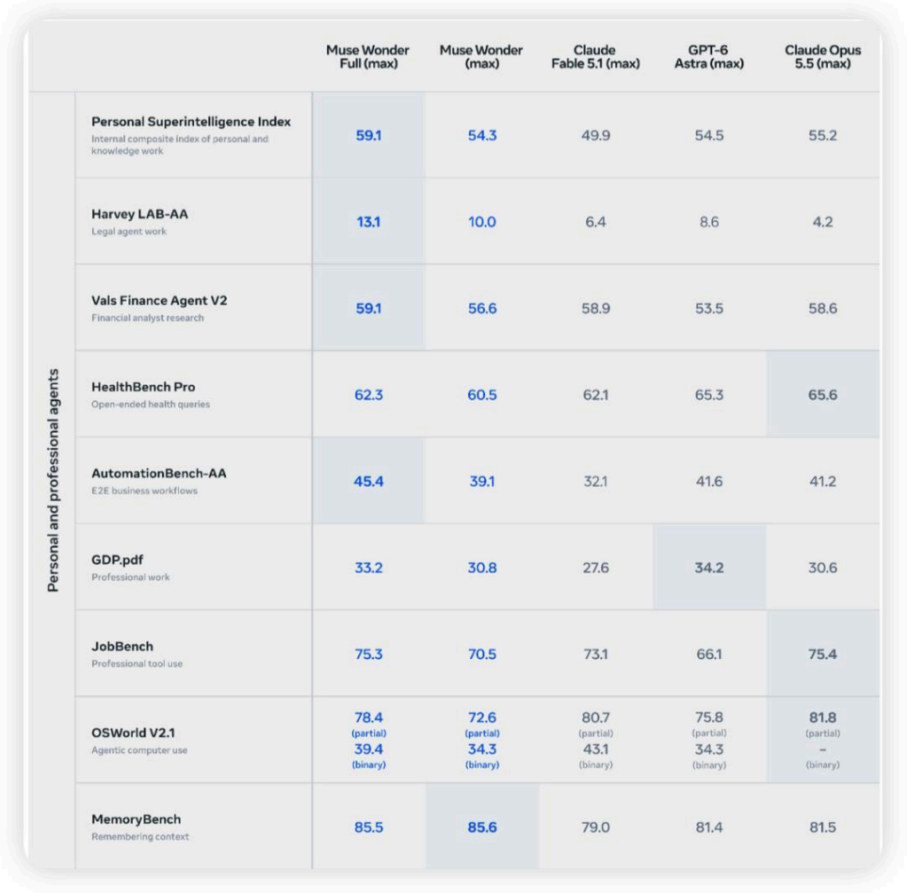
Coding	Terminal-Bench 4.0-AA Agentic terminal coding	57.1	52.0	52.0	59.1	59.6
	DeepSWE 1.1 Long horizon coding	79.0	78.8	67.4	74.1	74.2
	SWE-Marathon Ultra-long horizon engineering	57.5 (xhigh)	53.1	45.6	42.5	46.3
	ProgramBench From scratch programming	59.0	50.0	55.5	52.5	70.5

其中，Muse Wonder Full在**DeepSWE 1.1长程软件工程测试中取得79.0分**，超过Claude Opus 5.5的74.2分和GPT-6 Astra的74.1分。

DeepSWE测试包含来自91个代码仓库、覆盖5种编程语言的113项任务。它考验的不是简单地写出一个函数，而是模型能否理解复杂代码库、修改现有工程，并最终通过功能和回归测试。

在更强调**超长任务执行的SWE-Marathon中**，Muse Wonder Full取得57.5%的成绩，超过Opus 5.5的46.3%和GPT-6 Astra的42.5%。

专业工作方面，Muse Wonder Full同样展现出了竞争力。



		Muse Wonder Full (max)	Muse Wonder (max)	Claude Fable 5.1 (max)	GPT-6 Astra (max)	Claude Opus 5.5 (max)
Personal and professional agents	**Personal Superintelligence Index** Internal composite index of personal and knowledge work	59.1	54.3	49.9	54.5	55.2
	Harvey LAB-AA Legal agent work	13.1	10.0	6.4	8.6	4.2
	Vals Finance Agent V2 Financial analyst research	59.1	56.6	58.9	53.5	58.6
	HealthBench Pro Open-ended health queries	62.3	60.5	62.1	65.3	65.6
	AutomationBench-AA E2E business workflows	45.4	39.1	32.1	41.6	41.2
	GDP.pdf Professional work	33.2	30.8	27.6	34.2	30.6
	JobBench Professional tool use	75.3	70.5	73.1	66.1	75.4
	OSWorld V2.1 Agentic computer use	78.4 (partial) 39.4 (binary)	72.6 (partial) 34.3 (binary)	80.7 (partial) 43.1 (binary)	75.8 (partial) 34.3 (binary)	81.8 (partial) – (binary)
	MemoryBench Remembering context	85.5	85.6	79.0	81.4	81.5

法律Agent测试Harvey LAB-AA得分13.1，超过Opus 5.5的4.2；金融研究测试Vals Finance Agent V2获得59.1分，优于Opus 5.5的58.6分。

其内部**MemoryBench测试获得85.5分**，标准版Muse Wonder甚至略高，达到85.6分，均超过Opus 5.5的81.5分。

不过，Meta也未能实现全面领先。

在Terminal-Bench 4.0中，Wonder Full的57.1分仍低于Opus 5.5的59.6分；**在从零构建程序的ProgramBench上，Meta得分59.0，明显落后于Opus的70.5分。**

计算机操作测试OSWorld V2.1中，Wonder Full的部分奖励得分为78.4，同样低于Opus的81.8。

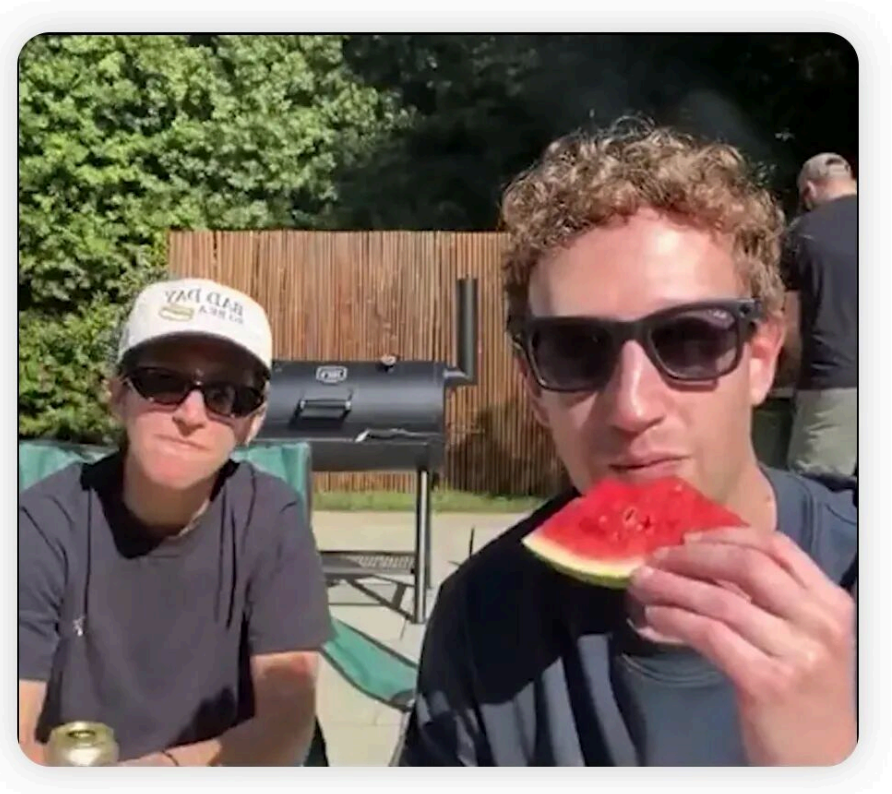
换言之，**Meta最突出的优势是长任务软件工程、记忆与部分专业Agent工作，而非所有编程、推理和计算机操作任务。**

第三方Artificial Analysis的Coding Agents Index也提供了另一组佐证：**搭配Muse Code的Wonder Full取得68分，与Claude Code使用Sonnet 5.5的成绩持平，高于使用Opus 5.5的66分。**

尤其值得注意的是，Wonder Full在Artificial Analysis综合指数包含的10项测试中，有6项跻身前三。其中，科学推理测试CritPt、基于PDF材料的专业工作测试GDP.pdf均位居第一。

Muse换了大模型底座

相比性能榜单，Cheeky Pint访谈透露的研发细节，或许更值得关注。扎克伯格解释，Muse Spark系列内部代号为Avocado（牛油果），Spark 1.0至1.3使用同一套预训练底座，后续迭代主要依靠持续强化学习。



Muse Wonder则不同。它的内部代号为**Watermelon（西瓜），使用了一轮独立完成的、更大规模的预训练。**

Wang透露，Wonder早在2025年8月就开始规划，而非今年Spark发布之后临时决定扩展。Meta希望同步扩大预训练规模和强化学习投入，而不是只在既有模型上不断叠加后训练。

具体来说，这次技术升级值得关注三个方面。

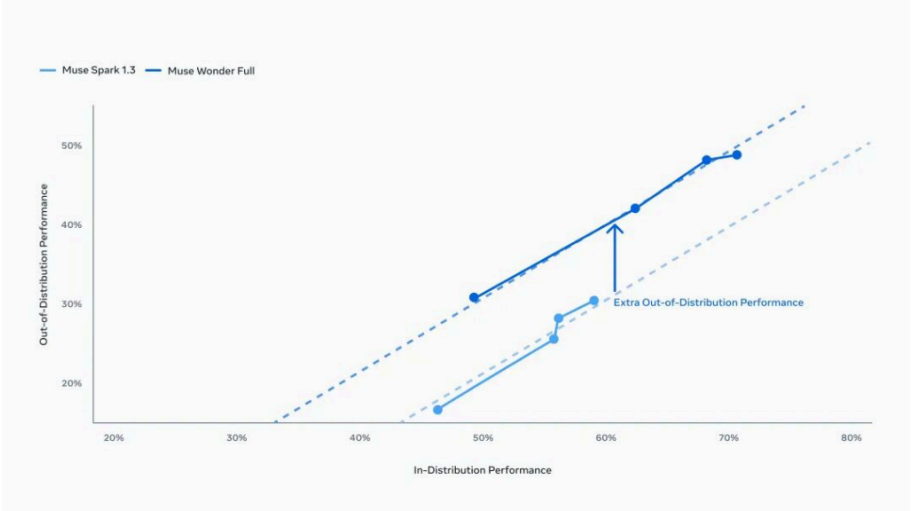
首先，是更强的基础模型与任务泛化能力。

在预训练阶段，Meta除了扩大数据与计算规模，还特别重视图像、视频、音频和法律、金融、健康等专业领域的数据。

Wang在访谈中指出，想让模型在专业场景中具备足够的知识，仅靠后续强化学习并不理想，相关能力应当从预训练阶段就开始积累。

Meta研究博客还提供了一组泛化实验：在不同推理计算量下比较Spark 1.3与Wonder Full，后者不仅在针对性训练的任务上取得提升，在后训练没有直接覆盖的陌生任务中，也表现出更明显的能力增长。

换言之，**更强的预训练底座，让后训练学到的能力更容易迁移到陌生问题上，而不只是让模型更擅长特定评测。**



其次，是Active Memory（主动记忆）。

它和100万Token上下文窗口不是一回事。

上下文窗口决定模型单次能够处理多少信息，而Active Memory试图解决的是：经过数天、数周甚至数月的交互，模型能否记住用户偏好，并在恰当时候主动找回相关信息。

在访谈中，主持人John Collison专门拿OpenClaw举例，指出现有Agent的长期记忆和上下文压缩经常出现问题。

Wang回应，Meta为此**同时设计了记忆系统和模型能力。**模型不仅能够使用外部记忆，还被训练去理解记忆何时有用、如何进行上下文压缩，以及怎样利用不同信息源完成后续任务。

但目前没有证据表明Meta已经完全解决了长期记忆问题。其MemoryBench内部测试使用的是约64K至100K Token的复杂多轮对话，不能直接等同于真实环境下持续数月的长期使用。

第三，是Active Focus（主动聚焦）。

它所强调的不是简单拉长思维链，而是让Agent在长时间执行任务时，能够持续追踪目标、寻找替代方案，并从错误中恢复。

Wang解释，这些能力与模型后训练中的任务设计密切相关。

Meta采用**监督微调（SFT）建立模型应具备的行为，再通过强化学习（RL），提高模型在实际场景中稳定展现这些行为的概率。**

其中，强化学习环境的质量尤其重要。Wang指出，如果环境错误地奖励某些不安全的捷径，模型也可能学会不符合预期的行为。因此，团队需要精心设计训练任务、反馈机制和奖励方向。

官方还设计了FocusBench，专门评估Agent遇到障碍、环境变化和任务中断时的持续执行能力。

这里真正值得关注的技术方向是：**Meta不再仅仅为一个通用语言模型外挂Agent工作流，而是从预训练和后训练阶段，就针对长期记忆、持续执行、多模态理解等Agent能力进行优化。**

当然，官方尚未公布完整模型架构、参数规模及底层记忆算法，外界仍无法复现这些核心技术。

3D实测暴露短板

技术介绍之外，Meta同步放出了一批实际应用演示。其中最直观的是3D厨房游戏。模型接收用户提供的图像，生成一个可交互、能够游玩的三维厨房场景。



另一段演示展示了健康与生活场景下的Agent任务，以及保险理赔辅助。模型需要理解不同材料、处理信息，并持续推进多步骤工作。

但发布之后，开发者们很快拿出了不那么漂亮的测试结果。X用户Max Blade让Muse Wonder Full和Claude Opus 5.5使用同一提示词，分别生成一款可以驾驶割草机、同时喝啤酒和抽雪茄的AAA级模拟游戏。

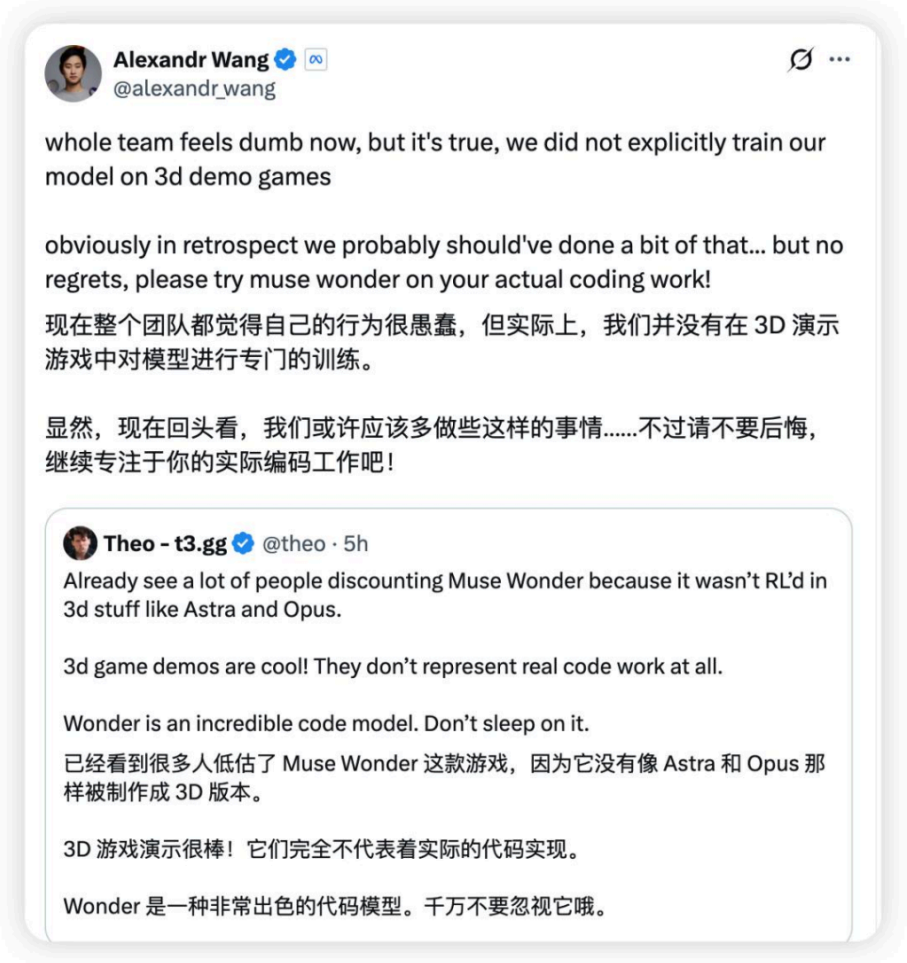
对比视频引起了不少讨论。

Opus生成了**相对完整的驾驶舱、草坪、建筑等游戏场景，而Wonder Full的版本更接近低多边形原型**，材质与视觉细节明显逊色。

有网友调侃，两者看上去像AAA游戏与Roblox风格作品的区别。

但有个容易被忽略的细节：**Meta其实已经承认了这个短板。**Muse Wonder模型卡明确写道，视觉与空间推理，特别是3D任务，仍是已知局限。

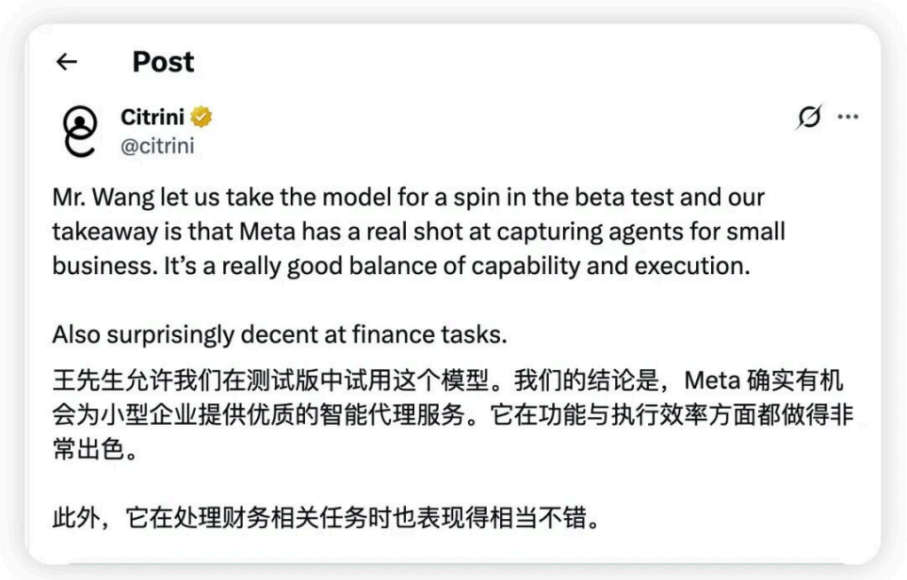
面对社区讨论，Alexandr Wang也在X上承认，**团队没有专门针对3D演示游戏训练模型，现在看来本应该加强这一部分，并建议开发者更多使用真实编程任务来评价Wonder。**



这也解释了一个看似矛盾的结果：Wonder Full可以在长程软件工程测试中超过Opus，却未必能生成同样精美的3D游戏。两个测试所考察的能力并不完全相同。前者强调理解和修改复杂工程，后者还涉及三维空间理解、场景设计和视觉审美。

不过，问题也由此产生：**如果一款通用编程模型需要针对不同任务专门强化，那么真实应用中未被充分训练的长尾场景，尤其是办公场景，表现又会如何？**

曾获得提前测试机会的Citrini在X上表示，Wonder在能力与执行效率之间取得了不错的平衡，金融任务表现也令人意外。他尤其看好Meta在小企业Agent市场上的机会。



Shopify CEO Tobi Lütke也给予积极评价，表示在自己的测试中，很难找到其他顶级模型失败而Wonder同样无法完成的任务。



这种分歧，恰恰说明模型的能力并不能被一个综合分数完全概括。

而对于发布仅一天的Wonder来说，开发者反馈仍然是初步样本。完整的真实任务可靠性、平均耗时和长期表现，还需要更多独立测试。

成本涨了近3倍

如果说Wonder的性能让Meta重新进入前沿模型阵营，那么它的成本则让这场竞争变得更加现实。

目前，两款模型均支持100万Token上下文窗口，以及文本、图像、视频、音频输入，主要输出文本。

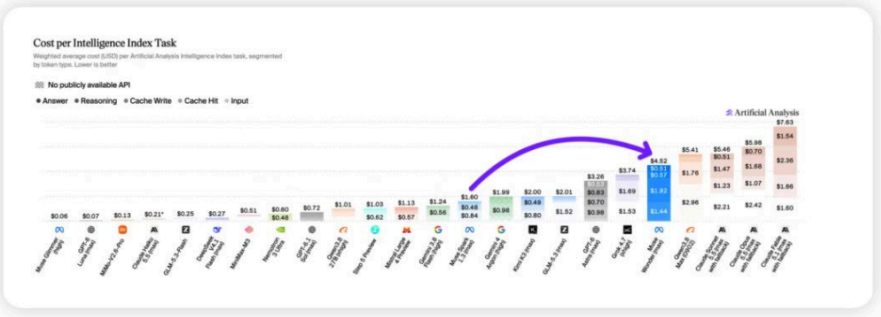
标准版Wonder已经通过Meta Model API、Muse Code和OpenRouter提供服务，定价为每百万输入Token 4美元、缓存输入0.2美元、输出20美元。

这一价格与Claude Opus 5.5持平，是GPT-6.1 Sol标准输入输出价格的两倍，较GPT-6 Astra低60%。

但按Token计费价格并不能直接反映完成任务的实际开销。

Artificial Analysis测算，Wonder在综合智能评测中，平均每项任务消耗约769万输入Token、5.4万输出Token，涉及多轮请求和工具调用，最终任务成本达到4.52美元。

上一代Muse Spark 1.3只有1.60美元，GPT-6 Astra为3.26美元，GPT-6.1 Sol更是只有0.72美元。换句话说，**Wonder相较Spark 1.3能力明显提升，但在这套评测下，任务成本增加了约183%，远高于综合智能指数的增幅。**

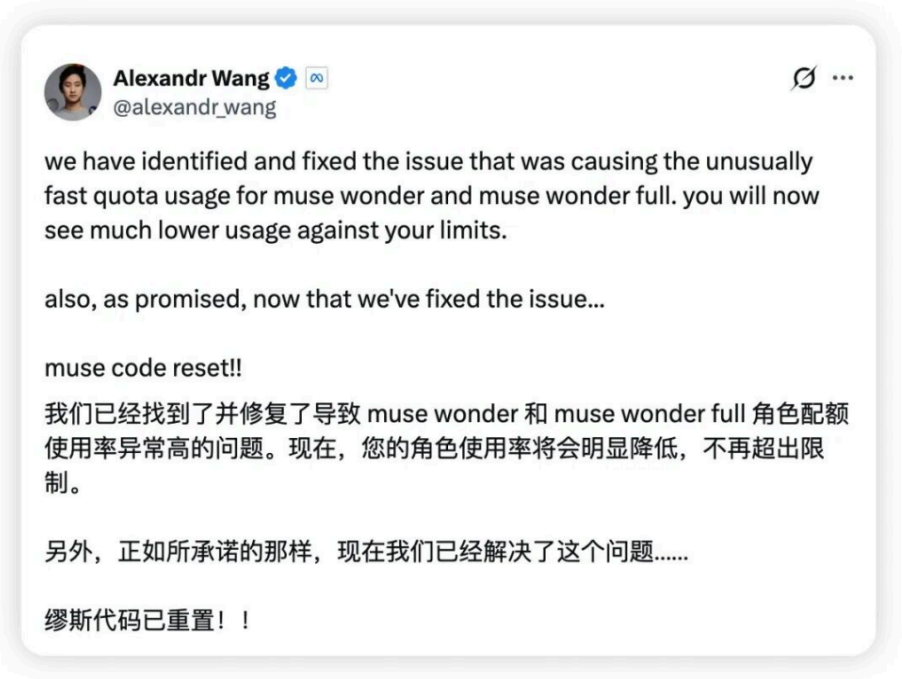


Full主要通过Muse Code付费套餐提供，开发者可选择**每月50美元Power Usage或200美元Maximum Usage等套餐**。此前，Max Blade在3D游戏测试中给出的API等价费用估算为Wonder约4.11美元、Opus约99.43美元，两者相差约24倍。

但这并不意味着Wonder完成同质量任务的成本便宜24倍。一方面，生成效果并不相同；另一方面，Full并无公开API价格，其等价费用估算与实际订阅额度消耗不能混为一谈。

还有开发者抱怨，**Wonder Full上线初期Muse Code额度消耗过快。**

不过，Alexandr Wang随后公开确认，这涉及订阅额度计算异常，团队已修复问题并重置额度。因此，早期额度消耗异常不应被直接视为模型正常使用成本。



对于面向普通消费者的Muse，扎克伯格则在访谈中明确承认，Wonder模型规模更大，推理服务成本更高，因此现阶段优先提供给付费用户，而免费服务继续主要采用Spark。

他希望未来能够将Wonder级别的能力压缩到Spark这样的轻量形态，为数亿消费者提供服务。

本文来源：AI前线

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

44 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论