

摘要：

杰富瑞报告指出，小型语言模型性能提升、成本下降，企业AI部署或从云端转向本地化，冲击超大规模数据中心投资。服务器利用率下降、科技巨头巨额资本开支与算力需求错配，部分数据中心恐成“搁置资产”。AI需求仍在，但集中式算力需求规模及回报面临重估。

AI应用持续扩张，但支撑这轮热潮的超大规模数据中心投资，正面临新的需求端挑战。

杰富瑞报告指出，随着小型语言模型性能提升、成本下降，企业AI部署可能从集中式云端转向本地化，由此对云端算力需求以及巨额数据中心资本开支形成压力。

这一判断的一个重要依据，是近期对AI服务器实际使用情况的观察。2026年9月，Swerve Research Technologies通过追踪Anthropic服务器请求队列的等待时间构建“拥堵指数”，发现相关服务器利用率较2026年1月至2月的峰值下降26%。这一指标并不能直接对应公司收入，但如果利用率持续走低，可能意味着部分算力供给开始出现闲置。

与此同时，AI基础设施投资仍在快速扩张。市场目前预计，Meta、Alphabet、亚马逊和微软四家美国科技巨头2027年资本支出合计可能达到9900亿美元。报告认为，如果AI算力需求增速最终无法匹配如此庞大的投资规模，部分数据中心可能面临回报不足甚至成为“搁置资产”的风险。

服务器利用率下降，AI算力供给面临考验

Meta旗下个人AI产品Muse于9月8日上线后，推动Meta股价在数周内上涨21%，成为近期AI消费应用的亮点。但报告认为，单个应用的成功并不足以证明整个AI基础设施投资周期能够持续。

更值得关注的是，AI企业自身也释放出一些不同于市场乐观预期的信号。Anthropic CEO、OpenAI CEO Sam Altman以及Elon Musk近期均曾公开讨论放缓AI发展的必要性；Anthropic原计划中的IPO则推迟至11月。

与此同时，Anthropic此前已与SpaceX签署价值450亿美元、为期三年的算力合同，并与亚马逊、谷歌云达成数十亿美元级别的算力合作。如果AI收入增速放缓，而此前签订的大规模算力合同仍需持续兑现，企业的成本压力可能进一步上升。

据报道，Meta还在7月与Anthropic谈判，拟在两年内向其出租最高100亿美元的数据中心算力。报告认为，大型科技公司开始积极寻找外部客户消化算力，也反映出随着基础设施供给快速扩张，如何提高资产利用率正成为新的问题。

小模型性能追赶，本地部署或分流云端需求

相比服务器利用率的短期变化，报告更加关注AI模型架构正在发生的变化。

斯坦福大学与Together AI联合发布的《Intelligence per Watt》研究显示，小型语言模型的性能正快速追赶大型语言模型，同时能耗和算力成本低50%至85%。如果这一趋势延续，企业部署AI所需的算力规模和成本结构都可能随之改变。

过去，企业更多依赖集中式云端大模型完成AI任务；随着小模型能力提升，部分场景可能转向本地部署。对于银行等对数据安全要求较高的行业，本地化部署本身已有较强需求；当小模型进

一步降低部署成本后，这一模式的适用范围可能继续扩大。

这意味着，AI应用增长并不必然对应云端算力需求同比例增长。企业可能一边扩大AI应用，一边减少对超大模型API和集中式云端算力的依赖。

这也是报告质疑近万亿美元资本开支的重要原因：如果未来更多AI应用由低成本、小规模、本地化模型承载，那么当前围绕超大规模数据中心形成的投资规模，可能与实际算力需求出现错配。

在这一情景下，真正需要重新评估的并非AI需求是否存在，而是AI需求究竟需要多少集中式算力，以及这些数据中心能否获得与其投资规模相匹配的回报。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

225 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论