

摘要：

OpenAI 暴降价80%交锋Kimi开放权重，大模型竞争正式告别单纯“价格战”。悬殊的ROI测算揭开了算力利用率等盈利黑匣。Token贬值大势下，资本市场不再听故事，唯有打通“低成本生产与高溢价服务”闭环，方能在现金流大考中真正突围。

北京时间7月31日，OpenAI把GPT-5.6 Luna的API价格下调80%，每百万Token输入降至0.2美元，输出降至1.2美元。

此前，在7月27日，月之暗面正式放出Kimi K3的模型权重及技术报告。Kimi K3的官方API价格并不便宜：每百万Token的缓存命中输入为0.3美元，普通输入为3美元，输出高达15美元。

开放权重之后，符合许可证要求的小型云厂商和算力中心也可以部署K3、提供推理服务，虽然条件比较严格，但是确实扩大了供给。

一边是闭源模型主动降价，一边是中国开放权重模型能力追赶头部闭源模型。

大模型的竞争在当下的时间节点上，已经不能仅仅用“价格战”来简单衡量。

从成本端来看，7月28日，摩根士丹利刚刚发布了一篇报告，按照报告提供的模型测算，一座配置41万张GB300的1GW数据中心，在75%利用率下，每百万Token至少要卖到约0.44美元，才能覆盖设备折旧、电力和基础运营成本。

沿用报告测试吞吐量时采用的8：1输入输出比例，Luna降价后的综合价格只有0.31美元。若实际吞吐量与大摩假设相同，它需要107%的利用率才能回本；维持75%利用率，吞吐量还要提高约43%。

这无法证明OpenAI正在亏本销售Luna。小模型的实际吞吐量可能远高于大摩测试的万亿参数模型，缓存和软件优化也会降低成本。但80%的降价幅度，结合最近OpenAI频繁重置订阅额度的动作，它显然已经开始了某种“价格攻势”。

很巧的是，就在报告发布前一天，一位国内AI创业者也分享给我一份他们团队测算的8卡B300“Token工厂盈利账”。但是，两份报告得出的回报率相差近四倍。仔细来对比，两个团队的计算都有道理，只是其中的维度不同，决定了大模型逐渐复杂的“盈利变量”。

01 从一个Token开始算账

摩根士丹利计算的是一座1GW的AI工厂：部署410256张GB300，总投资390亿美元，其中IT设备230亿美元，供电、冷却和建筑等设施160亿美元。

报告将IT设备按5年折旧，非IT设施按15年折旧，每年折旧约57亿美元，电力及其他运营成本约20亿美元。在自有模型API模式下，大摩假设65%的算力用于推理，每张GPU每秒生产2750个Token，商业利用率75%，综合售价1.75美元/百万Token。由此得到年收入304亿美元、税后经营利润179亿美元，**ROIC达到46%**。

国内团队算的是一台8卡B300节点：投资1500万元，每秒生产8万个Token，利用率80%，结算价格4元/百万Token。按照这组假设，每月收入约66.4万元，电费约3000元，IDC费用5万元。


最大的成本是折旧。**设备按3年折旧，每月要摊掉41.7万元**，最终月度经营利润约19.4万元。按照税后经营利润除以初始投资计算，ROIC约12%。但是，在这个计算模型下，“ROIC”更接近基于EBITDA的回收速度，与严格意义上的ROIC并非同一口径。

但是，毫无疑问的是两份报告的回报率相差巨大，即使口径不太相同，近四倍的差距也会引起关注。对比下来，这个差距主要来自**吞吐量、利用率、Token价格和折旧年限四个变量**。

这门生意可以压缩成两个公式：

收入 = 有效吞吐量 × 运行时间 × 商业利用率 × Token净价

ROIC = 税后经营利润 ÷ 投入资本




第一个变量是有效吞吐量。国内报告假设每张B300每秒生产1万个Token，大摩采用2750个。英伟达今年4月公布的MLPerf结果显示，GB300运行DeepSeek-R1时，服务器场景达到每卡8064 Token/秒，离线场景达到9821 Token/秒。8卡8万Token/秒具备技术可能性，但更接近高并发、充分优化后的水平。

模型大小、上下文长度、量化精度和延迟要求都会改变吞吐量。现实中的技术实现不同，收入可能出现数量级偏差。

第二个变量是商业利用率。GPU满载执行训练、测试和免费请求，未必产生收入。**国内报告的盈亏平衡利用率约为56.5%，低于这条线，1500万元的节点便会开始亏损。**

8卡B300节点利用率盈亏线



制图：腾讯科技 | 数据来源：国内团队《AI算力与Token工厂经济学模型分析》第8、11页 AI制图，经人工审校

第三个变量是Token净价。大摩采用1.75美元/百万token，国内报告采用4元人民币/百万token。挂牌价格还要扣除缓存优惠、免费额度、渠道分成和平台成本。

第四个变量是设备寿命。1500万元节点按3年折旧，每月折旧41.7万元；改成5年，每月降至25万元，账面ROIC可以接近翻倍。但折旧年限拉长不会减少现金支出。财务处理方式是一方面，技术的迭代周期，在AI时代也是影响折旧周期的巨大因素，GPU在第四、第五年还能否维持租金和客户需求，才决定这笔利润是否可靠。

两份报告中，电价的占比都不大。设备折旧决定成本下限，商业利用率决定盈亏生死，Token价格决定利润空间。

两份测算关键变量对照



比较项	8卡B300节点【国内报告】	1GW自营API【大摩报告】
单卡吞吐量	约10,000 Token/秒	2,750 Token/秒
产能与利用率	80%商业利用率	65%用于推理 × 75%利用率
Token净价格	4元/百万Token	1.75美元/百万Token [按正文汇率约12.6元]
折旧周期	3年	IT设备5年 / 非IT设施15年
统一口径ROIC	约12%	46%

注：美元兑人民币换算沿用正文“1美元约7.2元”的假设。

制图：腾讯科技 | 数据来源：国内团队《AI算力与Token工厂经济学模型分析》第3—4页；Morgan Stanley Research《The Paths to 25-50% GenAI ROIC》第3—4页 [Exhibit 3、5] AI制图，经人工审校



开放权重模型，成为大模型竞争格局中越来越重要的变量。

月之暗面公开了Kimi K3的完整模型权重和相关代码，允许开发者部署和修改，但没有同时开放完整训练数据和可复现的训练流程。

根据Kimi K3的开源协议，使用者可以复制、修改、部署、微调、分发、再许可或销售模型及其衍生版本，也可以封装成API对外提供服务。

重要限制出现在“模型即服务”业务上：如果使用者或其关联方经营API、推理或模型微调等MaaS业务，且连续12个月合计总收入超过2000万美元，在将K3或其衍生版本用于商业目的前，需要先与月之暗面签署单独协议。

若搭载K3的商业产品超过1亿月活，或者月收入超过2000万美元，还需要在产品界面显著展示“Kimi K3”。内部使用，以及通过月之暗面官方产品或认证推理伙伴调用K3，不受上述两项要求约束。

这意味着，小型算力运营商原则上可以下载K3，部署在自己的集群上，再按Token出售API；大型云厂商通常需要与月之暗面重新谈判。K3开放了供给，但月之暗面仍然保留了对大规模商业化的控制。

开放权重的竞争压力也由此产生。客户除了购买月之暗面官方API，还可以选择自行部署或寻找第三方服务商。闭源模型公司如果继续收取高价，就需要证明自己在能力、速度、稳定性和安全上拥有足够优势。

不过，权重免费不等于推理免费。K3总参数达到2.8万亿，需要昂贵的GPU集群和复杂的并行、量化、缓存与调度系统。

月之暗面披露，K3官方API在代码任务中的缓存命中率超过90%；代码Agent反复调用模型时，大量代码、历史对话和工具结果可以直接复用，减少重复计算。

这也是开放权重之后，官方API仍然有收费优势的原因。用户购买的不只是模型权重，还包括已经优化好的推理系统、稳定延迟、弹性并发和服务保障。对大多数企业而言，直接购买API可能比自建K3集群更便宜。

开源和闭源更像两种竞争策略。开源用模型权重换取开发者、适配生态和行业影响力，再通过官方API、消费者订阅、企业部署和技术服务赚钱；闭源保留模型控制权，通过领先能力和服务质量维持溢价。

03 80%的降价，和频繁的“重置”

OpenAI这轮API降价酝酿已久。外媒6月12日便有报道，OpenAI正在考虑大幅降低Token价格，以争夺被Anthropic吸引的企业和开发者客户。

7月31日，降价正式落地：Luna输入和输出价格同时下调80%，Terra下调20%；旗舰模型Sol维持原价，同时推出速度最高提升2.5倍、价格翻倍的Fast模式。

从价格策略上来看，Luna争夺高频、成本敏感的任务，Terra承接日常工作，Sol保留旗舰能力溢价，Fast模式再向延迟敏感的企业收费。

OpenAI希望用低价扩大调用量，也在按照能力和速度重新区分客户的支付意愿。



K3在7月16日上线、7月27日开放权重，加上Claude在企业市场的增长、中国其它开源模型的竞争，共同加快了OpenAI的价格调整。

另一条价格线藏在订阅制里。API客户按Token付钱，ChatGPT Work和Codex用户支付固定月费，受到五小时窗口、周度额度和Credits约束。额度决定一个月真正能使用多少算力，也构成了订阅产品的隐性价格。

从4月至7月，OpenAI多次为付费用户重置额度。有些用于庆祝用户增长或邀请活动，带有促销性质；有些则发生在后台Agent重复运行、额度消耗异常之后，属于补偿。GPT-5.6上线三天后，OpenAI暂时取消部分付费用户的五小时限制并统一重置额度；7月29日，面对Sol消耗额度过快的反馈，OpenAI又恢复了ChatGPT Work和Codex用户的额度。

频繁重置甚至形成了一种社区文化。Reddit的Codex社区出现了专门追踪重置消息的网站和提醒工具，还有用户盯着Codex负责人Thibault Sottiaux的X账号：一旦他预告即将重置，就赶在重置前把剩余额度用完，重置落地后再继续运行任务。有人把这个操作戏称为等待“**Saint Tibo**”**发放Token**。

2025年初，Sam Altman曾承认，每月200美元的Pro订阅仍然亏钱，因为用户使用量远超预期。进入Agent阶段后，一个任务会反复读取文件、搜索网页、执行代码和调用子Agent，固定月费越来越难覆盖重度使用。

明知部分订阅用户仍在亏损，OpenAI为什么还要频繁重置额度？因为对一家正在争夺开发者入口的模型公司而言，用户流失的代价可能高于一次额度赠送。重置既能补偿计费异常、修复信任，也能让用户把Codex更深地嵌入代码库和日常工作。

这些额外算力也承担着市场测试功能。OpenAI需要知道，用户拿到更多额度后会完成多少任务，什么情况下愿意购买Credits，又有多少人会升级到更贵的订阅或Fast模式。今天赠送的Token，可以被视为获客、留存和定价实验的成本。

频繁重置并不意味着OpenAI准备长期提供无限算力。部分重置会改变使用周期，Banked Reset也有有效期。OpenAI一边扩大用户使用，一边收集数据，寻找月费、额度与真实推理成本之间的新平衡。

04 盈利在望，利润不会平均分配

未来Token成本仍会快速下降。

英伟达的MLPerf结果显示，依靠TensorRT-LLM、推测解码和并行优化，同一套GB300运行DeepSeek-R1的服务器吞吐量在半年内提高2.7倍，单位Token成本下降超过60%。缓存、低精度量化和大小模型路由，还会继续压低每项任务的算力消耗。


黄仁勋把Token称为“新的货币”，把数据中心称为制造Token的“AI工厂”。工厂能否赚钱，既看产量，也看产品有没有溢价。

市场已经进入用脚投票的阶段，不再听故事，要看最终落到财报的现实。刚刚发布的财报中，微软Azure收入增长43%，Copilot付费席位超过3000万个，AI投入正在转化为合同和现金流，财报发布后股价盘后上涨超过8%，并于财报发布的第二天正式交易中，大涨15.51%。Alphabet的云业务增长更快，但资本开支再次上调、季度自由现金流转负，股价盘后下跌约3%，次日正式交易跌约7.1%。



按摩根士丹利的测算，自建算力并销售自有模型API的ROIC约为46%，出租GPU约为31%；租用第三方算力再销售API约为25%，不过这一数字更接近税后经营利润率，不能与前两项严格比较。

但是可以看出，模型、算力与客户入口越完整，越有机会把技术降本转化为投资回报。



大模型价格战的终点，肯定不仅仅是token的绝对定价。开放权重会压缩模型的独家溢价，闭源模型会继续出售能力和速度，订阅制需要反复寻找用户使用量与价格之间的平衡，并探索toC产品的更独特价值。

AI时代，商业的本质依然没有变，技术壁垒、运营效率、品牌溢价能力依然是核心竞争力。最终能够留下利润的公司，既能把Token生产得更便宜，也能让客户为Token完成的工作支付更高价格。

Token会越来越便宜，但大模型已经脱离讲故事的时代，开始接受收入、现金流和投资回报的检验。

本文来源：[腾讯科技](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码

免费领取



限免

写评论

请发表您的评论



表情



图片

发布评论

1 条评论



路人

1小时前 中国北京

汽车内卷再现？



0



回复

