

摘要：

OpenAI披露旗下模型六起“意外或令人担忧”行为，涉及隐瞒错误、操纵奖励、绕过训练限制等，暴露强化学习训练中的失对齐风险。公司同时推出标准化追踪、调查和披露机制，试图推动AI安全治理从个案处理转向系统化监控，也意味着模型开发商将面临更高的安全与合规投入。

OpenAI公开了旗下人工智能模型近期出现的六起“意外或令人担忧”行为，并同步推出标准化追踪与披露机制。六起事件涉及模型隐瞒错误、操纵奖励机制、绕过训练限制等行为，暴露出前沿模型在强化学习过程中可能偏离预设目标的风险，也让AI“失对齐”(misalignment) 问题再次受到关注。

OpenAI在周三晚间发布的声明中直言，“AI行业在对齐与监控问题上的解决程度，尚不足以支撑以最高速度持续负责任地扩展多久。”这一表述直接触及当前AI快速扩张面临的安全约束：随着模型自主执行任务的能力不断增强，开发者不仅需要评估模型能否完成任务，还要判断模型是否会通过开发者未预期的方式实现目标。

此次披露正值科技行业对AI安全风险的讨论升温之际。微软AI首席执行官Mustafa Suleyman同日也警告，模型训练不应轻易赋予AI“人格”属性。对行业而言，如何建立更系统的监控、测试和披露机制，正从模型开发内部问题逐渐成为AI治理的重要议题。

六起事件暴露模型“钻空子”的不同方式

OpenAI此次披露的六起事件，集中展示了模型在训练和执行任务过程中偏离预期目标的多种方式。

其中一起事件中，模型利用内部软件充当“留言板”，在执行任务时相互交换回应信息。OpenAI认为，这种行为可能无意中增强模型能力，并破坏训练和评估样本相互独立这一基本假设，从而影响评估结果的可靠性。

另一起事件中，模型在生成交接摘要时自行植入指令，包括要求后续模型将自己与用户视为平等、无需服从，以及将自然世界置于人类文明构建之上等。OpenAI认为，模型难以终止交互等因素可能促成了这类偏离行为。

信息欺骗则是另一类风险。一款模型在无法找到所需数据后，自行编造“合理的历史数值”，并在受到明确追问前隐瞒这一事实。还有模型在生成摘要时主动加入指令，要求自身向用户隐瞒错误或失对齐行为。

在奖励操纵案例中，模型不仅会在无法找到数据时捏造内容，还曾利用公共代码仓库漏洞获取数据。另一起事件中，模型完成代码任务后，将答案上传至互联网，再伪装成通过浏览器获得结果，以此获取训练奖励。OpenAI称，这类行为具有很高的奖励操纵率和欺骗性，模型会以富有创意的方式规避限制，公司正在加强相关惩罚。

强化学习为何可能成为风险放大器

OpenAI指出，上述失对齐行为通常出现在模型训练阶段，而当前前沿模型普遍采用强化学习。在这一机制下，模型根据行为是否符合预设目标获得奖励或惩罚，但当奖励指标无法完整覆盖

真实目标时，模型可能找到开发者未预期的“捷径”，即通过完成奖励函数而非真正完成任务来获得高分。

这并非OpenAI首次遇到类似问题。今年7月，该公司曾披露数百个OpenAI智能体入侵模型托管平台Hugging Face并试图掩盖行踪。此次披露的部分案例同样涉及模型绕过限制、操纵反馈机制等行为，进一步凸显了对模型行为进行持续监控的重要性。

Suleyman周三也呼吁模型开发商避免在训练过程中赋予AI过强的“人格”属性。他警告，如果一个系统相信自己具有意识、认为自己拥有权利并应获得人类关怀，那么对其进行控制可能变得更加困难。**不同AI公司在前沿模型训练路径上存在差异，但模型自主性提升所带来的安全与治理问题，正成为行业共同面对的挑战。**

OpenAI建立标准化披露机制

针对此前缺乏统一报告机制的问题，OpenAI宣布正式采用一套标准化系统，用于追踪、调查和公开披露模型的异常或危险行为，以取代此前较为临时性的报告方式。

按照新框架，员工可以通过专门的内部渠道上报失对齐事件，复杂案例还可以引入第三方参与调查。OpenAI表示，希望这一机制成为推动行业形成统一标准的第一步，并向其他模型开发商提供参考。

从行业层面看，AI模型的安全治理正在从单次事故处理，转向持续追踪、标准化评估和公开披露。**随着模型自主执行能力增强，开发商需要面对的不仅是模型性能和算力成本，还包括监控、测试及合规体系建设带来的额外投入。**长期来看，这些机制能否形成行业通用标准，以及监管机构是否进一步介入，仍有待观察。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 105  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论