

摘要：

谷歌工程师Patrick推测，Opus 5.5模型可能由Anthropic内部更强的"教师模型"Model 2通过知识蒸馏训练而成，并可能是首个体现"递归自我改进"路径的产品模型。目前无公开证据证实，但Anthropic已确认Model 2存在，且其代码库中逾80%代码由Claude撰写。该趋势表明模型能力提升与推理成本下降有望同时实现。

Anthropic最新发布的Claude Opus 5.5，在性能大幅跃升的同时将运行成本压低40%，这一反常规的组合引发了业界对其训练方式的密切关注。

社交平台X上，谷歌工程师Patrick C Toulme据此提出一个推测：**Opus 5.5可能经由Anthropic内部更强大的"教师模型"Model 2蒸馏而来，并可能是首个体现"递归自我改进"（RSI）路径的产品模型。**

目前没有公开证据直接证实这一推断，但Anthropic已公开确认Model 2的存在，且该公司发布的RSI相关文章显示，AI参与AI研发的程度正在快速深化，这使得上述猜测具备一定背景。

对于投资者和行业观察者而言，这一事件真正值得关注的，是它将三条此前相对分散的趋势串联在了一起：**更强的内部模型持续迭代、AI深度介入AI研发流程、以及更小更便宜的产品模型同步涌现。**

如果这条路径成立，模型能力提升与推理成本下降将有可能同时发生。

Opus 5.5为什么值得关注？

[华尔街见闻提及](#)，Anthropic将Claude Opus 5.5定位为其5.5系列的首款发布，性能在多数任务上与Claude Fable 5.1持平，但运行成本较Opus 5下降40%，输出速度提升逾30%。

定价层面的降幅尤为显著。输入和输出token价格分别为每百万4美元和20美元，较Opus 5下降20%；而在代理任务和编程场景中占主要成本的缓存读取，则从每百万0.50美元降至0.20美元，降幅达60%。

Pricing

Prices per 1M tokens	Claude Opus 5.5	Claude Opus 5
Cache reads	\$0.20	\$0.50
Input tokens	\$4	\$5
Output tokens	\$20	\$25
Cache writes	\$5	\$6.25

从实际使用表现来看，早期测试者完成了680,000行代码迁移，耗时不足一天，而此前类似工作需要工程团队数周；另一项测试中，Opus 5.5将一个Web应用全站页面加载时间优化成功率达到39/40，Opus 5在同等任务上则出现了改动应用行为的副作用。


在将HAProxy从C语言重写为Rust的内部测试中，Opus 5.5耗时9.5小时，较Fable 5.1的12小时缩短逾20%，成本节省51%。

Anthropic表示，效率优势还体现在token消耗层面——Opus 5.5不仅每个token价格更低，完成同等任务所需的token数量也更少，两者叠加共同形成了40%的综合成本降幅。

Patrick所说的“教师模型”到底是什么？

Patrick C Toulme在X上写道：

Opus 5.5显然是由一个更大的教师模型训练出来的，很可能是Model 2 Mythos。Opus 5.5是首个经过RSI训练、同时由内部教师模型蒸馏的模型。规模更小、成本更低，正是教师模型蒸馏的产物。



这里涉及的核心技术概念是“模型蒸馏”：让能力更强的教师模型生成高质量训练信号，再用这些信号训练规模更小的学生模型，从而在保留较高能力的同时显著降低推理成本。

Anthropic已公开确认，其内部存在一个比Mythos 5更强大的Model 2，并被大量用于代码生成、数据生成及代理任务。然而，目前没有任何公开材料直接证明Opus 5.5是由Model 2蒸馏而来。Anthropic在发布文档中也未提及具体训练方式。

值得注意的是，Anthropic在安全条款中将“蒸馏攻击”单独列为一类威胁——即攻击者通过大量虚假账户从模型中批量提取能力，并为此在Opus 5.5上引入了“保留推理链”等反蒸馏机制。

这一细节从侧面说明，蒸馏技术本身在Anthropic的技术体系中具有相当重要的地位。

AI开始参与AI研发

无论Opus 5.5的具体训练路径如何，Anthropic自身发布的RSI相关文章提供了一幅更宏观的图景：AI介入AI研发的深度，正在以可量化的速度加快。

截至2026年5月，Anthropic代码库中逾80%的代码由Claude撰写，而在2025年2月Claude Code推出研究预览版之前，这一比例仅为个位数。

在工程产出层面，Anthropic工程师人均每日合并代码量较2024年增长约8倍。

Anthropic文章同时指出，2026年4月，Claude在约800小时内将某类API错误降低了1000倍，而据主导此项工作的工程师估计，人工完成同等任务需要约四年时间。



在研究判断力层面，Anthropic设计了一项内部测试：在研究员与Claude的协作会话中，找出人类研究员选择了"次优"方向的关键节点，再比较不同版本的Claude与人类在这些节点上的判断优劣。

结果显示，2025年11月的Opus 4.5模型在51%的情况下给出了比人类更优的下一步建议，而2026年4月的Mythos Preview这一比例升至64%。

不过，该文章也明确指出了当前的边界：

在选择哪些问题值得研究方面，Claude与人类之间仍存在较大差距。这正是今日AI与能够自主设计下一代AI的未来系统之间的距离所在。

Anthropic同时强调，完全意义上的递归自我改进目前尚未实现，也并非必然到来。

但分析认为，过去模型竞争很大程度上是“谁拥有更多算力”，现在开始出现另一条路径：**让更强的模型帮助训练和改进更便宜的模型。如果这条路径成立，模型能力提升与推理成本下降可能同时发生。**

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码 免费领取

限免

👍 137

★ 收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论