

摘要：

花旗AI基础设施峰会纪要显示，随着AI进入推理、智能体和长上下文工作流，网络互联、内存带宽与容量、数据传输效率正成为算力之外的关键瓶颈。博通主推以太网互联降TCO，Marvell优化KV缓存与内存层级，三星升级HBM，AWS以定制芯片提升内存带宽经济性。竞争焦点正从算力规模转向系统级数据流动效率。

AI基础设施的竞争正从“堆算力”转向系统级优化。随着AI从模型训练进一步进入推理、智能体和长上下文工作流，**算力芯片已不再是唯一瓶颈，网络互联、内存带宽与容量，以及数据在不同层级之间的传输效率，正成为下一阶段基础设施升级的关键。**

据追风交易台，花旗发布的AI基础设施峰会纪要显示，博通、Marvell、三星及AWS等公司在峰会第二天集中阐述了各自在网络、存储和定制芯片领域的布局，释放出一个共同信号：**AI工作负载持续复杂化后，基础设施需要同时解决互联效率、内存容量、带宽、功耗和成本等问题。**

博通明确认为，以太网将成为大规模AI基础设施的首选互联方案，并称其架构相较替代方案可实现超过30%的五年总拥有成本（TCO）节省。三星则披露HBM路线图，预计新一代zHBM较HBM5可实现4至8倍的单GPU性能提升，同时将热阻降低75%至90%。

从博通的高速以太网，到Marvell针对KV缓存的内存层级优化，再到三星推动HBM架构升级、AWS通过定制芯片提升内存带宽经济性，AI基础设施的竞争正在从单纯追求算力规模，转向提升整个系统的数据流动效率。

网络与内存，成为AI扩展的新瓶颈


博通产品管理副总裁Hasan Siraj在峰会上介绍了公司的AI网络布局。博通认为，以太网正在成为大规模AI基础设施的首选互联技术，Tomahawk和Jericho系列则是其核心网络产品。

博通目前已形成覆盖网卡（NIC）、交换机和软件的AI以太网方案。其中，Tomahawk系列持续以每代翻倍的速度提升带宽，最新Tomahawk 6达到102.4 Tbps，面向更大规模AI集群。博通称，更高的网络效率能够同步降低功耗、散热及基础设施运营成本，其方案相比替代方案可节省超过30%的五年TCO。

Marvell数据中心网络集团执行副总裁兼总经理Dave Lazovsky则将重点放在内存层级。随着AI进入推理密集型和长上下文场景，KV缓存规模快速增长，可能超过HBM容量上限，系统因此需从速度更慢的内存层级重新加载数据，甚至重新计算上下文。

Marvell指出，**这一过程会推高推理延迟、内存流量和功耗，成为AI系统进一步扩展的瓶颈。**由此来看，未来AI基础设施不仅需要增加算力，也需要重新优化内存层级和数据传输路径，让数据能够更高效地在不同计算与存储层级之间流动。

Figure 2. Broadcom: TCO Savings with Efficient Architectures



Source: Broadcom

HBM与定制芯片，争夺系统效率

三星DRAM产品规划与业务拓展副总裁In Dong Kim判断，AI将沿“生成式AI→智能体AI→物理AI”的路径演进。三星预计，训练需求将增长约3倍，推理需求可能增长约100倍，内存、存储、功耗和散热的重要性随之提升。

三星预计，HBM4E将实现每GPU 16 TB/s带宽，性能功耗比相比HBM4提升20%；HBM5较HBM4E实现2倍性能提升。更激进的zHBM则被三星视为潜在颠覆性技术，其单GPU性能较HBM5提升4至8倍，性能功耗比提升3倍，热阻降低75%至90%。

三星同时介绍了Z-NAND方案，采用SLC NAND与TSV堆叠，读取性能可比肩LPDDR5 DRAM，比特密度约为DRAM的10倍，预计2028年开始送样。

AWS则通过定制芯片提升AI系统效率。AWS基础AI模型、定制芯片及量子计算高级副总裁Peter DeSantis表示，公司已形成Graviton、Inferentia和Trainium自研芯片体系，并将Trainium的核心优势归结为“单位成本内存带宽”，认为这一指标直接影响AI训练经济性和token效率。

随着AI从模型训练走向智能体和真实 workflow，基础设施竞争的焦点也在发生变化。算力规模仍然重要，但网络连接、内存带宽与容量，以及数据传输效率，正成为决定AI系统性能和成本的关键变量。

~~~~~

以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入 [【追风交易台·年度会员】](#)

# 追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

## 什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

## 在这里，你将看到

### 最专业的解读

来自全球顶尖投行、研究机构、  
一线从业者的最新解读



### 最独到的视角

以全球市场第一线的视角  
感知市场动向



### 最适时的时机

快速、完整、准确  
最终汇集成适时



## 如果你

关心全球宏观经济和资本市场

## 如果你

苦恼于没有合适的信息和研究



关注“追风交易台”  
成为“追风会员”

你将身处全球市场第一线

公众号 · 追风交易台

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

31    收藏

分享到:

写评论

请发表您的评论

表情    图片

发表评论