

摘要：

Token支出已成企业AI最烫手的难题，连微软都扛不住了。当“用得起”取代“用得强”成为企业的优先级，“模型路由”——根据任务复杂度动态匹配最经济模型的能力——不再是技术选型，而是决定AI项目能否算得过账的核心需求。

AI Token成本正在重塑企业AI的底层逻辑，而微软的一个内部决策，将这场变局推到了台前。

据[华尔街见闻此前文章](#)，微软正考虑将开源模型DeepSeek V4的微调版本引入其企业AI工具Copilot Cowork，作为OpenAI和Anthropic模型的低成本替代选项，并预计在未来数周内公布最终选择。

与此同时，微软已宣布将Copilot Cowork从无限使用模式切换为按计算量计费。这一系列动作释放出一个清晰信号：**即便是微软，也已无法承受无节制的模型调用成本。**

这一消息在企业AI市场引发广泛共鸣。追踪AI Token价格的Silicon Data Token指数已连续13个交易日中有12个交易日下跌，直奔近期低点。成本压力正在从个别企业蔓延为行业性议题，而“用哪个模型”的问题，正在让位于“如何用得起模型”。

当“用得起”取代“用得强”成为企业的优先级，“模型路由”——根据任务复杂度动态匹配最经济模型的能力——不再是技术选型，而是决定AI项目能否算得过账的核心需求。

微软的成本困局：无限使用模式走到尽头

微软Copilot Cowork此前向企业用户提供无限使用，但这条路已难以为继。

微软负责Copilot业务的执行副总裁Charles Lamanna直言：“有些用户每周完成数百项任务，效率很高——但代价是成本可以飙得非常高。”

为此，微软宣布将Copilot Cowork切换为按计算量计费的使用模式，并同步探索引入DeepSeek V4微调版本或其他开源模型，以大幅压低模型调用成本。背后的逻辑直接：**中美模型在输入/输出Token定价上存在显著差距，开源模型的成本优势已无法忽视。**

这一决策折射出整个企业AI市场的共同困境。前沿模型能力越来越强，但调用成本也水涨船高——以Fable 5为例，其输出Token成本较Opus 4.8在同类任务上高出约180%。更高的智能，正在带来更难以消化的账单。

Token经济学：下一个六到十二个月的主导议题

成本压力已经渗透进企业AI采购的每一个环节。

Mason Daugherty在社交媒体上表示，在他过去约两个月与客户的每一次对话中，全组织范围内的Token支出都被提及为一个令人担忧的问题。他预测，“**Token经济学**”将成为未来六到十二个月讨论AI采购与使用时的主导主题。

他指出，随着大型供应商的年度企业合同陆续进入续签周期，管理层已开始质疑是否还能以相同乃至更高的价格续约。与此同时，前沿API与自托管开源模型之间的成本差距正在持续扩大，这正是开源模型采购加速的直接驱动力。



Mason Daugherty  
@masondrxy

Follow



prediction: tokenomics will be the dominant theme when it comes to discussing AI adoption & usage over the course of the next 6-12 months.

org-wide token spend has come up as a point of concern in every. single. conversation i've had with customers in the past ~2 months. annual enterprise contracts with the big providers will soon begin to enter renewal, and leadership teams are already questioning whether they can justify signing at the same (& increasing) prices again.

it's no coincidence that open model adoption keeps accelerating. the cost delta between frontier APIs and running open models is widening.

Silicon Data Token指数的持续下行，印证了这一趋势的市场层面影响——Token定价的竞争压力已经在数据上留下痕迹。

架构才是护城河：模型路由成为企业AI的核心能力

在成本压力下，企业AI的竞争焦点正在发生根本性转移。

企业AI平台Glean的Arvind Jain指出，企业AI最大的瓶颈已不再是模型智能本身，而是"Token产出效率"——即系统每消耗一个Token能产出多少有效工作。他强调，企业AI的大部分成本并不在提示词本身，而在于模型周围的系统：检索、工具调用、记忆管理和多步推理。一个十一个词的请求，一旦系统开始收集上下文并逐步处理任务，可能扩展为数千乃至数万个Token。

Jain认为，真正的竞争优势不来自最激进地使用最强大的模型，而来自能够将正确的模型与正确的推理层级匹配到对应任务的AI架构——即具备强大路由能力、支出管控和治理机制的系统。"前沿智能正在变得充裕，高效执行却并非如此。"



Arvind Jain  
@jainarvind

Follow



The biggest bottleneck in enterprise AI is no longer model intelligence. It's token yield.

As frontier models get stronger, the harder question becomes economic: how much useful work does a system produce per token?

Fable 5 is a good example of the shift. It pushed the frontier forward, but at roughly 180% higher output-token cost than Opus 4.8 on comparable jobs.

Most enterprise AI cost is no longer in the prompt. It sits in the system around the model: retrieval, tool use, memory, and multi-step reasoning. An eleven-word request can expand into thousands or even tens of thousands of tokens once a system starts gathering context and working through the task.

这一判断与微软的实际动作高度吻合：引入低成本模型作为替代选项，本质上正是在构建一套模型路由机制，而非简单地"换一个便宜模型"。



纳德拉的警告：谁拥有学习循环，谁才拥有主权

微软CEO Satya Nadella近日提出了一个更宏观的框架，为上述趋势提供了战略注脚。

纳德拉表示，**每家公司都必须构建他所称的"Token资本"与"人力资本"——前者指企业自有的AI能力与系统，后者指员工的知识、关系与判断力**。他将两者定义为在AI经济中立足的核心资产，并强调人力资本的价值不会随Token资本的增长而下降："没有人的方向，你只是让算力在原地打转。"

他明确指出，真正的机会不在于选择最强的模型，而在于在模型之上构建一个持续学习的循环，让人与AI的能力相互复利增长。关键的检验标准是：企业能否在更换底层基础模型的同时，不丢失自身积累的专有知识与能力。"这是你在未来时代掌握控制权与主权的核​​心测试。"

纳德拉同时发出警告，若所有价值最终集中于少数几个主导模型，将重演全球化掏空工业经济的历史。他表示："没有任何社会许可，支持一个让整个行业空心化的AI未来。"这番表态，恰恰发生在微软自身正考虑引入开源替代模型、主动分散对少数头部供应商依赖的节点上，其内在张力耐人寻味。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码

免费领取



限免

35 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

