摘要：

在极端情景下，美国数据中心总容量会在 2028 年前后停在约 120 到 150GW，大约是今天的 2 到 2.5 倍，此后不再增长。两三百 GW 的规划被冻结，相当于数千万块最先进的 AI 芯片失去了机房。

2026 年 11 月 4 日，美国中期选举结果落定后的第二天上午，OpenAI 的高管们坐到了一起。

据外媒援引知情人士的消息，他们讨论的是要不要重设 2027 年的数据中心容量预期。讨论还没有形成决定，但焦虑已经摆上了台面。

过去几个月，美国各地的大型数据中心项目接连被按下暂停键。得州前任州长 Abbott 从 8 月起冻结了数据中心的并网和空气许可，要求审计到年底；新当选的州长 Gina Hinojosa 承诺，在州议会立法保护居民之前，暂停所有新数据中心审批，而议会会期要到 2027 年 5 月才结束。

俄亥俄新州长 Amy Acton 提出有条件暂停，要求新项目承担全部电力成本、只能建在旧工业用地上；佐治亚新州长 Keisha Lance Bottoms 则准备上任后直接签行政令，暂停全州新建。

据 Tokenpost 统计，今年 7 月到 11 月 4 日，美国至少有 21 个大型数据中心项目被取消，已经接近 2025 年全年的 23 个。Anthropic 在 10 月 26 日提交的招股书里，也把暂停令写进了风险因素：一些辖区正在考虑或已经批准暂停令，可能推迟或阻止它依赖的算力设施，而且反对数据中心的声音正在跨辖区变得更有组织。

如果我们把这股趋势推到极端，去设想这样一个场景，如果美国所有规划中的数据中心都建不成，对当下和未来的 AI，意味着什么？

01 潜在算力增长被砍掉 50%

为了把推演的边界划清楚，我们设定这样一个极端场景，它建立在三条假设上：

1，全美所有尚未开工的规划项目全部冻结，相当于把目前约 41% 的暂停范围推向全国；

2，已经在建的项目全部按期完工，这和德州等地暂停令只针对新审批的做法一致；

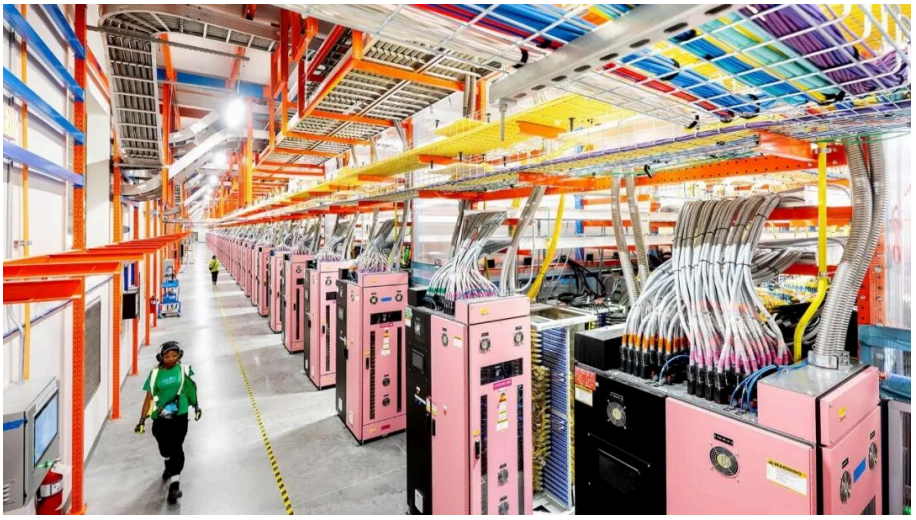
3，芯片照常供应，唯一的硬约束是电和地。我们只推演美国本土，暂不讨论算力外迁。

这个场景下，被卡住的算力规模有多大？据 Newmark 估计，美国数据中心当前用电约 60GW，这里包含所有数据中心，并非全是 AI。在建容量各家口径不同：Cleanview 约 57GW，Wood Mackenzie 约 80GW，DCMap 8 月的统计约 90GW。这部分项目在情景里会照常完工，构成未来几年美国算力的全部增量。

真正庞大的是「规划中、未开工」的部分，DCMap 8 月统计为 228GW，Wood Mackenzie 披露的累计管线超过 430GW，取一个约 230 到 340GW 的区间比较稳妥。

据此粗略推算，在极端情景下，美国数据中心总容量会在 2028 年前后停在约 120 到 150GW，大约是今天的 2 到 2.5 倍，此后不再增长。作为参照，Synergy 此前的预测是美国容量到 2029 年翻倍；而如果管线里的规划全部落地，这个数字本该是今天的 5 倍以上。极端场景砍掉的，是翻倍之后的那一大段增长。

换算成芯片会更直观。1GW 电力大约能带动数十万块 Blackwell 级 GPU：按单卡全口径功耗 1.8 到 2.3kW 理论计算，约 43 万到 55 万块；Abilene 这样的实际园区，约每 GW 27 万块。两三百 GW 的规划被冻结，相当于数千万块最先进的 AI 芯片失去了机房。



亚马逊为 Anthropic 建设的 Project Rainier 园区内部｜图片来源：Amazon

这个情景很极端，但不荒谬。据 Cleanview 测算，新州长承诺暂停的州里，规划容量合计 158.6GW，约占全国的 41%，其中德州 88.4GW、俄亥俄 21.9GW、佐治亚 20.2GW、新墨西哥 11GW、纽约 9.9GW。也就是说，情景 A 里接近一半的冻结，在现实中已经有了对应的政策承诺。2024 年以来被取消的 69 个大型项目里，有 33 个主要因为当地反对。参议员桑德斯还提出了全国性暂停法案，虽然通过的可能性很小。

有一点需要诚实说明，目前规划的数字水分很大。德州电网 ERCOT 的大负荷排队约 474GW、约 1800 个项目，相当于该电网峰值负荷的五倍左右，大部分是占位性质的投机申报。所以极端场景实际砍掉的有效算力，会小于账面数字。即便打掉水分，它依然是一次算力供给的急刹车。

这样一脚「算力刹车」踩下去后，会对 AI 产生怎样的影响?

02 当下照常，下一代 AI 受阻

如果极端情景明天发生，用户在一两年里其实感觉不到异样。2027 年之前的前沿模型，照常训练、照常迭代。

因为支撑这一代模型的训练基地，都已经建成或接近完工。据 Epoch AI 的数据库，目前已知最大的 AI 园区是 Anthropic 与亚马逊在印第安纳州的 New Carlisle，容量 1037MW；其次是 xAI 的 Colossus 2，946MW。OpenAI 在德州 Abilene 的园区规划 1.2GW，8 栋楼里的 6 栋截至 9 月已经交付，预计年底完工。



OpenAI 位于德州 Abilene 的 Stargate 园区卫星图｜图片来源：Epoch AI

被卡住的，是计划在 2028 到 2030 年登场、需要数个 GW 才能喂饱的下一代模型。

Epoch AI 的数据显示，前沿训练的电力需求每年增长 2.2 到 2.9 倍，目前的前沿训练已经超过 100MW。Epoch 预计，未来一年会有多个园区突破 1GW，大约两年后，最大规模的训练可能用到约 250 万块 H100 等效算力；照这个趋势，到 2030 年，最大单次训练需要 4 到 16GW。

作为对比，今天最大的园区刚刚超过 1GW。Epoch 也指出，数据中心的容量，实际上就是训练规模的上限：园区建多大，模型最多就能训多大。

而那些瞄准 2028 年之后的超级工程，已经有不少撞了墙。

OpenAI 的 Stargate 计划到 2029 年超过 9GW，美国 7 个站点中的多数原定 2027 到 2028 年大规模上线，主要集中在得州、新墨西哥和俄亥俄这几个暂停州。

其中，Abilene 旁原计划的扩建已被放弃；新墨西哥州 Doña Ana 规划 2.45GW 的 Project Jupiter，今年 3 月被州土地办公室否决了供气管道；俄亥俄州 Lordstown 站点，直到 4 月的卫星图像里还看不到大规模施工。

Meta 约 1GW 的 Prometheus 园区也在俄亥俄，只有路易斯安那州目标 5GW 的 Hyperion 避开了这一轮暂停。



新墨西哥州 Doña Ana 的 Project Jupiter 工地卫星图｜图片来源：Epoch AI

这就带出了接下来的疑问，下一代训练的算力基地搁浅之后，AI 的进步会慢多少？

03 降速，但不会停摆

要回答这个问题，需要把算力增长拆开来看。

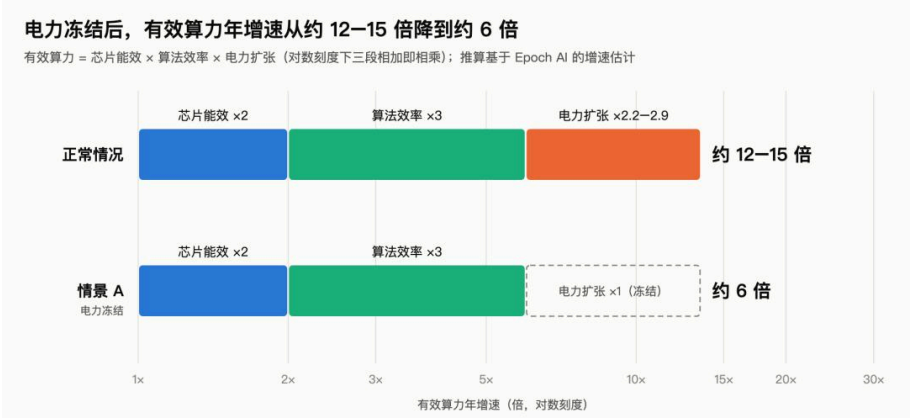
据 Epoch AI 统计，2020 年以来，前沿语言模型的训练算力每年增长约 4 到 5 倍。同期训练用电每年增长 2.2 到 2.9 倍。两者之间约 2 倍的差值，主要来自芯片能效的提升，也就是每瓦电能提供的算力在变多。

硬件之外，算法也在帮忙。常用的口径是算法效率每年提升约 3 倍（Ho 等人 2024 年的研究给出约 2.7 倍）。Epoch 后来把后训练也算进去，估计约每年 10 倍，但区间从 2 倍到 50 倍不等，这里采用更稳妥的 3 倍。

现在可以做一个粗略的推算。

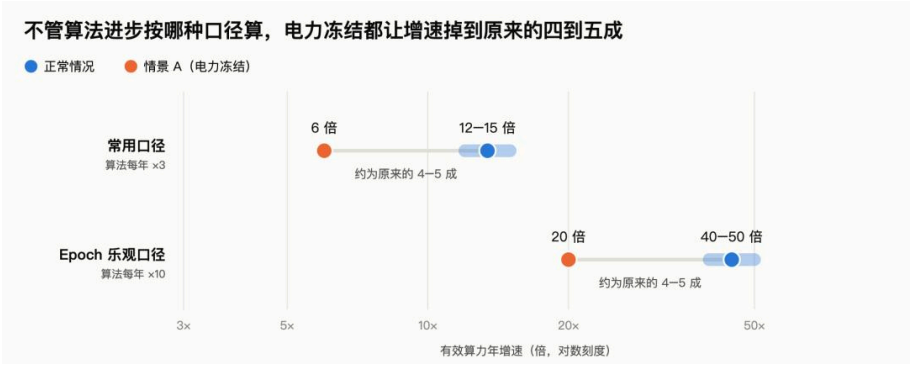
正常情况下，AI 每年获得的「有效算力」增长，等于物理算力增长（4 到 5 倍）乘以算法提升（约 3 倍），大约每年 12 到 15 倍。

在情景 A 下，2028 年之后新增电力归零，物理算力增长里最大的一根支柱被抽走，只剩芯片换代带来的能效提升，每年约 2 倍。再乘上算法的 3 倍，「有效算力」的年增速会从 12 到 15 倍，降到约 6 倍。



有效算力年增速拆解：正常情况与极端情景 A 对比（推算）｜图片来源：极客公园

如果换用 Epoch 更乐观的算法口径（每年约 10 倍），正常情况下的有效算力增速是每年 40 到 50 倍，情景 A 下约 20 倍。两种口径下，电力冻结都会让有效算力增速掉到原来的四成到一半左右。算法进步再快，也补不上电力扩张留下的那一块。



两种算法口径下，电力冻结前后的有效算力年增速（推算）｜图片来源：极客公园

这里还有一个隐患。芯片能效的红利，前提是新芯片能顺利装进机房。机房总电量锁死后，供电和散热改造的难度，可能让这 2 倍也打折扣。

即便如此，每年约 6 倍依然是可观的数字。推演下来，结论很清楚：

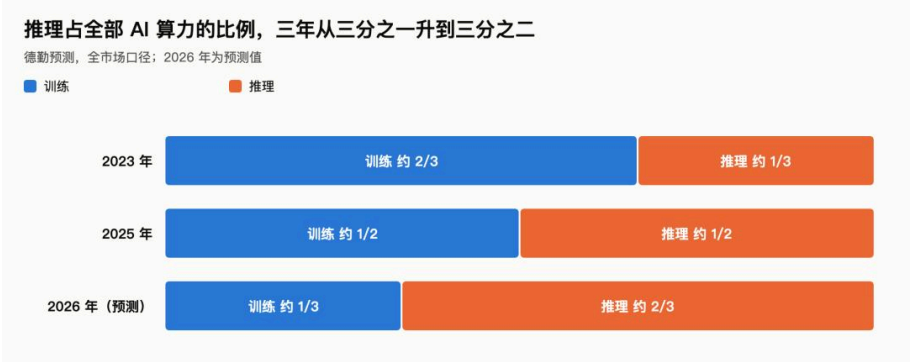
极端场景下，AI会明显减速，但不会停摆。

不过这笔账只算了训练需要的算力部分，把视野放到整个 AI 的运转上，电量锁死之后，还有一场争夺会立刻开始。

04 Token 限额时代来了

过去算力不够，就去圈地建新机房。在极端场景下，盘子里的电就这么多，分给训练的每一度电，都要从推理、智能体和后训练那里挤出来。

全市场的算力早已向推理倾斜。据德勤预测，推理占全部 AI 算力的比例，2023 年约三分之一，2025 年约一半，2026 年预计达到约三分之二。



推理与训练在全部 AI 算力中的占比变化｜图片来源：极客公园

AI实验室内部也在变。SemiAnalysis 基于 OpenAI 和 Anthropic 合计算力的估算显示，2024 年初，预训练占 67%，后训练和强化学习只占约 5%，推理约 29%；此后预训练占比逐季下滑，二季度 63%，三季度 57%，2025 年降到五成多，后训练占比持续上升，最新估计两者已经相当。有研究者提醒，这是占比变化，实验室总算力翻了很多倍，预训练的绝对量未必减少。

更大的压力，来自产品形态。推理模型在回答前会生成很长的思维链，用户看不到，但每一步都在耗电。Gartner 的数据显示，智能体完成一项任务消耗的 token，是普通聊天的 5 到 30 倍。

高盛预测，2026 到 2030 年，全球 token 总消耗将增长 24 倍。



智能体与 token 消耗的增长｜图片来源：极客公园

把这些数字放进极端情况下固定的电量里，每家实验室都会面对同一道选择题：每一兆瓦，要么拿去训练下一代更大的模型，要么拿去服务现有的用户和智能体。

想调几十万块卡训一个更大的基座模型，就得限制现有用户的调用量；优先保推理、保用户，下一代模型的进度就会落后。

增加电力这条路被堵住以后，剩下的问题，就是在固定的电量和算力下，继续发展 AI，还有什么路可走。

05 四条「补充路线」

在极端场景的压力下，那些过去因为「反正能加卡」而不受重视的省电技术，会变成主流方案：

把硬件的考核指标换成「每瓦电能产出多少 token」。

在电量固定的机房里，把旧芯片换成能效更高的新芯片，是唯一的扩容手段。

英伟达现在首选的指标，就是「每个全口径电力兆瓦每秒输出的 token」，分母里算上的是园区的全部用电，包括散热和网络。这个指标的流行本身就说明，芯片厂商已经默认客户的瓶颈在电，卡的数量反而是次要的。

按英伟达的说法，Vera Rubin 的每瓦性能是 Blackwell 的 10 倍，智能体场景下对比 GB300 最高可达 30 倍。独立测试也给出了接近的结果：CoreWeave 实测，在同一 DeepSeek R1 负荷、相同交互速度下，Vera Rubin NVL72 每兆瓦的 token 产出是 GB200 NVL72 的 10 倍。不过 Rubin 下半年才开始量产，多数客户要到 2027 年才能普遍用上。



英伟达 Vera Rubin NVL72 机柜｜图片来源：NVIDIA

跨机房分布式训练。

暂停令普遍针对的是动辄数百兆瓦的大型数据中心。一个自然的绕行思路，是把训练任务拆散，分到不同地区的中小机房里。政策压力会直接变成对分布式训练的技术需求。

这个方法，巨头们已经在尝试。谷歌说明过，Gemini 是在多个地点的集群上同步训练的；微软把威斯康星和佐治亚的机房连了起来；CoreWeave 与谷歌云宣布了跨云训练。谷歌的 DiLoCo 研究表明，训练可以在普通网络连接的远程设施之间进行，还能容忍硬件故障。

但这个方法的难度不小。DiLoCo 的作者也承认，这项技术目前只能补充超大集群，无法形成替代。2026 年的一项仿真研究发现，机房相距几十到几百公里时，网络延迟会明显削弱计算与通信的重叠，大量算力在等待数据中空转。

研发重心从预训练，转向后训练和强化学习。

预训练对单一超大集群的依赖最高，在极端下最先受限。数个 GW 的集群建不起来，工程师会把精力转向对集群规模要求没那么苛刻的后训练、强化学习，以及混合专家模型、低精度计算等架构改进。Cursor 就公开说过，其 Composer 1.5 模型在后训练上投入的算力，已经超过了预训练。

端侧和小模型给云端分流。

到 2026 年，蒸馏已经是做小模型的主流方法。量化后的小模型能直接在手机 NPU 上处理结构化任务，10 亿参数以下的模型大约每秒能跑 12 到 15 个 token。越来越多应用采用混合模式：本地小模型先处理大部分请求，少数复杂请求再交给云端大模型。

06 约束之下的机会

极端场景卡住的是美国本土的电。对另外两类玩家来说，这道约束反而打开了窗口：已经在效率路线上积累多年的模型公司，以及准备入场的 AI 创业者。

先看前沿和追赶者之间的距离。据 Epoch AI 今年 5 月的测算，最强的开源模型平均落后闭源前沿约 4 个月，大约相当于 GPT-5 和 GPT-5.5 之间的水平差。过去，前沿实验室靠每年十几倍的有效算力增长不断拉开代差；在极端情景下，这个速度降到约 6 倍，新的代差更难建立，追赶者需要追的距离会变短。

再看效率路线上的先行者。DeepSeek、Qwen、Kimi、GLM、MiniMax 等中国模型公司，一直以开源、低成本和混合专家架构见长，这条路线已经反映在使用数据上。

据 OpenRouter 与 a16z 的联合研究，中国开源模型在该平台的 token 占比，从 2024 年底的约 1.2% 涨到 2025 年的近 30%；进入 2026 年，多家统计给出的比例在五到六成之间。

a16z 合伙人 Martin Casado 还估计，使用开源技术栈的创业公司里，约八成在跑中国模型。OpenRouter 只是一个平台，不包含 ChatGPT 自家流量和企业私有部署，但趋势很清晰：

当整个行业都要回答「每度电能产出多少智能」这个难题，长期在这道题上下功夫的团队，手里的经验会更值钱。

来源：极客公园

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

13 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论