

摘要：

微软连发三款自研AI模型，意在降低对OpenAI的依赖。实测表现良莠不齐：语音生成逼真至带有口水声，转录模型却将“警校卧底”魔改成“剑桥会计”，图像模型能体现空间纵深感，但对复杂指令兼容有限，整体实战性能仍待打磨。

昨日微软一口气发布三款自研AI模型：**MAI-Transcribe-1**、**MAI-Voice-1**和**MAI-Image-2**，分别覆盖**语音转写**、**语音生成**与**图像生成**三大高频应用场景。

Today we're announcing 3 new world class MAI models, available in Foundry

有外媒评论，此举标志着微软正在自建AI技术体系，以**降低对OpenAI的依赖**。


官方博客显示，MAI-Transcribe-1批量转录速度是现有Microsoft Azure Fast产品的**2.5倍**，在**FLEURS基准测试中平均词错误率最低**；MAI-Voice-1则可在仅需**1秒即可生成60秒的音频**；MAI-Image-2的图像生成速度至少提升了**2倍**。

在我们的实测中，三款模型表现各异：MAI-Transcribe-1在一倍速下转写准确，但二倍速播放《无间道》天台对峙片段时，将“我也读过警校，你们这些卧底真有意思”误识为“我也读过剑桥，你们学会会计真有意思”；面对《寒战》中节奏更快、情绪更激烈的争吵片段，甚至出现**完全无响应的“宕机”**现象。

MAI-Voice-1则能生成风格迥异的语音：**英式版本**低沉有韵律，呈现**莎士比亚式舞台感**；**美式版本**轻快明亮，细节甚至包括**人说话时的口水声**，逼真感强。MAI-Image-2在官方示例中自然景观渲染表现在线，但在实测中**面对复杂指令时仍有局限**。

语音转录实测：中文结果无标点，把二倍速无间道对峙转成“剑桥会计”

MAI-Transcribe-1是语音转文本模型，微软称其在FLEURS基准测试中，针对微软产品使用率最高的25种语言，实现了最低的平均词错误率。




此外，微软还称该模型在这些语言中的表现**优于OpenAI的 Whisper-large-v3**，并在其余大多数基准测试语言中**胜过谷歌的 Gemini 3.1 Flash**。微软表示，其批量转录速度较现有的Azure产品有了显著提升。通过Foundry平台进行转录的起价为每小时0.36美元。

实测中，我们选取了电影《无间道》中刘德华与梁朝伟天台对峙的经典桥段，分别以一倍速与二倍速输入MAI-Transcribe-1。



▲ 电影《无间道》天台对峙名场面


一倍速播放测试环节，这款工具的表现算得上中规中矩：**整段天台对白的文字转录零误差**，但美中不足的是，输出文本完全没有标点断句，读起来更像一长串毫无停顿的文字流，少了原片里的对话节奏感。



▲ MAI-Transcribe-1正常速度语音转录结果

换句话说，它已经具备“听得准”的能力，但至少对于中文普通话来说，距离“直接可用”的字幕级体验，仍需要依赖后期人工整理来补足。

紧接着，当我们把播放速度调到二倍速，戏剧性的一幕出现了。



▲ MAI-Transcribe-1二倍速语音转录结果



原句里的“我也读过警校，你们这些卧底真有意思”，居然被“魔改”成了“我也读过剑桥，你们学会计真有意思”。

“警校”变“剑桥”，“卧底”成“会计”，语义发生整体偏移，甚至重构了场景语境。

最后，我们进一步加码测试，播放了电影《寒战》中节奏更快、情绪更激烈的经典争执片段。结果是，MAI-Transcribe-1几乎“当场宕机”，未能给出有效转录输出，稳定性出现明显下降。

▲ MAI-Transcribe-1寒战吵架名场面转录结果

一轮测试下来不难看出，MAI-Transcribe-1在常规语速下的转录准确性基本在线，但面对倍速播放、激烈争吵这类复杂语音场景，短板就暴露无遗了。尤其是在发音相近词汇的精准区分、语速加快后的语义连贯性判断，以及强情绪语音的识别适配等方面，都还有不小的优化空间。

语音生成实测：能模拟出说话时的口水声

根据微软官方博客信息，MAI-Voice-1是一款高效语音生成模型，可在单块GPU上于1秒内生成1分钟音频。该模型能够在长篇内容中保持说话人的身份。微软通过Foundry平台以每百万字符22美元的价格出售该技术。

鉴于目前只支持英语，实测环节中，我们选取了莎士比亚的经典诗歌Sonnet 18（十四行诗第18首）作为测试文本，输入至MAI-Voice-1，并分别生成“莎士比亚风格的英式口音版本”与“喜悦语气的美式口音版本”，以观察其在情绪建模与语音细节控制上的差异。

从结果来看，两种风格呈现出较为明显的分化。莎士比亚式的英音版本整体语速更缓，音频时长明显变长，音色趋于低沉，在句间与词间插入了更多停顿与换气声，形成类似舞台朗诵的节奏感。MAI-Voice-1对停顿、重音的调度，使得语音具备一定的情绪张力，接近人类在朗诵时的自然状态。

相比之下，喜悦语气的美音版本则更偏向轻快与流动，语速提升，语调上扬，整体听感更为明亮。在细节层面，可以感受到类似“口水声”等生理性噪音，这类细节一方面说明模型在尝试模拟更真实的发声环境，包括口腔湿润度、气流摩擦等微观特征。

图片生成：能体现空间纵深感

MAI-Image-2现已通过Foundry平台与其他两款模型一同面向大众市场。在Arena.ai的文本转图像排行榜上，它位列第三，仅次于谷歌的Nano Banana 2和OpenAI的GPT-Image 1.5。

微软将其定价为：文本输入每百万个token 5美元，图像输出每百万个token 33美元。该公司已开始在Copilot、Bing Image Creator和PowerPoint等产品中推广该模型。全球最大的广告公司之一WPP是首批大规模使用该模型的企业合作伙伴之一。



▲ MAI-Image-2官方生成效果（官方指令为“画面呈现出逼真的电影级风景：一条狭窄的山脊蜿蜒穿过深邃的峡谷，两侧耸立着垂直的岩壁，上面覆盖着郁郁葱葱的苔藓和柔软的植被。一条狭窄的土路沿着山脊蜿蜒而上，通往山顶，两个身材矮小的徒步者背对着镜头，凸显了峡谷的辽阔和孤寂。浓厚的雾气弥漫在峡谷中，营造出层次感和柔和的渐变效果，漫射的阴天光线柔和自然，没有生硬的阴影。湿润的苔藓、微妙的水汽和有机物的表面纹理极其细腻，色彩以深绿色和大地色调为主，呈现出柔和的自然色调。采用略微抬高的长焦镜头拍摄，压缩了景深，构图极具戏剧性，营造出一种广袤无垠和静谧孤寂之感，具有国家地理的风格，8K分辨率，浅雾，以及立体雾气效果。画面比例为1:1。”）

从官方样片中可以看出，苔藓、岩壁的纹理清晰，雾气与光影的层次过渡自然，色彩表现也柔和协调，没有传统文生图模型的“过饱和”或“扭曲”通病。**在长焦视角和景深处理上，模型能复刻真实摄影的空间感，具有纵深感。**

不过在实际测试中我们也发现，该模型对指令复杂度的兼容度有限。面对结构简单、元素单一的生成需求时表现稳定，但一旦输入包含多元素、多场景的复杂指令，系统便会直接提示无法生成。



▲ MAI-Image-2简单指令下生成效果（指令为“独自一人在浩瀚的宇宙中，周围只有偶尔漂浮而过的微小尘埃，强调人最大限度的孤独感，画面整体呈柔和的冷色调，有电影质感。”）



▲ MAI-Image-2复杂指令下生成效果（指令为“在浩瀚无垠、一览无余的外太空中央，瑞恩·高斯林身着一套精致的星空主题宇航服，在完全失重的状态下缓缓漂浮。他的身体轻轻旋转，四肢自然伸展，仿佛被宇宙温柔地环抱着。头盔的面罩反射着星光和远处闪烁的光芒，他的表情平静而又带着一丝沉思。周围空无一物——没有建筑物，没有干扰——只有偶尔漂浮的粒子和细小的宇宙尘埃，增强了太空的真实感和静谧的运动感。构图强调了人类极致的孤独感，将科幻美学与电影光影完美融合。整体风格明亮而超写实，画面流畅如胶片，光线柔和而冷峻。”）

结语：微软想要降低对OpenAI的依赖？

MAI-Transcribe-1、MAI-Voice-1和MAI-Image-2这三个模型现已可通过 Microsoft Foundry和MAI Playground获取。这是微软首次面向商业用户提供跨多种模态的自研模型，三款模型均由Mustafa Suleyman领导的微软人工智能超级智能团队自主研发。

微软同时仍保留了与OpenAI直至2032年的深度合约访问权限。Foundry平台通过同一API提供对OpenAI的GPT模型、Anthropic的Claude模型以及微软自家MAI系列模型的访问。

微软多年来一直是OpenAI技术的分销合作伙伴。如今，它正致力自建多种AI模型的竞争能力，同时托管OpenAI的模型、Anthropic的模型以及不断增长的开源替代方案库。

对于正在评估AI自研战略的高管们来说，问题不再是微软是否依赖OpenAI，而是微软能否以多快的速度用自有模型缩小性能差距，以及内部研发的经济效益是否足以支撑这项投资。

本文来源：[智东西](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

👍 201

★ 收藏

分享到:

写评论

请发表您的评论

😊 表情 图片

发表评论

2 条评论

