


摘要：

微软推出专用AI模型Microsoft-Decision-1，专为结构化决策任务设计。该模型可从预设选项选取最优解并赋予概率评分，支持路由分发、内容分类、任务优先级排序等场景。内部测试显示，其速度比GPT-6 Sol快35倍，输入成本仅0.042美元/百万tokens，输出免费。

微软推出专为结构化决策任务打造的新一代AI模型，在速度与成本上大幅领先现有大型语言模型。

周五，微软推出新一代快速决策AI模型**Microsoft-Decision-1**，该模型专为结构化决策任务设计。

微软称，Microsoft-Decision-1的P50已在内部多个场景完成测试，涵盖事故响应、质量控制和科学发现等领域。**运行速度比OpenAI的GPT-6 Sol快35倍，比Quyet-1.0-Large快4.5倍。**



首席执行官Satya Nadella在X平台发文表示，该模型“在结构化决策任务上表现出色，在延迟和质量方面均优于大语言模型及其他决策模型”，并已在微软内部用于事故响应、质量控制及科学研究等场景测试。


从定价来看，该模型输入端收费为每百万tokens 0.042美元，输出则免费，这一结构在成本层面对高频、重复性决策应用具有明显吸引力。

专注决策，填补大语言模型能力空白

与传统大语言模型侧重文本生成和复杂推理不同，Microsoft-Decision-1的设计目标更为聚焦。

Microsoft-Decision-1模型从预设选项中选取最优解，并为各备选答案赋予概率评分，从而帮助下游应用判断是继续执行、重新尝试、升级处理，还是交由人工审核。





(Microsoft-Decision-1 在准确率上排名第一，且是实测速度最快的模型)

微软表示，该模型覆盖近15万道题的36项基准测试中均取得最高精度。其功能定位包括路由分发、内容分类、任务优先级排序、结果验证及 workflow 控制，可无缝嵌入现有应用程序、AI 代理及工作流系统。

不过，上述性能数据来源于微软自身的基准测试，独立第三方验证目前尚未完成。

内部测试显示速度与成本优势显著


微软强调，每个决策都会增加延迟，尤其当一个步骤依赖于另一个步骤时。例如，如果连续做出 20 个决策，每个决策都增加 100 毫秒，那么整个工作流程就会增加 2 秒。

Microsoft-Decision-1 P50 的延迟比 GPT-6 Sol 快约 35 倍。



(单次请求生成决策的时间，数值越低越好，取JevBench测试集的中位数)

Xbox Research 团队使用其对逾1万条游戏反馈进行分类，结果显示与GPT-6 Sol质量相当，但速度超出14倍以上，成本则降低约200倍。微软Copilot团队亦发现该模型在AI响应评估任务上与GPT-5.6 Luna表现相近。



(Microsoft-Decision-1 分类相同的文本，成本仅为 GPT-6 Sol 的几十分之一)

在技术架构上，Microsoft-Decision-1 基于 Qwen3.5-9B 构建，经过以单次决策评分为核心的专项后训练。

微软还计划在未来将该模型迁移至其 MAI 系列模型及 OpenAI 模型等其他底座之上。

微软在公告中强调，该模型旨在"以安全、可信的环境将决策智能融入现有应用"，将其定位为AI代理 workflow编排的基础组件之一。

鲁棒性与安全性获重点强调

微软在设计中着重考量了模型的稳定性。

测试数据显示，在对同一请求进行八种形式的扰动处理后，Microsoft-Decision-1平均仅有1.3%的概率发生决策翻转，且在选项描述改写或选项顺序颠倒等场景下，翻转率为零。

在安全性方面，微软对该模型进行了涵盖11项基准、共5250条请求的测试，内容涉及有害内容识别、越狱攻击及提示词注入等，称模型在成功拒绝有害请求的同时保持了较高的正常使用效用。

目前，Microsoft-Decision-1已通过微软旗下AI开发平台Microsoft Foundry向开发者开放，OpenRouter的接入支持亦在计划之中。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

214 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论