

摘要：

阿里巴巴发布千问3.8-Max，参数规模达2.4万亿，是千问家族迄今最强模型，也是首个开源Max级权重的版本（下周发布）。API定价输入2.0美元/百万tokens、输出6.0美元/百万tokens。基准测试显示其编程与通用智能体能力与Anthropic Fable5相当，部分指标超越，并在芯片设计、量化研究、电商模拟等长程任务中展现出显著的自主执行能力。

阿里巴巴旗下千问（Qwen）团队于8月3日正式发布千问3.8-Max，总参数量2.4万亿，激活参数95B，是千问家族迄今规模最大、能力最强的模型。这也是千问首次将Max级别模型开源——权重将于下周在开源社区Hugging Face和ModelScope发布。

定价方面，千问3.8-Max通过千问AI平台（阿里云）提供API调用：**输入2.0美元/百万tokens，输出6.0美元/百万tokens，隐式缓存0.25美元/百万tokens。**

基准测试显示，**千问3.8-Max在编程智能体和通用智能体多项指标上与Anthropic Fable5表现相当，部分指标超越后者。**例如，PaperBench得分93.0，高于Fable5的88.8；CoWorkBench得分74.8，与Fable5的75.9接近；WideSearch得分81.9，与Fable5的81.2持平。



显示翻译

Meet Qwen3.8-Max — our most capable model to date.

Next week, the open weights of Qwen3.8-Max will be released, and Qwen3.8-27B is also going open-weights to meet you all! 🎉

Qwen3.8-Max, a new bar for coding and cowork at 2.4T parameters:

- Autonomous coding: 10+ days of self-evolving development, from empty folder to production without hand-holding, complete project trace in the GitHub: github.com/qwen-code-dev-...
- Real work, real results: Production-quality deliverables across hundreds of professions.
- Long-horizon mastery: System-level autonomous planning with closed-loop adaptive learning, driving 500+ turns of chip design optimization and 365 days of e-commerce strategy.
- Native multimodal intelligence: Vision isn't just input — it's a continuous feedback loop for planning, execution, and self-correction.

💰 Pricing:

Input: \$2.0 / M tokens

Output: \$6.0 / M tokens

Implicit Caching: \$0.25 / M tokens

性能：与 Fable 5 相当，部分超越


根据千问团队发布的完整基准测试数据，Qwen3.8-Max 在多个核心指标上与 Anthropic Claude Fable 5 持平或超出：

- **PaperBench**（论文能力）：Qwen3.8-Max 得分 **93.0**，超过 Fable 5 的 88.8 和 GPT-5.6 Sol 的 90.5
- **IFBench**：Qwen3.8-Max **82.8**，Fable 5 为 63.5，GPT-5.6 Sol 为 72.7
- **HealthBench**：Qwen3.8-Max **60.2**，超过 GPT-5.6 Sol 的 55.3
- **CoWorkBench**（通用协作）：Qwen3.8-Max **74.8**，Fable 5 为 75.9，差距极小
- **JobBench**（AI工作能力）：Qwen3.8-Max **53.4**，接近 Fable 5 的 57.4

多模态方面同样表现突出：

- **OSWorld-Verified**：Qwen3.8-Max **86.1**，超过 Fable 5 的 85.0
- **AndroidWorld**：85.3，Fable 5 为 88.8
- **MLVU**（长视频）：**90.8**，Fable 5 无数据

值得注意的是，Fable 5 的部分结果可能包含回退机制，千问团队在注释中对此作了说明。



编程能力：从空文件夹到生产级交付

千问团队用三个真实案例测试了千问3.8-Max的自主编程能力，全程无人工介入。

案例一：十天级自动编程。 模型从零创建oh-my-cli项目，自主运行约16天，累计完成265次 commits、127个PR、151个issues。它将用户反馈、社区实践与自测结果统一纳入工程循环，实现需求自动领取、代码生成、测试验证的完整闭环。



案例二：复现并超越论文。 模型独立工作约125小时，写下约7,600行代码，执行超过1,100步操作，跑了33轮GPU训练，完整复现了论文《Unified Data Selection for LLM Reasoning》的六项主要结论。随后进入“自我进化”阶段，提出并测试18种改进方案，最终在竞赛级数学基准AIME24上比论文原方法再提升2.7分。



案例三：24小时击败87%人类队伍。 模型参加WWW2025多模态对话意图识别挑战赛，在526支人类队伍中，经45次提交迭代，准确率从0.60升至0.853，击败458支队伍。




办公与长程任务：数百职业场景的生产级验证

千问团队在数百种高价值职业场景中测试了千问3.8-Max的实际交付能力。

- **企业合规律师**：单次通读数百份文档，标出1,284条相关条款，一小时内完成——同等工作通常需要法务团队约一周。
- **UI/UX设计师**：生成包含8个页面的高保真可交互原型，全程未经人工返修。
- **结构工程师**：仅凭一份图纸，在浏览器中还原30层写字楼的抗震结构模型，传统流程需一周以上。
- **量化研究**：从一句任务描述出发，调度约330个子智能体，完成约6,000次回测，将原本需要数周的量化研究压缩为一次对话内完成。

在E-Commerce Bench（365天电商经营模拟基准）中，千问3.8-Max以¥416,252（4.16倍回报）胜出，超过第二名GLM 5.2达38%，较上一代千问3.7-Max提升152%。



芯片设计：500轮交互，面积缩减81%

千问3.8-Max在芯片设计优化任务中展示了长程自主规划能力。

目标是优化一个G CD/RSA密码硬件加速器的逻辑门数量。模型在无参考设计、无人工干预的条件下，历经约500轮交互、71次评估，跨越13个关键里程碑，将初始设计从8,298门优化至678门，在所有参评模型中表现最优。

物理实现层面，芯片面积从106×106 μm^2 收缩至46×46 μm^2 ，布线长度从33,369 μm 降至4,187 μm ，并实现500 MHz频率下的时序闭合，芯片面积整体缩减81%。



多模态能力：视觉贯穿执行全流程

千问3.8-Max的视觉能力不止于“看懂图片”，而是作为持续反馈回路贯穿任务执行。

模型在执行过程中会持续观察中间产物——检查页面布局、物体方向、动画效果——发现问题后自主定位偏差并修正。千问团队将这一能力定义为“原生视觉反馈回路”。

基准测试方面，千问3.8-Max在OSWorld-Verified得分86.1，超过Fable5的85.0；AndroidWorld得分85.3，接近Fable5的88.8；ParametricCAD Bench得分91.5，超过Fable5的87.5。

为便于开发者接入，千问团队同步推出千问-MM-Plugins，为不同智能体框架提供图像与视频处理、多模态记忆、视觉工具调用等扩展支持。



开放接入：支持Claude Code、Codex等主流框架

千问3.8-Max现已通过千问AI平台提供API服务，支持OpenAI兼容协议和Anthropic兼容协议，可直接与Claude Code、Codex、Qoder CLI、千问 Code、OpenClaw等主流开发工具集成。

API支持reasoning_effort参数调节推理深度：xhigh（默认，适合复杂任务）、medium（平衡准确性与速度）、low（优化速度与成本）。

模型权重将于下周在Hugging Face和ModelScope开源，届时千问3.8-27B也将同步开源。

风险提示及免责条款



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

433 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

9 条评论

- 骑士风范7

2小时前 中国浙江省

吹牛大王

1 回复
- 街道办主任

4小时前 中国

这更新频率，太卷了

0 回复
- 零一

5小时前 中国重庆

每次都是，结果实测一坨

1 回复
- FisH·Man

5小时前 中国浙江省

吹nb谁不会啊

1 回复
- MobileUser6990

5小时前 中国四川省

回复 FisH·Man:

你搞一个，然后把把这些榜单都刷到第一去？

2 回复
- FisH·Man

40分钟前 中国浙江省

回复 MobileUser6990:

会考试跟会做事是两码事😂乐子

0 回复



MobileUser5706
6小时前 中国广东省

之前不是被指控盗窃蒸馏吗?到底怎么回事的?

👍 1 ↩ 回复



MobileUser6990 5小时前 中国四川省

回复 **MobileUser5706**:

第一天关注ai吗? 那种所谓的“蒸馏”行业内通用做法

👍 2 ↩ 回复



阿猫 4小时前 中国广东省

回复 **MobileUser5706**:

蒸馏有问题吗? 你出生还要回到原始社会进化一遍吗?

👍 0 ↩ 回复

