

摘要：

GPT-6 Astra在独立评测中与Claude Fable 5.1并列第一。二者性能不分伯仲，定价策略却走向两极：Astra将API单价定为前代的2.5倍，Fable 5.1却把缓存命中环节的价格较前代下调75%。分析指出，OpenAI的长远意图是从“按量收费”转向“按任务效果收费”的新商业模式。

9月3日，OpenAI发布GPT-6 Astra。据Artificial Analysis最新综合榜单，在独立评测中，Astra与Anthropic的Claude Fable 5.1并列第一，重新追平技术叙事。

Astra与Fable 5.1性能不分伯仲，定价策略却走向两极。

OpenAI没有延续此前旗舰模型的降价路线，而是把Astra的API单价定为前代GPT-5.6 Sol的2.5倍，并开始探索“按任务效果收费”——在性能仅追平而非碾压对手的节点，这更像一场对市场付费底线的大胆试探。

官方称在部分评测中Astra能用更少输出token取得更好结果，估算每项任务的API成本反而更低。

Anthropic则选择相反方向：**Fable 5.1未调整基础单价，但把缓存读取价格降至0.25美元/百万token、较Fable 5下调75%**，预计使典型工作负载成本下降约25%、高度Agent化任务的成本最高下降45%。

在两家公司双双秘密提交IPO、冲击万亿美元估值的关口，这一分歧直指大模型商业化的核心命题：企业客户为“额外智能”付费的意愿正逼近上限，“更贵但更强”的溢价叙事能否成立，将决定谁能把模型能力真正兑现为持续收入。

追平之后，定价逆势翻倍

OpenAI对Astra的定价没有延续前几代旗舰持续降价的思路，而是对最高端能力重新建立价格溢价。

其长远意图不止于提高token单价——从按量收费转向按任务完成效果收费，商业模式有望演变为基于项目复杂度、耗时或产出价值的定价体系。

支撑这一定价的是空前规模的投入。Astra在得克萨斯州Stargate基地使用超10万块GPU完成训练，远超GPT-5.6 Sol；

Astra ARC-AGI-3通用推理测试达到99.9%（前代为7.8%），成为此次发布中最醒目的单项能力变化。高企的硬件成本与能耗，直接推高了后续的API定价。

Anthropic反向降价，卡住性价比

Fable 5.1的输入和输出价格与前代保持不变，分别为每百万token 10美元和50美元；调整集中于“缓存命中”环节，即模型重新读取此前已处理内容时的计费，降幅达75%，降至每百万token 0.25美元。

Anthropic表示，对于典型工作负载，Fable 5.1的预期使用成本将比Fable 5低约25%；对于高度智能化的任务，节省幅度最高可达45%。

这一“以价换量”的策略，正对应企业客户为“额外智能”付费意愿接近上限的判断：当头部模型达到一定能力门槛后，企业更关心性价比，而非单纯为更高的Benchmark分数支付溢价。

估值与付费意愿的双重考验

两家公司如今都已秘密提交IPO申请、冲击万亿美元估值，Anthropic最新一轮融资后估值已达9650亿美元，反超OpenAI的8520亿美元。

在资本市场的定价逻辑下，胜负手不再是谁多拿几个Benchmark第一，而是谁能把昂贵的模型能力更稳定地转化为持续收入。

OpenAI用2.5倍提价测试“按效果付费”的接受度，Anthropic则用降价换取企业工作流的渗透率——两条路线谁先跑通，谁就更可能占据下一阶段竞争的制高点。

后续焦点将落在Astra“按效果收费”模式的实际落地进度，以及企业客户在“更贵但可能更有效”与“更便宜且够用”之间的真实选择上。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

153 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论