

摘要：

戴尔科技首席运营官Jeff Clarke表示，代理AI通过承担更多工作任务，持续推高计算和存储需求，使本轮AI基础设施周期区别于传统硬件更新周期。到2030年，数据中心算力预计新增200吉瓦，推理Token生成量增长87倍，基础设施需求有望持续扩张。

代理AI正在改变传统硬件周期的底层逻辑，也可能让基础设施供应紧张从短期波动演变为持续数年的结构性约束。

戴尔科技首席运营官Jeff Clarke在近期与摩根士丹利的会谈中表示，**代理AI与过去的硬件周期存在明显不同。若相关AI工作负载持续增长，关键零部件的供应短缺可能持续五年以上，其中内存和HDD是他目前最担忧的环节。**相比过去通常持续数个季度的硬件供应紧张，这一轮需求增长可能带来更长期的供需缺口。

摩根士丹利在会谈后重新评估当前AI基础设施周期。分析师指出，过去40年间的八次硬件繁荣与萧条周期，更多围绕设备更新和资本开支波动展开，而此次周期的关键变量在于AI工作负载能否持续扩大。换言之，**戴尔高管所强调的并非一次普通的硬件补库周期，而是代理AI需求增长可能带来的基础设施长期扩容。**

代理AI重塑基础设施需求逻辑

报告指出，Clarke认为，此轮AI周期与过去数十年的硬件繁荣与萧条存在根本区别。过去八次硬件周期——涵盖服务器、存储、PC等品类——主要由设备渗透率变化和更新周期推动，需求随着更新节奏变化而起落，但硬件市场本身规模并未发生实质性扩张。

以疫情期间的PC需求为例，人机比例曾短暂提升，但随着社会重启恢复正常，PC需求也随之回落，疫情前后的市场总规模并没有发生本质变化。**代理AI的逻辑则不同。Clarke认为，代理AI正在将认知产出与人力投入解耦，企业无需增加人手，就可以完成更多工作，由此带来10倍乃至100倍的生产力提升。**

在这一过程中，AI不再只是辅助人完成任务，而是本身成为持续消耗计算资源的“生产力工具”。生产力提升将推动更多企业，无论规模大小，都开始进行AI转型，并由此持续扩大基础设施TAM。

戴尔预计，到2030年，数据中心算力将新增200吉瓦，ZettaFLOPS算力将增长5倍至830，推理token的增长则将呈指数级。代理AI完成每单位工作所需的token数量远高于基础聊天机器人，Clarke预计，到2030年推理token生成量将增长87倍。

云端与本地部署并非零和博弈

市场对这一轮AI基础设施周期的一个核心疑问是：快速增长的token需求，最终是否会主要流向云计算平台，而不是本地基础设施？

Clarke对此的判断是，**代理AI工作负载将呈现混合部署形态。企业会根据安全性与成本效益，在公有云与本地环境之间持续调整推理工作负载的运行位置。**

Clarke以戴尔自身为例：公司会将内容相关工作负载部署在公有云，但不会将专有源代码或遥测数据移出自有设施。这意味着，AI工作负载并不存在单一的部署路径，本地基础设施仍将承接一



部分持续增长的计算需求。

在这一框架下，token消耗的指数级增长，并不意味着云端与本地基础设施之间必然形成此消彼长的关系。**Clarke认为，开源权重模型的普及还将进一步推动本地基础设施投资，因为企业可以在本地环境中针对成本对模型输出进行优化。**

服务器出货量下滑，不改长期需求增长逻辑

当前传统服务器出货量同比仍在下降，这与推理token的爆发式增长看似存在矛盾。Clarke的解释是，服务器性能密度的大幅提升正在压低设备出货数量。

戴尔第17/18代服务器可以替代多达13台第14代传统服务器，**因此在短期内，即使服务器出货量下降，单台设备的价值和承载能力仍在提升。**

随着数据中心逐步完成以加速计算为核心的架构重构，以及代理AI普及进一步拉动CPU服务器需求，服务器出货量最终仍有望重新增长。Clarke甚至表示，如果推理 token 在五年内真正实现87倍增长，传统服务器出货量也可能出现指数级变化。

存储同样将受到代理AI的持续拉动。代理AI执行每一项操作，包括记忆保留、工件生成等，都会产生持续的数据存储需求；随着KV Cache大规模应用，存储容量需求也将进一步增长。

供应短缺或成为五年以上的结构性约束

相比宏观经济、地缘政治冲突、数据中心过度建设以及电力短缺，Clarke将供应问题列为当前最大的担忧，并用“我们身处梦幻之地（We're in neverland）”形容当前的供应环境。

摩根士丹利指出，历史上的大宗商品供应周期通常持续2至4个季度，主要受到硬件更新周期的繁荣与萧条以及供应侧决策影响。**但Clarke认为，如果认可吉瓦和推理 token的增长逻辑，那么内存、HDD等关键零部件就不再只是处于一个普通的短期周期之中。**

因此，戴尔目前正以关键零部件可能出现多年持续短缺为前提进行运营，尤其关注内存和HDD。换言之，此轮供应紧张的核心风险并不是短期供给不足，而是AI需求持续扩张后，供应端可能需要多年才能跟上。

Clarke同时表示，戴尔在供应管理方面优于同业，这一优势正在转化为服务器、存储和PC等多个细分市场的份额增益。

利润率扩张背后是供需结构变化

关键零部件持续紧张，也正在改变基础设施行业的定价环境。

摩根士丹利此前曾将服务器和存储业务毛利率的扩张部分归因于“利润堆叠”，即在内存等零部件成本上升的同时，厂商进一步叠加利润空间。Clarke则给出了不同解释。

他承认，同类产品的服务器和存储利润率确实在扩张，但认为背后存在两个结构性因素：**首先，在零部件供应有限的情况下，企业会优先将稀缺资源分配给利润率最高的产品；其次，基础设施市场规模持续扩大后，企业争夺增量客户的压力下降，无需通过压低价格换取新客户。**

因此，利润率的提升并不完全是短期供需错配带来的机会性收益，也反映了基础设施需求持续扩张后，行业定价基准发生变化。

如果代理AI带来的工作负载增长能够持续兑现，AI基础设施周期的核心变量就将从“设备更新”转向“新增需求”。这意味着，算力、服务器和存储的需求扩张可能持续更久，而内存、HDD等关键组件的供给约束也可能从短期周期性波动转变为多年期的结构性问题。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

56 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论