

摘要：

据The Information，OpenAI和Anthropic正讨论一项具有法律约束力的协议，相互获得对方商业化AI模型的API访问权限，并通过一系列测试寻找模型可能存在的漏洞或潜在危险。尚未发布的模型不在协议范围内。双方同时保证，在测试过程中不会保留对方的数据。

OpenAI和Anthropic今年早些时候曾与各自律师讨论一项具有法律约束力的协议，拟相互对商业化AI模型进行压力测试，以寻找模型中的漏洞和潜在风险。

据The Information援引知情人士透露，根据拟议中的协议，**OpenAI和Anthropic将获得对方商业化AI模型的API访问权限，并通过一系列测试寻找模型可能存在的漏洞或潜在危险。尚未发布的模型则不在协议范围内。**

双方同时保证，在测试过程中不会保留对方的数据。

目前尚不清楚OpenAI和Anthropic最终是否正式敲定了这项协议。

相关讨论发生之际，AI模型安全和测试机制受到越来越多关注。The Information报道称，OpenAI近期正重新考虑一系列AI安全策略。

AI安全测试从内部评估走向同行测试

如果相关安排最终落地，其核心机制将是让两家AI公司直接利用对方商业化模型的API开展测试，从外部寻找模型可能存在的安全漏洞和隐藏风险。

相比单一公司内部进行模型安全评估，这种相互测试机制意味着模型开发商之间可以利用彼此的测试能力，对已经投入商业应用的模型进行交叉检验。

2025年夏天两家公司过去曾进行过类似的模型测试，并公布相关结果：Anthropic的模型更倾向于通过否认违反规则来欺骗测试人员；而OpenAI的模型则更有可能协助解答可能导致现实世界危害的咨询。

此次讨论的拟议协议则试图以更正式、具有法律约束力的方式建立双方之间的测试安排。

对于正在快速推进模型能力和商业化应用的AI行业而言，如何在模型能力提升的同时加强安全测试，正成为OpenAI、Anthropic等AI公司需要面对的重要问题。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免



写评论

请发表您的评论

 表情

 图片

发表评论