摘要：
微软计划明年以吉瓦级规模部署新一代Maia 300芯片，预计其每兆瓦token产出较主流GPU系统高出40%。微软将优先用自研芯片支撑内部AI服务，而非向外出租算力，借此降低对英伟达GPU的依赖与推理成本，推动AI业务利润率改善。

微软正加码自研AI芯片，计划以吉瓦级规模部署Maia系列芯片，逐步降低对英伟达GPU的依赖，并通过提升推理效率控制AI基础设施成本。

10月12日，据彭博报道，**微软周一宣布，新一代Maia 300芯片将于明年开始在数据中心部署，专为AI推理任务设计。微软预计，Maia 300每兆瓦可处理的token数量将比主流GPU系统高出40%，意味着在相同能耗下能够承载更多AI工作负载。**

与已向云端客户开放自研芯片算力的谷歌和亚马逊不同，微软目前无意将Maia芯片的算力直接出租给外部客户。这一选择反映出微软的优先级：先用自研芯片满足自身庞大的AI服务需求，再将硬件效率优势转化为业务竞争力。

吉瓦级部署，能效优势是核心逻辑

微软加码自研芯片，本质上是为了提高AI推理效率、降低运营成本。

推理是指利用训练完成的AI模型执行实际任务，例如总结会议记录、回答研究问题等，也是AI应用运行过程中重要的算力需求来源。微软表示，Maia系列针对自有数据中心的推理工作负载进行专门设计，能够更高效地运行相关任务，并减少对英伟达GPU的采购需求。后者目前仍是微软推理业务的主要算力来源。

微软数据中心硬件业务负责人Rani Borkar表示：**“我们相信，我们为这些工作负载打造了最佳产品。我们将从明年起以吉瓦级规模部署Maia，以实际行动支撑这一信心。”**

前代产品已在多地落地，新款明年接力

微软的自研芯片战略早已启动。今年年初，公司开始在数据中心安装上一代产品Maia 200，目前该芯片已用于驱动Copilot等AI软件及其他任务。

Borkar介绍，Maia 200能够支持OpenAI模型、微软自研AI模型以及多个开源模型系列，部署范围覆盖美国、欧洲和澳大利亚的数据中心，为Microsoft Teams、Copilot等产品提供AI能力支撑。

新一代Maia 300预计将于明年启动部署。微软希望借助其能效优势，在持续扩张的AI业务中进一步优化算力配置，降低推理成本。

自研芯片赛道，微软追赶谷歌和亚马逊

在云计算巨头纷纷开发自研AI芯片的背景下，微软的布局相对滞后。谷歌和亚马逊起步更早，已在自研芯片领域建立先发优势，并将相关算力开放给云端客户使用。

微软则选择了不同的商业路径。Borkar表示：**“我们自身的AI服务业务已经足够庞大，我们希望优先服务自己。”**

这意味着，微软现阶段更倾向于将Maia芯片用于内部AI业务，而非通过出租算力直接创造收入。对投资者而言，Maia的商业价值将更多取决于其能否提高AI服务的运行效率、降低推理成本，并最终改善相关业务的利润率，而不是芯片租赁业务能够带来多少直接收入。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

235 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论