摘要：

英伟达被曝开发基于Groq片上SRAM架构的新型推理芯片，投资者担忧SRAM的使用会减少对包括HBM在内的主内存的需求。但机构分析KIS直指市场误读：SRAM并非HBM/DRAM替代品，而是面向超低延迟场景的差异化选择，内存层级细分将最终扩大整个行业总量。

过去两天，韩国基准指数KOSPI跌幅均超过10%，创下2008年以来最大两日跌幅。

市场普遍认为，特朗普对伊朗动武引发的全球资金避险情绪，令包括韩国在内的亚洲股市承受了惨烈的跌幅。然而，有最新分析指出，英伟达为韩国惨跌也做了“贡献”。

一则关于英伟达的技术传闻对韩国内存股造成了精准打击。据韩国Citrini7分析师Jukan引述独立分析机构KIS的评论，有报道称**英伟达正在开发一种利用Groq片上SRAM架构的新型推理芯片，并计划在3月的GTC大会上公布。**

这一消息导致韩国内存股走弱，**投资者担忧SRAM的使用会减少对包括HBM在内的主内存的需求。**

不过韩国股市今日出现了强劲反弹。最新行情显示，韩国KOSPI指数今日涨幅扩大至11%，科技巨头三星电子大涨13%，SK海力士飙升15%。

SRAM推理芯片冲击HBM、DRAM？可能误判了

然而，市场可能误判了SRAM推理芯片的冲击。

KIS明确指出：“声称‘低成本’SRAM推理芯片的出现将减少HBM等现有主内存使用的观点，反映了对内存的糟糕理解。”

从物理特性来看，**SRAM的单元面积更大，密度低于DRAM，导致其每比特成本显著更高。**对于相同容量，SRAM通常需要DRAM 5到10倍的裸片面积。因此，SRAM历史上一直用于需要极低

延迟的缓存或片上缓冲应用，而非作为存储大量数据的主内存。

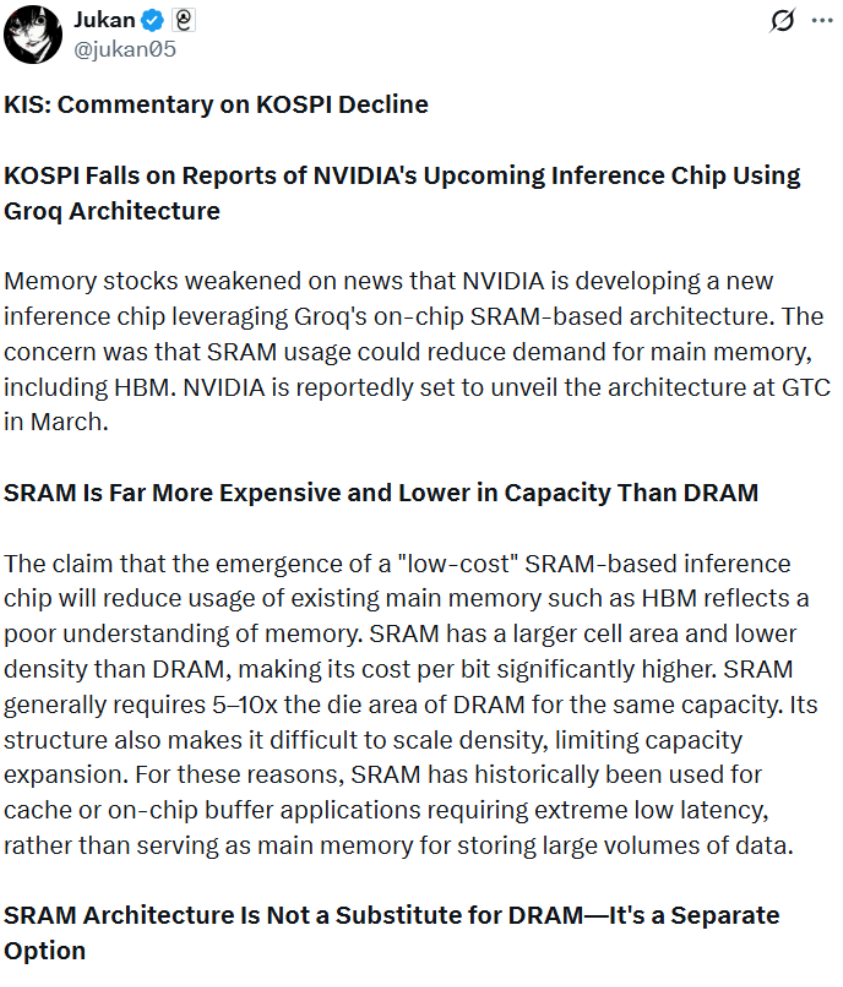

Jukan
@jukan05

KIS: Commentary on KOSPI Decline

KOSPI Falls on Reports of NVIDIA's Upcoming Inference Chip Using Groq Architecture

Memory stocks weakened on news that NVIDIA is developing a new inference chip leveraging Groq's on-chip SRAM-based architecture. The concern was that SRAM usage could reduce demand for main memory, including HBM. NVIDIA is reportedly set to unveil the architecture at GTC in March.

SRAM Is Far More Expensive and Lower in Capacity Than DRAM

The claim that the emergence of a "low-cost" SRAM-based inference chip will reduce usage of existing main memory such as HBM reflects a poor understanding of memory. SRAM has a larger cell area and lower density than DRAM, making its cost per bit significantly higher. SRAM generally requires 5–10x the die area of DRAM for the same capacity. Its structure also makes it difficult to scale density, limiting capacity expansion. For these reasons, SRAM has historically been used for cache or on-chip buffer applications requiring extreme low latency, rather than serving as main memory for storing large volumes of data.

SRAM Architecture Is Not a Substitute for DRAM—It's a Separate Option

SRAM或将推动内存层级多元化

SRAM架构并非DRAM的替代品，而是一个独立的选项。与DRAM相比，以SRAM为中心的架构具有访问延迟低得多和数据移动最小化的优势。

KIS分析称，英伟达计划利用Groq架构，是为了针对GPU难以处理的特定推理工作负载进行优化。采用SRAM架构应被理解为针对需要超低延迟的特定数据中心工作负载，以及需要实时响应的物理AI边缘应用（如机器人和自动驾驶）的独特选择。事实上，OpenAI已经在其数据中心部署了Cerebras的SRAM芯片，基于这些芯片构建的推理服务收取比标准GPU推理服务更高的API费用。

随着AI产业的进步，基于Groq的SRAM架构的普及将进一步细分AI基础设施内的内存层级。HBM和DRAM将继续作为大规模模型训练和通用推理服务器的主内存。KIS总结道：**“涵盖SRAM、HBM和DRAM的内存层级将变得越来越具有多层次性，最终推动整个内存行业总潜在市场（TAM）的扩张。”**

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时0元领
VIP会员·7天畅读卡｜大师课·入门串讲
* 同一用户免费领取一次
扫码
免费领取
限免

427 收藏 分享到:

写评论

请发表您的评论

表情　图片　发布评论

3 条评论

MobileUser3076
8小时前　中国安徽省

怎么冲击？开完发布会直接年产几百万片？如果厂子都建好了，消息早出来了

0　回复

见闻用户
9小时前　中国上海

去年deepseek说算力会减少，今年又这么说，做空做多全靠机构的一张嘴😐

0　回复

零一
9小时前　中国重庆

“英伟达已将台积电部分H200芯片产能重新分配，转向Vera Rubin硬件”，印证了推理端 SRAM 正在部分取代/挤压 HBM 需求

0　回复