

摘要：

这意味着客户未来可能需要部署更多GPU才能完成同等算力任务，微软、Meta、谷歌等科技巨头的数据中心建设成本或将进一步攀升。

AI基础设施热潮正在逼近供应链极限。

据The Information报道，英伟达正评估一项颇为激进的调整方案——为下一代AI GPU Rubin Ultra推出低于原计划HBM的版本，以缓解高端高带宽内存（HBM）供应不足带来的量产压力。

这意味着，即便是掌握GPU市场主导权的英伟达，也不得不在产品规格与供应能力之间寻求平衡。

这一变化不仅反映出HBM供应已成为AI产业链最关键的瓶颈之一，也意味着AI服务器成本或进一步攀升，数据中心建设压力仍将持续向下游传导。

周四英伟达股价收跌0.1%，SK海力士股价收跌4.97%。



英伟达

NASDAQ: NVDA


218.99 USD ↓ 0.10% -0.23 今天

+ 关注

收盘时间: 8月6日 GMT-4下午5:56 • 免责声明

盘后价 218.74 -0.25 (0.11%)

1天 | 5天 | 1个月 | 6个月 | YTD | 1年 | 5年 | 最大



SK海力士

NASDAQ: SKHY


143.53 USD ↓ 4.97% -7.50 今天

+ 关注

收盘时间: 8月6日 GMT-4下午5:56 • 免责声明

盘后价 144.36 +0.83 (0.58%)

1天 | 5天 | 1个月 | 6个月 | YTD | 1年 | 5年 | 最大



HBM供应紧张，英伟达测试多个“降显存”版本

知情人士透露，过去数周，英伟达已经测试至少三个不同版本的Rubin Ultra GPU，其中部分版本采用了低于最初规划的显存容量。

英伟达考虑推出低显存版本，一个重要原因在于未来可能无法获得足够数量的高端HBM芯片，以支撑原始设计的大规模量产。

Rubin Ultra是英伟达下一代AI计算平台的重要组成部分，定位高于即将量产的Rubin系列，被视为未来训练超大规模AI模型的重要硬件平台。按照原有规划，其将搭载容量更高、带宽更大的HBM，以进一步提升模型训练和推理性能。

不过，在HBM供应持续偏紧的背景下，英伟达正在重新评估产品配置，希望通过调整显存规格保证产品按计划上市，而不是继续等待供应链扩产。

显存减少意味着需要部署更多GPU

对于AI训练而言，HBM不仅决定GPU的数据吞吐能力，更直接影响能够容纳的大模型规模。

如果Rubin Ultra最终采用较低显存配置，在运行大语言模型等大型AI工作负载时，客户可能需要部署更多GPU，才能完成原本由较少芯片即可完成的计算任务。

虽然英伟达仍可通过提高GPU计算能力、优化互连带宽等方式部分弥补性能损失，但总体来看，系统部署成本和集群复杂度仍可能有所提高。

对于微软、Meta、亚马逊、谷歌等持续扩大AI资本开支的大型云厂商而言，这意味着未来数据中心建设成本可能进一步上升。

AI热潮暴露产业链最大瓶颈

HBM已经成为当前AI产业链最紧缺的核心零部件之一。

近年来，大模型训练需求快速增长，使GPU出货量持续攀升，而GPU所需的HBM主要由三星电子、SK海力士和美光等少数厂商供应。由于HBM制造工艺复杂、良率要求高、扩产周期长，供应增长速度始终难以追赶AI需求。

业内普遍预计，未来数年HBM仍将维持供不应求状态，这也是AI服务器价格居高不下的重要原因之一。

此次英伟达主动考虑降低Rubin Ultra显存配置，也反映出即便拥有产业链最强议价能力，其产品规划依然受到HBM供应约束。

成本压力向整个科技行业蔓延

HBM价格上涨带来的影响已经不仅局限于AI服务器。

随着GPU、HBM等关键元器件持续紧缺，整个科技行业的硬件成本均受到推升。企业采购AI基础设施的预算不断增加，越来越多公司不得不提高资本支出，以满足生成式AI部署需求。

与此同时，上游芯片成本上涨也开始向消费电子领域传导。包括苹果在内的部分硬件厂商，已经通过提高终端产品售价等方式消化供应链成本压力。



市场人士认为，只要AI算力需求继续高速增长，而HBM新增产能释放速度有限，围绕高端存储资源的竞争仍将持续，HBM供应能力也将继续成为决定AI产业扩张速度的关键因素。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

505 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论