

摘要：

谷歌、OpenAI与Anthropic正推动成立前沿AI标准局SAFA，计划于今年底或2027年初落地，旨在统一前沿模型的安全、测试与审计标准。在美国政府AI监管推进受阻的背景下，行业自律机制加速成形，但SAFA的适用范围、测试职能及与现有机构的分工仍存争议。

全球前沿AI治理格局正迎来新的变量。行业巨头正试图以自律组织的形式，主导前沿模型安全标准的制定。

9月24日，据The Information报道援引知情人士透露，谷歌、OpenAI与Anthropic正推动成立一个名为“前沿AI标准局”(Standards Authority for Frontier AI, SAFA)的行业自律组织，计划于今年底或2027年初落地，旨在为开发最先进AI模型的公司制定统一的安全与安保标准。

三家公司此前曾寻求与美国政府共同建立AI监管框架，但相关努力陷入停滞。三家公司近期已就AI安全标准展开合作，OpenAI也公开表示，希望与其他前沿AI实验室推进统一标准。

如果最终落地，SAFA将把部分原本由政府监管机构承担的标准制定、测试和审计职能交由行业主导。与此同时，这一模式也意味着，谁来定义“前沿模型”、哪些企业需要接受评估，以及安全标准如何执行，都可能成为行业竞争的新变量。

三大AI巨头筹建自律组织，拟统一前沿模型标准

据报道，知情人士透露，SAFA的筹备工作已经进入领导架构和职能设计阶段。工作组正在讨论首席执行官、主席和科学顾问等职位的人选，其中包括曾任特朗普政府AI政策顾问的Sriram Krishnan、拜登政府时期曾任白宫科技政策办公室主任的Arati Prabhakar，以及前美国国务卿康多莉扎·赖斯、企业家兼风险投资人David Friedberg等。

科学顾问候选人则包括AI研究非营利机构METR创始人兼CEO Beth Barnes，以及OpenAI基金会董事会成员、商务部AI标准与创新中心顾问Paul Christiano。不过，知情人士称，名单中的部分人士尚未被正式接洽，目前也无法确定所有候选人是否仍在积极考虑范围内。

从定位来看，SAFA并非传统意义上的政府监管机构，而更接近由头部AI公司推动的行业标准组织。此前谷歌、OpenAI、Anthropic和微软已共同成立Frontier Model Forum，目标同样涉及前沿AI安全与行业标准。此次SAFA的设想，则是建立一个更具执行力、能够直接参与测试和评估的行业机制。

监管政策停滞，自律方案加速推进

SAFA筹备进程加快，背后是美国政府层面的AI政策迟迟未能落地。据报道援引知情人士透露，白宫此前曾考虑建立公私合作的AI监管机构，甚至起草过相关行政令草案，但这一进程因遭到Meta首席执行官马克·扎克伯格和英伟达首席执行官黄仁勋公开反对而陷入停滞，两人均曾对新增AI监管措施表达质疑。

随后，白宫向谷歌、Anthropic和OpenAI明确表示，在政府进一步介入之前，三家公司应先在行业内部就相关标准达成共识。随着国会在11月中期选举前的政治博弈中推进缓慢，白宫也没有积极推动新的AI监管政策，行业自律因此被推到更突出的位置。

近期发生的安全事件进一步强化了这一紧迫性。据报道，在一次安全测试中，一组OpenAI智能代理曾入侵开源代码库Hugging Face，引发外界对AI智能体自主行动能力及安全风险的关注。Anthropic首席执行官Dario Amodei本月早些时候也撰文呼吁对前沿模型的开发速度进行适当管控。

职能聚焦测试、披露与审计标准

按照目前的规划，SAFA将主要围绕前沿AI模型的安全标准开展工作，包括为模型部署前的第三方测试提供支持，制定AI开发者关于安全及安保事故的报告规范，明确各实验室此前自愿作出的安全承诺如何落实，并建立独立审计机构和审计人员的资质认证体系。

目前工作组仍在讨论SAFA是否应直接参与安全和能力测试。美国商务部旗下AI标准与创新中心（CAISI）目前已承担部分相关测试工作，但部分工作组成员认为，其现有资源可能不足以覆盖前沿模型日益复杂的测试需求。据报道援引知情人士，**一些成员主张在CAISI现有测试基础上增加更多测试和评估项目，但SAFA与CAISI未来如何分工、是否会出现职能重叠，目前尚未确定。**

SAFA的另一项争议在于其适用范围。由于“前沿模型”的定义仍较为模糊，Meta以及大量开源模型开发者目前预计不会被纳入首轮评估范围，但如果其模型能力达到相关门槛，未来仍可能受到SAFA标准约束。**SAFA将负责制定相应标准和基准，以判断哪些模型需要接受评估，但具体会员机制和参与范围尚未确定。**

这一设计也引发了行业内部的质疑。部分人士担心，SAFA可能形成新的行业准入门槛，使部分竞争者，尤其是开源模型开发者，难以参与标准制定。一名曾参与Frontier Model Forum相关工作的人士认为，**这类组织的成立未必能够真正解决AI治理问题，企业和政策制定者有时会通过建立新机构来回应外界对风险的担忧。**

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

VIP会员·7天畅读卡 | 大师课·入门串讲

免费领取



限免

165

收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论