

摘要：

字节在大模型上真正的口碑逆转，就是从 Seedance 2.0 开始的。这款视频生成模型凭借坚持大尺寸参数和高质量数据，在效果上实现绝对领先，并以高达90%的毛利率和千万级年框销售门槛，为火山引擎带来井喷式收入。其成功根植于人才与数据的重金押注，更依托“模型迭代-内容爆发-平台增收”的商业飞轮，证明大模型不仅能烧钱，更能赚取高利润。

2025 年底，在一次模型团队的聚餐上，Seedance 模型的负责人曾妍向 leader 提到，她还是想试试训一个更大尺寸的模型，至少达到 200B（2000亿参数）。

曾妍是字节 Seed 一位非常年轻的研究员，2021 年校招生，研究方向始终聚焦在视频理解与生成上。“她一直都挺有自己的技术判断。”一位与曾妍打过交道的人告诉 36 氪，“而且很主动，对于相信的事情比较坚持，会想办法争取资源去实现。”

这个评价几乎复现了曾妍做 Seedance2.0 训练时的处境。“她想训一个参数量更大的模型，但当时团队内部有一些分歧，有人觉得把模型直接 scale up 到 200B-300B 的级别有点冒进了，并且整体的训练资源也紧张，可能先训一个 100B 级别的模型更安全。”一位知情人士告诉 36 氪。

上述人士说，但恰巧有高管参与上述聚餐，了解到曾妍的想法后，说可以给 Seedance2.0 的训练协调一些资源，“后来在 Seed 内部最终的正式评审会上，Seed 负责人吴永辉和视觉多模态生成方向负责人周畅讨论后，，最终也选择了支持曾妍的想法。”

这个在当时看起来有些激进的技术选择，最终被证明是正确的。“因为曾妍坚持模型要足够大，训练数据要足够丰富，Seedance 2.0 才成了。”上述知情人士说。

我们采访了多位字节内外的 AI 从业者，大部分人都认为，**字节在大模型上真正的口碑逆转，就是从 Seedance 2.0 开始的**：在大语言模型上，豆包大模型直到 2025 年年中迭代到 1.6，才被行业认为可进入国内第一梯队；Coding 能力在豆包 2.1 推出前，始终没有太大突破，在国内赶不上GLM，Kimi，DeepSeek 等创业公司当时的旗舰模型，而 Seedance 2.0 几乎是字节第一款，也是目前唯一一款在效果上能形成绝对领先的模型。

这个绝对领先的模型也是第一个帮字节真正赚到钱的模型。36 氪曾独家报道，自 2026 年以来，火山引擎一直在不断提高 MaaS 的营收目标。火山引擎负责人谭待则告诉 36 氪，今年火山 MaaS 收入的一半以上，都是由 Seedance 贡献的。

字节命中了一个好生意。

关于 Seedance2.0 的利润率有很多不同说法。晚点曾报道，这款模型的毛利率达到 70%，而多名 AI 从业者都告诉 36 氪，他们预估 Seedance 2.0 的毛利率达到了 90%。（虽然火山引擎负责人谭待表示，外界过多关注 Seedance 的利润了，其实没有这么高。）无论如何，**相比现阶段的大语言模型，视频模型在中国确实是一个更好的生意：能做较高的定价，且行业竞争更小。**

并且，字节的多条业务线之间还形成了一个基于 Seedance 的独特商业飞轮：红果、抖音等内容平台跟过往比加大了对 AI 剧的资源扶持——更多内容制作公司为了产出高质量 AI 短剧而向火山购买模型——AI 剧数量激增为红果和抖音带来更多广告或投流收入。

一个正向循环由此形成。

模型能力阶跃式提升的时刻，往往就能解锁新的生产力场景，而钱的流向，也会因此而改变。这件事在 Claude Opus 4.6 发布后被验证过一次，在 Seedance 2.0 上，又被验证了一次。

而 Seedance，不仅是字节入局大模型 3 年多来，打的第一场翻身仗，也让中国整个大模型行业看到了一件非常重要的事：**没错，大模型的背后是天价资本开支，但它也能赚到利润率足够高的钱。**

人才的胜利，数据的胜利

字节在 AI 上向来“不计成本地投入”—— GPU、数据、人才，全部饱和投入。

首先是人才的饱和投入上。

一直以来，字节都善于“让老人做新业务”，这个思路起初也用在了 Seed 上。但做了一年多，没太大起色。2024 年中，字节开始在 AI 人才招聘上下重注，**这也是核心管理团队深入业务一线抓 AI 后带来的第一个重要变化：全球范围挖猎大模型人才，不惜付出极高的薪资水平。**

2024 年年中，一支专门服务于 AI 业务的招聘团队成立了。这个团队的特别之处在于：不少 HR 都有很强的业务背景，这样能更好地与高阶的 AI 人才对话——两任负责人都曾在字节做过重要业务，且有战略工作的背景。字节给这个团队开出的薪资也很高——做高招的 HR 年薪动辄超过百万。

一张“AI 人才表”也开始形成：国内国外的头部 AI 人才均在其中，“小几百人，随时滚动更新”，一位高招 HR 说，“Seed 部门几乎不需要遵循字节的薪资体系给 offer，只要是我们想招的人，TP（薪酬包）都可定制。”

此外，张一鸣也回到了一线战斗状态，频繁约见大模型人才“直接聊聊”，不少高阶研究员在金钱和诚意面前，都选择了加入。

“人”之所以重要，是因为：“一个有经验、能做对方向判断的负责人，带着一队足够聪明的年轻人踏实地做训练实验，再给足够的资源，这事很难做不好”，多位业内人士都表达了这样的观点。

随着周畅和吴永辉的陆续加入，Seed 内部减少了同方向下的赛马，并且对技术方向和训练路线的判断也更加收敛、准确，这在 Seedance 上体现的尤为明显。

此前，字节内部有两个独立的团队在做视频生成模型的训练：AI Lab 的曾妍在做 PixelDance，Seed 的蒋路在做 Seaweed。“那会儿字节内部各立山头，做视频的几拨人最早在架构选型上其实是选错了。”一位了解早期情况的人士说。

以 PixelDance 的第一版为例，它选择了 2D UNet 扩展到 3D 的架构，我们可以理解为图像扩散模型的视频化，而非原生视频架构。这在视频生成的技术路线远未收敛的当口，是一个看起来更快、更稳妥，但事后却被证明上限不高的方向。

而同一时期，快手的可灵团队选择了与 Sora 一致的 DiT（Diffusion Transformer）架构，并且是原生视频路线，上限更高，也更难。“人和数据都没有拖后腿，模型训出来效果不会差。”一位知情人士说，这中间形成的时间差，让可灵在随后近一年里先行领跑。

2024 年底，蒋路离开字节加入 Apple，曾妍随着 AI Lab 的组织变动加入了 Seed，成为了视觉生成模型 Seedance 的主要负责人。这是一个精简的团队，核心算法工程师仅十几人。从这个



时间点开始，字节视频生成模型的团队和技术路线，都开始收敛。

从 PixelDance 后期过渡到 Seedance 的这个阶段，跟最早期相比最大的变化是训练架构进行了调整：从 UNet 架构调整到了以 DiT 为基础的架构方向。这个架构能更好地实现大模型的 Scaling Law——随着参数量、数据量和算力变大，模型效果会有明显提升。

但 Seedance 1.0 及 1.5 都算不上成功：这两个版本和谷歌 Veo 都有明显的差距，全球市占率大约排在第四，在国内也不及可灵。一位火山人士说，那段时间字节紧盯的对手是可灵和 Runway，“盯着可灵打，打了蛮久”，却始终没能追上。而一位视频 Agent 公司的市场负责人对 36 氪描述的感受是，**可灵一度占据了视频生成市场近八成的份额。**

字节和快手之间的漫长纠葛从短视频、直播、电商，来到了如今的视频模型。这是一场字节的必争之战。

2025 年 12 月，Seedance1.5 刚上线不久，团队就开始投入 2.0 版本的训练。这成了 Seedance 的翻身一杖。

“Seedance 非常重视训练数据和模型结构。”一位 Seed 人士说。单纯比拼 GPU 的数量，字节和 OpenAI 以及谷歌，无论是数量还是质量，差距都很大。海外公司普遍已经使用大集群 B 卡（英伟达 B200/B300 显卡搭建的大规模 AI 算力集群）训视频模型，而字节内部，虽然 Seedance 优先级也很高，但仍排在语言模型之后，使用的也是相对较差的 GPU 做训练。因此，团队只能在结构和数据上下功夫。

“这两个最重要的事情做对了，接下来就是持续迭代。”这又回到了那个行业共识：人对、方向对、资源到位，剩下的只是时间问题。而这几样东西，恰好也是 Seedance 有的。

关于“人和组织”，一位接触过 Seedance 团队的大模型创业者告诉 36 氪，“大的技术创新往往需要天才研究员，需要宽松的研究环境来激发，可一旦技术路线确定，那需要的就是严格的 schedule 管理来确保把训练的每一步都做到位。Seedance 的团队确实把每一个细节都做的很到位，**军团作战的战斗力很强。**”

而被认为是 Seedance 2.0 成功最关键的一环，是用以训练的数据。“这是一场数据的胜利。”多位从业者在跟 36 氪聊起 Seedance 2.0 的成功原因时，都得出了这个结论。

大模型预训练阶段需要做大量的小规模实验，需要非常多人来做数据标准制定、合成、寻源、标注、清洗、评测等工作，也需要足够大量和丰富、多样的数据。

“Seedance 的数据标注做的很扎实，这能让用户输入的提示词被很精准地匹配到特定数据上。”一位知情人士告诉我们。**在字节内部，为 Seedance 做模型数据评测的团队就有上千人，与之形成对比的是，很多视频领域赛道的头部创业公司，内部评测团队达到数十人，就已经算比较大的投入。每一位 Seedance 算法的背后，往往都配着十余位数据同事做支持。**这个庞大的数据团队要做到能够迅速交付算法需要用于实验和训练的数据，以及收集用户反馈，以保证算法人员能够迅速捕捉到任何用于迭代模型的信号。

Seedance 算法团队里还有一个专门负责和数据团队做对接的人。多位接近 Seed 的人士告诉我们，这个角色就像一个训练团队里的数据产品经理，非常关键——他很清楚训练需要什么样的数据，能给数据团队提出清晰有效的需求，甚至算法还会自己构造数据，自己做精细化的数据清洗工作。

在具体的数据选择上，Seedance 几乎没有使用抖音的数据，而是采买了大量影视资源，尤其是大量使用优质影视级别的素材，再用语言模型把它们拆解成脚本和分镜，“出来的效果就像把一群电影大师放进了模型里。”

团队会根据不同的场景做针对性的数据训练。比如，“Seedance 2.0 对一些跑跳动作丰富的影视作品进行了系统学习，因为它们能还原很多真实运动场景；他们还会模拟或录屏游戏来学习，以及通过专业场景数据来帮助模型学习各种室内空间。”一位字节的数据人士告诉 36 氪。这些各种场景下的数据组成了 Seedance 2.0 庞大的训练数据集。

其实不仅是针对视频模型，字节在各个模型的训练数据上都有巨大投入。据 36 氪了解，在世界模型和 Coding 模型的训练上，2026 年初的数据预算超过千万美元，并且，“如果觉得不够，可以随时追加预算。”

在 AI 数据上的巨大投入，有一个很重要的原因是 Seed 从成立之初就定下了“不做蒸馏”的原则。如果所有数据都要靠自己合成、采买、清洗，势必需要一个庞大的团队来支持。“字节在几乎所有模型上的目标都是达到全球第一梯队，甚至 SOTA，这是通过蒸馏难以达到的。”一位字节人士告诉 36 氪。

火山井喷

“内部气势如虹。”一位火山销售对 36 氪描述。因为 Seedance 2.0 的爆火，火山销售团队倾巢而出，“都在给客户卖 Seedance”。面对客户的犹豫，有些销售则会自信地说：“一年之内，我们的模型都会一直保持 SOTA。”

2026 年 4 月，火山引擎向客户全量开放了 Seedance 2.0 API 的销售，条件是，**必须一次性签订至少 1000 万元的 Seedance 使用年框，才能获得 2.0 的“满血版”使用资格。**所谓满血版，指的是能承受高并发，并且支持真人肖像授权签约，这两点对于 Seedance 2.0 的主力用户群体——拥有真人 IP、需要量产内容的 AI 内容制作公司至关重要。

这种做法在过往火山引擎 MaaS 的销售方案里没有出现过。从 2025 年 2 月 DeepSeek R1 面世后，大语言模型的价格就被骤然打了下来，模型厂的竞争迅速来到了买方市场阶段：对于买家来说，谁家好用又便宜，就用谁。在地板价上拼市场份额，让模型方几乎没什么议价权。而对于主卖自家模型的火山引擎来说，更是不可能给出一个看起来如此高的销售门槛。

“2025 年，火山能卖的模型有限，走综合性价比路线。”一位火山引擎人士告诉 36 氪：“语言模型竞争太激烈，当时也没有跑出来 Coding 这种高价值场景。Seedream 图像模型在国内竞争力还可以，但量也不大。”由于 Seedance 1.0 和 1.5 效果都不够好，当时在市场竞争中打不过可灵，买单的客户也不多。

“到了 2026 年初，我们把希望都寄托在 Seedance 2.0 上了，必须要拿出能给客户讲的新故事了。”据上述火山引擎人士说，当时他们内部听说了 Seedance 2.0 是个能打的模型，觉得可能能有一两个月的领先优势，“但没想到这么能打，几个月过去了我们的优势竟然还在。”

模型好用的第一波反馈是来自 C 端用户的。2026 年春节期间，豆包、剪映、即梦等字节的 C 端 AI 产品开始全量接入 Seedance 2.0，流量如潮水般涌来，导致生成一个 12-15 秒的视频甚至需要排队等待十小时。

反应迅速的即梦随即给出了付费选项：充会员并购买积分可以拥有优先排队的资格——忍受不了等待的用户贡献了 Seedance 2.0 的第一批收入。据某大厂战略对 36 氪估算，即梦在 3 月的



收入约为 1.4 亿元，4 月则来到了 2.1-2.2 亿元水平，这其中绝大部分来自 Seedance 2.0 调用。

但很快，火山引擎接过了赚钱的接力棒。

3 月的一天下午，周志鹏和家人在百望山爬山，但电话却没停过，“接了六个火山销售的电话，都是给我推销 Seedance 2.0 的。”他是 AI 内容出品公司水母智能的联合创始人，这家公司的出品的两部 AI 短剧《摸金之天机入梦》和《饿塔》在今年 5 月进入了今年戛纳电影节的竖屏剧展演。

因为自己公司有 AI 创作工具平台，周志鹏和火山销售打交道已经一年多时间了，但始终没下过单。对于头部 AI 内容制作公司来说，一年在创作模型和工具上花 1000 万并不算多，但让他感到有些为难的是，这 1000 万花出去等于和字节的视频生成模型产生了一个为期一年的绑定关系：如果一年内有比 Seedance 2.0 及其之后版本更好用的其它模型出来，他也很难快速迁移过去，因为钱已经花在 Seedance 上了。

这意味着下注字节在视频生成模型上有多领先，以及领先优势到底能保持多久。不少短剧从业者跟我们说，**Seedance 2.0 在多镜头叙事、多镜头间的一致性以及音画同出上做到比现有其它视频模型都好，而这几项能力对于进行工业化的内容生产来说，非常重要。**

“爬完山回去第二天，我就决定跟火山签了。”在周志鹏看来，AI 剧的竞争从春节后按下了加速键，能不能第一时间用上最好的模型决定了他们能不能最快地推出市场上第一批精品 AI 剧，这事关竞争速度，甚至生死存亡。“一旦决定把产能和工具都放在 Seedance 模型上，一年的消耗肯定不止 1000 万，有可能是 2000-3000 万。”

有周志鹏这个想法的显然不止他一人。中文在线、九州文化、酱油文化等头部短/漫剧制作公司纷纷掏钱，金额高的一次充值就 5000 万。还有一批体量小一点的公司则想办法以拼单的方式凑到 1000 万，也要挤上这趟疾驰的列车。

从定价上看，如果和语言、语音类模型相比，视频模型的单价能高出几十倍。按官方报价，若用 Seedance 2.0 生成 720P 的视频，每秒的价格约为 1 元，这个数字比国内同代视频模型贵了将近一倍。可灵很快将价格作为了自己的一个优势，开始以 7-8 折的优惠价来抢占客户，而 Vidu 等模型则吃下了更看重性价比的漫剧、二次元客户。

视频模型领域主要玩家及价格

公司	最新旗舰模型	发布日期	API单价（以720P为基准）
字节跳动	Seedance 2.0	2026年2月	约0.13美元/秒
Google DeepMind	Veo 3.1	2025年4月	约0.05美元-0.1美元/秒
Runway	Gen-4.5	2025年12月	约0.12美元/秒
快手	Kling 3.0	2026年2月	约0.10美元/秒
阿里	HappyHorse 1.1	2026年6月	约0.07美元/秒
生数科技	Vidu Q3	2026年1月	约0.07美元/秒
爱诗科技	PixVerse C1	2026年4月	约0.065美元/秒

信息来源：36氪综合公开信息整理，以720P为基准计算



来源：智能涌现制图

虽然目前价格是行业里最高，但 Seedance 2.0 从不打折，哪怕面向字节内部的剪映、火山、红果等业务。对外，火山销售还会看客户的接受度进行搭售。“我们会用卖奢侈品的思路卖 Seedance 2.0——想买 Seedance 2.0？那再配点 Seedream 的货吧。”一位火山人士半开玩笑地说。

但对视频质量有高要求，需要规模化生产的视频制作公司都选择接受。“去年是火山销售求着我们买，今年变成了我们求着他们卖。”另一位从业者笑称，“1.0 和 1.5 效果都不好，我们一年下来可能也就几百次调用，消耗基本都在可灵上，但今年用过 2.0 以后，发现确实没对手了，必须 all in。”

就这样，内容制作公司纷纷重金投入。这再次证明：把模型做到全球范围内的 SOTA，意味着可以赚到全市场的钱。

火山的 MaaS 增速让同行的销售感受到了巨大的压力。“火山是阿里云有史以来最难打的对手。”一位阿里云销售对 36 氪说。

在过往的云计算年代，阿里云在近 10 年时间里一骑绝尘。但大模型时代来临后带动的以 GPU 云为核心的算力，是公有云外的全新增量，而火山凭借着视频模型上的突破，找到了前所未有的增长曲线。

为了更快把营收数据提上去，阿里云从 2025 年底起单独组建了好几支 MaaS 销售团队，专门去撬动存量的云计算大客户，并在销售 KPI 里大幅提高了 token 销售权重——调用量乘上激励系数计入业绩，并敦促销售替客户琢磨“到底有什么场景能把 token 用起来”。

但对阿里云来说最关键的还不是客户场景。“MaaS 要卖的好，最关键的还是模型能力要足够强。”上述阿里云销售说。

而火山近期则开始重视的另外一个指标：市占率，今年要让不同模态的模型，提升在全球各个地区的市占率。如今 Seedance 2.0 的全球市占率排在第二，仅次于谷歌 Veo，后者占据全球近半的市场份额——下半年，随着 Seedance 2.5 即将发布，火山对 Seedance 的目标很明确：拿下全球第一。



红果和抖音，圆环的另一半

Seedance 给火山引擎带来的收入是直接且显性的，但字节其它的业务板块也因其而受益。视频模型，与字节各业务板块之间形成了一个几乎是独属于字节的商业闭环。

红果短剧和抖音是这个闭环里最重要的节点，它们承接住了用 Seedance 做出来的大量 AI 短剧，并将其转化为不同形式的收入。

进入 2026 年以来，红果要重点扶持的除了精品剧，还多了一个 AI 剧。

最直接的差异体现在分账上。“漫剧的分账系数是 40-50 倍，高于 2025 年，而仿真真人剧能达到 60-80 倍；非精品的真人剧分账系数下降到了 40 倍，不过真人剧的分账基数依然高于 AI 剧。”一位 AI 剧制作公司负责人告诉我们。

分账差异背后，还有与之相反的巨大的制作成本差异；分账多的，反而成本低。短剧发行公司嘉书科技的创始人王小书粗略地算过一笔账：一部 100 分钟左右的短剧（非头部精品剧），真人实拍需 50-100 万成本，而用 AI 制作只需 5-10 万。

在成本和激励的双重刺激下，不少短剧制作公司停掉了大部分真人剧项目，转投 AI 剧。这一变化不仅给火山引擎带去了大量冲着 Seedance 而来的客户，也给红果直接带来了大量内容供给，最终导向更高的 DAU、用户时长、收入。

红果合作的所有短剧都会同时在红果和抖音上线。一位业内人士粗略地算过：去年整个行业在真人剧上每个月大概能拿到 10 个亿的分账；而今年 AI 剧爆发才两三个月，每个月的分账规模至少 3 亿。

广告分账之外，还有另外一笔更大的钱。

据 36 氪了解，红果短剧不支持发行方做流量投放，平台完全依靠算法做分发，给头部精品剧（包括 AI 剧）的支持主要在宣发层面。如此一来，短视频平台便接住了大笔投流费用，包括抖音、快手、视频号等。

“投放是 AI 短剧在各个内容平台上最重要的获量方式。”王小书说。并且，由于内容的制作成本大幅下降了，所以可以用来投流的预算就大大提升了。

“年初，我们在 AI 剧上一天的投入金额可能也就是几十万，现在已经达到几百万的规模了。”王小书告诉 36 氪。而这只是他一家公司的投入规模。“行业整体的投流费用（包括对真人剧），每个月有几十亿规模，增长了百分之几十，主要增量就是在 AI 剧上。”这些费用被抖音、快手等视频平台瓜分。

这个逻辑同样也适用于在抖音上投放信息流广告的营销公司和他们背后的广告主——因为用 Seedance 做广告素材比实拍和做动画来的更容易了，成本下降、效率提高，所以可以在不改变预算的情况下，产出更多广告素材，并且拨出更多钱来做广告投放。“巨量引擎会找我们帮他们平台上的大客户用 AI 批量生产广告素材，目的也是帮大客户提高广告消耗。”一位用上了 Seedance 2.0 的营销从业者告诉 36 氪。

Coding 之外，视频模型也可以赚钱

大模型毫无疑问是一个昂贵的游戏。




仅训练成本，就在几亿到几十亿美元不等。随着模型尺寸的继续增大，Epoch AI 的研究显示，过去几年来，每一代大语言模型的训练成本都在以 2-3 倍的速度提升。2026 年初，Anthropic CEO Dario Amodei 接受 TIME 采访时表示，Anthropic 下一代 AI 模型的训练成本就将达到约 10 亿美元，再下一代则可能攀升至 100 亿美元。

这还没算上模型上线后，用户的每一次使用会带来的推理成本。“用户规模越大，亏损也越大”一度成为了 Chatbot 类产品的困境。SemiAnalysis 早在 ChatGPT 问世之初就做过测算：**当模型达到一定用户规模后，单周的推理成本就会超过一次训练的总费用。**

这个判断在接下来的几年中被反复验证——据 Sacra 估算，OpenAI 在 2025 年的推理成本高达 84 亿美元，2026 年预计将攀升至 141 亿美元——这还是在单 Token 成本两年内下降了超过 99% 的前提下，而 OpenAI 的同期营收仅超过 200 亿美元。

就在行业对于大模型这个有史以来最烧钱的生意是否真的能赚钱产生巨大质疑时，Anthropic 率先打消了大家的疑虑。2025 年底，Anthropic 的全年收入还只有 90 亿美元，但仅仅四个月后，凭借 Claude Opus 系列带动 Claude Code 在开发者群体中的爆发式增长，Anthropic 的 ARR 在今年 5 月已经暴涨到 470 亿美元。

Anthropic's operating income, by segment



来源：华尔街日报

这个令行业眼前一亮的变化，恰恰说明了，**模型可以赚钱，但需要满足两个条件：模型能够为用户提供高价值，比如 Coding、Agent 等，也就是说 token 需要更值钱；与此同时，模型要足够好，要达到所处领域的 SOTA。**

硅谷的经验在中国同样适用，只是，在中国率先跑出来的“高价值 SOTA 模型”，是视频模型。

这有一定的必然性。中国在大语言模型上起步相对较晚，但在视频模型上和硅谷几乎是同一时间开始探索，这意味着大家站在一条技术起跑线上。此外，中国的内容创作领域一直很活跃，短视频就了一个庞大的创作者生态，这使得字节、快手这样以短视频起家的公司对视频模型的机会天然更敏锐，并且视频从业者也比较懂怎么把模型转化为商品，更快跑通商业化闭环。

火山引擎负责人谭待给 36 氪分析过视频模型定价的逻辑：看 token 到底能创造多少价值。“你的定价要让客户的迁移收益高于迁移成本至少两倍以上，大家才有意愿来用。比如，以前拍一个广告 1 秒钟成本 100 块，现在用 Seedance 做出相似的效果只要几块钱，那模型就是创造了足够价值的。”

高价值带来更高议价空间，但视频模型的推理成本却还能进一步压低。一位视频模型创业者告诉 36 氪，**视频生成是计算密集型任务，不像语言模型那样对存储带宽有那么高的要求，所以用更便宜的国产芯片就可以跑推理。而且不受限于英伟达等高端 GPU 的供给也让模型公司能放开手脚地扩大业务规模。**

这些条件自然地导向了高毛利，以及对训练阶段所投入成本的快速摊薄。

这是一门好生意。据多位从业者，可灵一直以来保持着较高的利润水平，而 MiniMax 的海螺视频模型，也一直是拉动公司整体营收的主力，并且维持正毛利。

但 Seedance 2.0 发布后行业格局发生很大变化。一家头部视频 Agent 公司对 36 氪表示，发布前，视频内容生产者们所使用的模型种类尚且是“雨露均沾”，其中可灵的份额最高；但 Seedance 2.0 在发布后，形势迅速调转，平台上 Seedance 2.0 的调用量接近 70%。“我们现在已经把 90% 的生产都放在 Seedance 2.0 上了。”另一家头部短剧公司对 36 氪表示。

据 36 氪了解，**2025 年期间，快手高层曾对于可灵的目标有过多次讨论，当时的结论是，把商业化当作重要目标，这必然导致在下一代模型上的投入会降低。**而 Seedance 的异军突起让快手意识到，“如果你想做最厉害的模型，前期投入一定是巨大的，把盈利作为核心目标大概率会导致模型发展放缓。”一位知情的前快手人士说。这也是当下可灵独立拆分并推动 IPO 的主要动力——谋求更多空间和资源。

现实很残酷：想把大模型做成一个可持续的生意，就必须保持模型的 SOTA。一旦模型能力被反超，市场份额就会被快速吸走。这是一场暂时还看不到尽头的军备竞赛。

据 36 氪了解，**Seedance 的新一代模型 2.5 将在 7 月下旬正式发布**，而可灵、Veo 的新版本也将很快到来。除了大公司外，国内不少视频模型创业公司如爱诗、Sand.ai 也在有节奏地发布新模型。Seedance 还会继续保持领先吗？

而字节想要让大模型的商业化飞轮持续高速运转下去，至少还需要补上 Coding 这块拼图。这也让 6 月底刚上线的豆包 2.1 被放在了一个至关重要的位置。火山引擎负责人谭待称其在 Coding 和 Agent 方面“上牌桌了”，“国内现在真正上牌桌的还没几个”。他还说，“虽然我们现在 Seedance 卖的多一点，但我希望后面 LLM 能成为主力。”

本文来源：[36氪](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

VIP会员·7天畅读卡 | 大师课·入门串讲

免费领取



限免



写评论

请发表您的评论

 表情  图片

发表评论