

摘要：

中国移动自主研发的九天35B通用大模型即将发布。摩尔线程基于旗舰级AI训推一体全功能GPU MTT S5000，已率先完成九天35B模型的全流程适配与推理验证。意味着国产AI算力已具备支撑行业级大模型规模化落地的核心能力。

近日，中国移动自主研发的九天35B通用大模型即将正式发布。作为中国移动重要的生态合作伙伴及“AI能力联合舰队”的核心算力成员，摩尔线程基于旗舰级AI训推一体全功能GPU MTT S5000，依托成熟的MUSA软件栈与高性能算子优化，已率先完成九天35B模型的全流程适配与推理验证。这不仅是国产GPU与央企大模型的深度协同，更意味着国产AI算力已具备支撑行业级大模型规模化落地的核心能力。

软硬协同优化，释放极致性能

本次适配中，摩尔线程基于自研MUSA软件栈与SGLang-MUSA高性能推理引擎，深度打通九天35B模型推理全链路。MTT S5000基于第四代MUSA“平湖”架构打造，单卡AI稠密算力可达1000 TFLOPS，支持从FP8到FP64全精度计算，为大模型推理提供了坚实的硬件底座，精准匹配九天35B大模型在长文本处理与高并发响应方面的核心需求。

为追求极致效率，摩尔线程通过MUSA C开发框架、muDNN计算库与MATE开源算子库的全栈优化，针对九天35B模型特有的注意力机制与长序列推理进行深度适配，确保模型在MTT S5000上高效执行。实测表明，在标准推理场景下，MTT S5000可稳定支撑九天35B模型的高并发请求，充分满足各行业对大模型低时延、高可靠的部署要求。

国产GPU+央企大模型，夯实全栈算力底座

中移九天35B大模型作为中国移动“九天”基座核心产品，具备高安全、高可控、全自主的央企特性，已通过生成式AI服务双备案与A级安全认证，广泛适配数智化转型场景。此次摩尔线程MTT S5000快速完成适配，不仅验证国产GPU生态成熟度与响应速度，更构建“国产GPU+央企大模型”全栈国产化方案，为中国移动算网融合、AI能力规模化输出提供关键支撑，助力千行百业智能化升级。

作为中国移动深度生态伙伴，摩尔线程积极参与移动云智算中心、万卡级集群建设，近期更联合中国移动研究院、之江实验室等产业伙伴，共同发布《OISA高密超节点参考设计技术规范》，推动国产AI算力基础设施的标准化与高密度演进。未来，摩尔线程将持续依托AI智算产品与MUSA全栈技术，携手中国移动及更多产业伙伴，深化智算基础设施与AI应用的协同创新，加速构建自主可控、高效可靠的新一代AI基础设施，为千行百业智能化升级提供坚实底座。

本文来源：[摩尔线程](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

121 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论