

摘要：

摩尔线程发布“云边端”全栈智算矩阵

5月18日，摩尔线程在北京发布最新云边端产品矩阵。

这场发布会的信息量很大。

夸娥万卡级智算集群、长江SoC、AICUBE、AIBOOK、E300边缘模组、小麦智能体、MT Lambda具身智能仿真平台，以及MUSA软件生态的进展，被集中放到同一场发布会上。



产品清单之外，更值得看的，是这些产品被组织起来的方式。

摩尔线程把云端训练、软件迁移、边缘设备、终端智能体和具身仿真串成一条线，传递出一个清晰信号，市场对它的理解，正在从GPU芯片公司转向AI基础设施公司。


过去几年，国产GPU公司最常被问到的问题很直接。卡能不能跑，性能接近多少，主流框架能不能用，CUDA生态能不能迁移，主流模型能不能快速适配。

这些问题依然重要。

只是AI进入Agent阶段后，客户的问题变得更具体。一家大模型公司关心集群能否连续训练，硬件故障后能否恢复；一家自动驾驶公司关心世界模型和仿真链路能否接上；一家机器人公司关心训练出的策略能否下发到端侧设备；企业客户还会计算迁移和维护成本。

单卡性能是入口，系统能力才会影响采购和复购。

摩尔线程这次想强调的，正是这种系统能力。



云端是它目前最重要的证明场。

材料显示，夸娥万卡级智算集群已经落地，Dense大模型训练MFU达到60%，MoE大模型达到40%，训练线性扩展效率达到95%，有效训练时长达到90%。

大模型训练的复杂性，往往在规模扩大后集中暴露。

更多GPU带来更高算力，也带来通信、调度、容错、存储、散热、框架适配上的压力。训练周期越长，系统稳定性越重要。夸娥承担的任务，是向企业客户证明摩尔线程具备系统交付能力。

围绕云端能力，摩尔线程也在补软件栈。

它已经适配DeepSeek、GLM、MiniMax、Kimi、Qwen等国内主流模型，在SGLang主线代码中获得官方原生支持，并开源vLLM-MUSA。MUSA SDK 5.1.0对标CUDA 12.8，并完整支持PyTorch全部3194个算子。

这些进展的战略价值，在于降低开发者迁移摩尔线程GPU的阻力。

国产GPU生态的难处，常常出现在长尾里。

主流框架能跑，企业历史工程未必能顺利迁移；模型完成适配，后续版本还要继续跟；算子补齐，业务里仍可能有自定义Kernel和旧版本依赖。开发者对硬件平台的耐心，通常消耗在这些细节中。



摩尔线程强调MUSA兼容、vLLM-MUSA开源、SGLang官方支持，以及Automusify自动迁移、MUSACODE编程助手，实际都在处理同一个问题，尽可能把国产GPU从可用推向好用。

边缘和终端部分，能看到摩尔线程更主动的一面。



基于长江SoC，摩尔线程推出了AICUBE、AIBOOK和E300。AICUBE面向家庭场景，整合小麦智能体、AI PC和AI NAS，尝试把家庭数据、设备控制和智能体服务放到一个入口里。

AIBOOK面向开发者和学习者，运行MTT AIOS，预装龙虾智能体OpenClaw，支持多智能体协作。E300面向工业质检、能源巡检、具身智能、智能汽车、低空经济等边缘场景，提供50TOPS异构AI算力，强调本地推理、低延迟和稳定运行。

这些产品把摩尔线程带入了一个更复杂的市场。

家庭用户看高频需求，开发者看 workflow，行业客户看部署成本、故障率和服务响应。AICUBE、AIBOOK和E300的价值，需要通过使用频率、开发者留存、行业项目复用率来观察。

在这套矩阵里，MT Lambda是一个关键变量。



摩尔线程把MT Lambda定义为全栈具身智能仿真平台。它基于全功能GPU，把渲染、物理和AI计算放到同一芯片中，上层提供数据合成、策略训练和仿真验证工具。

这部分让摩尔线程的GPU叙事进入物理AI。



大模型训练主要检验云端算力。具身智能会把要求拉宽，机器人、自动驾驶、工业设备需要理解环境，也需要在物理世界中行动。它们依赖语言、视觉、动作、物理仿真、图形渲染和端侧实时响应。

真实世界的试错成本很高。

机器人会摔，设备会坏，产线会受影响，自动驾驶也不能依赖现实道路无限冒险，仿真训练由此成为基础设施。

摩尔线程强调全功能GPU，原因正在这里。进入具身智能后，图形渲染、物理仿真、AI计算要放在同一张计算底座上看。谁能高效生成可信合成数据，谁能在虚拟环境里完成策略训练和验证，谁就能降低机器人和自动驾驶进入真实场景的成本。

更多的企业间合作，也在服务这条线。摩尔线程联合智源研究院完成RoboBrain 2.5训练；与光轮智能、小马智行、五一视界、光线云等伙伴，在仿真数据、世界模型、自动驾驶和具身仿真平台上推进适配。

把云端、软件、终端和仿真放在一起看，摩尔线程这次发布会的公司战略逐渐清晰。夸娥集群负责大规模AI计算，MUSA生态降低迁移成本，长江SoC和端侧产品进入设备和场景，MT Lambda切入具身智能 workflow。

这是一条从芯片向系统、平台和场景延伸的路径。

优势在于，摩尔线程可以减少对单点硬件销售的依赖，**把自己放到客户AI系统建设的更深位置**。客户购买AI基础设施时，会同时计算算力价格、稳定性、迁移成本、服务能力和场景结果。

风险也很明显。每深入一层，评价标准都会变化。云端看规模交付和稳定性，软件看开发者体验，终端看高频需求，具身智能看真实场景验证。摩尔线程需要在多个战场同时证明自己。

发布会给出的是一张结构完整的图。

后面要验证的，是各个节点能否跑起来。夸娥训练出的模型，能否部署到边缘和终端；MT Lambda生成的策略，能否进入机器人和自动驾驶客户流程；MUSA生态能否让开发者迁移成本降到可接受范围。

从行业趋势看，AI竞争正在从模型能力外溢到系统能力。过去两年，行业注意力集中在参数规模、上下文长度、多模态表现、推理成本和Agent能力。模型仍是核心，但产业已经开始面对更具体的问题。算力如何稳定供给，数据如何生成，模型如何训练和部署，机器人如何在仿真中学习并在现实中执行。

这些问题需要基础设施来承接。

摩尔线程这次发布会的意义，在于它把自己放进了这个新命题里。国产GPU公司下一阶段的突破点，将来自系统交付、软件生态和场景闭环。**摩尔线程给出的方向，是进入大规模智算集群、边缘终端和具身智能仿真生态。**

接下来，市场会检验这些产品之间能否形成真实协同。

本文来自[微信公众号“硬AI”](#)，关注更多AI前沿资讯请[移步这里](#)





风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

👍 124 ★ 收藏

分享到:  

写评论

请发表您的评论

😊 表情 🖼️ 图片

发表评论