

摘要：

摩根大通认为，模型能力一旦突破阈值，足以大规模解锁真实工作流，需求便会加速扩张。中国AI基础模型行业正进入商业化加速阶段，行业竞争焦点将从价格转向模型能力，能力前沿的模型有望实现量价双升，而未能持续改善的模型则将面临价格下滑。

中国人工智能基础模型行业正步入商业化加速阶段。摩根大通认为，随着模型质量持续改善并开始转化为更快的需求增长，大模型能力将决定定价权，较强与较弱公司之间的差距将日益扩大。

据追风交易台，3月27日摩根大通发布报告，系统回答了市场对需求增长、API定价、竞争格局、盈利能力及全球扩张风险等十个关键问题。

报告认为，2026年是中国企业端AI需求能否复制2025年美国市场增长曲线的关键一年，编码和智能体应用正成为最重要的需求催化剂。

需求加速：非线性拐点逻辑，编码与智能体是主要催化剂


摩根大通认为，AI需求应被理解为“拐点驱动”而非线性增长——模型能力一旦突破阈值，足以大规模解锁真实工作流，需求便会加速扩张。

美国市场已提供先例。据报告援引的数据，Anthropic的年度经常性收入（ARR）从2024年12月的10亿美元快速增至2026年3月的190亿美元，15个月内增加约19倍。

摩根大通认为，目前中国具备遵循类似模式的条件：国内模型能力已接近甚至超过美国领先模型一年前的水平，而国内定价也更符合本土人工经济效益，两者共同改善了落地的商业回报。


智能体侧的需求逻辑同样在强化。报告指出，OpenClaw已成为重要催化剂，将使用场景从单轮交互推向多步骤执行，显著提高了每个任务的token强度。腾讯、阿里巴巴和字节跳动已将与OpenClaw挂钩的工具融入各自生态系统。

图 1: Anthropic 的 ARR 轨迹




资料来源：公司官网、The information、CNBC、Yahoo Finance、路透社（数据截至 2026 年 3 月 26 日）

图 2: OpenAI 的 ARR 轨迹




资料来源：公司官网、The information、CNBC、Yahoo Finance、路透社（数据截至 2026 年 3 月 26 日）

图 3: 只要模型质量好到足以解锁真实应用，AI 使用量往往就会加速 - Anthropic 的新模型能力（按 Artificial Analysis 智能指数得分量化）和 ARR 的对比就是证明



资料来源：Artificial Analysis、公司官网、The information、CNBC、Yahoo Finance、路透社（数据截至 2026 年 3 月 26 日）

图 4: 按 Artificial Analysis 智能指数得分衡量，智谱和 MiniMax 目前的模型能力已超过 Anthropic 模型一年前的水平



资料来源：Artificial Analysis（数据截至 2026 年 3 月 26 日）

API 定价：分化是主旋律，能力决定定价权


摩根大通判断，API 定价不太可能单向移动，更可能走向分化。

一方面，能力形成定价权。若某个模型能独一无二地释放高价值任务，如智能体编码、长时程 workflow 或企业级可靠性，客户就会支付溢价，因为回报可量化且独立于 token 单价之外。

另一方面，随着硬件、系统和算法效率不断改善，推理单位成本将持续下降，这会给“足够好但停止进步”的模型带来定价压力。

报告由此得出结论：留在能力前沿的模型有望同时实现量价双升；而未能持续改善的模型则更可能在使用量增长的同时面临价格下滑，利润率前景不确定。

图 5: API 定价可能分化：留在前沿的模型能保持定价权，而未能不断改善的模型更有可能看到价格滑坡



资料来源：Artificial Analysis（数据截至 2026 年 3 月 26 日）

竞争焦点：从价格战转向模型能力

报告强调，这是与去年讨论的关键差异——特别是在中国，此前市场关注的焦点是全面价格竞争。

在智能体使用场景中，客户购买的实际上并非廉价token，而是任务的顺利完成。报告援引测算数据显示，在多步骤 workflows 中，单步骤可靠性的微小提升可带来任务最终完成率的大幅改善（单步骤成功率从90%提升至95%，20步骤完成率将从12%跃升至36%）。

这意味着token均价更高但可靠性更强的模型，其每项成功任务的实际成本反而可能更低。

摩根大通认为，拥有强大前沿模型的公司通常能更容易地向低端市场延伸，而立足于低价的公司则难以向高端市场进军。因此，竞争越来越集中在绝对模型质量和工程效率上，而非单纯价格。

表 1: 单步骤可靠性的小幅提升可带来任务最终完成率的更大改善

单步骤成功率	5 步骤任务完成率	10 步骤任务完成率	20 步骤任务完成率
85%	44%	20%	4%
90%	59%	35%	12%
95%	77%	60%	36%
98%	90%	82%	67%

资料来源：摩根大通估算（数据截至 2026 年 3 月 26 日）

表 2: 智能体 workflows 中的任务层级经济性比 token 层级定价更重要

模型	特点	每次尝试的 token 平均成本(美元)	每完成一项任务的平均尝试次数	每次尝试的实际成功率	每项成功任务的成本(美元)
模型 A	token 价格较低，能力较弱	1.5	8.0	13%	12.0
模型 B	价格适中，能力较强	4.0	2.0	50%	8.0
模型 C	token 价格最高，可靠性最强	10.0	1.1	91%	11.0

资料来源：摩根大通估算（数据截至 2026 年 3 月 26 日）

行业格局：生死相搏，强者愈强

摩根大通维持其“对大语言基础模型行业”生死相搏的判断，核心逻辑在于：技术差距小、产品周期无止境，商业模式向API销售聚拢，失去动能的公司可以很快被挤出。

报告指出，在中国，各家大语言模型公司之间的差距经常比投资者认为的要小得多，这使市场高度不稳定。公司必须持续支出并不断迭代以避免落后——原地踏步并非中性，而意味着市场地位的丧失。

对于互联网巨头进军B端AI领域这一趋势，报告认为这使独立模型提供商与大平台之间的竞争变得更加直接。

阿里巴巴已明确将云和AI作为战略重点，腾讯最近推出的智能体产品已细分至个人、开发者和企业场景。摩根大通判断，随着平台更积极推进B端变现，“云中立”的定位优势正在弱化，双方的竞争焦点均趋向模型能力本身。

盈利能力：毛利率改善可期，运营杠杆仍待验证

摩根大通认为，对于保持全球顶级地位的大语言模型提供商，毛利率应随模型效率和推理芯片效率的改善而上升，更高价值的工作负载也将支持更有利的收入结构。然而，盈利能力更关键的问题在于：毛利润增速能否超过研发支出增长率。

报告以Anthropic为参照——即便该公司在2026年2月的收入水平已达140亿美元，同期仍宣布了一轮300亿美元融资并强调继续前沿开发，印证了高收入并不意味着训练强度已正常化。

摩根大通对智谱和MiniMax均维持“增持”评级，目标价分别为800港元和1,100港元。预测智谱和MiniMax均将从2029年起扭亏为盈。报告同时强调，比实现利润的确切年份更重要的是使用量的持续增长及单位经济效益的改善趋势。



~~~~~

以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入【[追风交易台·年度会员](#)】



# 追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

## 什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

## 在这里，你将看到

### 最专业的解读

来自全球顶尖投行、研究机构、  
一线从业者的最新解读



### 最独到的视角

以全球市场第一线的视角  
感知市场动向



### 最适时的时机

快速、完整、准确  
最终汇集成适时



## 如果你

关心全球宏观经济和资本市场

## 如果你

苦恼于没有合适的信息和研究



关注“追风交易台”  
成为“追风会员”

你将身处全球市场第一线

公众号 · 追风交易台

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

56

收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论