


摘要：

大模型正迎来一个关键分水岭：以英伟达Blackwell架构训练的首批旗舰模型即将亮相。花旗将其定性为当前竞争格局中“最重要的近期技术催化剂”。近期Anthropic提前发布Claude Opus 4.8，xAI与MiniMax等也密集预告新品。Blackwell训练模型的出现或许意味着一次真正的能力断层。

AI大模型竞争正迈入新的技术节点。以英伟达Blackwell架构训练的首批旗舰模型即将亮相，花旗研究将其定性为当前行业竞争格局中“最重要的近期技术催化剂”，而在此之前，多家头部AI实验室已密集推出或预告新品，新一轮能力跃迁正在加速兑现。

Anthropic本周正式发布Claude Opus 4.8，在智能体协作、可控推理与诚实度方面全面升级，发布时间较外界此前预期明显提前；马斯克在X平台披露，参数量高达1.5万亿的Grok-5训练已完成，预计2至3周内发布，参数规模是现役Grok-4的三倍；MiniMax工程主管同期发布预告，暗示采用全新稀疏注意力机制的MiniMax-M3即将登场。与此同时，OpenAI的GPT-6.0、谷歌的Gemini 3.5 Pro等新一代模型也已排入发布日程。

据追风交易台消息，花旗研究5月22日报告指出，**当前AI需求呈现OpenAI首席财务官Sarah Friar所称的“垂直的需求之墙”态势**：谷歌每月处理的tokens量已达3.2千万亿（Q），同比增长7倍；Anthropic预计二季度末年化收入（ARR）约达500亿美元，较3月底的300亿美元大幅跳升，二季度收入预测为109亿美元，环比增幅约130%；OpenAI一季度单季收入57亿美元，已超去年上半年约43亿美元的总和。然而，供给侧增速更为渐进，算力与推理成本双双走高，供需错配格局正在重塑整个行业的定价逻辑。



上述动态意味着AI平台商业化路径正沿两个方向演进：能力竞赛驱动前沿推理的持续溢价，供给约束则推动算力服务走向类云计算的预留定价模式。Blackwell训练模型能否真正带动能力跃迁，将是检验这一逻辑的关键节点。

Blackwell训练模型：下一轮技术跃迁的真正起点

花旗研究把“首批基于Blackwell架构训练的模型”列为近期AI竞争中最关键的技术催化剂，逻辑很直接：目前所有排在前沿模型榜单上的产品，包括OpenAI GPT-5.5（花旗AI智能指数60）、谷歌Gemini 3.1 Pro Preview（57）、Anthropic Claude Opus 4.7（57），全部是用上一代算力训练出来的。

换句话说，Blackwell的算力优势到现在还没有真正体现在模型能力上。市场普遍预期，一旦首批Blackwell训练模型落地，将与现有产品之间形成明显的能力断层。

这也是为什么花旗特别强调Mythos的节点意义——Anthropic的Claude Mythos预览版，是目前已知的“前Blackwell时代”最后一批顶级模型之一，其对齐性和推理能力已被视为当前架构的天花板。Mythos之后，下一批重磅模型将是首批真正吃到Blackwell红利的产品。

花旗模型发布日历显示，未来数月发布节点密集：谷歌Gemini 3.5 Pro、Anthropic Claude Sonnet 4.7等预计二季度内落地；Claude Opus 5、Sonnet 5及DeepSeek V5等定档四季度；OpenAI GPT-6.0则排期三季度。其中哪些将成为首批由Blackwell算力全程训练的产品，是市场当前最核心的关注点。

Figure 3. Events Calendar

Start Date	End Date	Event	Type	Location
May 31, 2026	May 31, 2026	NVIDIA GTC Taipei	Conference	Taipei, Taiwan
June 1, 2026	June 4, 2026	Snowflake Summit	Conference	San Francisco, CA
June 1, 2026	June 7, 2026	a16a Tech Week 2026	Conference	New York, NY
June 2, 2026	June 3, 2026	Microsoft Build	DevDay	San Francisco, CA
June 3, 2026	June 7, 2026	CVPR	Conference	Denver, USA
June 6, 2026	June 10, 2026	ACM Conference on Economics and Computation	Conference	Rome, Italy
June 8, 2026	June 12, 2026	Apple WWDC	DevDay	Cupertino, CA
June 15, 2026	June 18, 2026	Databricks Data + AI Summit	Conference	San Francisco, CA
June 17, 2026	June 17, 2026	Meta AI & Data	Conference	Menlo Park, CA
June 17, 2026	June 17, 2026	AWS Summit NYC	Conference	New York, NY
June 22, 2026	June 26, 2026	ISC	Conference	Hamburg, Germany
June 22, 2026	June 26, 2026	STOC	Conference	Salt Lake City, UT
June 23, 2026	June 24, 2026	AI World Congress	Conference	London, UK
June 29, 2026	July 2, 2026	AI Engineer World's Fair	Conference	San Francisco, CA
July 2, 2026	July 7, 2026	ACL	Conference	San Diego, CA
July 6, 2026	July 12, 2026	ICML	Conference	Seoul, South Korea
July 8, 2026	July 9, 2026	RAISE Summit	Conference	Paris, France
August 4, 2026	August 6, 2026	Ai4	Conference	Las Vegas, NV
August 15, 2026	August 21, 2026	UCAI-ECAI	Conference	Bremen, Germany
August 17, 2026	August 20, 2026	Hot Chips	Conference	Silicon Valley, CA
September 8, 2026	September 10, 2026	Citi TMT Conference	Conference	New York, NY
September 15, 2026	September 17, 2026	AI Infra Summit	Conference	Santa Clara, CA
September 15, 2026	September 17, 2026	Salesforce Dreamforce	Conference	San Francisco, CA
September 29, 2026	September 29, 2026	OpenAI DevDay	DevDay	San Francisco, CA
September 29, 2026	October 1, 2026	The AI Conference	Conference	San Francisco, CA
October 5, 2026	October 11, 2026	a16a Tech Week	Conference	San Francisco, CA
October 6, 2026	October 9, 2026	COLM	Conference	San Francisco, CA
October 7, 2026	October 8, 2026	World Summit AI	Conference	Amsterdam, The Netherlands
October 18, 2026	October 28, 2026	Open Source AI Week	Conference	San Francisco, CA
October 24, 2026	October 29, 2026	EMNLP	Conference	Budapest, Hungary
October 26, 2026	October 29, 2026	Oracle AI World	Conference	Las Vegas, NV
November 15, 2026	November 19, 2026	ACM CCS 2026	Conference	The Hague, The Netherlands
November 15, 2026	November 20, 2026	Supercomputing Conference	Conference	Chicago, IL
November 30, 2026	December 4, 2026	AWS re:Invent	DevDay	Las Vegas, NV
December 6, 2026	December 12, 2026	NeurIPS	Conference	Sydney, Australia
December 9, 2026	December 10, 2026	The AI Summit New York	Conference	New York, NY

© 2026 Citigroup Inc. No redistribution without Citigroup's written permission.

Source: Citi Research

GPU算力租赁市场数据同样印证了这一预期。花旗追踪的Blackwell系列芯片（(G)B200/(G)B300等）租赁价格自2025年下半年以来持续攀升，直接反映出市场对下一代训练算力需求的强劲升温。

Claude Opus 4.8：Anthropic在Blackwell前夕加速迭代

在距Claude Opus 4.7发布仅约一个月后，Anthropic本周发布Claude Opus 4.8，时间较此前外界根据代码泄露推测的“6月中旬”窗口明显提前。在OpenAI、谷歌等厂商持续推进智能体与推理模型竞争的背景下，Anthropic正以更快的迭代频率押注高端企业AI市场。

此次升级的核心变化有三：一是新增“投入控制”（effort control）机制，用户可主动调节模型推理资源的投入强度，在速度、成本与推理深度之间灵活取舍；二是推出“动态工作流”（Dynamic Workflows）研究预览版，整合进Claude Code，支持协调数百个并行子智能体完成大规模复杂任务——Anthropic举例称，新系统可端到端处理覆盖数十万行代码的大型代码库迁移；三是着力提升“诚实度”（honesty），内部评估显示，Opus 4.8允许代码缺陷未加提示通过的概率，仅为Opus 4.7的约四分之一，且对齐性已达到与Claude Mythos预览版相媲美的水平。

在基准测试上，Claude Opus 4.8在衡量浏览器智能体能力的Online-Mind2Web中获得84%，Anthropic称其优于Opus 4.7和GPT-5.5。



定价维持与Opus 4.7一致：每百万输入token 5美元、每百万输出token 25美元。新增“快速模式”（Fast Mode），定价为每百万输入token 10美元，速度为标准模式的2.5倍，成本据称仅为此前模型的三分之一。模型已在亚马逊AWS、谷歌云及微软Foundry同步上线。

Anthropic还在公告中透露，少数机构已开始在网络安全场景中试用Claude Mythos预览版（Glasswing项目），并预计“在未来数周内”将Mythos级别模型向全部客户开放。

Grok-5与MiniMax-M3：更多强模型即将来袭

Blackwell训练模型即将登场的背景下，多家头部实验室正密集预告新品，试图在新一轮能力竞赛正式开始前抢占位置。

马斯克本周在X平台披露，1.5万亿参数的Grok V9-Medium（Grok-5）训练已完成，预计2至3周内向公众发布。



Elon Musk

@elonmusk

Subscribe

Grok foundation model V9-Medium (1.5T) has finished training. Evals look good. A lot of Cursor data was added in supplementary training and there is more to come.

Fine-tuning is underway and reinforcement learning begins in a few days. 2 to 3 weeks to public release.

This will be a major improvement over the 0.5T v8-small that currently serves all Grok production traffic, especially for difficult coding tasks.

Grok 基础模型 V9-Medium (1.5T) 的训练已经完成。测试结果相当不错。在补充训练中，我们加入了大量 Cursor 数据，未来还会继续添加更多数据。

微调工作正在进行中，强化学习阶段也将在几天后开始。预计再过 2 到 3 周，该系统就能正式向公众发布。

与目前负责处理 Grok 所有生产流量的 0.5T v8-small 相比，这无疑是一个巨大的改进，尤其是在处理那些复杂的编码任务时。

1:48 PM · May 25, 2026 · 15.1M Views

6.7K

9.3K

70K

3.9K

6.7 千

9.3 千

7 万

3.9 千

View quotes >

Relevant

Post your reply

Reply



Danny Limanseta

@DannyLimanseta · May 25

This is incredibly exciting. Just curious, what's in the cursor data? This means that the upcoming Grok model will be much better at coding?

这真是令人兴奋不已。不过好奇一下，光标数据里到底包含什么内容呢？这意味着即将推出的 Grok 模型在编程能力方面会更强吧？

45

43

1K

257K



Elon Musk

@elonmusk · May 25

Much better at coding

编程能力强多了

相比之下，当前xAI全部生产流量运行在参数约0.5万亿的Grok-4上，新模型参数规模一举扩至三倍。马斯克特别提到，来自AI编程工具Cursor的大量编程数据已被纳入补充训练，后续还有更多数据将跟进。Cursor当前年经常性收入（ARR）已达20亿美元，三个月内翻倍，开发者在其上产生的代码补全、重构、调试交互数据，提供了完整的思维链训练素材，对编程能力建模的价值明显高于直接爬取代码仓库。

在此前战略布局中，SpaceX已于4月21日宣布与Cursor达成合作，Cursor可使用Colossus超算训练模型，SpaceX获得以600亿美元收购Cursor的期权，否则需支付100亿美元合作费用。这一架构下，Grok-5针对编程场景的升级，将在与OpenAI Codex、Anthropic Claude Code的竞争中进一步加码。

MiniMax方面，工程主管本周发布预告图，暗示采用全新稀疏注意力机制的MiniMax-M3即将推出，据市场解读，预填速度可提升9.7倍、解码速度提升15.6倍。据花旗前沿模型排行榜，当前MiniMax-M2.7以每百万tokens仅0.22美元的极低定价在市场中占据一席，M3落地后，其在性价比赛道的优势有望进一步延续。



此外，DeepSeek V4 Pro（4月24日发布，花旗AI智能指数52）以及来自中国多家机构的Qwen3.6 Plus、Kimi K2.6等产品也相继入场，前沿模型竞争格局的多极化趋势愈发清晰。

需求“垂直墙”：企业采用仍在早期

花旗研究用“垂直的需求之墙”来描述当前AI需求的增长态势——这个词最早来自OpenAI首席财务官Sarah Friar，意思很直白：需求增速几乎是垂直拉升的。

具体数据印证了这一判断：谷歌每月tokens处理量同比增长7倍，达到每月3.2千万亿（Q）；Anthropic预计二季度末年化收入（ARR）约达500亿美元，较3月底的300亿美元大幅跳升，二季度收入预测为109亿美元，环比增幅约130%；OpenAI一季度单季收入57亿美元，已超去年上半年约43亿美元的总和。

花旗认为，这些数据背后更重要的信号是：企业端AI采用加速仍处于早期阶段，需求的天花板远未到来。

与此同时，Intuit、Meta及Cisco相继宣布裁员，花旗将这些行动解读为AI加速冲击传统生产效率场景的潜在信号，并指出一个核心问题仍悬而未决：AI带来的生产力红利，究竟将流向AI平台、软件厂商、企业客户还是劳动力市场？这一问题正随着基础设施容量的边际收紧而日益紧迫。

推理定价：高端溢价强化，低端竞争加剧




花旗研究的定价跟踪数据显示，AI定价体系正形成明显的双轨格局：**接入层面竞争趋于激烈，但前沿推理定价几乎未见下行压力。**

谷歌将AI Ultra订阅价格从每月250美元下调至200美元，并于5月19日推出100美元/月新档位，面向专业个人用户，提供5倍于Pro套餐的使用限额，并捆绑YouTube Premium。相比之下，GPT-5.5相较GPT-5.4的价格约上涨2倍，叠加AI实验室加速淘汰旧款模型的趋势，显示出头部厂商正通过订阅分层与前沿推理溢价对用户群体进行更精细化的市场切割。


企业端采用在边际上亦承受一定成本压力。据OpenRouter 5月4日对GPT-5.5的成本分析，不同工作负载下成本增幅为49%至92%，部分被输出tokens减少19%至34%所抵消。

Figure 11. Accuracy, Cost/Run, and Tokens/Run Across Models



© 2026 Citigroup Inc. No redistribution without Citigroup's written permission.
Source: Citi Research, WeirdML

Figure 12. Closed v. Open Models



供给约束：算力稀缺催生预留定价新模式

供给增速跟不上需求，直接推动了AI算力服务模式的变革。

算力不够用怎么办？前沿AI实验室开始像云服务商一样“预售算力”。OpenAI于5月20日推出“保证容量”方案：企业签1到3年合约锁定算力，承诺消费越多、token折扣越大。Anthropic近期也签下多项类似协议。花旗指出，这本质上是把AI算力当“云资源”卖——预留实例、算力即服务，提前锁定稀缺产能。

分析师还特别指出，前沿能力供给中最严峻的约束，依然在于人才层面。比芯片更难抢的是人。顶尖AI研究员Andrej Karpathy刚刚加入Anthropic——这类顶级人才的流向，往往比算力更能预示前沿能力的下一站。

~~~~~

以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入【[追风交易台·年度会员](#)】



# 追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

## 什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

## 在这里，你将看到

### 最专业的解读

来自全球顶尖投行、研究机构、  
一线从业者的最新解读



### 最独到的视角

以全球市场第一线的视角  
感知市场动向



### 最适时的时机

快速、完整、准确  
最终汇集成适时



## 如果你

关心全球宏观经济和资本市场

## 如果你

苦恼于没有合适的信息和研究



关注“追风交易台”  
成为“追风会员”

你将身处全球市场第一线

公众号 · 追风交易台

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

\* 体验资格每人限申领一次

扫码  
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

115 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论