

摘要：

GPT-5.6 Sol本周四正式发布，编码基准Terminal-Bench 2.1上以91.9%登顶，推理效率超越Claude Mythos。定价5美元/百万Token输入，ultra多智能体模式突破单一模型上限；7月将登陆Cerebras硬件，推理速度最高达750 Token/秒。OpenAI投入70万GPU小时红队测试，全力护航史上最强旗舰上线。

OpenAI即将推出其最新旗舰模型，标志着AI能力与商业化部署进入新阶段。

OpenAI首席执行官Sam Altman周三在社交媒体上宣布，GPT-5.6 Sol将于本周四正式发布。这是GPT-5.6系列中的旗舰模型，搭载全新ultra多智能体模式与max推理强度，在编码、生物学和网络安全等核心基准测试中均刷新最佳纪录。



Sam Altman  
@sama



GPT-5.6 sol launches thursday!

happy building

[使用DeepL翻译](#) 

12:15 PM · Jul 8, 2026 · 396.2K Views

在定价方面，Sol定价为每百万Token输入5美元、输出30美元，位居GPT-5.6系列三款产品的最高端。OpenAI同时宣布，将于7月在Cerebras硬件上推出Sol，推理速度最高可达每秒750个Token。


此次发布采用分阶段策略，初期仅向部分可信合作伙伴开放API和Codex访问权限，OpenAI计划在未来数周内向更广泛用户普及GPT-5.6全系列。

旗舰性能：Sol Ultra以91.9%领跑行业

在编码基准Terminal-Bench 2.1上，GPT-5.6 Sol Ultra以91.9%的得分位居第一，GPT-5.6 Sol以88.8%紧随其后，竞品Claude Mythos 5以88.0%排名第三，差距约为0.8个百分点。Gemini 3.1 Pro Preview以70.7%垫底，与第一梯队差距明显。




TerminalBench 2.1




从梯队分布来看，GPT-5.6 Sol Ultra与Sol构成第一梯队；Claude Mythos 5、GPT-5.6 Terra和Claude Fable 5均在84%以上，形成第二梯队；GPT-5.5和GPT-5.6 Luna属于第三梯队。

在成本效率维度，GPT-5.6 Sol在相同API成本下持续取得最高得分，性价比居系列之首。GPT-5.5和GPT-5.6 Luna则呈现明显的“成本瓶颈”——增加投入带来的性能提升十分有限。

GeneBench v1



在推理能力方面，随着输出Token数量增加，GPT-5.6 Sol的得分提升斜率最陡，说明其能最有效地利用复杂推理过程改善输出质量；Luna曲线则相对平缓，即使增加输出量，质量提升也十分有限。



全新模式：Ultra多智能体架构超越单一模型上限

GPT-5.6引入两项关键技术升级。其一是max推理强度，赋予Sol充足时间进行深度推理；其二是ultra模式，通过调用子智能体协同工作，突破单一智能体的能力边界，专为加速复杂任务设计。

在生物学领域，Sol在评估长周期基因组学和定量生物学分析的GeneBench v1基准上，以更少Token取得了优于GPT-5.5的结果，显示出更高的计算效率。

在网络安全领域，Sol在ExploitBench基准上仅使用约三分之一的输出Token，即可与Claude Mythos Preview竞争。在由UC Berkeley研究人员与OpenAI及其他前沿实验室合作创建的ExploitGym基准上，GPT-5.6 Sol、Terra和Luna三款模型均随推理强度提升展现出网络安全能力的显著增长。

OpenAI表示，Sol更擅长帮助用户发现并修复漏洞，而非可靠地执行端到端攻击，并强调其优先目标是确保这些能力惠及防御者。

三级产品矩阵：价格覆盖不同需求层次

GPT-5.6系列采用全新命名体系，以数字标识代际，Sol、Terra、Luna代表三个可独立演进的能力层级，旨在为用户和开发者提供更清晰的智能、速度与成本选择。

定价方面，Sol为输入5美元/百万Token、输出30美元；Terra为输入2.50美元、输出15美元，约为Sol的一半；Luna为输入1美元、输出6美元，是系列中成本最低的选项。OpenAI指出，Terra的性能可与GPT-5.5竞争，成本仅为后者的一半；Luna则以最低成本提供基础能力。

在缓存机制上，GPT-5.6引入更可预测的提示缓存，支持显式缓存断点和30分钟最低缓存生命周期。缓存写入按未缓存输入费率的1.25倍计费，缓存读取享受90%折扣。

此外，OpenAI计划7月在Cerebras上推出GPT-5.6 Sol，推理速度最高达每秒750个Token，初期访问权限将限于部分客户，随容量扩展逐步放开。

安全机制：分层防护栈配合700万GPU小时红队测试

鉴于Sol在网络安全领域的强大能力，OpenAI为GPT-5.6系列配备了其迄今最稳健的安全防护体系，并采用分阶段发布策略。

防护体系采用多层架构，包括训练层面的模型级拒绝机制、生成过程中的实时网络安全与生物学滥用分类器、账号级行为审查，以及差异化访问控制。对于高风险请求，系统可在生成过程中暂停输出，由更大的推理模型审查上下文，并在内容到达用户前予以拦截。

在压力测试方面，OpenAI投入超过70万个A100等效GPU小时用于自动化红队测试，专注于发现可跨多种提示和上下文生效的通用越狱攻击，并辅以第三方人类专家红队测试。

根据OpenAI的准备框架，GPT-5.6 Sol未跨越网络安全“危急”阈值。在涉及Chromium和Firefox的评估中，Sol识别出了漏洞和利用原语，但在测试条件下未能自主生成可用的完整攻击链漏洞利用。

OpenAI表示，此次先行向可信合作伙伴开放的有限预览，是与美国政府持续沟通的一部分，但同时明确表示“不认为这种政府访问流程应成为长期默认做法”，并将与政府合作制定面向未来模型发布的可重复流程。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

VIP会员·7天畅读卡 | 大师课·入门串讲

免费领取

限免

39

收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论