

摘要：

AI投资正从“拼GPU算力”转向“全栈系统效率”。智能体时代，瓶颈已从算力变为编排：GPU决定能不能做，系统决定能不能赚钱。下一轮超额利润将加速流向CPU、内存及载板等扩产最慢的供应链环节，基础设施重定价的大幕已然拉开。

AI投资的主叙事，正在发生一次深层且不可逆的结构性迁移。

如果说过去两年市场围绕的是“谁拥有更多GPU、谁就拥有未来”，那么现在随着AI从“生成内容”走向“自动执行任务”，整个产业的核心矛盾，正在从“算力不足”转向“系统效率不足”，而对应的投资逻辑，也将从“单芯片算力竞赛”扩展为“全栈系统工程”。

据追风交易台，摩根士丹利研究部分析师Shawn Kim在报告中直接写道，“智能体AI标志着从计算到编排的结构性转变。”在智能体工作流中，CPU侧编排时间可占总时延的50%至90%，由此推导出到2030年新增325亿至600亿美元的CPU增量市场空间，并将服务器CPU总TAM推至825亿至1100亿美元量级。在2030年将额外催生15至45EB的DRAM需求，规模相当于2027年全行业年供给的26%至77%。

与此同时，DRAM、ABF载板、晶圆代工、存储、连接器与被动元件等环节，均将从“配角”跃升为新的瓶颈与利润池。

这一判断对市场意味着：AI资本开支的受益者将从少数芯片巨头扩散至整条全球供应链，下一轮超额收益，可能更多来自那些在智能体工作流中最先成为瓶颈、且最难快速扩产的“使能环节”。随着瓶颈在不同环节迁移，AI价值链的权重分布随之改变。

AI到底在优化什么？

在理解这份研报之前，必须先回答一个更底层的问题：AI系统真正优化的目标是什么？

在生成式AI阶段，答案很简单——模型能力，即“能不能生成更好的内容”。这对应的核心指标是：模型规模（参数量）、训练效率（FLOPs）、推理性能（tokens/s）。

因此，GPU成为绝对中心，NVIDIA 也自然成为这一阶段的最大受益者。

但当AI进入“智能体”（Agentic AI）阶段后，目标函数发生了根本变化。系统不再只需生成内容，而是需要完成任务，这意味着评估标准从“能力”转向“效率”：单位任务成本（cost per task）、系统延迟（latency）、吞吐能力（throughput）。

这一变化直接导出一个关键结论：GPU决定“能不能做”，但CPU与系统决定“能不能赚钱”。

结构性转折：从“生成”到“行动”，瓶颈从算力转向编排

生成式AI的典型工作流结构相对简单：用户请求到达后，CPU完成少量预处理，GPU负责token生成，随后输出结果。在这一链路中，GPU承担了绝大多数价值，CPU仅作为辅助存在。

然而，智能体AI的工作流完全不同。一个完整任务往往需要经历规划、检索、工具调用、执行、反馈与再决策等多个阶段，同时还涉及多智能体协作、权限管理、状态持久化以及持续调度。

智能体带来的不是更“重”的单次推理，而是更多步骤、更多状态、更多协调，而这些工作天然更适合CPU处理。

换言之，AI的主要矛盾，正在从“算不动”，转向“调不动”。

由此带来两个直接后果：其一，集群层面CPU与GPU的配比将系统性上升；其二，DRAM从“容量配置项”升格为“性能与吞吐的核心系统组件”。数据中心的瓶颈将越来越多地出现在内存带宽、数据搬运、互连时延与系统级协调，而非单纯的GPU算力。


CPU重估：从“1:12”走向“1:2”乃至反转

过去，“1颗CPU服务约12块GPU”曾是AI服务器的典型架构描述。但报告指出，随着智能体 workflow 变长、工具调用与上下文管理趋于复杂，这一比例正在快速收窄。

以NVIDIA路线图为例，更新估算显示：在Rubin平台附近，CPU与GPU的配比已接近1:2；若向Rubin Ultra等更激进形态演进，甚至可能出现2颗CPU对应1颗GPU的反转配置。即便仅从1:12改善至1:8，对超大规模部署而言，CPU的绝对需求量也将出现量级跳升。

一旦这一方向成立，CPU的需求弹性将从“跟着服务器出货走”转变为“跟着智能体复杂度走”，这意味着CPU需求的增长将更具结构性，而非仅仅是传统硬件换代周期的延续。

Exhibit 3: Cluster-level CPU:GPU intensity rises as AI moves from reasoning to action




CPU TAM重算：2030年825亿—1100亿美元，增量来自编排

摩根士丹利采用“系统分层”方法，将智能体带来的CPU机会从传统服务器更新换代逻辑中剥离，建立三个独立分析口径：

- **Head Node CPU**对应贴近GPU系统的机架控制层，以2030年全球约500万颗AI加速器、每颗加速器配2颗高端CPU、CPU平均售价约5000美元为假设，对应约500亿美元TAM。
- **Orchestration CPU**覆盖智能体编排新增需求，包括规划与调度、工具链、RAG管线、KV cache与向量库相关内存服务、策略与可观测性等。算额外新增1000万至1500万颗CPU、ASP约3000美元，对应300亿至450亿美元TAM。
- **Other CPU**涵盖存储节点、部分网络节点等，对应约25亿至150亿美元。

Exhibit 4: Agentic AI could add \$32.5-60bn CPU opportunity...



三项合计，2030年服务器CPU总TAM约825亿至1100亿美元，其中智能体带来的增量约325亿至600亿美元。整个测算的底层锚点是对2030年全球AI数据中心基础设施销售额约1.2万亿美元的判断（2025年约为2420亿美元）。

报告同时给出了“上修开关”：若按NVIDIA口径，2030年AI基础设施销售额达到3万亿或5万亿美元，则CPU TAM区间将被整体推至2060亿至2750亿美元，乃至3440亿至4580亿美元。**这并非基准预测，但揭示了“AI工厂”规模扩张对CPU需求的系统性放大效应。**

内存跃迁：从容量配置到性能核心


如果说CPU是系统的“控制中枢”，那么内存则正在成为系统的“运行空间”。在智能体架构下，大量状态信息需要被持续保存与快速调用，包括上下文数据、KV cache、工具调用中间态以及多任务并发数据集。

因此，DRAM不再只是容量配置项，而是直接决定系统吞吐能力的核心组件。

根据测算，到2030年，智能体将额外催生15至45EB的DRAM需求，相当于2027年行业年供给的26%至77%。这一增长将推动内存行业从传统的强周期属性，向结构性成长转变。以 SK hynix 和 Samsung Electronics 为代表的厂商，有望在这一过程中获得更稳定的盈利预期。

更值得关注的是，内存正在成为AI系统中最具“持续变现能力”的层级之一。无论是主机DRAM、内存接口芯片，还是CXL扩展与分层存储体系，都将成为承接长期价值的重要载体。

Exhibit 5: ...and 15-45EB of DRAM demand by 2030




Source: Morgan Stanley Research estimates

供给越紧的环节越具定价权：ABF载板、代工与使能组件

相比CPU与内存，更具超额收益潜力的，往往是那些“产能扩张缓慢、验证周期较长”的使能环节。

ABF载板：这轮AI驱动的ABF上行周期可能延续至本十年末，2026至2027年附近存在供需缺口风险。仅“CPU TAM扩大”一项，就可能带来2030年ABF需求5%至10%的上修；其中服务器CPU ABF载板市场到2030年约达47亿美元，CPU带来的增量需求约12亿美元。

Exhibit 7: We estimate agentic AI could drive 5-10% incremental ABF substrate demand upside by 2030 from the enlarged CPU TAM alone



Source: Prismark, Morgan Stanley Research estimates (e)

晶圆代工（尤其先进制程）：CPU代工可服务市场2026年约330亿美元，2028年约370亿美元。台积电在CPU代工领域的份额预计从2026年约70%进一步提升至2028年的约75%；并预计英特尔可能在2027年下半年开始将服务器CPU外包给台积电。

BMC与内存接口：Aspeed被强调为CPU服务器BMC的核心受益者，其在该细分领域约有70%的市场份额，新一代AST2700平台带来40%至50%的ASP提升空间；Montage则被置于“内存互连”价值链，全球收入份额约36.8%。

CPU Socket与被动元件：报告以Lotes与FIT作为CPU socket的直接映射，测算每增加100万颗CPU需求，Lotes收入约增加0.6%、FIT约增加0.2%（仅按socket口径计）。被动元件方面，以“每台通用服务器约30美元MLCC内容量”为简化假设，推算出2030年额外5亿美元MLCC需求增量，约占届时全球MLCC市场的2%至3%。

这些环节的共同特点在于：它们处于AI系统的数据流路径之中，一旦成为瓶颈，就具备较强的定价权。以 Samsung Electro-Mechanics 为代表的封装与载板企业，正是这一逻辑的典型体现。

这一现象可以总结为一句话：

AI的利润，将流向最慢扩产的环节。

市场错配与投资节奏：从集中到扩散

尽管产业逻辑已经发生变化，但资本市场仍在很大程度上停留在“GPU中心叙事”中。这种错配意味着，未来一段时间内，资金将逐步从高度集中的算力资产，向更广泛的基础设施环节扩散。

从投资节奏来看，可以大致分为三个阶段：

- GPU主导阶段（已发生）：算力供给成为核心矛盾
- 系统瓶颈暴露阶段（正在发生）：延迟与成本问题凸显
- 基础设施重定价阶段（即将展开）：内存、CPU与互连全面受益

在这一过程中，超额收益将不再集中于单一公司，而是分布于整个系统链条之中。

结语：AI进入“系统效率时代”

综合来看，这份研报真正揭示的，并非某一个细分赛道的机会，而是AI产业逻辑的整体跃迁。人工智能正在从“算力驱动”迈向“效率驱动”，从“模型竞争”走向“系统竞争”。

在这一新阶段中，决定胜负的不再是单一组件的性能极限，而是整个系统的协同效率。GPU依然重要，但它只是系统的一部分；真正的定价权，将属于那些掌握调度能力、控制数据流并处于关键瓶颈位置的参与者。

对于投资者而言，这意味着必须完成一次认知升级：从寻找“最强芯片”，转向理解“最关键系统”。只有把握住这一逻辑迁移，才能在AI的下一轮周期中，真正捕捉到持续且结构性的超额收益。

~~~~~  
以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入 [【追风交易台·年度会员】](#)

# 追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

## 什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

## 在这里，你将看到

### 最专业的解读

来自全球顶尖投行、研究机构、  
一线从业者的最新解读



### 最独到的视角

以全球市场第一线的视角  
感知市场动向



### 最适时的时机

快速、完整、准确  
最终汇集成适时



## 如果你

关心全球宏观经济和资本市场

## 如果你

苦恼于没有合适的信息和研究



关注“追风交易台”  
成为“追风会员”

你将身处全球市场第一线

公众号 · 追风交易台

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

\* 体验资格每人限申领一次

扫码  
免费领取

VIP会员 · 7天畅读卡 | 大师课 · 入门串讲



限免

304 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论