

摘要：

模型越强，用户越愿意把编程、搜索、测试等复杂任务交给AI，Token消耗也随之暴增，增速甚至超过成本下降的速度。算力压力之下，AI公司开始从“不限量”转向按额度收费，商业模式也从“卖模型”转向“卖调用”。

最近，有读者发来一条智谱的公告。

用了几个月的老套餐，要没了。

此前那个“不限周额度”的GLM Coding Plan，将停止自动续订，智谱给老用户补偿两个月新套餐。

老套餐迁移及补偿方案公告

感谢大家一直以来对GLM Coding Plan的支持。

GLM Coding Plan 的持续成长，离不开每一位用户的信任与支持，这也激励着我们尽力优化Coding Plan的体验与GLM模型的代码质量。随着使用规模的持续增长，老套餐（无周限额）原有的供给方式已难以支撑长期稳定的服务，我们不得不对该套餐做出调整。

这项变动会影响部分长期订阅的用户，我们深知这不是令人愉快的消息，也非常理解大家可能因此产生的失望，在此向各位致以诚挚的歉意。考虑到受影响用户大多是较早支持GLM Coding Plan的用户，我们将为大家赠送2个月同等级的新套餐权益。


1. 受影响用户范围：当前订阅老套餐（无周限额）且已开启自动续订的用户。
2. 迁移说明：老套餐将于2026年4月30日10:00（北京时间）起停止自动续订，当前订阅周期的价格和权益不受影响。赠送2个月的新套餐权益将于4月30日自动发放。后续如需继续使用GLM Coding Plan，可自行订阅届时线上提供的最新套餐方案。

希望这份补偿的心意能陪伴各位平稳完成过渡。再次感谢每一位用户在早期对我们的信任与支持，我们会继续努力，把产品做得更好。

几个月前，AI编程市场还在比谁家套餐更便宜；到了现在，大家开始比另一个东西：

你到底能用多少Token。

9月2日，智谱正式入驻天猫，开设官方旗舰店，上架GLM Coding Plan。个人版Lite月付118元、Pro月付538元、Max月付1078元，分别对应不同的积分额度；产品基于GLM-5.3，并适配ZCode、Claude Code、Codex等20余款主流Agent。



这意味着，一件过去听起来非常“技术”的东西，开始进入电商货架：

AI的使用额度，可以像手机流量一样被直接购买。

但这里真正值得关注的，并不是“智谱上天猫卖Token”这件事本身。

而是一个看起来有些反常识的变化：

Token越来越便宜了，AI公司却开始越来越在意你用了多少Token。

大家都开始限量了

过去几个月，AI行业出现了一个非常有意思的变化。

Kimi曾因为算力压力暂停C端新用户订阅。7月19日，月之暗面公告称，Kimi K3上线后请求量大幅超出预期，已经逼近现有集群承载极限，因此暂停C端新用户订阅，把算力优先留给已经付费的用户。

致Kimi用户： 关于算力紧缺与会员暂停开放的说明

尊敬的 Kimi 用户：

自 Kimi K3 发布以来，我们收获了远超预期的支持，但也面临始料未及的算力挑战。过去 48 小时，用户请求量已大幅超出我们的预估，并且逼近现有集群的承载极限。

为了保障已有订阅用户的体验，我们决定即日起，暂停 C 端新用户订阅，将已有算力全部投入于服务已订阅用户，保障已订阅用户的全部权益不受影响。同时，我们已在全速推进算力扩容。随着新算力陆续到位，我们将逐步开放更多订阅名额直至全面恢复正常订阅。

对于后续新订阅用户，我们将拆分 Kimi 主权益（包含 Kimi Web, Kimi APP, Kimi Work）和 Kimi Code 权益，以方便更精准匹配算力，保障用户体验。

我们向满怀期待、却没能获得期待中体验的朋友郑重道歉，也对给予我们理解和包容的朋友深表谢意。

Kimi 团队
2026 年 7 月 19 日

阿里云也在调整Coding Plan。其Lite套餐从3月20日起停止新购，4月13日起停止续费和升级。

腾讯云则在3月调整部分混元模型价格。其中，HY2.0 Instruct输入价格从每千Token 0.0008元提高到0.004505元，涨幅超过460%。

AI为什么突然不再“大方”了？

过去20年，互联网产品给人的最大经验是数字化之后，边际成本会越来越低。

手机流量就是最典型的例子。基站、光纤和网络基础设施建好以后，多传1GB数据的边际成本非常低。随着基础设施规模扩大，流量价格一路下降。

所以很多人自然会把这套逻辑套到AI上，芯片越来越强，模型越来越高效，单位Token的推理成本越来越低，那么AI应该越来越便宜。

事实上，这个判断的前半句完全正确。

智谱自己披露，随着模型架构和推理基础设施持续优化，其单位Token推理成本较年初下降80%。公司还称，目前已经实现10万级国产芯片规模化低成本推理。

问题在于，Token便宜了，但Token的消耗速度增长得更快。这才是今天AI行业真正的矛盾。



Token不是普通的数据流量。

一枚Token背后，是模型推理所消耗的计算资源，是GPU或AI加速芯片、高带宽内存、网络、存储，以及数据中心里的电力和散热。

Token更像是AI算力被计量、被交易的一种单位。

当模型只是陪你聊天时，一次调用可能只需要几百、几千Token。但当你让AI替你完成一个复杂任务，它的消耗就完全不同了。

从“卖模型”到“卖调用”

智谱最新半年报，把这个变化写在了财务数据里。

2026年上半年，智谱实现营收9.54亿元，同比增长399.7%。上半年，智谱MaaS开放平台及API业务收入达到8.25亿元，同比增长2735.7%，占总收入的86.5%。



而去年同期，这一比例只有15.2%。与此同时，本地化部署收入占比从84.8%下降到13.5%。

一年时间，智谱的商业模式几乎完成了一次换挡。

过去，客户买的是模型。模型部署到企业自己的服务器里，进行定制、集成和交付，一次项目往往对应一次收入。

现在，越来越多客户直接调用云端模型。调用一次，计一次费，用得越多，付得越多。这就是典型的MaaS生意。

而且，智谱这次的变化并不是简单的“降价换规模”。恰恰相反，它出现了一个很有意思的组合：

Token调用量较年初增长超过40倍；API平均售价提升约101%；单位Token推理成本下降80%；MaaS业务毛利率提升至24.6%。

成本在下降，收入在增长，用户用得更多，平均售价反而还在提升。AI商业化可能正在摆脱最初那种简单的“价格战”。



早期模型能力不够强，平台只能通过低价甚至免费，把用户吸引进来。

但当模型开始能够真正完成代码生成、工具调用、持续执行等复杂任务后，用户购买的就不再只是“一个模型”，而是模型替自己完成工作的能力。

这也是为什么智谱管理层把商业模式概括成了一条很有意思的路径：卖模型 → 卖调用 → 卖订阅 → 卖端到端任务结果。

这四步，其实对应着AI商业化的四个阶段。

智谱真正想卖的根本不是Token

过去是Chatbot模式：你问一句，它回答一句。一次可能只需要几百、几千Token。

现在是Agent模式：你说“帮我做一个网站”，它可能需要理解需求、搜索资料、写代码、调工具、跑测试、找Bug、修改、再测试……一个任务可能消耗几十万、几百万甚至更多Token。

再往后是Multi-Agent：一个Agent负责规划，一个负责搜索，一个写代码，一个测试，一个审查。Token需求继续膨胀。

2026年第一季度，全球每周Token使用量暴增250%至22.7万亿。OpenAI平台Token调用量从2025年10月的每分钟约60亿次，飙升至2026年3月底的150亿次，不足半年暴增150%。摩根士丹利报告显示，顶尖大语言模型正经历“非线性的能力跃升”，AI爆炸式增长正碰上系统性的供应瓶颈。

所以真正发生的事情不是Token变贵了，而是每个人开始需要越来越多Token。这可能比单纯涨价更可怕。

经济学里有一个经典现象叫“杰文斯悖论”：

当一种资源的使用效率提高、单位成本下降之后，人们未必会减少使用，反而可能因为它变便宜了而大量增加使用。

AI正在出现类似的情况。

Token越便宜，大家越敢让AI干更多事情；AI越聪明，大家又越愿意把更复杂的事情交给它。

于是，Token消耗形成了一个新的增长飞轮。

智谱上天猫卖Token，看起来是在卖AI额度。但从半年报看，它真正做的是把模型能力变成可以持续计费的云服务。

2025年，智谱主要收入还是本地化部署；到了2026年上半年，MaaS/API已经占收入86.5%。公司将这一演进路径概括为：“卖模型 → 卖调用 → 卖订阅 → 卖端到端任务结果”。

智谱董事会秘书肖磊在财报电话会上直言：“相较收入增速，收入构成的切换更值得关注。”

这种切换意味着商业模式的根本变化——从一次性项目交付，变成持续性的服务收入。而定价逻辑也会随之改变：从“每百万Token多少钱”变成“完成一个任务多少钱”。智谱董事长刘德兵在



电话会上表示：“单点榜单领先很快会被追平，真正重要的是谁能持续用更低成本交付更高智能。”

未来的趋势可能是这样的：

基础Token会越来越便宜，但高级智能会越来越贵。

就像云计算：服务器越来越便宜，但企业买云服务的钱并没有因此消失，因为大家用得更多了。

AI也一样。单Token价格下降≠AI使用成本下降。因为模型越强，大家让它做的事情越复杂。从问一个问题到完成一个任务，再到管理一整套 workflow，Token消耗会不断扩大。

智谱半年报中有一句话值得反复咀嚼：“模型每完成一次能力跃迁，客户购买的东西就向结果靠近一步，本公司的收入结构随之改写一次。”

所以未来真正值得关注的可能不是“1元能买多少Token”，而是一个人、一家公司，每个月到底消耗多少AI智能。

而智谱把Token摆上天猫，可能只是这场“AI计量经济”走向大众的第一步。

本文来源：[创业邦](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

**限时权益申领**

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

 244  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论

1 条评论



MobileUser8023

7小时前 中国湖北省

不降价，订阅用户跑去其他家。
不限量，推理成本亏太多。

👍 0 ↩ 回复

