



摘要：

GLM-5.3 Flash拥有300B参数规模，参数量约为上一代旗舰GLM-5.3的40%，几乎持平 DeepSeek V4 Flash；算力供应商或来自华为、摩尔线程与海光；每百万 token输入0.8 元，输出2.8元，缓存命中价格 0.23 元，为GLM-5.3的十分之一。

智谱发布旨在对标 DeepSeek V4 Flash 的轻量级旗舰模型 GLM-5.3 Flash，调用超过 10 万张国产芯片集群用于该模型推理服务。据《晚点 LatePost》了解，其算力供应商或来自华为、摩尔线程与海光，智谱官方没有评论这一信息。

GLM-5.3 Flash拥有300B 参数规模，参数量约为 GLM-5.3 的 40%，与 DeepSeek V4 Flash 几乎持平。与同代小尺寸模型往往蒸馏自大模型不同，GLM-5.3 Flash 采用与 GLM-5.3 不同的架构设计，具有原生多模态能力，支持图像视频输入，这也是智谱战略聚焦 coding 以来第一次推出具有多模态能力的新模型。

随着 AI 模型能力持续提升，轻量旗舰模型能够负担越来越多的工作任务，这创造了新的增长空间，8 月 DeepSeek V4 Flash 的提价不仅证明了市场强劲需求，也预示了更激烈竞争的到来。

根据《晚点 LatePost》看到的智谱内部评测，GLM-5.3 Flash 的 Artificial Analysis Intelligence 分数为 57 分。这一分数超过上一代旗舰模型 GLM-5.2，和 Claude Opus 4.8 持平，也高于 DeepSeek 旗舰模型 V4 Pro 正式版的 53 分。

GLM-5.3 Flash 每百万 token 输入 0.8 元，输出 2.8 元，缓存命中价格 0.23 元，正好为 GLM-5.3 的十分之一。横向对比调价后的 DeepSeek V4 Flash，其谷时价格分别为 1.5 元、4.5 元和 0.05 元。综合输入和输出成本，GLM-5.3 Flash 在绝大多数常规调用场景下更便宜。

智谱已经表示，上线前两周 GLM-5.3 Flash 会实行半价。

正式发布前智谱已在包括 OpenRouter 在内的第三方开放平台以 Ox Alpha 名义测试，5 天流量累积据悉超过 50 T，由于完全免费，刷新了 OpenRouter 与 OpenCode 流量增长纪录。

这不是智谱第一次以匿名形式发布新模型，今年春节前夕，OpenRouter 上出现一个名为 Pony Alpha 的模型，名字呼应中国农历马年，后来被证明是智谱的 GLM-5 模型。

GLM-5.3 Flash 全栈适配国产算力，线上流量均由国产芯片承接，据悉智谱调用超过 10 万张国产芯片集群用于该模型推理服务。智谱在技术文档中表示，其集群“硬件效率及单位 token 成本已经达到了与主流英伟达 GPU 相当的水平”，但没有明确具体型号。

6 月以来，中国公司争相发布能力接近美国次等级闭源模型的产品。6 月 13 日，智谱发布 GLM-5.2，7 月中 Kimi 的 K3 模型发布，8 月 DeepSeek V4 Pro 正式版发布，智谱则在 8 月 14 日发布 GLM-5.3，其参数与模型结构与 GLM-5.2 完全一致，但性能大幅提升，官方宣称其性能完全基于后训练强化学习。

性能提升的同时，涨价一度占据了叙事的主流。Kimi K3 的输出价格高达 100 元，超过 K2.6 三倍还多。智谱在上半年提价后输出价格也达到 28 元。

在流出的梁文峰录音中，他曾说到，智能需求没有弹性，同一份录音中，他还表示 DeepSeek 只需赚取合理利润，然而 8 月 DeepSeek 全面提价，DeepSeek V4 Pro 从 6 元涨到 13.5 元，



高峰 27 元；DeepSeek V4 Flash 的输出从每百万 token 2 元涨到 4.5 元，高峰时段 9 元。官方理由是算力稀缺，长期低价会侵蚀现金流。

事实证明智能能力需求同样有弹性，特别是轻量级旗舰模型。在保证基本模型能力的同时，用户依旧对价格敏感。涨价后，在另一个第三方开放平台 OpenCode 上，DeepSeek V4 Flash 模型调用量掉了一半，这部分需求成了国产模型厂商新的增长空间。

在美国，被归类为第二梯队的 Meta 和 SpaceXAI 等正将目标对准 OpenAI 和 Anthropic 的最先进模型，而后者价格往往是中国模型的数十倍之多。以 Claude Opus 4.8 为例，官方输出价格为 25 美元，而 GLM-5.3 Flash 海外输出价格则为 0.5 美元。

在中国，模型选择多、能力差距小，厂商不仅要和同行竞争，也要面对开源部署、云厂商赠送额度等，模型难以作为稀缺品定价，更接近标准云服务的价格。因此，中国厂商不断把接近旗舰的模型能力推入低价区间，用价格、开源和兼容性争夺调用量。

不考虑算力采购与研发成本，模型推理是一门毛利很高的好生意，前提是有足够大的需求与足够用的性能。随着 DeepSeek 模型涨价，轻量旗舰模型覆盖的市场区间或将迎来更多竞争者。

本文来源：[晚点LatePost](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

VIP会员·7天畅读卡 | 大师课·入门串讲

免费领取

限免

237

收藏

分享到:

写评论

请发表您的评论

表情

图片

发布评论