

摘要：

智谱GLM-5.3-Flash正式认领神秘模型“牛来”(Ox-Alpha)。该模型测试期间每日100万亿token的流量，全部由超过10万张国产芯片承载，智谱称其成本效率已与英伟达GPU相当。传闻称芯片供应或来自华为、摩尔线程与海光。此外，模型定价为Claude Opus 4.8的1/40。

8月26日，智谱正式确认：此前在开发者社区引发热议的匿名模型Ox Alpha（中文社区称“牛来”），就是其最新发布的GLM-5.3-Flash。模型代号灵感来源于国内近期热映电影《牛来》。

这个模型在正式亮相前，以匿名形式在OpenRouter和OpenCode上免费开放测试，5天内流量累计超过50万亿token，刷新了两个平台的流量增长纪录，当前使用量已超过DeepSeek的两倍以上。但真正引发市场关注的，是智谱随后披露的一个细节：**这些流量，全部由国产芯片承载。**

智谱在官方技术文档中表示，**调用超过10万张国产芯片集群用于该模型推理服务**，“硬件效率及单token成本已经达到了与主流英伟达GPU相当的水平”。



jietang  
@jietang


关注

 翻译自英语 [显示原文](#) 

Ox Alpha = GLM-5.3 Flash
AA = 57 ,
1/100 frontier price,

由纯中国芯片驱动。
在 OpenRouter 上每周提供近 20% 的 token 份额（排名第一）。

感谢大家的支持。



智谱创始人唐杰X账号

半导体研究机构SemiAnalysis随即在X平台发文评论：“所有流量均由国产芯片承载，硬件效率和单token成本已可与英伟达GPU相媲美。继Jalapeño（OpenAI自研推理芯片）昨日宣布之后，CUDA护城河再度受到考验。”



SemiAnalysis @SemiAnalysis · 9小时



But ALL traffic was served on Chinese chips, attaining hardware efficiency and per-token cost comparable to Nvidia GPUs. The cuda moat is being tested once again after Jalapeño's announcement yesterday. (3/3)

Serving at Scale on Chinese AI Chips

Over the past week, we have served GLM-5.3-Flash on a large-scale cluster of Chinese AI chips, supported by a high-bandwidth interconnect and a serving stack optimized for the underlying hardware.

To overcome the relatively limited compute and memory capacity of individual chips, we built a dedicated inference engine for this architecture on top of SGLang. Notably, this effort was accelerated by our GLM-5.3-powered infrastructure agent, which assisted engineers in developing and optimizing kernels, diagnosing performance bottlenecks, and improving the serving stack — creating a feedback loop in which the model helped optimize the system serving the model itself.

These chips are primarily constrained by memory capacity and bandwidth, especially when supporting context lengths of up to one million tokens. This calls for aggressive memory optimization, including compute-for-bandwidth and communication-for-bandwidth techniques tailored to the underlying architecture. Our stack combines intra-node tensor parallelism for Linear Attention and the LM head, ReplaySSM, W8A8 quantization, hybrid INT8/FP8/BF16 cache quantization, and Layer Split.

At cluster scale, our production-grade Encode–Prefill–Decode (EPD) disaggregated architecture separates multimodal encoding, prompt prefill, and token-by-token decoding into independently scheduled and scalable worker pools, enabling efficient and reliable serving across tens of thousands of domestically developed accelerators.

Compared with our initial baseline on the same hardware, we achieved a 3× improvement in end-to-end serving performance, reaching hardware efficiency and per-token cost comparable to mainstream NVIDIA GPUs. This demonstrates that Chinese chips can support frontier-model inference efficiently and economically at scale.



10万张国产卡：从测试到生产

智谱在技术文档中描述了这套国产芯片集群的部署细节。

单张芯片的主要瓶颈在于内存容量与带宽，支持长达100万token的上下文长度尤为困难。为此，智谱在SGLang基础上构建了专用推理引擎，采用W8A8量化、INT8/FP8/BF16混合缓存量化，以及节点内张量并行等技术，并引入生产级Encode–Prefill–Decode（EPD）分离式架构，将多模态编码、prompt预填充和逐token解码拆分为可独立调度的工作池。

智谱称，与同一硬件上的初始基线相比，端到端服务性能提升了3倍。


据《晚点LatePost》了解，这批芯片的供应商或来自华为、摩尔线程与海光。智谱官方对此未予置评，技术文档中也未明确具体芯片型号。

SemiAnalysis在评论中特别指出，此前有观点认为只有顶级前沿实验室才具备每日100万亿token的算力规模，“而这里每日100万亿token的免费流量，全部跑在国产芯片上。”



显示翻译

Ox Alpha has been unveiled as GLM-5.3-Flash, but what's shocking is that the 100T tokens per day is served on Chinese chip. (1/3)



下午10:42 · 2026年8月26日 · 29.8万 查看

模型本身：对标DeepSeek，定价是Claude Opus 4.8的1/40


GLM-5.3-Flash的参数规模为320B总参数，激活参数18B，参数量约为上一代旗舰GLM-5.3的40%，与DeepSeek V4 Flash几乎持平。

性能方面，智谱官方评测显示，GLM-5.3-Flash在Artificial Analysis Intelligence Index (AA综合智能指数) 中取得57分，超过上一代旗舰GLM-5.2，与Anthropic的Claude Opus 4.8持平，也高于DeepSeek旗舰模型V4 Pro正式版的53分。

LLM Performance Evaluation

6 benchmarks: Terminal Bench 2.1, DeepSWE v1.1, Agents' Last Exam, AutomationBench v1.0.6, HLE w/ Tools, GDPVal-AA v2


■ GLM-5.3-Flash ■ GLM-5.2 ■ DeepSeek-V4-Vision-Exp ■ Claude Opus 4.8 ■ GPT-5.6 Terra ■ Gemini 3.7 Flash



定价方面，GLM-5.3-Flash每百万token输入0.8元，输出2.8元，缓存命中价格0.23元，为GLM-5.3的十分之一。上线前两周实行半价。

智谱表示，GLM-5.3-Flash定价为GLM-5.3的1/10，限时折扣内为GLM-5.3的1/20，为Claude Opus 4.8的1/40。

与调价后的DeepSeek V4 Flash相比（谷时输入1.5元、输出4.5元），GLM-5.3-Flash在绝大多数常规调用场景下更便宜。




架构创新：激活参数和层数近乎减半

GLM-5.3-Flash采用了与GLM-5.3完全不同的架构设计，这也是其能够以更低成本实现更高性能的核心原因。

与GLM-4.5相比，GLM-5.3-Flash总参数量相近（355B vs. 320B），但激活参数量从32B降至18B，层数从92层减至45层，几乎减半。

智谱称，GLM-5.3-Flash是首个采用稀疏注意力与线性注意力混合架构的开源前沿模型。相较于GLM-5.3，其注意力计算量与KV缓存大小分别降低了3.01倍和4.44倍。

此外，该模型是GLM-5系列首个原生多模态模型，支持图像和视频输入，也是智谱战略聚焦coding以来首次推出具备多模态能力的新模型。



涨价潮中的低价突围

GLM-5.3-Flash的发布，发生在中国AI模型市场一轮集体涨价之后。

Kimi K3输出价格高达每百万token 100元，超过前代K2.6三倍以上；智谱上半年提价后输出价格也达到28元；DeepSeek V4 Pro从6元涨至13.5元，高峰时段27元；DeepSeek V4 Flash输出价格从2元涨至4.5元，高峰时段9元。



涨价的直接后果是需求外溢。《晚点LatePost》指出，DeepSeek V4 Flash提价后，在OpenCode平台上的调用量下滑了一半，这部分需求成为国产模型厂商新的增长空间。

GLM-5.3-Flash的定价策略，正是瞄准了这一缺口。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码 免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲

限免

855

收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论

7 条评论

Matrix

2小时前 中国上海

可别扯淡了.....智谱比他么的codex还贵

0

回复

Russia

2小时前 中国湖北省

回复 Matrix:

贵还供不应求，说明了啥。有经济学常识的都懂

0

回复

MobileUser3166

3小时前 中国江苏省

美国公司买不到啊!

0

回复

MobileUser8587

4小时前 中国重庆

英伟达半年营收是A股3400家民营企业总和的2倍。吹牛逼一般最好用数学比较有可信度。

0

回复



SoongSzai
10小时前 中国广东省

果真名副其实，手搓牛来，👍

👍 0 ↩ 回复



liss
11小时前 中国江苏省

嘴巴没输过

👍 4 ↩ 回复



阿白 8小时前 中国河北省

回复 **liss**:

至于吗??

👍 1 ↩ 回复