

摘要：

花旗半导体分析师Peter Lee认为，Kimi K3触发“杰文斯悖论”，即技术效率提升降低单位使用成本后，最终资源总消耗不降反升，服务器DDR5和eSSD等通用内存需求仍会增加。美银证券认为，更强的中国开源模型未必会让美国AI巨头削减算力投入，相反模型差距收窄会提高领先者维持优势的成本。

Kimi K3把AI投资者重新带回一个核心问题：模型更便宜、更高效，是否意味着芯片和内存需求下降？花旗和美银证券的答案都偏向否定，效率提升可能释放更多使用量，进而推高总资源消耗。

据追风交易台，月之暗面发布的Kimi K3拥有2.8万亿参数，面向100万token上下文窗口和长周期智能体任务。花旗半导体分析师Peter Lee认为，**即便Kimi K3被广泛使用，服务器DDR5和eSSD等通用内存需求仍会增加。**

美银证券半导体分析师Vivek Arya在7月17日的研究中也指出，美国前沿AI实验室更可能增加算力投入，而不是减少投入。**若中国开源模型持续逼近，OpenAI，Anthropic和Google等领先者需要用更大训练规模，更重推理和更快产品迭代维持差异化。**

这意味着市场对Kimi K3的定价逻辑，不能只看单次推理成本下降。更关键的是，低价模型是否带来更多调用，更长任务链和更多token生成。若答案为是，GPU，HBM，DDR5，eSSD，高速网络和推理系统都可能继续受益。

低价高性能，触发“杰文斯悖论”

花旗将Kimi K3视为AI产业链中“杰文斯悖论”的潜在案例。该悖论的核心是，**技术效率提升降低单位使用成本后，使用量可能大幅增加，最终资源总消耗不降反升。**

Kimi K3的吸引力来自低成本与高性能组合。公开价格显示，缓存命中输入价格为每百万token 0.3美元，输出价格为每百万token 15美元。其完整权重计划于7月27日披露，目标是支持长周期智能体工作。

花旗的判断是，模型降价不会自动减少硬件需求。相反，低成本可能提高开发者和企业调用模型的意愿，推动更多AI智能体部署。智能体任务并非一次性问答，而是在连续任务中不断生成，读取和处理token。调用次数和任务长度上升，会把单位成本下降重新转化为总资源消耗。

因此，Kimi K3对半导体链条的影响，重点不在“单次调用是否更便宜”，而在“总token量是否扩大”。这正是花旗看好服务器DDR5和eSSD需求的原因。

长上下文推理，把压力传导至内存

Kimi K3采用三项关键技术：Kimi Delta Attention，Attention Residuals和Stable LatentMoE。Kimi Delta Attention用于降低100万token上下文窗口的成本，Attention Residuals用于在模型不同深度之间选择性检索表征，Stable LatentMoE则提升稀疏化程度，每个token仅激活896个专家中的16个。

月之暗面的技术资料称，这套架构使Kimi K3的扩展效率达到K2的2.5倍。高稀疏度和长上下文能力，是其压低运行成本的重要基础。

但花旗强调，这并不等于推理端资源压力消失。Kimi K3仍不是轻量级部署方案，其运行需要多节点集群，超级节点配置超过64颗GPU。**更重要的是，长上下文和智能体任务会推高KV Cache占用，进而增加推理端内存负担。**

KV Cache需求直接关联服务器DDR5和eSSD。DDR5承担高频数据存取，eSSD受益于更大的缓存和数据存储需求。对内存厂商而言，关键变量不是单个模型是否更省算力，而是低价之后模型被调用多少次，每次调用生成多少token，以及智能体任务链被拉多长。

模型逼近，反而抬高算力门槛

美银证券的结论与花旗形成呼应，但关注点更偏向GPU和AI基础设施。Vivek Arya认为，更强的中国开源模型未必会让美国AI巨头削减算力投入。相反，模型差距收窄会提高领先者维持优势的成本。

美银证券指出，如果开源模型持续逼近，OpenAI，Anthropic和Google需要依靠更大规模训练，更多强化学习与合成数据循环，更重的测试时推理，以及更快的产品发布节奏来守住差异化。

这套逻辑不取决于哪一个模型短期领先。大模型排行榜可能快速轮换，但企业真正购买的是稳定，低延迟，高可用的AI输出，以及更低的“每单位有效产出”成本。**当模型能力趋同，竞争压力会传导至底层基础设施，包括GPU，HBM，高速网络和推理系统。**

因此，美银证券认为，Kimi K3这类模型的出现，不应被简单理解为“模型更高效，芯片更少”。更现实的路径是，模型竞争加剧，领先者为了保持距离继续加码算力。

MoE架构改变瓶颈，显存和互连更重要

Kimi K3采用MoE架构，意味着总参数量和每次推理实际激活的参数可以分离。这一变化降低了部分计算压力，但也让基础设施瓶颈从单纯算力，转向显存访问，专家路由，响应延迟和互连能力。

美银证券强调，**MoE推理要求系统更高效地搬运数据，调度专家模块，并连接更大的计算集群。**英伟达提出，现代MoE推理需要更大的GPU域。其测算显示，GB300 NVL72在领先开源模型上的每瓦性能，最高可达到Hopper平台的25倍。

CoreWeave围绕Kimi K2.6的测试也说明，开源MoE模型即使每次只激活部分参数，若要在速度和性价比上保持领先，仍需要经过优化的英伟达GB300/GB200 NVL72基础设施。


这意味着，模型权重可能逐步商品化，但运行模型所需的GPU，高带宽内存，网络互连和推理系统不会失去价值。相反，随着模型调用量扩大，这些环节可能成为竞争更集中的地方。

Token使用仍在扩张，需求端未见顶

美银证券还引用OpenRouter数据指出，模型调用量仍在快速增加。作为连接多家模型实验室的第三方API平台，OpenRouter上的token使用量持续增长，其中中国AI实验室模型的token使用量已经超过非中国实验室模型。

OpenRouter Token Data

Exhibit 1: Token usage continues to proliferate
Weekly token usage on OpenRouter by top AI lab




这一数据不能直接代表所有企业和消费者场景，但它至少显示，开发者在开放模型生态中的选择正在变化。模型价格下降和能力提升，可能推动调用量继续扩张，而不是被单一模型的效率提升抵消。

企业付费使用也在增加。Ramp数据显示，截至2026年6月，约55%的美国企业已付费订阅AI模型，平台或工具，高于美国人口普查局BTOS调查的21%估计。按模型看，Anthropic企业采用率为42.4%，OpenAI为39.5%。

不过，AI支出仍高度集中。头部1%的企业用户，平均每名员工每月AI支出约4833美元，前10%为516美元，整体中位数仅为11美元。科技与媒体行业订阅率达到79.8%，大型企业采用率为65.5%，高于中型企业的61.3%和小型企业的48.7%。

Exhibit 6: Large size businesses lead adoption rate at 65.5%, followed by Medium (61.3%), and Small (48.7%)
Ramp AI adoption index, business size adoption rate



这组数据支持一个判断：AI使用仍处于扩散过程中。若低价模型降低进入门槛，未来增量需求可能来自更多企业，更多开发者和更多智能体应用。

从“更省算力”转向“更多工作负载”

花旗和美银证券的共同结论是，Kimi K3的意义不在于单一模型是否降低单位推理成本，而在于低成本是否释放更大规模的工作负载。

对花旗而言，最直接的受益方向是服务器DDR5和eSSD。长上下文，KV Cache和智能体任务会提高内存访问与存储需求。对美银证券而言，更重要的是GPU，HBM，高速网络和推理系统，因为模型竞争会迫使领先者继续投入基础设施。

美银证券还提到，Kimi K3涉及“45纳米开源EDA”不应被简单解读为商业EDA被替代。相反，这表明芯片设计仍离不开EDA工具。在先进制程上，Cadence和Synopsys等商业EDA厂商仍处于关键位置。

风险在于另一种情形：如果模型压缩，推理优化和硬件效率提升长期快于新增工作负载，AI基础设施扩张可能阶段性降温。但在当前两家投行的框架下，Kimi K3更像是推高使用量的催化剂，而不是削弱芯片需求的信号。效率提升之后，市场需要关注的反而是更多token，更多推理，以及更多底层硬件消耗。

~~~~~

以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入【[追风交易台·年度会员](#)】

# 追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

## 什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

## 在这里，你将看到

### 最专业的解读

来自全球顶尖投行、研究机构、  
一线从业者的最新解读



### 最独到的视角

以全球市场第一线的视角  
感知市场动向



### 最适时的时机

快速、完整、准确  
最终汇集成适时



## 如果你

关心全球宏观经济和资本市场

## 如果你

苦恼于没有合适的信息和研究



关注“追风交易台”  
成为“追风会员”

你将身处全球市场第一线



公众号 · 追风交易台

#### 风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

\* 体验资格每人限申领一次

扫码

VIP会员·7天畅读卡 | 大师课·入门串讲

免费领取



限免

496

收藏

分享到:

#### 写评论

请发表您的评论



表情



图片

发表评论

#### 5 条评论



见闻用户

1小时前 中国广东省

这些所谓分析师其实是sellers 先有利益立场再有分析引导

1 回复



MobileUser1884

4小时前 中国北京

屁的悖论，不过是新模型发布时的短暂脉冲罢了，其他模型马上就会分流

1 回复



MobileUser9906

5小时前 中国江苏省

实际使用下来并没有便宜多少

0 回复



MobileUser0096 VIP会员

6小时前 中国江苏省

这样早期阶段就开始杀成本，卷价格，不利于行业发展高度



👍 0    ↩ 回复



**GDAI**  
6小时前    中国浙江省

就是浪费资源

👍 1    ↩ 回复