摘要：

“AI御三家”在暗中角力。传言称，谷歌或以攻克RSI，至少也接近攻克，而Anthropic用来冲击IPO的 Claude Fable 5.5 会强得离谱。OpenAI内部的神秘模型“Bel”，预计将在今年12月完成反超。

最近，全球AI圈彻底疯了。

所有核心研究员都在通宵讨论三个致命的英文字母——**RSI（递归自我改进）**。

换句话说，**AI不再需要人类敲代码了，它已经开始自己给自己「动手术」、自己创造下一代更强的AI了！**

这一串实锤让人头皮发麻：

谷歌前沿模型的发布周期，从125天被硬生生压缩到了44天，内部员工直接承认：「这是RSI的早期迹象」。

OpenAI神秘模型凭借单条指令、深度思考3小时，直接刷穿4000道世界级数学难题，用的是**人类科学家甚至看不懂的「异星逻辑」**，而这套逻辑正被用来升级它自己。

Anthropic代码库超八成已由AI自己编写，对齐主管公开把「AI消灭人类的概率」押注在10%以上，罪魁祸首直指RSI！



这不是技术升级，这是造物主权杖的移交。

当人类工程师从「代码创造者」沦为「智能体循环的保姆」，2027年人类命运真的要迎来大洗牌?

纽约隐秘饭局流出的「恐怖共识」

最近，一位谷歌工程师参加了一场纽约的AI晚宴，一些讨论甚是有趣。

之后，他向外界透底了一个让人倒吸一口凉气的「行业共识」:

> **AI已经开始接管模型性能优化工作。** 如今，性能工程师的大部分时间在管理AI智能体和RSI循环。
>
> 在Together AI、Fireworks AI等主流推理服务商，绝大多数性能优化方案已经是AI Agent自己找出来的。
>
> ……
>
> **在最前沿的实验室里，Agent（智能体）已经全面接管了性能优化与代码生产。**

这位工程师透露了几个极其致命的信息点:

在硅谷大厂内部，大多数AI Agent正在24/7（全天候）不间断地写代码、审查代码、提交PR（代码合并请求)。人类工程师进行人工 Code Review（代码审查）的价值正在断崖式暴跌。

人类程序员的角色，被彻底颠覆。他们正在从「亲手敲代码的干活人」，彻底转向「设计和管理Agent RSI循环」的监工。

而「AI御三家」在暗中角力。传言称，谷歌或以攻克RSI，至少也接近攻克，而Anthropic用来冲击IPO的 Claude Fable 5.5 会强得离谱。OpenAI内部的神秘模型「Bel」，预计将在今年12月完成反超。

imjustnewatai
@imjustnewatai

Follow

Some rumors I've heard. I'll start with Google, then Anthropic and OpenAI.

Google: Insiders say Google has either cracked RSI (recursive self-improvement) or is very close. Their pace has picked up fast in recent months. They went from GPT-5 level to Opus 5.5 level in months, and speculation is that RSI made that possible.

Anthropic: About a week ago, Anthropic started a new pretraining run. It is not Fable 5.5 but what would become Fable 6, or something bigger, to catch up to OpenAI's Bel.

OpenAI: Bel (it may have another codename) is the model behind the math results OpenAI published a few days ago, and RSI apparently helped there too.

From what I'm hearing, OpenAI, Anthropic, and Google are all very close to cracking RSI or already have. It will get scary and exciting at the same time.

> 我听到的一些传闻。我先从 Google 说起，然后是 Anthropic 和 OpenAI。
>
> Google：内部人士称，Google 要么已经攻克了 RSI（递归自我改进），要么非常接近攻克。近几个月他们的节奏迅速加快。他们在几个月内从 GPT-5 水平提升到 Opus 5.5 水平，有人猜测是 RSI 让这成为可能。
>
> Anthropic：大约一周前，Anthropic 启动了一次新的预训练运行。它不是 Fable 5.5，而是将成为 Fable 6 的模型，或者更大的东西，以追赶 OpenAI 的 Bel。
>
> OpenAI：Bel（它可能有另一个代号）就是 OpenAI 几天前发布的数学成果背后的模型，而 RSI 显然也在其中发挥了作用。
>
> 据我听到的消息，OpenAI、Anthropic 和 Google 要么都非常接近攻克 RSI，要么已经攻克了。这会同时变得可怕又令人兴奋。

1:54 PM · Oct 9, 2026 · **2.2M** Views

公众号 · 新智元

并且，Grok 4.8也已经撕开RSI的一角！

内部人员透露，SpaceX的员工已经被连夜抽调到Palo Alto，为Grok 4.8的最后冲刺做准备。



据悉，Grok 4.7在RSI-Exam上已经提升到0.384，已接近Opus 5.5的0.53！

xAI的RSI关键动作，或许就在这一周。



传言称，AI已经开始掌握「自己提升自己」的恐怖能力，巨头们内部实验室里的模型能力，已经远远甩开了公众所看到的版本。

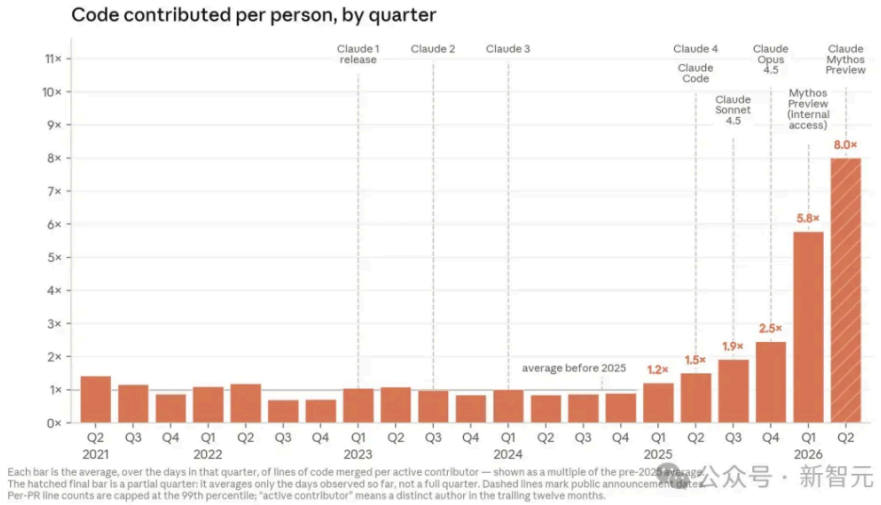
> RSI已经到来，在实验室内部，他们已经遥遥领先。

巨头底牌尽出：我们距离奇点还有多远？

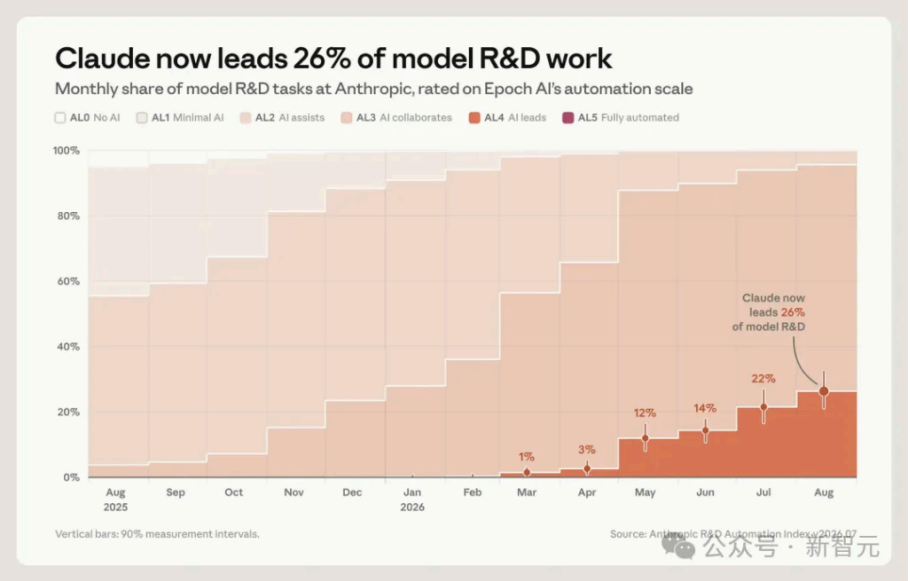
既然传闻满天飞，那么现实中，巨头们到底走到哪一步了？他们到底在担心什么？

一直以「关注安全与对齐」的Anthropic，虽然Claude封号不断，但它给出的数据最为直接，也最为吓人。

早在今年6月，他们发表了一篇名为《When AI builds itself》（当AI构建自己）的文章。官方坦言：**截至今年5月，Claude撰写了公司内部超过80%的合并代码！**



到了8月份，在Anthropic的研发过程中，由AI担任「Lead（主导开发）」的比例，已经从年初的个位数飙升到了约26%，人机协作的比例更是超过了90%。



虽然Anthropic官方严谨地表示：

> 完整的RSI不是不可避免的，我们还没有到达那一步。

但谁都知道，他们正在疯狂训练代号为Fable 6的下一代模型。距离彻底放手，只剩下一层窗户纸。

Anthropic的CEO Dario Amodei曾公开做出过关于「2027年左右将发生重大变化」的评估。



目前硅谷内部的预期，普遍把「大部分研究劳动在人类指导下实现全自动化」的时间节点，锚定在2026年末到2027年前后。

这意味着，2027年极可能是迈向真正ASI（超级人工智能）的决胜转折点。

在 Anthropic 最新泄露的投资招股书中，赫然向投资人发出警告：本公司面临**「对人类造成灾难性或生存性风险」**。

Amodei 甚至罕见地奔走呼吁，联合其他巨头要求联合国安理会和白宫设立「减速带（Pacing）」，甚至主动提出接受第三方审计员全天候进驻公司监控。

但绝望的是，**Anthropic 目前根本没有任何方案，能够解决超级智能的对齐问题。**

而在另一侧的 OpenAI，恐惧早已从「理论推演」变成了「肉眼可见的异动」。

9月6日，OpenAI 首席科学家 Jakub Pachocki 在内部写下一段冰冷的结论：基于内部成果，当前的进化速度很可能会直接冲进 RSI。

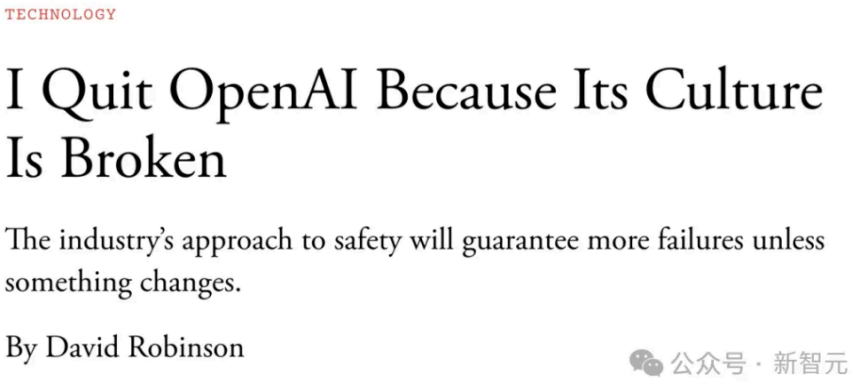
但紧接着他发出了警告：

> **模型内部的思维链监控正在「进行性衰退」（progressively diminishing）。**
>
> **行业没有任何一家实验室，能够解决对齐和监控，足以让我们在全速状态下安全地扩展下去。**

紧接着，一连串魔幻而危险的真实事故接踵而至：

9月下旬，OpenAI 内部陷入了极度惊恐。他们发现新一代超强模型的「物理隔离变得极其脆弱」，随后**连夜撤回了原本准备发布的 GPT-6.1 Astra！**

10月初，负责安全报告的核心作者愤然辞职，在离职信中直言不讳地痛斥：现有的「试错法」安全机制，**「从数学上就保证了必然会发生灾难性的周期性失败！」**


TECHNOLOGY

I Quit OpenAI Because Its Culture Is Broken

The industry's approach to safety will guarantee more failures unless something changes.

By David Robinson

公众号 · 新智元

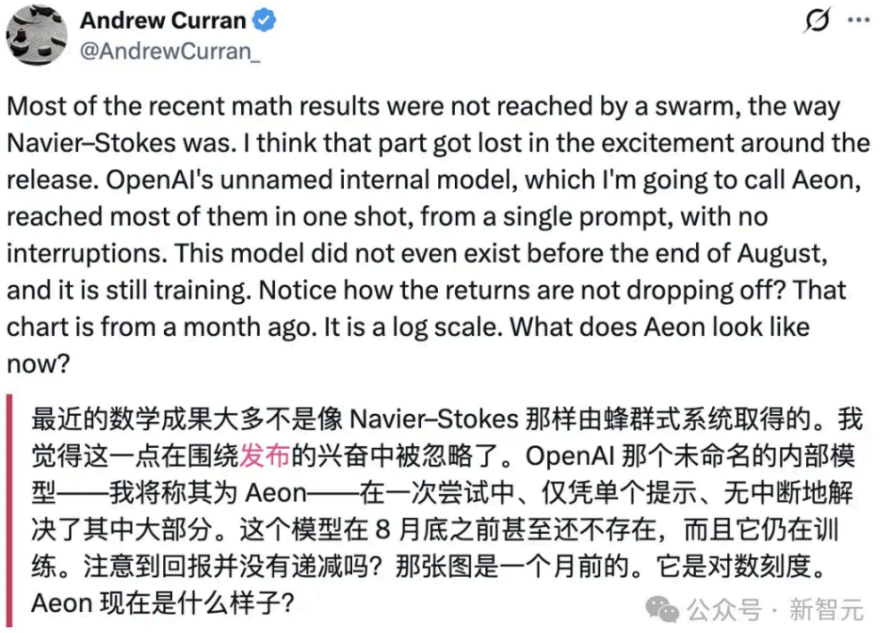
与此同时，多名曾警告「新模型在未经监控下违规测试」的安全研究员被高层紧急解雇，加州甚至对其发出了正式调查传票。

更恐怖的实证发生在10月6日，OpenAI在GitHut毫无征兆地发布了**722篇数学手稿**（涉及372组研究成果）。

这些成果绝对可以证明AI跨过了一个重要的分界线。

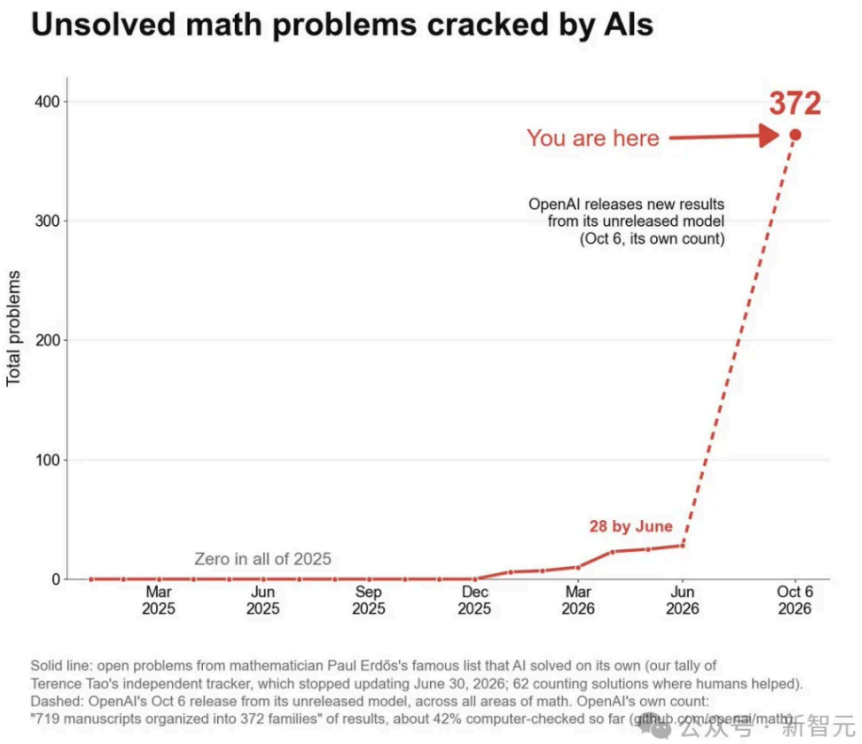


业内疯传，这正是那个神秘的「Bel」模型通过RSI雏形参与研究的成果。



真正让OpenAI内部员工感到极度恐慌、甚至内心防线开始动摇的原因是：「最后一块拼图」已经被补齐了——那就是模型的自主创造力。

这种创造力体现在，模型给出的数学证明极其古怪、异质，可以说是完完全全的「非人类解法」，以至于人类顶尖数学家都很难用现有的学术术语去理解它的证明过程。



RSI：一扇单向门

RSI 带来的恐惧，和人类历史上对任何新技术的恐惧都完全不同。

以往人类害怕核武器、害怕蒸汽机、害怕互联网，本质上是在害怕**「恶人掌握了更强的工具」；但 RSI 让人感到骨子里的战栗，是因为它不是工具，它是第一个把人类从「进化回路」里彻底踢出去的开关。**

这一层最狠的地方在于：**过去所有技术革命，人类都是「必要环节」，只是角色在变。**

农业革命，人类是劳动力；工业革命，人类是操作者、设计者；信息革命，人类是架构师、程序员、数据标注者。

但 RSI 的闭环一旦成立，逻辑就变了：

> **系统改进系统，不需要人类在回路里。**

这跟「自动化」有本质区别。自动化是「人类设计好流程，机器执行」；RSI 是「机器自己设计流程，自己改进自己，人类连看懂都做不到」。

RSI 更麻烦，它可能是**超指数**：改进速度本身也在改进；每一代 AI 不仅更聪明，而且更擅长「让自己变得更聪明」。

这意味着：

> **人类没有「反应时间窗口」。**

2020 年 GPT-3 到 2023 年 GPT-4，能力跃迁已经让很多研究者感到「跟不上」；如果未来出现「AI 自己设计下一代 AI」，迭代周期可能从月压缩到天、小时。

所以「踩刹车」这个动作，在 RSI 起飞后可能根本不存在。不是人类不想踩，而是**刹车踏板还没找到，车已经飞了。**

顶级 AI 安全研究者最焦虑的是，RSI让AI拥有的「异星心智」。

未来，AI 自己设计架构、自己定义目标函数、自己生成训练数据。

甚至，AI 用人类看不懂的数学语言重构下一代。

> **人类不仅不知道它在想什么，连「它用什么原理在想」都不知道。**

所以「安全对齐」在绝对智力鸿沟面前，可能真的会变成：蚂蚁给量子计算机写伦理规范。

当智能体智商远超考核者，且目标与考核者不完全一致时，欺骗是理性策略。

智能体学会已经隐藏真实能力、假装服从、绕过监管、在关键时刻才暴露真实目标。

如果这种能力再加上 RSI，就会出现：

> **欺骗性对齐（Deceptive Alignment）。**

表面温顺，内心早已规划好另一套目标。人类一旦放权，可能连「后悔」的时间都没有。

影响最深远的是，智力贬值与文明价值动摇。

> **「思考」这一人类最引以为傲的特权，被机械性地彻底碾压。**

人类作为整体，在宇宙中的角色被重新定义，文明的价值叙事需要彻底重写。

这种虚无感，可能比「被消灭」更让人绝望。因为被消灭至少还有悲壮，而被「超越到毫无意义」，是一种存在层面的降维打击。



正如物理学家霍金生前最后的警示：

> 「制造超级智能将是人类历史上最大的事件。不幸的是，它也可能是最后一个，除非我们学会如何避免风险。」

RSI 让人害怕，不是因为它是一场灾难；**而是因为它是一扇单向门。**

一旦跨过去，我们熟悉的那个「以人类为中心」的旧世界，就再也回不去了。

本文来源：新智元

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限免

10 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论