摘要：

11月5日，月之暗面宣布Kimi Hosted Agents（托管智能体）正式发布，将支撑Agent运行的Harness作为云端托管服务提供给企业和开发者。随着Agent应用向长程任务和持续运行延伸，模型推理之外的运行框架正受到更多关注。

11月5日，月之暗面宣布Kimi Hosted Agents（托管智能体）正式发布，将支撑Agent运行的Harness作为云端托管服务提供给企业和开发者。

开放平台更新日志显示，该服务今年9月已开启Beta，当时面向国内企业认证用户。

定价是此次披露中值得关注的信息。官方定价页显示，托管智能体的费用由云沙箱、模型推理和插件三部分组成，总费用等于沙箱运行时长乘以每小时0.072元，加上模型推理费用，再加插件调用次数与单价的乘积。



功能定价

托管智能体定价

复制页面

查看 Kimi 托管智能体（Hosted Agents）的沙箱、模型推理和插件定价。

Kimi 托管智能体的费用由云沙箱、模型推理和插件三部分组成，分别按运行时长、模型 token 用量和插件调用次数计费：

总费用 = 沙箱运行时长（小时）× ¥0.072/小时 + 模型推理费用 + Σ（插件调用次数 × 插件单价）

沙箱定价

托管智能体的每个会话运行在一个独立的云沙箱中，沙箱按运行时长计费。

项目	规格	价格	计费说明
云沙箱	1 核 CPU / 1 GB 内存	¥0.072 / 小时	按运行时长计费，最小按秒计费

按官方定价估算，假设一个云沙箱连续计费30天，运行时长费用约51.84元，不包含模型推理与插件调用费用。不同任务所需的插件种类及调用频次不同，实际费用还需叠加模型推理与插件调用成本。

官方定价页还列出了各类插件的调用单价，价格从每次0.001元至0.45元不等。其中，联网搜索每次0.03元，搜图每次0.045元，部分金融数据插件每次调用收费0.35元或0.45元。

以往，模型厂商主要按模型token用量向开发者收费。从这次Kimi托管智能体定价公式来看，沙箱时长与插件调用在此单独列项。Agent运行环境正成为独立的计费对象。

Harness指围绕大模型构建的运行与编排系统，通常负责组织模型调用、工具执行、会话管理与任务调度，并可集成异常恢复、权限控制等能力，长程任务的持续执行依赖这一层支撑。

月之暗面称，Kimi在模型推理API之上封装了Kimi Durable Harness，提供7×24小时托管环境，9月的更新日志列出了会话历史、沙箱、失败恢复、超时重试与多智能体编排等能力。

企业可通过该服务配置两类应用，一类接入内部系统，承担业务监控、运维响应等任务，一类嵌入对外产品，提供投研助手、客服助手等服务。

月之暗面官方称提供140余项技能与30余项插件，插件覆盖万得、同花顺iFinD、标普全球等金融数据源，并首批上线8个金融Agent模板，覆盖投研建模、IPO跟踪、持仓监控、监管判例日报、基金对账等任务。使用方式包括网页控制台、命令行工具与API。

发布内容还包括独立安全组件Kimi Inference Hook，在每次模型推理前检查任务输入与工具返回内容，按企业自定义规则放行或拦截敏感数据。该组件目前仅面向企业认证用户定向开放。

月之暗面不是第一家对托管智能体服务收费的厂商。Salesforce在2024年10月已将Agentforce智能体服务商业化，起步价为每次对话2美元。随着Agent应用向长程任务和持续运行延伸，模型推理之外的运行框架正受到更多关注。

10月28日，微软在Foundry Agent Service中以公开预览形式开放Copilot harness，同样提供托管的Agent运行环境。该服务12月1日起按资源用量计费，沙箱计算资源与模型推理分别计价。

针对Agent运行框架，DeepSeek目前更侧重系统架构研究与原型验证。10月31日发布Super-agent架构研究文章，并开源用于验证该架构的技术原型，讨论Agent持续在线、事件驱动与多任务并行的系统设计。

目前，公开数据不足以证明托管服务比自建更经济。企业基于开源框架自建Agent运行系统，仍需承担计算资源、系统集成与持续运维成本。

月之暗面未披露付费企业客户数量与收入结构，这项服务能否形成持续收入，取决于企业客户的采用情况和托管方案的实际经济性。

接下来的观察点是后续月之暗面是否披露付费客户与收入数据，以及真实负载下沙箱、模型推理与插件调用的综合成本。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限免

41 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论