

摘要：

据研究机构Artificial Analysis测算，DeepSeek新款模型V4-Flash每次任务完成成本仅约3美分，而Claude Fable 5高达3.15美元，前者仅为后者的1/105，刷新了主流大模型的性价比纪录。V4-Flash的推出，标志着AI竞争正从性能比拼转向成本效率之争，也令AI巨额资本开支的回报前景再度成为焦点。

DeepSeek发布最新模型V4-Flash，再次将AI模型的成本竞争推到台前。

研究机构Artificial Analysis最新测算显示，**V4-Flash平均每次任务完成成本仅约3美分，为当前全球主流大模型中最低，仅相当于Anthropic旗下Claude Fable 5的约1/105。**这意味着，在不少通用任务中，企业部署AI应用的边际成本有望进一步下降，也再次引发市场对于AI巨额资本开支回报率率的讨论。

值得关注的是，V4-Flash发布正值DeepSeek商业化进程加速之际。据报道援引知情人士消息，**DeepSeek正筹备潜在IPO。**其通过AI模型API云服务获得的年度经常性收入（ARR）已达4亿至5亿美元，毛利率超过50%。

此次推出的V4-Flash则延续了公司一贯的低成本、高效率路线，进一步强化其以价格和效率驱动市场竞争的策略。

## V4-Flash“每次任务成本”仅3美分，性价比领跑全球主流模型

根据Artificial Analysis的数据，V4-Flash的定价为每百万输入token 0.14美元、每百万输出token 0.28美元。

不过，该机构指出，**相比单纯的标价，“每次任务完成成本（Cost per Task）”更能体现模型的实际使用成本。**这一指标综合考量了模型在完成同一任务时所消耗的输入和输出token总量，因而更具参考意义。

按此口径测算，**V4-Flash平均每次任务成本约为3美分，在全球主流模型中处于最低水平。**

作为对比，Moonshot AI的Kimi K3约为86美分，OpenAI GPT-5.6 Sol约为1.86美元，**Anthropic Claude Fable 5则约为3.15美元。V4-Flash的成本仅相当于后者的约1/105。**

Artificial Analysis进一步强调，单位token价格低的模型，如果在任务执行中需要生成更多内容或经历更多交互步骤，最终使用成本仍可能高于定价更高但效率更优的模型。因此，“每次任务完成成本”比单一价格指标更能真实反映模型的性价比。

## 低价突围，AI竞争从“拼性能”转向“拼性价比”

相比性能排名，V4-Flash此次更受市场关注的是其成本优势。

过去一年，AI行业竞争焦点已逐渐从模型能力扩展至推理成本和商业化效率。**随着企业AI应用规模不断扩大，模型运行成本正成为采购决策的重要考量因素。**

当一款模型能够以约3美分完成一次任务，而部分高端模型成本达到数美元时，企业在部署客服、办公自动化、代码辅助等高频场景时，整体使用成本可能出现数量级下降。



这也再次触及华尔街持续关注的问题：AI巨额资本投入最终能否转化为足够的商业回报。

2025年初，DeepSeek发布R1模型后，市场曾一度重新评估全球AI基础设施投入的必要性，引发科技股大幅波动。如今，V4-Flash再次以极低的运行成本作为核心卖点，意味着AI行业的竞争正进一步从“谁的模型更强”，转向“谁能以更低成本提供足够好的能力”，AI投资回报率的讨论或将再次升温。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

\* 体验资格每人限申领一次

扫码  
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

48 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论