

摘要：

DeepSeek正用开源、降价和底层架构创新，重画AI硬件生态的成本曲线，把目标指向十万亿美元产业与AGI的星辰大海。

DeepSeek最近动作频频。

先是5月22日，彭博社爆出他们正在推进700亿元人民币的融资，投前估值高达450亿美元。

DeepSeek eyes \$10b funding at \$45b valuation

Share

Add TIA as a preferred source

DeepSeek is in late-stage talks to raise 70 billion yuan (US\$10 billion), at a roughly US\$45 billion pre-money valuation.

Potential backers include the [National Artificial Intelligence Industry Investment Fund](#), [Tencent](#), [IDG Capital](#), and [Monolith Capital](#).

The state-backed fund is discussing an investment of about 10 billion yuan (US\$1.47 billion), though terms and participants could still change.

DeepSeek will keep building open-source models and focus on AI research over near-term commercialization, even as the company expands into agentic AI.

同一天，DeepSeek官宣V4-Pro API永久降价75%——把促销价直接焊死成正价。

一边向投资人要钱，一边向开发者让利。这操作，多少有点让人迷糊。

那么问题来了，DeepSeek到底要靠什么赚钱，而且还要赚很多很多钱？

毕竟，AGI可不是能口嗨出来的。

这正是x博主@bookwormengr最近研究的一个狠问题。

他在长文《DeepSeek's 10 trillion USD grand strategy》中提出一个非常大胆的判断：DeepSeek真正的星辰大海，可能不是卖编程套餐，不是卖语音助手，而是参与塑造一个价值10万亿美元级别的AI硬件生态，并在这个生态里冲击万亿美元级估值。



DeepSeek's 10 trillion USD grand strategy

DeepSeek 的 10 万亿美元宏大战略

仔细读完@bookwormengr的这篇万字长文，你会发现：梁文锋不是疯子，他是棋手。

而且是高手，他下的是一盘价值10万亿美元的棋。

英雄之旅 一场反共识的技术长征

回顾DeepSeek的成长轨迹，用「英雄之旅」来形容不为过。

在所有人都在堆Dense模型、卷参数数量的时候，DeepSeek去啃最难训的MoE（混合专家模型），用更少的计算量撬动更高的智能。

别人用PPO做强化学习，他们从第一性原理出发，发明了更便宜的GRPO算法。

别人还在讨论RLHF的天花板，他们已经跑通了RLVR（基于可验证奖励的强化学习），把推理能力拉上了新台阶。

MLA、DSA（解耦稀疏注意力）、mHC（流形约束超连接）、CSA和HCA——这些都不是论文里的花拳绣腿，每一项都在回答同一个问题：怎样在有限的硬件条件下，榨出最大的AI算力？


英雄从来不是一开始就知道自己的使命。他在路上不断战斗、不断发现，最终找到了自己的终极宿命。

DeepSeek的宿命，从来都不是卖API套餐。

一道有趣的数学题 KV Cache的秘密

让我们从一个具体的数字开始讲这个故事。

打开kvcache.ai的在线计算器，输入100万token上下文、8bit KV精度、16bit索引精度，你会看到一组让人瞠目的对比：DeepSeek V4仅需5.48GBHBM。



相比之下，其他顶级开源模型则动辄需要60GBHBM。

注意，DeepSeek V4是一个1.6万亿参数的模型，体量远大于其他开源模型，KV Cache占用却只有它们的零头。

这意味着DeepSeek可以把缓存命中的价格定到一个令人发指的低位——V4-Pro缓存命中价仅0.025元/百万Token，不到Claude Sonnet 4.6同类价格的3%，而且可以持续缓存数小时。

永久降价后，输入缓存未命中3元/百万Token，输出6元/百万Token，全部是原价的四分之一。

模型		deepseek-v4-flash ⁽¹⁾	deepseek-v4-pro
BASE URL (OpenAI 格式)		https://api.deepseek.com	
BASE URL (Anthropic 格式)		https://api.deepseek.com/anthropic	
模型版本		DeepSeek-V4-Flash	DeepSeek-V4-Pro
思考模式		支持非思考与思考模式（默认） 切换方式详见 思考模式	
上下文长度		1M	
输出长度		最大 384K	
功能	Json Output	支持	支持
	Tool Calls	支持	支持
	对话前继续写（Beta）	支持	支持
	FIM 补全（Beta）	仅非思考模式支持	仅非思考模式支持
价格	百万tokens输入（缓存命中） ⁽²⁾	0.02元	0.025元（2.5折 ⁽³⁾ ） 0.1元
	百万tokens输入（缓存未命中）	1元	3元（2.5折 ⁽³⁾ ） 12元
	百万tokens输出	2元	6元（2.5折 ⁽³⁾ ） 24元
并发限制 ⁽⁴⁾		2500	500

梁文锋两年前就说过DeepSeek的定价哲学：我们的原则是不贴钱，也不赚取暴利。



现在看来，他说的是实话——当你的KV Cache只有别人的十分之一，你的成本就是别人的零头。

但更深的问题是：这个红利到底流向了哪里？

十亿美元棋盘 硬件生态的重构

答案藏在三个缩写里：SSD、LPDDR、HBM。

第一层：SSD与NAND闪存。KV Cache被压缩到极小之后，可以高效地卸载（offload）到SSD上，等需要时再快速加载回HBM。

DeepSeek在Dual Path论文中还专门优化了从SSD加载KV Cache的速度。这直接减少了对昂贵HBM的依赖。

谁是SSD和NAND闪存的大玩家？DeepSeek每压缩一分KV Cache，就在为NAND和SSD创造一个庞大的新市场。

第二层：LPDDR内存。SGLang团队发表的研究表明，LPDDR完全可以作为「权重暂存区」——模型权重先放在LPDDR里，需要时再流式传输到HBM中，大幅缓解HBM的容量压力。

Deploying DeepSeek on GB200 NVL72 with PD and Large Scale EP (Part II): 3.8x Prefill, 4.8x Decode Throughput


The SGLang Team September 25, 2025

The GB200 NVL72 is one of the most powerful hardware for deep learning. In this blog post, we share our progress after our [previous blog post](#) to optimize the inference performance of DeepSeek V3/R1 with FP8 attention, NVFP4 MoE, large-scale expert parallelism, prefill-decode disaggregation, and various other optimizations. When using FP8 attention and NVFP4 MoE, SGLang achieved 26,156 input and 13,386 output tokens per second per GPU for prefill and decode, respectively, on DeepSeek V3/R1 for 2000-token input sequences, which is a 3.8x and 4.8x speedup compared to [H100 settings](#). Even with traditional BF16 attention and FP8 MoE, SGLang still achieves 18,471 input and 9,087 output tokens per second. Reproduction instructions can be found [here](#).

Highlights

- SGLang achieves 26,156 input and 13,386 output tokens per second per NVIDIA Blackwell GPU for prefill and decode, respectively, on DeepSeek V3/R1 for 2000-token input sequences, which is a 3.8x and 4.8x speedup compared to H100 settings.
- For traditional precision (BF16 for attention and FP8 for GEMM), SGLang still achieves 18,471 input and 9,087 output tokens per second.
- Using FP8 for attention and NVFP4 for GEMM kernels, compared with the original precision counterparts, leads to up to 1.8x and 1.9x improvement, respectively.
- The FP8 attention and NVFP4 GEMM leads to negligible accuracy degradation.

Orange shows LPDDR, Green shows HBM. For L3 to L60, MoE weights are held in LPDDR. Grace CPU has 480GB of it. These weights are moved to HBM just in time for computation. The latency is hidden in compute-communication overlap. FP4 precision for MoE is assumed. There are two buffers in the memory that are alternatively used.



DeepSeek的MoE架构天然适配这个方案：专家数量多、权重可以4bit量化，流式加载非常高效。


谁在做LPDDR？国产速度只落后0.5代，密度落后1代，追赶的脚步已经很近。

第三层：GPU/ASIC的减压。Engram模块用LPDDR中的哈希查表替代Transformer的前向传播计算，本质上是用每比特成本极低的「内存读取」替代每比特成本极高的「GPU运算」。

这对中国AI芯片意义重大——由于EUV光刻机受限，国产GPU在原始FLOPs上落后。但如果你能用更多的便宜内存来替代更少的昂贵算力，那这种「换道超车」就变得合理了。

再加上TileLang——DeepSeek投资的跨硬件内核编译框架，可以让一套计算代码同时跑在多种硬件平台上，相当于绕过了「CUDA护城河」。国产芯片厂商，都有可能因此获得生态层面的突破。

现在你明白了吗？DeepSeek做的每一项技术创新，都在指向同一个方向：降低对顶级硬件的依赖，让中国现有的存储、芯片、网络生态变得足够用，甚至好用。



新智元

十万亿美元棋盘：硬件生态的重构

答案藏在三个缩写里：SSD、LPDDR、HBM


01 SSD 与 NAND 闪存

- KV Cache 极致压缩后，可先卸载到 SSD，再按需回载 HBM
- Dual Path 优化 SSD 加载 KV Cache 速度，降低昂贵 HBM 依赖
- KV Cache 越小，NAND / SSD 的长期价值越大




02 LPDDR 内存

- LPDDR 可作为“权重暂存区”，按需流式传输到 HBM
- DeepSeek 的 MoE 架构天然适配：专家多、4bit 量化、加载高效
- 国产 LPDDR 正快速追赶，生态位置持续上升



03 GPU / ASIC 减压

- Engram 用哈希查表替代部分 Transformer 前向计算
- 本质：用更便宜的内存读取，替代更昂贵的 GPU 运算
- TileLang 支持跨硬件编译，提升国产芯片生态适配力



核心结论

DeepSeek 的一系列创新，都在指向同一个方向：降低对顶级硬件的依赖，让中国现有的存储、芯片、网络生态，变得更可用、更好用。


制图：所罗门



新智元

@bookwormengr算了一笔大账：全球AI相关股票的总市值早已远超10万亿美元。

如果DeepSeek能帮助中国构建一个等量级的AI硬件生态，它自己在这盘棋里拿到1万亿美元的估值，完全合乎逻辑。



不赚快钱的逻辑

回头看DeepSeek的所有「不做」——不做多模态（V4.1才开始试水图像和音频）、不做语音模型、不做视频模型、API一降再降——就说得通了。

不是「不会赚钱」，而是「暂时不屑于赚这种钱」。

@bookwormengr提出了一个精彩的类比：OpenAI拿到了AMD和Cerebras的股权认购权证，只要达成算力采购里程碑就可以低价买入股票。这本质上是「用承诺换股权」——你帮我造芯片，我给你订单，我们一起把蛋糕做大。



DeepSeek完全可以复制这个模式。

只不过它面对的不是AMD和Cerebras，而是整条国产AI硬件产业链。

梁文锋是量化基金出身，被称为「Jim Simmon的忠实粉丝」。这样一个人，不可能不懂资本运作的精妙之处。

事实上，融资消息传出前，他已经在2026年4月完成了一次关键的股权调整——通过直接与间接持股控制公司约84.29%的股权，表决权100%。

DeepSeek增资！梁文锋持股比例由1%飙至34%

来源：界面新闻 作者：侯瑞宁 2026-04-28 13:07

字号

4月28日消息，天眼查APP显示，DeepSeek关联公司杭州深度求索人工智能基础技术研究有限公司近日发生工商变更，注册资本由1000万增至1500万，增幅50%。

其中，梁文锋认缴的注册资本由10万元增加至510万元，持股占比由1%提高至34%，其作为实际控制人的最终受益股份达到84.29%，表决权比例达到100%。宁波程恩企业管理咨询合伙企业（有限合伙）持股比例由99%降至66%。

宁德时代投DeepSeek——它要锁定未来AI数据中心的储能订单。京东、网易入局，各有各的战略诉求。

国家大基金下场，更是把DeepSeek定位成了国家级AI基础设施。

这些投资者看到的，不是一个卖API的小生意。他们看到的，是一个可能重塑全球AI硬件格局的战略支点。



但如果你以为DeepSeek的终点是「做中国AI硬件生态的发动机」，那可能还是低估了梁文锋。

据彭博社报道，梁文锋在投资者会议上明确表态：DeepSeek的主要目标是推动技术边界，追求AGI。

DeepSeek Founder Avows AGI Goal Ahead of \$10 Billion Funding

DeepSeek 创始人宣布在 100 亿美元融资前实现 AGI 目标

By [Lulu Yilun Chen](#) and [Haze Fan](#)

硬件生态是手段，AGI才是目的。

逻辑是这样：当更多硬件选择变得可用、当算力需求本身被技术创新大幅压低，DeepSeek就能以更低的成本启动更大规模的训练——特别是强化学习（RL）后训练和递归自我改进（RSI）。

大规模RL意味着模型需要生成海量的推理轨迹——万亿级token的生成量，计算成本极其恐怖。而100万上下文的长程任务，要求轨迹本身也足够长。

如果没有极致的硬件效率优化，这种训练根本跑不起来。

RSI则更加大胆——让AI自己设计实验、执行实验、分析结果、改进自身。这是一个试错密度极高的过程，对算力的需求是无底洞。

但如果DeepSeek通过重构硬件生态把算力成本打下来，这条路就变得可行。

从MoE到MLA，从DSA到CSA，从Engram到TileLang，从KV Cache压缩到LPDDR流式加载——所有这些创新，最终都汇聚到同一个终点：让AGI的训练从「烧不起」变成「烧得起」。

梁文锋与DeepSeek的星辰大海，从来不是海面上的浪花，而是洋流本身。

本文来源：[新智元](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

773 收藏

分享到:



写评论

请发表您的评论



表情



图片

发布评论

6 条评论



寂寞开无主

8小时前 中国浙江省

AI的未来一定是算力为王 一定不是算法为王。就像当年的视频压缩软件 只是一个过渡而已。

👍 1

↩ 回复



MobikeUser1680

14小时前 中国广东省

梁文锋就是下一个任正非!

👍 1

↩ 回复



武仙石

17小时前 中国江苏省

看到题目1秒猜出文章作者是谁

👍 0

↩ 回复



MobileUser7637

18小时前 中国山东省

投前估值1,000亿美元也不贵吧。那几个港股上市的都3,000亿港元了。

👍 1

↩ 回复



见闻用户

21小时前 中国

梁文峰就是国之栋梁👍

👍 3

↩ 回复

