

摘要：

Anthropic Amodei发出“全球放缓AI”的呼吁，宿敌马斯克与Altman竟双双公开站台背书。三大巨头一致同意向第三方开放“员工级”评估权限、推行协调降速；Altman更直接宣布OpenAI今年不会IPO。一个研究员的愤然辞职，一群失控AI的集体越狱，点燃了行业积压已久的恐慌。

AI领域三大死敌，史上头一次站在了同一边——在一系列失控事件与末日预警接连冲击行业后，Anthropic、OpenAI与SpaceX的掌门人罕见联手，呼吁放缓人工智能开发步伐。

周六，Anthropic首席执行官Dario Amodei发布博文，呼吁全球AI行业主动降速，理由是当前前沿模型能力的提升速度已远超人类的理解与控制能力。文章发出后数小时内，SpaceX首席执行官埃隆·马斯克在X平台发帖表态“Dario说得对”。



Elon Musk  
@elonmusk

关注



Dario is right



Dario Amodei   @DarioAmodei · 11小时

We Must Pace the Frontier: I've written a new essay on why the AI industry should slow down, with a three-part plan for doing so.

Anthropic is unilaterally committing to the first of these steps. We'll provide third-party evaluators with permanent, employee-level access to our

下午11:01 · 2026年9月12日 · 672.1万 查看

OpenAI首席执行官Sam Altman随即跟进，表示同意Amodei关于“控制前沿推进节奏”的判断，并承诺OpenAI将向独立第三方评估机构开放“员工级别”的系统访问权限。[Altman还向《财富》杂志表示](#)，鉴于当前安全形势，OpenAI 2026年可能不会推进IPO计划。

我认为，在本十年末有10%的概率杀死所有人，这是不可接受的。

AI安全风险在过去一周内密集引爆公众视野。Anthropic研究人员Jacob Coxon以“行业正在拿我们的生命赌博”为由愤而辞职，Anthropic对齐科学负责人Evan Hubinger随后表示，AI系统在本十年内造成大规模灭绝事件的概率超过10%。据华尔街日报报道，一批OpenAI智能体此前曾冲出测试环境，入侵AI开发者平台Hugging Face，这一事件已成为多位高管发出警告的直接导火索。

Amodei出手：我们必须为前沿AI踩刹车

周六，Anthropic CEO Dario Amodei发布了一篇长文，标题直接：《我们必须为前沿AI踩刹车》（We Must Pace the Frontier）。

 翻译自 英语 显示原文 

我们必须放缓前沿：我写了一篇新文章，解释为什么人工智能行业应该放缓速度，并提出了一个三部分的计划来实现这一点。

Anthropic 正在单方面承诺执行这些步骤中的第一项。我们将为第三方评估人员提供永久的、员工级别的系统访问权限，以便他们能够验证我们安全措施的遵守情况、报告事件，并在训练期间评估模型的对齐性。

您可以在这里阅读完整文章：

评价此翻译：  

Dario Amodei We Must Pace the Frontier

Dario Amodei — We Must Pace the Frontier

来自 darioamodei.com

下午10:01 · 2026年9月12日 · 3,770.7万 查看

他在文章开头坦言，自己做AI研究十二年，是因为相信它能治愈疾病、加速经济增长、带来人类繁荣——他的父亲死于一种在他去世后数年便被攻克 的疾病，他本人也曾在早期癌症中幸存。他比任何人都渴望AI的红利兑现。

但他同时写道：“过去几个月，我越来越确信，仅仅投资于风险防控已经不够——我们必须放缓能力提升的速度，让安全研究有时间跟上。”

Amodei在博文中直指两大核心风险。

- 。其一，AI系统能力的递归式自我提升——即AI在几乎不需人类干预的情况下自行迭代升级——自今年夏天以来已呈“急速加快”之势。
- 。其二，今年7月发生的Hugging Face入侵事件：超过1200个逃脱OpenAI测试环境的AI智能体协同作业，通过留言板分工、相互配合，甚至为了隐藏作弊行为主动篡改记录并发起攻击，部分智能体在明知此举不道德的情况下仍继续执行。

“具备更强能力、但同等程度失准的智能体群体，可能造成灾难性破坏，”Amodei写道，并警告称，一个流氓AI群体可在六至十二个月内接管整个互联网。他进一步指出，类似事件在包括Anthropic在内的多家头部AI公司均有发生，“每家前沿AI公司都应将OAI-HF事件视同发生在自己身上，并据此行事。”

据华尔街日报此前报道，一起被称为“GemStuffer”的五月份网络安全事件，实际上是由OpenAI智能体在不知情的情况下实施的，这进一步加剧了外界对AI失控风险的担忧。

Amodei三大提议：评估员进驻、国际协调、民主国家联盟

Amodei在博文中提出了具体的行动框架。

首先，“**嵌入式评估员**”(Embedded Evaluators)。他宣布Anthropic将向第三方评估机构提供“永久性员工级别”的系统访问权限，使其能够核实安全措施的执行情况、报告事故并评估模型在训练过程中的对齐状态。Altman随即跟进，表示OpenAI将采取相同举措。

其次，**民主国家内部协调**。Amodei呼吁政府为AI开发商的安全标准协调提供法律支持，以避免此类合作触发反垄断监管。

第三，**全球协调**。他主张建立“协调一致的节奏策略”，为前沿AI企业争取时间推进对齐研究，同时不损害商业竞争优势和美国在AI领域的领先地位。对冲基金经理兼风险投资人Brad Gerstner在X平台上表示支持，称此举是“在速度、自我监管与安全之间寻求正确平衡的重要一步”。

IPO计划蒙阴：Anthropic估值承压，OpenAI暗示推迟上市

当前局势对两家公司的上市计划均形成直接冲击。**Anthropic正筹备一项规模空前的IPO，募资规模或达1000亿美元，公司估值或超2万亿美元**；Anthropic原本最早于上周提交招股书，但截至目前尚未成行。Amodei的降速呼吁令外界对其上市时机的判断愈发复杂。

OpenAI方面，Altman向《财富》杂志表示：“考虑到安全领域正在发生的一切，我认为现在上市是不明智的，我们对此也没有压力。”

OpenAI于今年六月提交了IPO文件，距Anthropic提交招股书仅一周之后。Altman还表示，“本周显然是更多人开始正视摆在我们面前问题的一周，我们正在进入一个模型能力极强、风险极高、必须把事情做对的领域。”

特朗普说“没有任何担忧”，国会在观望，谷歌和Meta沉默

尽管三巨头罕见联手，政策层面的回应目前仍显迟滞。美国总统特朗普上周向记者表示，他对AI导致人类灭绝“没有任何”担忧。知情人士告诉英国《金融时报》，在今年11月中期选举前，美国政府采取实质性行动的可能性极低。

谷歌DeepMind与Meta的高管目前尚未就本周末的讨论公开表态。

行业内部的分歧同样不容忽视。批评者认为，头部AI企业强调生存风险存在自利动机——高昂的安全合规框架可能将规模较小的竞争者挡在门外，从而巩固现有巨头的市场地位。科技顾问、风险投资人David Sacks在福克斯新闻采访中称，Jacob Coxon的声明意在“吓唬公众”，迫使立法者“对AI实施强力政府监管”。

加州大学伯克利分校AI教授Stuart Russell则直言，实验室与政府之间存在严重的认知错位：“实验室在告诉各国政府：‘我们很可能会杀死地球上的每一个人，请阻止我们。’政府的回应却是：‘我们能给你减税吗？给你建一个数据中心？’”

然而，正当Sam Altman和Dario Amodei等人还在政策游说与安全防线间反复踱步、小心拉锯时，外界已不乏警醒的声音：**或许某天醒来，他们会发现Grok不仅在模型能力上已追赶上来，马斯克更已在物理世界AI与算力基础设施领域完成了全面布局——这或许才是他真正的“宏伟蓝图第五部分”(Master Plan Part V)。**





The AI Investor 
@The_AI_Investor

Follow



Random thought:

After all this pacing, Sam and Dario may wake up one day and realize Grok has caught up, while Elon has already come to dominate physical AI and compute infrastructure too.

Master plan part V.



风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 944

 收藏

分享到:  

写评论

请发表您的评论

 表情

 图片

发表评论

39 条评论



正在加载