

摘要：

高盛最新报告显示，衡量AI推理定价的SDLLMTK指数8月单月暴跌29%，首次跌破每百万Token 1美元关口，较高点累计腰斩。标价下调、用户向低成本开源模型迁移、竞争加剧与本地推理令每Token定价模式遭遇结构性侵蚀，量升价跌的剪刀差正瓦解“更多Token等于更多收入”的核心叙事。

AI基础设施投资的核心叙事正面临单位经济学层面的严峻挑战。Token价格的崩塌速度已超出市场此前的预期，令过去两年支撑AI板块估值的收入逻辑出现根本性动摇。

据高盛One-Delta交易平台负责人Rich Privorotsky的最新报告，衡量市场每百万Token使用加权均价的Silicon Data LLM Token Expenditure Index（代码：SDLLMTK）在8月单月下跌29%，月末报约0.97美元，创历史新低，较5月高点约2.05美元累计跌幅已超50%。这是该指数首次跌破每百万Token 1美元关口。



与此同时，据摩根大通数据中心报告，OpenRouter平台8月Token使用量环比增长约47%，但美元支出仅增长约7%。量升价跌的剪刀差直接揭示了当前AI投资逻辑的核心矛盾：股票市场的回报以美元计算，而非以Token数量计算，超大规模数据中心的资本开支正是基于美元收入预期来核算的。

Privorotsky在报告中明确指出，“更多需求加上更低价格，若价格跌速超过消费增速，并不自动构成利好。”

Token价格崩塌：不是需求消失，而是单价在瓦解

Silicon Data的LLM Token Expenditure Index并非衡量Token需求量的指标，而是一个使用量加权的价格指数。该公司本身已提示市场，该指数的下跌可能源于标价下调、用户向低成本开源模型迁移，或两者兼而有之，并不意味着AI使用量在萎缩。

然而，这恰恰是问题所在。OpenRouter路由量大幅上升，H100 GPU租赁价格却在下跌——这与“Token需求激增”的叙事相悖。Privorotsky指出，8月的数据呈现出清晰的格局：量大幅上升，价格跌幅更大，美元支出几乎原地踏步。

高盛的结论是：过去两年的股权定价建立在“更多Token等于更多收入”的假设之上，而8月的数据首次清晰地打破了这一假设。

竞争加剧与本地推理：每Token定价模式的结构性侵蚀

Privorotsky在报告中直言，他对“按Token计费”作为持久商业模式持怀疑态度。云端推理按百万Token定价的逻辑，依赖三个前提同时成立：**模型体量大到无法本地运行、用户无法以开源替代品替换、工作负载足够突发以至于自建算力不划算**。而这三个前提目前正在同步瓦解。

在硬件端，RTX Spark级笔记本、DGX Spark工作站、运行700亿参数级模型的Mac Studio，以及算力在40至75+ TOPS区间的NPU，已将大量Token的边际成本压缩至接近电费水平。一旦企业每月的API账单超过一台5000至15000美元设备的摊销成本，该企业便从Token消费者转变为一次性硬件买家，而非持续贡献40%利润率的软件订阅用户。

在模型竞争端，Meta于9月2日开始推出的Muse Spark 1.3在独立基准测试中已与GPT-5.6 Sol及Claude Opus 5处于同一梯队，且在智能体任务和代码生成方面表现突出。Privorotsky指出，“前沿优势以周计算，不构成护城河，只是产品周期。”每当次优模型足够接近且价格更低，企业便会绕开溢价层级，而Token价格指数正是这一路由决策的聚合体现。

资本开支逻辑承压：信用市场已率先发出警示

高盛报告指出，本轮AI资本开支周期并非灵活的运营支出，而是已锁定的重资产承诺。据报告，五家获评级的超大规模云厂商2026年资本开支预计合计约7370亿美元，约占其收入的38%。穆迪已就自由现金流压缩、资产负债表从轻资产向重资产转型，以及未以债券形式体现但实质约束发行人的租赁承诺发出预警。

信用市场的反应已先于股票市场。据一份对相关债券的统计，**2026年发行的91只超大规模云厂商债券中，已有78只在8月底前跌破发行价**。Privorotsky将此称为“信用的重新定价”，并指出**股票估值倍数是滞后指标**。

其逻辑链条清晰：Token价格下跌30%、使用量增长20%，推理收入下降；推理收入下降而2025至2027年建设周期的折旧与利息仍在爬坡，投资回报率随之崩塌；投资回报率崩塌后，市场无需“泡沫破裂”的戏剧性叙事，只需将估值倍数调整至反映一个拥有大量资产、但定价能力受限的公用事业型企业的水平。

GPT-6 Astra：唯一尚存的叙事反转变量

报告中，Privorotsky将OpenAI下一代模型Astra视为当前唯一可能扭转局面的近期催化剂。OpenAI于9月1日表示，Astra已达到其Preparedness Framework下的关键网络安全门槛，成为首个被纳入该类别的模型。

然而，高盛的交易平台对此保持审慎。一个受访问限制、需要监控、使用摩擦较高的激进模型，并不自动补充Token收入池。若高价值工作负载始终停留在受控测试环节而未进入公开计费系统，Astra甚至可能减少计费Token数量。

报告的结论是：Astra是能够使收入组合重新向高价值层级倾斜的最后一个近期变量。在此之前，8月的Token价格数据是当前市场状态最真实的信号——需求可以无限增长，但若无限需求到来时的价格无法覆盖建设数据中心所发行债务的成本，股价仍然可以下跌。

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

154 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论