

摘要：

DeepSeek历时5个月发布新版本，期间完成与华为昇腾国产芯片的深度适配，实现高吞吐、低时延推理部署。这是技术上的新探索，也是中国AI在软硬件协同领域的一种进步信号。尽管当前中国的制程不占优、单卡性能有限，但我们也会通过系统设计、集群架构、软硬件协同、电力能耗等优势排布，在既有条件下，探索新的发展解法。

不诱于誉，不恐于诽，率道而行，端然正己。

带着十六个字，DeepSeek新版本，姗姗来迟。

距离上一次更新的V3.2版本，已经过去近5个月。

这期间，安索皮克（Anthropic）的克劳德神话（Claude Mythos）模型在网络攻击上展现出前所未有的能力，有机构称其将网络攻击的时代从“手工化”带到了“工业化”；GPT-Image-2也让网友惊呼“有图有真相”的时代已经过去……



在这个国外主流大模型平均91.4天就迭代一个版本的时代，DeepSeek的“静默”，在很多人眼里几乎等同于落后，甚至掉队。


沉默的DeepSeek，让人很不习惯——2025年初的横空出世、用更少的算力实现更优的性能、打破美西方营造的“算力焦虑”。这些标签，让它的意义不止于一个公司的一款产品。

因此，几个月里，关于DeepSeek-V4的市场传闻就没断过。

当时，国外科技媒体称V4模型将在今年春节发布，具有强大的编码能力。

当一家公司最核心产品的动态被匿名信源、外媒报道和券商研报所定义——这本身已偏离了技术讨论的轨道。

DeepSeek官方从未对外界的消息做过任何确认，这种沉默，又让讨论升级。



2月26日，事情迎来转折。

路透社称，据知情人士透露，DeepSeek发布V4之前，没有向美国芯片公司英伟达和超微半导体（AMD）提供模型早期访问权限，而是让中国企业华为提前数周开展软件适配优化工作。

路透社在报道中用了——

breaking from standard industry practice（打破行业惯例）。

这是此前无论中国公司还是外国公司的大模型，都没有采用过的方式。

显然，此时讨论的已经不只是一个公司能否发布新产品的问题了。

此次DeepSeek与华为昇腾国产芯片体系深度适配，并不令人意外。

去年8月，DeepSeek发布DeepSeek-V3.1时就宣布采用UE8M0 FP8 Scale参数精度，特别表示这一数据格式是针对即将发布的下一代国产芯片设计。

软件主动适配硬件特性，本质上是在为国产芯片“量体裁衣”。

这背后的难度超乎想象，需要大量改写调用芯片的软件代码，使其与目标系统在各个环节都实现兼容。

依据新款芯片的特点，哪些代码还能沿用，哪些必须重写？

原本依赖的算子、通信方式和并行策略，放到国产芯片上还能否成立？

训练流程中最关键的环节，怎样调整才能既跑得通，又不损失太多性能？

因此，要想一款国产芯片嵌入既有的模型训练和推理体系，并达到可用、好用、能规模化使用的状态，往往需要长期摸索。

而当国产芯片开始在具体场景里能够接住原本由外国芯片承担的计算任务，企业就可以不再依赖特定进口型号。

国产芯片，能接得住吗？DeepSeek的姗姗来迟，似乎给了这个问题一个答案。但很少有人注意到这样一个细节。

2025年12月31日，国家发展改革委召开了2025年的最后一场新闻发布会。会上，有记者问了这样一个问题：

目前国产算力达到什么水平？

发言人回应：

目前，国产芯片产品在不同场景中加速适配，应用成效可以说非常好。特别是“超节点”等集群互联技术发展，为国产算力赶上国际领先水平提供了良好机遇，拓展了广阔发展空间。

不少人都知道，芯片、算力等的国产化，我们回应不多。

就拿发改委来说，2015年以来，发改委的新闻发布会上，提及国产算力寥寥无几，并且很少对具体发展情况作出说明。

从“回应不多”到“正面回应”，转变，在持续发生。

科技与战略风云学会副会长陈经表示，从去年开始，国产芯片的需求端被真正拉动起来了。

2025年，国产AI芯片的国内市场份额已达到41%左右。

有人用，是商业逻辑的重要一步。

上海财经大学胡延平教授就提到，从去年开始，国产AI芯片企业开始集中上市。

其意义不只在市值水平，企业能够把更多资源投向下一代AI训练、推理芯片的研发。

从技术产品，到市场应用，再回到资本支持，一个相对完整的正态循环正在形成。

北京邮电大学人机交互与认知工程实验室主任刘伟有一个观点——模型加上芯片，是人工智能竞争更进一步的形态。

未来的AI发展，不仅在于算法的好坏，同样也要看整个生态是否具有韧性。

主流的英雄达生态，将硬件、软件和开发者深度绑定，形成了事实上的行业标准，在中国大模型训练芯片市场的占比一度高达95%。



可以说，几乎所有顶级大模型都必须基于CUDA框架运行。

于是，现在国产AI芯片面临两个选择：

一是兼容CUDA生态，降低迁移成本；二是自研软件栈，重构开发体系。

而中国大模型要想实现真正的自主，就必须形成软硬件一体化的协同能力。

DeepSeek-V4模型在适配昇腾芯片后，实现了高吞吐、低时延的推理部署。

这是技术上的新探索，也是我们在软硬件协同领域的一种进步信号。

今年初，智谱GLM-5也宣布完成与7家主流国产芯片平台的深度适配，可以在国产算力集群之上实现稳定运行。

在大模型训练中，也出现了“纯国产”的实践样本。

一些企业的大模型，训练过程基于国产算力体系完成。

陈经分析称，这意味着一套国产软硬件协同的AI研发生态正在逐渐完善。

尽管当前中国的制程不占优、单卡性能有限，但我们也会通过系统设计、集群架构、软硬件协同、电力能耗等优势排布，在既有条件下，探索新的发展解法。

当我们讨论中国AI企业时，我们讨论的其实不只是企业本身，更是一个行业，以及背后代表的一种发展模式。

正如那十六个字的后半句所说：

率道而行，端然正己。

中国AI，更需要活在自己的节奏里。

本文来源：[玉渊谭天](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

445 收藏

分享到:

| 写评论

请发表您的评论





表情



图片

发布评论

1 条评论



MobileUser0205

4小时前 中国福建省

和互联网发展一样



1



回复

