

摘要：

国泰海通认为，具身智能发展的核心瓶颈已从算法转向数据，其需求量及采集复杂度正呈指数级爆发。未来“仿真/视频预训练+真实微调”有望成为主流路径，这一路径下，数据采集工具链、仿真平台与视频升维技术作为物理AI时代的“卖铲人”，将占据产业链核心价值节点。

人工智能的底层逻辑正从大语言模型的“语言理解”转向世界模型的“预测世界”。在这一跃迁中，物理数据的质量与采集能力成为发展核心。作为解决世界模型与具身智能“数据燃料”问题的关键，**具身数据采集**正开启下一代数据基建浪潮。

国泰海通最新报告指出，具身智能发展的最大障碍已不再是算法，而是数据缺口。其对数据的需求量呈指数级膨胀，远超传统AI模型。在这一背景下，**能够率先填补数据缺口的数据供应商与基础设施商，将作为物理AI时代的“卖铲人”，占据产业链核心价值节点**，有望享受显著的估值溢价。

技术路线上，真实数据、仿真/合成数据、视频数据各有利弊：纯真实数据成本过高，纯仿真数据存在“Sim2Real”（仿真到现实）鸿沟。未来主流路径逐渐清晰：仿真/视频数据用于大规模预训练 + 真实数据用于微调与强化学习。

随着主流技术路线日渐清晰，资本正加速涌入**数据采集工具链（动捕、遥操作）、视频数据升维平台及仿真训练场**——这些数据采集基础设施，正成为机器人产业真正的风口与“铲子”生意。

范式转移：世界模型重塑AI基石，数据需求膨胀至EB级

AI正从“数据相关性”驱动转向“物理因果性”驱动，**2025年已成为世界模型应用落地的元年**。具身智能对数据的需求量及复杂度正呈指数级爆发。

传统神经网络与大语言模型本质上依赖模式识别与概率关联，而“**世界模型**”的核心在于**内建物理规律（如重力、惯性），并具备预测时空演化的能力**。自2025年起，该领域迎来集中突破：Meta的V-JEPA 2、谷歌的Genie、OpenAI的Sora以及World Labs的RTFM相继问世。


图1：世界模型需具备“理解世界”与“预测未来”两大核心能力



数据来源：北京科技报、DeepTech 深科技，国泰海通证券研究


世界模型将赋能游戏、自动驾驶与具身智能三大核心场景。其中，**具身智能的爆发对数据提出了前所未有的苛刻要求**。与大语言模型及自动驾驶（PB级数据量、以文本或视觉为主）不同，具身智能需适应形态各异的硬件平台，数据需求高达EB级，且极度强调物理交互（力觉、触觉、关节反馈）。目前行业仍处早期阶段，**预训练数据极度紧缺，“数据孤岛”与异构数据融合难题已成为制约产业爆发的核心瓶颈**。

图5: 具身智能技术架构中“数据”的内核更加复杂



数据来源: 向硅行, 国泰海通证券研究

图7: 数据采集是具身数据飞轮运转的重要前提




数据来源: 深度投研洞见, 国泰海通证券研究

三大主流数据采集方案利弊共存，视频数据成为业内关注新焦点

构建高效的数据闭环，是具身智能能力跃升的核心。当前，资本与技术主要围绕三大数据采集方案展开：

- 。真实数据（高保真但极度昂贵）：通过遥操作、穿戴式动捕等方式直接采集。优势在于不存在 Sim2Real 差距；致命短板是成本高、扩展性差，难以覆盖长尾边缘场景。


图9: 真实数据路线当前主要通过遥操作、部署型采集等方式采集



数据来源: 向硅行

- 。合成/仿真数据（高性价比但存在迁移鸿沟）：利用物理引擎在虚拟环境中生成。成本极低且自带完美标签，但面临显著的“Sim2Real Gap”（动力学、感知、控制等差异），导致模型在真实环境中性能衰减。

图10: 合成/仿真数据路线利用仿真平台进行模拟采集



数据来源：深蓝 AI

。视频数据（来源广但直接应用难）：业内新兴焦点，通过升维技术利用海量互联网视频。成本低、规模大，但缺乏物理交互属性（如重力、摩擦力），噪声大且缺少精确的三维标注。

图11: 视频数据路线对海量的视频进行采集训练



数据来源：枢途科技

产业演进趋势：Generalist AI的GEN-0模型（≥7B参数）已证明，在海量真实交互数据下，模型性能呈幂律增长。在真实数据成本被彻底打下来之前，“仿真/视频数据预训练 + 真实数据微调/强化学习”的虚实结合方案将是绝对主流。

与此同时，底层数据基建正在国家力量与开源生态的推动下加速成型：上海落地了全国首个具身智能领域国家级标准化试点（“1+N”模式训练场），北京建立了首个基于真实场景的数据训练基地。谷歌、星海图、傅利叶、智元等纷纷发布开源数据集，中国信通院则牵头制定了国内首个具身智能数据集质量评价标准。

图16: 全国部分具身智能数据训练场

华北地区	□ 北京石景山首钢园人形机器人数据训练中心 □ 北京人形机器人创新中心具身智能数据训练基地 □ 青岛具身智能机器人公共训练场 □ 天津帕西尼具身智能超级数据工厂
华东地区	□ 合肥具身智能机器人数据采集预训练场 □ 长三角（德清）具身智能数据采集训练场 □ 上海浦东张江模力社区异构人形机器人训练场 □ 上海虚实融合具身智能训练场 □ 上海嘉定区具身智能机器人训练场 □ 杭州西湖区之江机器人产业服务港
华南地区	□ 广大黄埔校区无人智能与具身智能数据采集训练场 □ 佛山顺德多模态具身智能机器人训练场
西部地区	□ 四川省具身智能机器人训练场（西部首个）

数据来源：创新石景山公众号、中关村融智特种机器人产业联盟公众号、中科紫东太初公众号、天津河西公众号、合肥晚报公众号、湖州莫干山高新区公众号、人形机器人世界公众号、世界人工智能大会公众号、数据嘉定公众号、之江万事公众号、PnP 机器人公众号、佛山市工商联公众号、四川科技公众号、国泰海通证券研究

正是由于真实数据成本高、仿真数据存在迁移鸿沟、视频数据噪声大，国内外主流机器人本体厂商在数据路线上出现了明显分化。这一分化，反过来为数据采集基建的方向提供了最直接的产业验证。


- 。真实数据优先派：认为只有真实交互才能跨越Sim2Real鸿沟。智元机器人在大模型训练阶段100%使用真机真实数据，仿真仅用于工程迭代；自变量机器人在复杂物理交互场景中完全不使用仿真数据；1X Technologies同样将“大规模真实世界数据”作为核心壁垒。

图18: 智元机器人主要产品



数据来源：公司官网

图19: 自变量机器人主要产品



数据来源：公司官网

- 。合成与仿真数据优先派：押注成本与规模。银河通用采用99%的合成数据配以1%的真实数据进行训练，试图以极低成本逼近真实分布。

图20: 银河通用主要产品



数据来源：公司官网

- 。视频数据战略高地：特斯拉、Figure AI等巨头正加速布局，核心逻辑在于互联网视频规模远超任何单一机器人平台能采集的真实数据。特斯拉Optimus已放弃早期动捕与遥操作，转向深挖互联网视频；千寻智能Spirit v1的70%预训练来自互联网视频；Figure AI启动Project Go-Big，探索人类视频到机器人的零样本迁移；星动纪元、逐际动力则分别采用“视频预训练+真机微调”及多源数据组合策略。

图 22: 千寻智能主要产品



数据来源：公司官网

图 23: 星动纪元主要产品



数据来源：公司官网

这三条路线的并存恰恰说明：当前尚无单一数据来源能独立解决具身智能的数据瓶颈。无论最终哪条路线收敛，数据采集工具链、仿真平台与视频升维技术——即物理AI时代的“卖铲人”——都将是确定性受益的方向。

数据“卖铲人”全景图

随着具身智能对数据的需求量级与复杂度指数级上升，能够有效解决数据获取成本与效率问题的供应商，正迎来一轮估值重估。这一重估覆盖四个关键方向：视频数据转化、仿真平台、多模态硬件采集，以及综合数据服务。

- 视频数据转化方向：核心突破在于将海量互联网视频低成本转化为机器人可用的训练数据，部分方案已能将综合采集成本降至行业平均水平的千分之五以下。
- 仿真平台方向：全链路合成数据体系以极低成本生成带完美标注的大规模虚拟数据，并逐步缩小Sim2Real差距。
- 真实数据采集硬件方向：光惯融合手套、电子皮肤等传感器结合高质量开源数据集，正在构建高保真底座。
- 真实数据生态与遥操作方向：大规模自建采集场景与高精度遥操作设备，已成为主流微调数据的重要来源。

在二级市场视角下，综合性数据服务商通过多元方案（遥操作、动捕、合成数据）建设具身智能数据训练场与工程化平台；仿真平台公司则通过收购整合打通虚实数据壁垒，提供全生命周期物理AI解决方案。

整体来看，无论是视频转化、仿真生成、硬件采集还是综合服务，能够显著提升数据“可获得性”与“成本效率”的供应商，正在从产业边缘走向估值中枢。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

150 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论



见闻用户
1小时前 中国上海

卖铲子🔨? 是啥公司

0 回复