

摘要：

新版模型搭载了严格的安全分类器，导致大量编程调试类请求被自动降级至Opus 4.8等旧模型处理，核心能力的实际调用场景因此显著收窄。开发者普遍认为，名义上“解禁”的Fable 5已实质弱化，与初版相比可用性明显缩水，更像受限的折中版本，而非真正的能力回归。

经历数周限制风波后，Anthropic的Fable 5终于获准重新上线，但代价是核心能力被大幅收紧。

当地时间6月30日周二，美国商务部正式解除对Anthropic Fable 5和Mythos 5模型的出口限制，Anthropic随后在X平台上确认，将于周三恢复访问。



Anthropic
@AnthropicAI



翻译自 英语 显示原文

我们已收到通知，美国商务部已解除对 Claude Fable 5 和 Mythos 5 的出口管制。

我们将于明天开始恢复访问，并将很快分享更新。

我们感谢用户的耐心等待，也感谢所有与我们合作重新部署模型的人员。

评价此翻译：

上午7:52 · 2026年7月1日 · 7.2万 查看

不过，Anthropic在X平台上发帖表示，与此前版本相比，重新上线的Fable 5已加入更严格的安全分类器（classifier），一些编程、调试等请求将自动降级至旧一代模型Opus 4.8处理，意味着用户能够真正调用Fable 5能力的场景被明显压缩。



Claude Fable 5 将于明日在全球范围内重新上线。在与美国政府进行了一系列富有成效的对话后，我们正在重新部署该模型，并配备一套新的分类器，以识别和阻止更多网络安全任务。短期内，一些常规任务（例如编码和调试）将回退到 Opus 4.8。我们将在未来几周内继续改进这些分类器，以减少误报，并更好地区分真正的滥用和合法请求。我们还与亚马逊、微软、谷歌和其他 Glasswing 合作伙伴开始起草一个共识框架，用于评估 AI 越狱的严重程度以及 AI 开发人员应如何应对。我们诚邀其他行业合作伙伴和模型提供商加入我们，共同推进这项工作。最后，我们正在扩大与美国政府在模型测试和安全保障方面的合作。这将包括提前提供模型和安全保障以供评估、共享有关越狱和滥用的信息，以及为联合研究提供专门资源。感谢各位用户的耐心等待，也感谢政府、行业和研究界的合作伙伴与我们携手合作，使《神鬼寓言5》得以重新上线。阅读我们的完整博客：

ANTHROPIC

重新部署克劳德·费布尔 5

来自anthropic.com

2026年7月1日 上午11:42 · 410万 浏览量

这一变化迅速引发开发者社区热议。不少业内人士认为，Fable 5虽然名义上重新开放，但其最具竞争力的能力已被“阉割”，更像是一个受到严格限制的版本，而非此前发布的完整模型。

Fable 5回来了，但核心能力“被降级”

公司公布了一项重要调整：新版Fable 5新增了一套安全分类器，用于识别可能涉及敏感网络安全能力的请求。Anthropic承认，这套分类器的代价是会“更频繁地误判正常请求”，包括日常编程、代码调试等任务。

官方说明写道：

新的分类器也意味着，在日常编码和调试任务中，更多正常请求会被错误识别。

我们的测试证实，许多能力较弱的模型——包括 Claude Opus 4.8、GPT-5.5 和 Kimi K2.7——都能识别出报告中 Fable 5 所发现的相同漏洞。在演示如何利用该漏洞时，我们测试的每个模型都能做出与 Fable 5 相同的演示（包括 Claude Haiku 4.5、Sonnet 4.6、Opus 4.6、Opus 4.7、Opus 4.8、GPT-5.4、GPT-5.5 和 Kimi K2.7）。

重要的是，所报告的技术并未暴露任何独特的“神话级”网络能力。这种行为反映了《神鬼寓言5》安全机制的一个临界情况——正如我们将在下文解释的那样，有些任务虽然不太可能造成危险，但出于谨慎起见，安全机制仍然会阻止它们执行。所报告的技术允许进行其中一项此类操作，但它仅涉及常规的防御性网络安全工作。

尽管如此，我们还是迅速采取行动应对了所报告的绕过漏洞。我们与政府密切合作，训练了一个改进的安全分类器，该分类器能够识别并阻止报告中描述的行为。如果对 Fable 5 的请求被阻止，用户将会收到通知，并且该请求将被转而发送到 Opus 4.8。

新的分类器意味着亚马逊报告中描述的特定技术在超过 99% 的情况下都会被拦截。在极少数情况下，该模型可能提供的信息不够详细，不足以帮助网络攻击者。正如我们将在下文所述，该模型的安全措施预计不会拦截所有低风险的常规网络防御功能，而只会拦截那些可能造成危害的功能。美国商务部人工智能标准与创新中心(CAISI)的研究人员已经测试了我们之前和新的安全措施，并一致认为它们非常强大。

新的分类器也带来了一些问题，例如在日常编码和调试任务中，会更频繁地将一些良性请求误报。与我们所有的安全措施一样，我们将继续改进它，以便更好地区分真正的滥用行为和合法请求，并减少误报。

对于这些被识别出的请求，系统不会调用 Fable 5，而是自动切换至上一代 Opus 4.8 模型完成。开发者普遍认为，这意味着 Fable 5 最强的代码生成能力实际上已无法完整使用。

开发者 Wise 表示：Fable 5 已经不是 Fable 5 了。为了换取解除出口限制，Anthropic 增加了新的安全分类器，同时将大量日常编程和调试任务重新交给 Opus 4.8 处理。



Wise 
@trikcode

Subscribe



Fable 5 is not fable 5 anymore

- they lifted export controls after adding new classifiers
- added new safeguards.
- and now the routine coding/debugging falls back to Opus 4.8


知名加密市场分析师 Miles Deutscher 也指出，新版 Fable 5 不仅限制 Coding 能力，同时仅允许用户在约 50% 的额度内使用该模型，其余请求仍会落回旧模型，因此此次“重启”更像是一次受限开放，而非真正恢复原有能力。



迈尔斯·德意志 @milesdeutscher · 3小时



Fable 5 重新发布：> 无需编码 > 仅限使用限额的 50% 虽然我们仍然有很多事情可以做，但这将大大限制我们使用该模型所能实现的目标。



28

5

73

25K



从全面封锁到有条件解禁

此次调整，是美国政府与Anthropic持续数周谈判后的结果。

6月12日，美国商务部以国家网络安全风险为由，禁止Anthropic向用户提供Fable和Mythos两款前沿模型。监管部门最大的担忧集中在所谓“越狱（jailbreak）”风险，即用户可能绕过模型安全限制，获取更强大的网络攻击能力。

随后，美国政府于上周率先允许Mythos 5向部分美国企业和政府机构有限开放，而消费级产品Fable 5则继续维持封锁。据媒体此前报道，为推动解禁，Anthropic最终调整了谈判策略，不再坚持“无法彻底消除越狱风险”的立场，而是承诺增加更严格的安全防护机制，以降低风险发生概率。

如今重新上线的Fable 5所新增的安全分类器，正是双方妥协后的主要成果。

AI监管进入“能力可用，但必须可控”阶段

此次Fable 5恢复上线，也进一步反映出美国AI监管思路正在发生变化。

相比直接禁止模型开放，美国政府更倾向于要求企业通过增加安全分类器、限制敏感能力、动态降级模型等方式，对前沿模型实施持续监管。

Anthropic并非唯一受到影响的公司。此前，OpenAI最新模型ChatGPT-5.6同样在白宫及相关监管部门要求下，仅向小范围用户开放，发布节奏明显放缓。OpenAI管理层曾公开表示，希望尽快建立一套明确、稳定的AI模型评估和审批机制，以减少临时性监管带来的不确定性。

对于整个AI行业而言，Fable 5此次“解禁”或许意味着一个新的监管范式正在形成：前沿模型可以发布，但最敏感、最强大的能力，将越来越多地通过安全分类器、能力降级和访问限制进行动态管控。开发者获得的是一个能够使用的Fable 5，但未必还是最初那个完整的Fable 5。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

116 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论