

摘要：

Patel表示，AI模型越智能，算力变现能力越强，导致算力价格飙升。目前头部实验室营收年增10倍而算力仅增3倍，极低的供应链弹性使算力面临严重短缺。高昂成本将引发“价格挤出”效应，普通用户与低端应用恐遭市场边缘化。

随着人工智能模型能力呈现指数级跨越，底层算力的价值正被重新定义。

科技播客主持人及博主Dwarkesh Patel近日在其视频中表示，**AI模型越智能，其将算力变现的能力就越强，这将不可避免地推高算力价格，最终导致普通AI应用和普通用户面临被“价格挤出”的风险。**

在这一趋势下，顶级AI实验室正面临极端的供需失衡。Patel测算，以Anthropic为代表的头部企业营收正呈现每年10倍的爆炸性增长，但行业整体算力规模每年仅能实现3倍扩张。为填补这一巨大缺口，算力现货价格自今年2月的低谷以来已飙升超过40%。巨头们正以极高的溢价锁定资源，谷歌每月向SpaceX支付9亿美元租赁11万张GPU，其单价已达到现货市场价格的两倍。


算力供给的极度缺乏在短期内无法通过市场机制有效缓解。受制于芯片制造设备交付周期以及晶圆代工产能的物理极限，算力供应链表现出极低的弹性。在达到技术奇点之前，整个AI产业将进入一个资源极度稀缺、权力高度集中的新周期。



算力增长滞后于营收，推高硬件与推理成本

AI行业的超额收益与硬件瓶颈之间的脱节，正在引发一连串的连锁反应。如果头部实验室要维持营收每年10倍的增长，而算力仅增长3倍，市场必须通过提高实验室利润率、推高算力价格或增加推理算力占比来寻求平衡。Patel指出，这三种现象目前已经同时发生。

在利润率方面，Anthropic的推理利润率已从去年中期的40%飙升至目前的80%以上。在算力分配上，据Epoch的数据显示，OpenAI在2024年初仅将四分之一的算力用于推理，而现在这一比例可能已接近甚至超过50%。




然而，增加推理算力占比是头部实验室最不愿看到的局面。对于致力于开发通用人工智能（AGI）的实验室而言，推理业务的核心目的仅是为了向投资者证明商业价值，从而获取更多资金去训练下一代更强大的模型。将大量算力转化为云计算服务，意味着宣告技术进展停滞。因此，大部分算力仍需被强制锁定在模型训练中，这使得算力价格的持续上涨成为消化供需矛盾的唯一排气阀。

巨头争夺稀缺资源，硬件溢价持续扩大


算力价格的上涨趋势在头部实验室的采购策略中表现得更为激进。前沿实验室无法简单地依赖零散的现货实例，他们需要建立极其庞大的集群，以确保模型训练的效率、灵活性，以及保护权重文件和客户数据所需的安全架构。

这迫使科技巨头愿意为规模化算力支付极高的溢价。以Google租赁SpaceX的GB200和GB300混合算力集群为例，其支付的每小时租金是当前现货价格的两倍。这种财大气粗的采购行为，直接拔高了整个行业的底层成本基线。随着顶级实验室在变现算力方面变得越来越出色，且算力成本不断上升，其他任何竞争对手都难以在资源竞价中与他们抗衡。



经济学效应显现，普通用户面临“价格挤出”

算力价值的飙升直接与AI模型的智能化程度挂钩。Patel提出了一项核心推演：当AI模型具备人类软件工程师的水平时，一张等效的H100芯片如果按当前工程师的薪酬水平出租，其年租金将超过25万美元，这是目前H100现货价格的15倍以上。基于标准经济学理论，技术创新和专业化将极大提升劳动的价值，这意味着算力的边际价值将保持在令人瞩目的高位。




这种高昂的成本将引发经济学中的Alchian-Allen效应。如果租赁H100的成本高达每小时20美元，那么在昂贵的算力上运行低效、弱小的模型将是极其荒谬的资源浪费。只有能用更少算力达成相同效果的最优模型，才能产生最高的溢价利润。

由此带来的直接后果是，当前许多流行的平民化AI应用将被剥夺生存空间。当AI突破能力阈值后，Google、Anthropic或OpenAI等巨头将更愿意将有限的算力出售或应用于高价值的自动化AI研究，而不是廉价提供给普通用户生成无意义的“AI废话”。低利润率的日常消费者需求将被高昂的底层成本彻底挤出市场。

供应链瓶颈难解，行业走向高度集中

针对市场对“价格信号最终会解决稀缺问题”的乐观预期，Patel引用了著名的Simon-Ehrlich赌局作为反面教材。与Paul Ehrlich当年对大宗商品短缺的错误悲观预测不同，当前算力市场的供给缺乏弹性，无法像金属开采那样通过替代品或价格刺激在短期内吸收巨大的需求冲击。



支撑每年3倍算力增长的底层支柱已摇摇欲坠。其中由Moore定律贡献的1.4倍增长已接近物理极限，未来几年能够维持已属奇迹。由新建晶圆厂贡献的1.2倍增长，则被ASML EUV光刻机的产能严重掣肘，正如Dylan此前所言，这一瓶颈至少会持续到2030年。

此外，由智能手机和PC端转移至AI的晶圆配额（贡献1.8倍增长）即将触顶。到明年年底，在TSMC最先进的N3节点上，AI的产能占比将从60%暴增至86%。当所有前沿晶圆产能被AI完全吞噬后，行业将面临无晶圆可用的硬着陆。

在机器人能够直接将硅砂和铜矿转化为芯片的“奇点”到来之前，行业必将长期处于资源受限的状态。这种智能训练中呈现出的极强规模经济效应，虽然避免了人类劳动需要从头培训的低效，



但也必然导致令人担忧的市场权力极度集中。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

限免

174

收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论

5 条评论

- 见闻用户

7小时前 中国北京

工业品稀缺吗

1

回复
- momoo

10小时前 中国上海

越来越像邪教了

0

回复
- MobileUser3166

11小时前 中国

所以印度人就硬蹭了个ai主播🤡

2

回复
- 见闻用户

12小时前 中国广东省

算力成本肯定是一直下降的

1

回复
- MobileUser9923

12小时前 中国山东省

他的叙事建立在头部 AI 实验室大模型智能一骑绝尘的前提下，事实更可能是大模型的壁垒没有想象中那么强。真的在复杂项目中使用大模型会发现各家大模型各有各的问题，离所谓奇点还很遥远。

0

回复