

摘要：

Gavin Baker表示，7月AI股票下跌40%-60%与实际基本面严重背离——他在硅谷实地调研后，未发现任何负面可量化指标，GPU租金价格反而上涨50%-60%。他认为唯一真实的风险是信用市场收紧，但若超大规模云厂商运营现金流如期加速，债务融资需求将大幅缩减。而监管被其列为最大尾部风险。

市场在恐慌，但硅谷的数据讲述着另一个故事。

近日，知名科技投资人Gavin Baker在播客节目《Invest Like the Best》中复盘了2026年7月AI及半导体板块的剧烈抛售。**Baker将这段时期描述为“把2022年压缩进了一个月”，并表示：在硅谷实地调研数周后，他找不到任何一个负面的可量化指标。**



抛售的导火索：一连串叙事，而非基本面

Baker梳理了7月市场下跌的触发链条。

首先是Meta宣布将出租部分算力，市场将其解读为“算力过剩、削减资本开支”的信号，股价随即下跌。但Baker认为这是误读——“Meta的资本开支计划根本没有任何变化，如果说有什么不同，他们变得更激进了。”随后Meta发布了表现强劲的Llama模型，进一步证明其并未踩刹车。

紧接着，Kimi K3等开源模型发布，叠加Silicon Data Token Index出现结构性变化，市场担忧开源模型抢占份额会压缩AI基础设施需求。Baker对此明确反驳：“生成一个token，无论是开源还是闭源，消耗的算力完全相同——同样的浮点运算、同样的内存、同样的功耗。开源抢份额，只是把利润从前沿模型层转移到了AI基础设施层，对算力需求没有任何负面影响。”

然后是DUV光刻机的传闻，引发半导体设备板块大跌。Baker认为市场反应过度，但也不应完全忽视。

唯一真实的风险：信用市场

在所有触发因素中，Baker唯独对信用市场的变化表示认真对待。

“真实利率上升，信用利差走阔，这些是不可否认的事实。”他指出，Meta上周发行的债券定价远不如预期，各大科技公司的CDS利差全面走阔。

问题的核心在于：AI基础设施的大规模建设，究竟需要多少债务融资？

Baker的判断是：如果超大规模云厂商的运营现金流如期加速，债务融资的需求将大幅缩减。他援引数据称，微软、Meta、亚马逊的运营现金流（非自由现金流）已从上季度的28%增速加速至32%，剔除欧盟罚款等一次性项目后，实际增速达到35%。“这在这个体量下是实质性的加速。”

他进一步推算：若超大规模云厂商的算力按当前Blackwell价格而非更低的旧一代价格变现，运营现金流可能从目前共识预期的1.3万亿至1.4亿美元跃升至约2万亿美元，从而将约7000亿美元的信贷需求从市场上移除。

“如果按当前价格重新定价，未来几年的建设可能完全依靠运营现金流自我融资。”

GPU价格：涨幅50%-60%，与预期完全相反

Baker分享了一个他认为最能说明问题的案例。

一家知名初创公司7个月前以约每GPU每小时2美元的价格租用了一批Blackwell集群，续约时预计支付接近4美元——涨幅约50%-60%。“你本来会预期价格温和下降就已经是利好了，结果是垂直上涨。”

他还提到，某家推理云公司在播客上公开表示，合同到期后计划支付100%更高的Blackwell价格。“这意味着所有超大规模云厂商都在低估自己的盈利能力。”

Baker表示，他在硅谷的调研目标就是“尽可能努力地寻找负面数据点”，但除了关于Anthropic增速放缓的第三方数据存在争议外，“我找不到任何一个负面的可量化指标”。

内存市场的博弈论：没人敢违约LTA

Baker花了大量篇幅分析长期供应协议（LTA）在内存市场的战略意义。

他指出，内存（HBM DRAM）是当前AI算力中最关键的瓶颈——“每单位算力配置的内存越多，产出的token就越多，这是提升token输出效率最重要的单一变量。”

在这个背景下，违约LTA的代价极其高昂。Baker以博弈论框架分析：假设某家超大规模云厂商在2027年或2028年试图以市场供过于求为由压低价格、违约LTA，内存供应商完全可以将原本分配给它的产能转给竞争对手。“你刚刚失去了市场份额。而这个行业是周期性的，供过于求之后必然是供不应求。你下一次的分配会怎样？”

他总结道：“在当前环境下，违约LTA可能毁掉你的整个业务和市场地位。这在以前从未是这种情况。”

英伟达的新商业模式：信用包装加收益分成

Baker认为英伟达目前的估值被严重低估。

英伟达正在推行一种“信用包装加收益分成”的模式：为GPU买家提供融资便利，同时在GPU价格高于某一底价时获得收益分成。“这实际上可能让他们迅速建立起一个通过版税运营的大型云业务。”

Baker认为这一模式被市场严重误解，建议英伟达加强对外解释。他的逻辑是：在当前环境下，没有任何资产比英伟达GPU更容易融资；英伟达在土地、电力资源的撮合上也表现出色；加上其对几乎所有AI实验室的股权投资，英伟达实际上是在用数百亿美元的自由现金流，系统性地强化自身的竞争护城河。

"英伟达目前的远期市盈率处于过去两年的最低点。市场100%认为他们的盈利能力被严重高估了。也许吧，但我在硅谷找不到支持这一判断的数据。"

SpaceX：被低估的算力巨头

Baker援引Substack作者Will Funda AI的报告称，SpaceX计划在18个月内建成8吉瓦的算力。"我永远不会押注Elon失败，但这将是一项真正令人难以置信的壮举。"

Baker指出，SpaceX目前的算力变现效率约为每吉瓦500亿美元，而市场对其明年的收入共识预期为730亿美元。"忘掉Starlink V3，忘掉Grok 4.5和Cursor，仅这些业务加起来的ARR就可能很快突破100亿美元。而这些都还没有被充分计入估值。"

他还提到，Benchmark投资了轨道算力公司Star Cloud，后者正与SpaceX合作使用星链激光技术。"也许我疯了，也许Elon疯了，也许Benchmark也疯了，也许SpaceX的工程师也疯了——但这看起来不太可能。"

最大尾部风险：监管，而非技术

Baker表示，"纽约的数据中心暂停令让我感到不安。我们生活在一个后事实、后逻辑的政治世界里。"他认为，AI行业在公关上"做得非常糟糕"，导致普通美国人形成了"数据中心会推高电价、耗尽水资源、抢走工作"的错误印象。

Baker逐一反驳这些叙事：在当前的数据中心选址协议下，周边居民的电价通常会下降；一本学术书籍对数据中心用水量的估算存在"四个数量级"的错误，作者本人已多次承认；数据中心带来的蓝领就业岗位是持续性的，而非一次性的。



全文访谈如下：

AI抛售与基本面背离——顶级AI投资人深度解析

节目：像最优秀的人一样投资（Invest Like the Best） 录制日期：2026年8月4日

节目简介

本期节目中，Patrick O'Shaughnessy与Gavin Baker深度剖析2026年7月AI及半导体市场的剧烈抛售行情。Gavin将这一时期描述为"把2022年整年的波动压缩进了一个月"，并解释了为何公开市场的恐慌情绪与硅谷实地观察到的强劲基本面形成了鲜明反差。两人深入探讨了超大规模云厂商（hyperscaler）不断加速的经营性现金流、GPU现货价格的飙升、开源AI模型为何反而在驱动大规模基础设施需求，以及内存市场长期协议（LTA）背后的博弈论逻辑、英伟达的战略主导地位、SpaceX宏大的数据中心布局，以及AI算力面临的监管风险。

时间戳

- 0:00 引言
- 1:17 AI抛售与基本面背离
- 10:20 为AI基础设施建设融资
- 18:18 GPU价格持续攀升
- 24:23 Claude搅动市场
- 29:01 哪些因素可能打破当前逻辑
- 36:59 内存供应战
- 42:08 英伟达的新打法
- 61:51 数据中心与监管
- 71:11 SpaceX与轨道计算

文字记录

Gavin（说话人1）： 我希望自己能感到害怕。看着这些股票越跌越便宜，我不想像个疯子一样还觉得预期回报在上升。我这周在硅谷的主要任务就是压力测试——让我找到一个负面信号，告诉我点负面的东西。但我一直找不到任何量化指标层面的负面数据，基本面实际上还在持续改善。股票方面，以我们录制本期节目时的价格来看，英伟达的远期市盈率已经是过去十年的最低点。市场百分之百认为它们的盈利能力被严重高估了。

Patrick（说话人2）： Gavin，距离上次才两个月。模型发布的节奏越来越快，我们录播客的间隔也在不断缩短。我们现在基本上是在跟着模型发布的节奏录节目了。另外，我记得之前有人指出，我们的播客似乎和市场……

Gavin： 局部顶部同步出现——这次之后没人能这么说了。你现在在想什么？这个月真是疯了。

我觉得7月就是把2022年整年的走势压缩进了一个月。基本上确实存在一些负面因素，我们应该谈谈，但总体来看，我认为基本面的天平正在显著改善。大量AI相关标的从高点下跌了50%至60%，一个月内单边下跌了40%至60%。

我出发前问了你，你在硅谷待了整个夏天，有没有听到任何一个关于AI的负面量化指标？有没有听到任何一个减速的迹象？一个都没有。事实上，每一项指标都在加速。而且这不是那种对AI充满热情的人的盲目乐观——他们是有数据支撑的，来自各自不同的视角。

AI抛售与基本面背离

无论你从哪个角度切入——GPU可用性、GPU租赁定价、本月DRAM现货价格、token增长量——一切实际上都在加速。我认为问题的一大根源在于：市场对Anthropic和OpenAI缺乏透明度，以及美国国内那些通过推理服务变现的开源推理云——比如Fireworks、Modal、Together——这些公司都不是上市公司。



一旦你看到这些数据，画面就会截然不同。因为得益于GLM 5.2和Kimi K3，开源推理需求已经大幅加速。Nevatron也在稳步推进。我们还看到了一个颇具价值的小型美国开源模型发布。OpenAI整体在加速，Anthropic持续强劲增长，且几乎可以肯定已在产生可观的自由现金流。

大家都在看那张图：半导体现金流像这样，超大规模云厂商的自由现金流像那样。但如果你遗漏了这些私有公司，那张图就会失去一些非常重要的信息。

更关键的是：在2024年和2025年，即便是最乐观的人也会预期，GPU价格会缓慢下降。如果你是悲观派，则预期价格会急剧下滑。但我认为没有人在2024、2025年预料到，到2026年，老一代GPU的价格还会垂直上涨。

所以大家当时都想着要聪明一点，提前签好长期合同。在某种程度上，很多新兴云服务商（Neo Cloud）也不得不这样做，因为它们需要通过承购协议（off-take agreement）来为GPU融资。于是，已安装算力的合同价格相对于当前现货市场出现了巨大折价。随着合同陆续到期，算力被重新定价至更高水平，现货折价将收窄，算力价格仍将走高。

我认为随着ROI问题逐步得到解答，你会看到大量加速迹象——本季度其实已经开始显现了。从经营性现金流（注意是经营性现金流，不是自由现金流）来看，微软、Meta和亚马逊报告的经营性现金流同比加速，从28%提升至32%。这些超大规模云厂商现在确实存在一些非常规的大额项目——比如几十亿美元的法律费用（主要是对欧盟的罚款）——本季度的一次性项目数量尤为突出。如果剔除这些，增速从28%跳升至35%，在这个规模上，这是相当显著的加速。而这还是在Rubin架构算力大规模点亮之前——Rubin点亮后将带来更高溢价，而那些合同也尚未重新定价。

这是一段颇为煎熬的经历。

事件复盘

我们来梳理一下这个月是怎么演变的。

首先，Meta宣布将对外出租算力，市场将此解读为极度利空——认为他们有产能过剩、要削减资本支出，是一场灾难。但实际情况完全不是这样。他们后来发布的财报并没有削减资本支出。真实情况是：他们看到SpaceX手握大量已安装算力，并以远高于合同价格的溢价，将部分经过交易优化的集群售入市场。至少在分析师层面，他们看到了机会——有大量猜测说他们会去融资。也许他们的想法是：先用一小部分产能证明能够产生强劲的内部收益率，然后去募集股权资本，从而加快发展步伐，并提升资本支出。

事后来看，这并不像是他们的真实意图。但市场对此做出了非常负面的解读并随即抛售。我当时非常确信这不是利空。Meta资本支出计划的各种先行指标一点都没有变化，反而是在继续加码。没过多久，他们就发布了很久以来最好的模型——Llama 1.1，确实是一个非常优秀的模型，只是被Claude 4.5的光芒掩盖了，但它比你两年前的预期要好得多。所以他们根本不可能踩刹车。

接着Kimi发布，市场对开源产生了巨大恐慌。与此同时，Silicon Data Token Index（硅谷数据Token指数）出现了一些下滑和走平，这两件事其实是有关联的。Silicon Data Token Index捕捉的是token的结构（mix），它并不能看到所有token。但由于GLM 5.2和Kimi的出现（尽管渗透需要时间），这份数据中出现了一种结构性转移：从更昂贵的前沿模型token（推理毛利率可能在80%至95%之间，姑且存疑，但总之极高）向开源token迁移。市场不知为何将此解读为利空。

但现实是：一个token就是一个token，生成一个token所需的算力完全相同——无论flops、内存还是功耗，都是一样的。token不是完全等价的，但大体而言，开源抢份额这件事，只不过是把利润从前沿模型层转移出去，并通过弹性效应刺激了更多token需求，从而驱动更多算力需求。而利润则从前沿模型层流向了AI基础设施层——Anthropic和开源模型都跑在同样的底层云基础设



施上，后者收取同样的算力费用。所以你实际上只是在把利润从前沿模型那里抽走，让更多利润流向AI基础设施层。这正是催化剂之一。

然后这些事情叠加在一起，不断发酵。比如：Jensen Huang是全球最大的开源支持者——如果开源对他的生意不利，他还会这么做吗？他当然还会支持，因为这对世界是正确的事，但也许这就不会是他最标志性的议题了。顺带一提，我认为在只有一两个主导性前沿模型、毛利率高达90%的世界里，开源对人类和社会都非常重要，我们需要更多模型并存。

随后是DUV光刻机，由于大家都被打包进了同一类篮子里，这引发了半导体设备板块的大规模抛售。

然后，我认为真正核心的担忧出现了：实际利率上升——这是合理的，因为大规模投资需要融资，信贷市场正在承担越来越大的压力，尽管绝大多数融资仍来自经营性现金流。于是实际利率上升，信用利差走阔。

Meta上周发行了一笔债券，定价并不理想，这清楚地表明信贷市场承压——所有公司的信用违约互换（CDS）都在走扩。非常聪明的私募资本人士说，这完全在预料之中，不过是银行对冲自身承诺的正常操作。但不管怎样，表面上看起来并不好看。CDS扩大、利差走阔、实际利率上升，这些都是不可否认的事实。如果我们需要用债务来为这轮建设融资，那确实会非常令人担忧。

为AI基础设施建设融资

这正是现货价格与合同价格之间的差异如此重要的原因所在。

我来梳理一下数字逻辑：如果看已安装算力所对应的超大规模云厂商经营性现金流，市场的一致预期实际上是按照Ampere架构（落后两代，而非一代Hopper）的变现速率来建模的。这样算下来，超大规模云厂商的经营性现金流约为1.3至1.4万亿美元。但如果按当前Blackwell价格打一个折扣来变现，数字会更接近2万亿，这就使信贷需求减少约7000亿。随着这些已安装算力重新定价，信贷指标会随之改善，届时信贷融资反而会变得更容易——尽管他们是否真的会选择举债，还有待观察。

两个月前，我们谈到过Blackwell“气穴”（air pocket）风险——花数千亿美元采购Blackwell，而这些算力初期主要用于训练，训练并不能立竿见影地产生回报，这可能构成风险。我们确实在一季度看到了这一现象。而我对这个风险逐渐感到释然的原因，正是因为Anthropic的表现实在令人印象深刻。市场在4月、5月、6月都对此选择了忽视，但到了7月，各种因素叠加，市场停止了忽视——恰恰就在经营性现金流开始真正加速的时候。这是既成事实。微软在6月份带来了大量新产能，甚至还没反映在第二季度财报里。

核心问题

归根结底，一切都取决于你是否相信：硅谷的量化需求信号将持续，从而推动已安装算力随合同到期而重新定价至更高水平，经营性现金流持续加速，并足以支撑大部分乃至全部的建设融资。如果按当前利率重新定价，未来数年的融资需求可能完全可以通过经营性现金流内部解决。

2022年，市场有明确的担忧对象——衰退、加息、通胀，大家心里都很清楚。这次的担忧——DeepSeek、Liberation Day（“解放日”关税）——同样清晰可辨，这在某种奇怪的意义上面反而让人心安一些。那些担忧——除了信贷这一项之外——在事实层面感觉就是无稽之谈。而我们的分析让我相信，即便真的需要信贷，随着重新定价的推进，这个问题也将迎刃而解。

GPU价格持续攀升

今天早上我和一家公司聊天，他们是那种最受欢迎的创业公司之一。他们之前租了一个几千颗Blackwell的集群，价格大约在每GPU每小时2美元出头。七个月后，他们续租完全相同的集群——相同规模，B200，完全一样——希望以略低于4美元的价格成交。



就在今天听到这个消息，真的很疯狂。你本来只期望价格温和下降就已经是利好了，结果六个月内涨了50%到60%。这样的故事比比皆是。我记得某家推理云公司——我记不清名字了——在一个播客上说，他们预计合同到期后为Blackwell支付的价格将增加100%。这意味着，所有超大规模云厂商都处于盈利不足的状态。

我这周末硅谷的主要任务就是做压力测试，全力寻找负面数据点。大家提到的主要负面信号，是第三方数据显示Anthropic的增长曲线似乎稍微偏离了轨道。这可能确实如此，但OpenAI和开源正在大幅加速。如果综合来看，整体仍在净加速。

开源对公开市场来说就像宇宙中的暗物质——很难直接测量，但如果你追踪那些推理云说的话，无论是播客上还是会议上，需求显然在加速——这也合情合理，因为GLM 5.2和Kimi K3带来了巨大的能力飞跃，而这种趋势将会延续。英伟达也在将Nevatron稳步推向前沿。

这个月确实充满了挑战和挫折。但每一个假设都经过了压力测试，基本面仍在改善。以我们录制本期节目时的数据来看，英伟达的远期市盈率是过去两年的最低点。半导体公司估值更便宜的时候，只有Liberation Day和DeepSeek那两次，而那两次都是V型底。这意味着市场百分之百认为它们的盈利能力被严重高估。

我们需要保持谦逊，也许市场是对的。但我来硅谷这周的使命就是尽可能用力地寻找负面数据点。通常来说，来硅谷会有正有负，总体偏正。但这次，除了Anthropic的第三方数据这一点之外，我找不到任何量化层面的负面指标。而这一点也受到Anthropic股东们的强烈质疑——他们迫切地想告诉你他们所掌握的信息，只是担心说出来会影响到未来的IPO配额。

Grok和Cursor从第三方数据来看7月也发生了相当显著的变化，Grok 4.5和Grok Build的发布使7月成为一个颇具转折意义的月份。

Claude搅动市场

这里值得一提的一个观察是：我收到一篇文章，作者是Mike Mauboussin，大意思是说多样性的崩溃是泡沫和崩盘的根源。现在，我认识的公开股票投资者——无论散户还是机构——每一条消息都会立刻被输入Claude或Claude Code，有时是Claude智能体。Claude是概率性的，但它对这些消息的解读方式可能并没有太多差异。这有点像回到了沃尔特·克朗凯特（Walter Cronkite）的时代——那时只有一个公认的权威声音，后来媒体碎片化了，权威声音消失了；而现在，Claude在某种意义上就成了股市的"沃尔特·克朗凯特"，所有人都相信它说的。

Claude确实非常聪明，但它并不总是对的，它的解读并不总是正确的。在股市中，你从根本上面面对的是对未来的概率性贝叶斯判断。所以你看到的就是一条消息出来，经过Claude处理，得出某种解读，大量市场参与者据此交易。

有个叫T.B.U.的匿名半导体社区人士发了一张日本电容器股票的图表，说我们在六周内经历了一个完整的电容器周期。那些股票——不管是翻倍、三倍还是四倍——垂直拉升，然后轰然崩落。实际的基本面变化都还没发生，但一个本来需要三年的周期，就这样在六周内走完了。

Patrick：你在这里的感受，尤其是让我对这件事更好奇的，是这里在推理服务效率提升、模型训练各个环节的创新进展。这些将如何随时间影响公开市场？你有没有了解到什么让你特别感兴趣或好奇的、时间线较长的创新方向？

Gavin：有一件事让我非常好奇：好像有很多人觉得他们离解决"持续学习"和"样本高效学习"已经非常近了——这两个课题我们之前也聊过。如果这两个问题得到解决，从某种意义上来说，会不会带来一种暂时性的需求不连续？

我听说，有些模型是在大约200亿个token上训练的，而现在这些大模型是在300万亿个token上训练的。如果你能用10万亿个token训练出一个模型，然后让它在现实世界中进行样本高效学



习，这对训练需求听起来似乎不太妙。但训练在整个半导体算力需求中的占比，终将渐近于某个很小的数值——不是趋向零，但会非常小。

这可能是本周最核心的技术洞察，但你也知道它是长期还是短期的事。SSI说他们将在8月发布模型，一整批专注于此的新实验室也在涌现。如果这真的实现，对世界来说将是巨大的福音。我们都希望看到这一天。

但我很难相信这会对AI基础设施需求产生负面影响。英伟达和所有这些创业公司都深度绑定，所以如果你强迫我回答，哪些情形会让我真正改变看法、感到担忧？

哪些因素可能打破当前逻辑

最主要的风险是：经营性现金流不再持续加速。这在一定程度上取决于Anthropic、OpenAI、Grok、Cursor以及开源的表现。

其次，如果GPU价格出现相对持续的大幅下跌，市场会立即做出反应。如果GPU开始变得容易获取，那会令人担忧。但你有没有听过任何人说他们GPU太多了？一个都没有。情况完全相反，感觉就像毒品市场一样。

如果这些实验室的用户规模增长停滞甚至下滑，那确实是实质性利空——除非这只是因为开源token在整体扩大蛋糕的同时抢占了一部分份额。我确实认为未来是多模型并存的格局，尤其是对AI原生企业而言。它们可以拿一个开源模型，经过监督微调 and 强化学习定制，部署在路由器后面——路由器优先把查询发给自己的模型，再由Claude或Grok等前沿模型做校验。在很多场景下，以一半的成本获得略优的效果。

但很多人听到“成本减半”就以为这对AI不利，其实完全不是。用户支付的成本不过是token毛利率的函数，实质上只是把token从约90%毛利的昂贵前沿模型，转移到约30%毛利的开源token。但这些token消耗的算力是完全一样的。

大公司正在变得聪明起来：他们设置路由器，把AI速度放慢，但实际上并不减少token消耗量，反而可能因为转向更便宜的开源token而消耗更多。而AI原生企业则完全相反，它们正在全力押注AI，几乎不雇用人类，把预算全部压在token上，没有任何放缓迹象。

让我无法忘怀的一个想法：全球大概只有50万人在使用智能体AI，其中大约25万人处于算力严重短缺的状态。而地球上有78亿人。当用户从50万增长到1%，到1亿，到5亿，会发生什么？

很多人会问：这些经营性现金流究竟从哪里来？谁是最终付款方？从根本上说，要么来自生产率提升带来的更快经济增长，要么来自劳动替代。在很多AI原生企业，你确实看到了劳动替代，但不是因为裁员，而是因为根本就不招那么多人了。每位员工创造的毛利润正在大幅提升，相比过去几代创业公司，这个数字几乎是垂直上升的。

还有一个有趣的观察：我今天早上从一位创立了多家公司的顶尖科技CEO那里听到——如果你看那些创始人主导和控制的公司，剔除疫情期间的过度招聘，几乎没有人在大规模裁员。这些人本应是最快拥抱AI来提效的，但他们基本没有进行大规模裁员——这可能说明他们认为仍然有大量机会留给人类，再加上token消费的快速增长。

从Cognition Reup在Stripe的数据来看，AI花费最多的公司增长速度明显更快。Cognition指数的数据令人震惊，尽管批评者说它没有充分控制行业差异，但如果你深入挖掘，会发现即便是管道工、暖通空调承包商这类蓝领行业，AI也在带来显著提升。

内存供应战

我必须提到一个我认为市场非常重要、但我此前理解有误的转变：我们正在发生结构性变化，尤其是内存领域，从追求短期业绩超预期，转向以牺牲短期上行换取确定性的供应链协议，也就是所谓的长期协议（LTA）。在LTA框架下，客户预付，并锁定一个价格区间。



这让我想到了博弈论的问题。我们来梳理一下打破LTA的博弈逻辑。在这个游戏中，真正有规模影响力的玩家只有四个：亚马逊（Trainium）、谷歌（TPU）、AMD，以及远超其他三者合计的英伟达。

内存之所以如此关键，是因为在给定算力单元中，内存越多，token产出越高——这是提升单位算力token产出最关键的维度，同时也会降低每token成本，这正是为什么需求完全没有因此而下滑。

现在假设是2027年或2028年，你想打破某个LTA，争取更低的价格。但在相当程度上，市场份额在未来几年将由供应链预分配决定。如果你打破了LTA——假设不是处于严重供过于求的状态——而未来两三年内，由于任何原因，议价权再次回到内存厂商手中，你的业务就完了。

就算谷歌在供过于求时打破了LTA，那往往意味着价格下跌、产能自然收缩。但你觉得，下一次供给紧张周期来临时，谷歌的产能分配会怎样？

我认为，在当前这个内存是一切核心轴的环境下，打破LTA可能毁掉你的整个业务和市场地位。这和以前截然不同。以前苹果可以对内存厂商为所欲为——因为它是压倒性的最大买家，没有竞争对手，不论怎样对待SK海力士，美光也会乖乖接下来。但现在不同了。你至少有四个大玩家，还有大量创业公司在竞争。如果你打破LTA，内存厂商可以说：好，你破了价格协议，我们就破数量协议，把份额给你的竞争对手。

这也是为什么英伟达的主导地位在当前环境下如此令人费解地被低估。没有什么比英伟达GPU更容易融资的了。在用地选址、电力获取方面，他们也在下好棋——通过撮合和资源整合发挥着重要作用。他们还推出了一个颇为聪明的新商业模式：类似于一种“信用包装+收入分成”结构，如果GPU价格高于某个底线，就可以非常快速地通过特许权使用费建立起一个相当大的云业务。

英伟达的新打法

英伟达这个模式，我认为被严重误解了。本质上，他们并不是在直接借钱给GPU买家——他们是在参与信用包装，别人来承担融资责任。所以这并非严格意义上的供应商融资，而更像是股权投资加上收入分成。

他们确实在进行股权投资，而且几乎每次没有参与股权投资的时候，事后来看都是一个错误。他们投资了几乎所有东西——除了长期以来的内存公司，以及曾经没有投Anthropic（不过后来已经投了）。

如果你手握丰沛的现金流，又对AI极度看好，同时还能看到所有实验室的进展——持续学习实验室、Safe Super Intelligence都在和他们合作——Jensen自然对所看到的东西保持乐观。所以，为什么不同时获得股权上行，加上收入分成？这样既能缓解各方现金流的错配，又能强化自身的竞争地位，还能显著提升每千瓦的收入。

如果我是SK海力士的CEO，我会做完全一样的事：去找GPU买家，说我也愿意参与英伟达的信用包装结构。内存公司的业务本质上没那么稳定和可预期，但也许可以通过预付一部分现金来降低自身风险，同时争取获得持续收入的分成。我确信黑石和阿波罗等机构正在向内存公司建议类似的方案。

这其实是LTA逻辑的自然延伸——通过牺牲部分上行来换取持续性，还可以获得经常性收入的特许权。这正是英伟达正在做的事，而我认为他们应该更清楚地把这个逻辑解释给市场。

从博弈论的角度来说，Anthropic如果在算力上像OpenAI那样积极布局，早就可以遥遥领先了。OpenAI现在重新回到了竞争前列，Grok也在局中，这些都是拥有最前沿算力的公司。在看到这一切之后，还有谁会放松油门？尤其是当融资可以完全来自经营性现金流的时候。



Patrick： 你怎么看DUV光刻机的消息？

Gavin： 我认为两种说法可以同时成立。打个比方：如果说DUV机器是一台喷气式涡轮发动机，那EUV机器可能就是曲速引擎；或者说DUV是螺旋桨飞机，EUV是喷气式飞机。他们之前没有，现在据称有了，这是一次相变——你从液态变成了固态。那台“喷气发动机”，或者说“螺旋桨飞机”，可能比当前技术落后25年，但依然重要，不应被忽视。

市场的反应确实像是严重过度了。如果这件事要影响到ASML的订单，可能要等到5年后，而市场在这期间会对它反复担忧、反复淡忘。所以这可能是过激反应，但也不应置之不理。

数据中心与监管

关于其他公司

开源越来越接近前沿，而像Fireworks这样的公司让模型定制变得极其简便——你可以针对特定场景训练出媲美甚至超越前沿模型的效果，且成本大幅降低，这对整个软件行业和大量AI原生企业都是天大的好事。

我们的朋友Vijaya说，他从没见过这么多公司能在9个月内从成立到实现5000万美元年收入并产生现金流。这些公司以前可能被人嗤之以鼻地称为“ChatGPT套壳”，但现在有了开源，它们已经积累了领域专有数据，打造出了真正的护城河。

Fireworks推出了一个叫Nexus的产品，只需三行代码，它就能摄入你的数据，经过强化学习微调，再通过路由器智能分发查询——Harvey（被收购前）、Cursor、Harvey、Lagora都在大力使用这套思路，因为如果你能把30%至60%的token消耗转移到自己的强化学习模型上，只在剩余部分使用前沿模型，你就不再只是个套壳，而拥有了真正的护城河。

Patrick： Cursor那件事很有意思——AI在速跑我们人类的学习曲线：用前沿模型规划，把任务分配给更轻量的模型，效率提升了15倍。

Gavin： 确实，这很有意思。也许低毛利率的开源token——只比前沿模型略逊一筹——反而会使最顶尖的前沿token更加值钱。如果你有一批智力水平为120的开源模型，价格极低，那一个能够统筹调度它们、智力水平为160的模型，岂不是更值钱？我们上次聊到，经济回报高度集中于前沿模型一直让我感到惊讶。这一格局正在改变，但开源token反而可能强化最顶尖前沿token的价值。

最令人震惊的是：那些基于开源的推理云公司，增长速度几乎和早期前沿实验室一样快，却几乎不烧钱，Rule of 40的指标极其惊人。

关于最大风险

监管，毫无疑问是最大的风险，也是最显而易见的风险。纽约宣布数据中心暂停令，我们生活在一个后事实、后逻辑的政治世界里。AI行业在公关方面做得很糟糕，而普通美国人的主流叙事是：数据中心会推高你的电费，抢占你的水资源，然后抢走你的工作。

而现实是：按照现在签订的协议，数据中心进驻后，周边居民的电费实际上往往会下降，因为背后有“表后协议”（behind-the-meter deals）。以前数据中心开发商只需给当地警察局和消防局买几辆车，现在他们要建医院、学校、警察局和消防局，还要降低居民电费。

而且相关就业岗位是持续性的，因为数据中心需要大量管道工、电工、暖通空调承包商——数据中心在某种意义上是我有生之年蓝领工资增长最大的推动力。然而，名义上代表蓝领工人的民主党，却在阻挠这些就业机会。



有个关于数据中心用水量的说法：一个学者在书里犯了计算错误，把用水量高估了10000倍——不是一个数量级，是四个数量级。作者自己都多次承认了这个错误，这个问题早已被充分证伪，但谣言还在传。这让我想到了大力水手吃菠菜的故事——也是因为某本学术书上小数点放错了位置，菠菜含铁量被高估，这个错误一直流传至今。

这个行业需要有人站出来说真话。也许需要一个基金会，在NFL、世界大赛、大学橄榄球赛季中投放广告，告诉公众数据中心真正的样子：签署了承诺协议的数据中心，你的电费会降，社区会受益，会有大量高薪蓝领就业机会持续出现，对水资源和环境几乎没有影响，而且它完全可以建在城郊10英里之外。

同时，AI拯救生命、治愈罕见疾病的故事也需要被讲出去。今年ASCO年会的氛围——"这是历史上单次会议中科学突破最多的一届"——其中相当一部分贡献来自AI。如果你有一个生病的孩子、父母或挚爱，AI正在切实提升他们康复的概率。

行业里的人认为这些都是显而易见的常识，所以他们理所当然地以为所有人都懂。但事实上，这与大多数普通美国人的认知之间存在巨大鸿沟。纽约的禁令感觉只是个开始，即便在那些最亲商的深红州，如果你不主动讲好自己的故事，也不会有人替你讲。

SpaceX与轨道计算

Patrick： 你怎么看SpaceX被公开市场消化这件事？你认为市场真正理解这家公司吗？

Gavin： 感觉并不理解。从IPO以来，基本面一直在改善——Grok 4.5、Cursor的收购和加速、以及他们证明了自己能以比任何人都低的成本、更快的速度引入更多算力。

他们进入市场时，恰好撞上了现货高点——这在某种奇怪的意义上，反而是算力需求旺盛的佐证之一：他们一下子把大量算力投入市场，市场几乎没有任何感觉，就像一列货运列车完全没有减速。

有一篇Substack分析（Funder AI）认为SpaceX将尝试引入8吉瓦的算力。我永远不会赌伊隆输，但这将是一项极其惊人的壮举。自他们上次签订合同以来，利率上升了，没有下降，他们的变现效率大约是每吉瓦500亿美元。明年的一致预期是730亿美元。

先别提Starlink V3、Starlink星地直连、Grok 4.5和Cursor，仅这些业务合计就能很快达到100亿美元的年经常性收入。忽略核心Starlink基础业务——如果他们真的能引入那么多算力，一致预期的730亿是8吉瓦乘以每吉瓦500亿，而且显然不会在2027年初就全部点亮，这在我看来极不可能实现，我几乎不相信那篇报告。

但值得注意的是：迄今为止，每年能引入超过500兆瓦电力的公司，只有超大规模云厂商、Coreweave、Weave、Crusoe和SpaceX，而SpaceX以最低成本、最快速度完成了这一壮举。他们的集群确实深受用户好评。

市场目前对SpaceX的主流解读是：现货价格将下跌90%，大量算力进来也不会产生预期中的收益。也许吧。但我见识过伊隆的公司一次次把看似不可能变成可能。

我认为当前股价中，来自这部分潜在算力的预期体现极少。大规模引入算力非常难，为GPU通电极其困难，但他们做到了，而且这感觉并没有被计入市场预期或估值。

很有意思的是，"SpaceX——数据中心公司"这个梗现在看来越来越不像玩笑。我在星际基地待了不少时间，轨道计算感觉每天都在变得更加真实。前几天的Starship着陆，真的很酷。

我们的Benchmark朋友投资了Star Cloud——一家轨道计算公司，SpaceX在某种程度上与其合作，据说将开放星链激光通信技术，这对轨道计算至关重要。Benchmark的人非常聪明，完全



不在伊隆的生态圈里，却选择不具备SpaceX内部发射成本优势的情况下，以相当高的估值投资了一家轨道计算公司——这对我来说是一个很好的"理性人检验"。

也许我疯了，也许伊隆疯了，也许Benchmark也疯了，也许SpaceX的工程师也疯了，但这几个都疯了这件事，我觉得概率实在太低。

Patrick： 我们是在Benchmark的办公室录制这期节目，坐在他们那张著名的晚宴桌旁。感谢Benchmark，感谢Eric帮忙协调，感谢所有合伙人。

Gavin： 一年后我们就知道谁对谁错了。时间会证明一切。未来是概率性的，但我们正处在一个令人兴奋的时刻。

Patrick： 如果我们继续跟着模型发布节奏录节目，我们几周后可能就会再见了，也许还是在Benchmark这里。和你聊总是一件乐事。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 269  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论

1 条评论



正在加载