摘要：
人才留不留得住、模型能不能保持领先、AI能不能真金白银变现……这些问题，越来越取决于手里还剩多少算力。

没招了！硅谷为了争夺AI算力已经**彻！底！疯！狂！**

就连A社CEO Dario Amodei也低声下气求到了对家Meta门前：

老铁，给点**算力**吧。。。



结果你猜怎么着，小扎婉拒，马斯克坐收渔利：

SpaceX充当英伟达GPU二道贩子，给Anthropic倒卖算力，赚得那叫个盆满钵满——

8月首份财报长势喜人，光季度AI业务收入就高达**25.61亿美元**，同比增长247%，环比更是翻了两倍之多。



好家伙！为了算力，硅谷这是拼了，**大连横时代**堂堂来袭。

甭管以前在网上互喷有多狠，台下还是要为了GW弯腰。

不弯不行啊，你看隔壁掉队的**谷歌**。

豪掷27亿美元请回来的顶级科学家Noam Shazeer，因为**差算力**，没两年就托马斯回旋跳去了OpenAI。

别人砸钱还要听个响，你谷歌纯纯做慈善来的。（doge）

反正硅谷现在是咂摸出味儿了：

人才留不留得住、模型能不能保持领先、AI能不能真金白银变现……这些问题，越来越取决于手里还剩多少算力。

GPU成硅谷硬通货

以前缺钱缺人，现在冒头的是**算力经济**。

即便强如谷歌这样的科技巨头，也无法保证明星研究员能获得足够的GPU资源。



提起**Noam Shazeer**，最先想到的是Transformer八子之一，他于2021年离开谷歌创立Character.AI，致力于开发生成式AI聊天机器人。

2024年，谷歌斥资**27亿美元**，通过交易促成Shazeer回归，并担任Gemini联合负责人。

这样的研究员，本该是巨头争相保障资源的人。

但根据外媒最新报道，他的团队同样遭遇了算力被重新分配的艰难处境，Shazeer被迫转投对家**OpenAI**。

无独有偶，此前**哈萨比斯**也曾长期对项目算力不足表达过不满，在一定程度上也影响了他卸任DeepMind CEO的决定。

目前谷歌内部，关于资源分配存在较大分歧，**谢尔盖·布林**有时会直接介入，将资源重新调配给自己认为重要的项目。

但归根结底还是算力资源不够，只能开源节流。

公司外部的竞争，则让行业关系变得愈加复杂。

OpenAI、Anthropic这些顶尖初创不仅要拼模型能力，还要争夺数据中心、服务器和供电能力。



以**Anthropic**为例，其模型的算力需求已经大到，需要与另一家模型公司讨论供货。

今年5月与SpaceX的合作协议规定，将在当月收获超300兆瓦的新容量，涉及22万块英伟达GPU，同时提高Claude Code和API的使用额度。

换句话说，这样做的目的就是**让后端拿到更多算力供给前端**。算力有了，模型强了，用户也留下来了。

于是模型公司的竞争开始出现两套同时运行的逻辑：

产品层面，大家还是争用户、争开发人才；**基础设施层面**，谁能及时提供资源，谁都可能成为潜在合作对象。



那么在夹缝中生存的小型AI创业公司呢？

它们的情况更具戏剧性。

这些公司难以自建数据中心，但过去，它们可以靠灵活租用AWS等云平台的GPU，**按需付费**。

然而随着头部AI实验室大量锁定算力资源，部分云服务商开始要求多年合约，预付款高达合同金额的**30%**，甚至要求创业公司寻找付款担保方。

以上种种，都让初创公司陷入了两难境地。

算力买太多，如果未来用户增长不及预期，持续消耗的现金就打了水漂；买太少，则可能因为没有计算资源处理需求而错失增长机会。

这样的情况反而催生出了一门新生意：**全球算力淘金**。

也就是寻找全球各地尚未充分利用的AI服务器资源，再将这些算力出租给需要的企业。

比如代表性的San Francisco Compute公司就曾跑到美国乡村旧鸡舍里收服务器，**马斯克也和台积电**讨论起了进一步的算力合作。

硅谷的顶级VC也开始亲自囤GPU，YC在7月为旗下创业公司推出专供的GPU集群，Radical Ventures还会帮助被投公司协调供应商合同。

这对于正在训练或部署模型的小型团队，稍微解决了燃眉之急。

AI算力争夺战失控

但**堵不如疏**，算力会出现这种短缺情况，其实个中原因相当复杂。



OpenAI、Meta乃至谷歌都在积极建设新的数据中心，承诺**未来**会提供海量GPU资源。

但模型快速增长的需求等不及，这中间的时间差，或者说画的大饼，就是公司还得继续四处找算力的原因之一。

用户使用AI的方式，也在无形之中加码了供给压力。

从今年开始，**Agent**开始代替一问一答成为用户使用的核心范式，连续长时的工作任务迫使服务器承担起更多的并行计算。

需求增加之后，连同芯片的租赁行情都发生了翻天覆地的变化。

SemiAnalysis今年4月公布的数据显示，**H100**一年期租赁合约价格，从2025年10月低点的每GPU每小时1.70美元，上涨至2026年3月的2.35美元，涨幅接近**40%**。



GPU堪比黄金的说法，并非空穴来风。

真正能即时交付、稳定运行的算力不足，新的算力还遥遥无期，共同造就了算力市场的困境。

于是**算力霸权**变得具体。

初创公司挑战行业巨头的叙事将日益凋零，即使有人有路线，计算资源不够也完蛋。

肉眼可见的是，**算力正在成为AI时代的准入门槛**，并强化拥有自建基础设施的大公司的优势。

可谓是算力我有，实力在手。

做AI产品的，要考虑的也变多了。既要担心产品没人用，也要担心用户增长速度超过自身算力扩张。

但困境亦是机遇，**卖铲子的中间层**乐开了花。

你说是吧，老黄？

本文来源：量子位

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

27 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论