

摘要：

匿名AI模型“stealth/ox-alpha”现身OpenRouter。独立研究人员Ben Davis测试发现，其视频编码器、分词器、输出风格等多项技术特征高度接近智谱GLM系列，并在部分编程基准中超过GPT、Claude等主流模型。Davis称其“99%确定”该模型来自智谱，但目前尚未获官方确认。

一个匿名AI模型悄然现身模型分发平台OpenRouter。独立研究人员测试显示，名为“stealth/ox-alpha”的模型不仅在部分编程基准中超越GPT、Claude等主流模型，其技术特征也高度指向智谱尚未发布的下一代多模态旗舰模型。

据技术人员Ben Davis 8月21日发布的测试报告，ox-alpha于8月20日上线OpenRouter，目前提供为期一周的免费访问。该模型支持文本、图像和视频输入，具备推理能力，上下文窗口达到104.8万token。

Davis在X平台表示，他“99%确定”ox-alpha属于智谱GLM-5.x系列，视频编码器、分词器、输出风格以及音频拒绝行为等多项证据均指向这一结论。其测试还显示，ox-alpha在部分GPT和Claude对比测试中表现更优。

不过，需要强调的是，上述结论均基于个人测试与技术推断，目前尚未得到智谱官方确认。



本·戴维斯 @davis7

订阅



99%确定是GLM-5.x，所有证据都指向它（相同的视频编码器、相同的分词器、风格匹配、相同的音频剔除等等）。GLM-5.3发布会上关于强化学习环境的内容看起来非常棒，感觉很有发展潜力，没想到它进步这么快，但事实就是如此。这东西简直好得离谱。我做的第一批测试结果都非常出色。我已经和GPT/Fable做了几次对比测试，它的表现甚至比它们都好.....看来OpenAI和Anthropic又要开始放弃一些模型了，因为这玩意儿（至少看起来）就是新的最先进水平.....



本·戴维斯 @davis7 · 4小时

我在 DeepSWE 上用它跑了 10 个任务（所以它的真实得分可能波动很大，这只是其中一部分），但是.....gpt-5.6-sol: 52%，fable: 65%，这个什么玩意儿: 80%（差点就成功了，所以实际上超过了 80%）。我彻底懵了。x.com/opencode/statu...

Task	fable-5 [max]	glm-5.3 [max]	gpt-5.6-sol [max]	grok-4.6 [xhigh]	ox-alpha
anko-typed-variable-bindings	4/4	4/4	2/4	1/4	✓
arktype-json-schema-refs	2/4	1/4	3/4	1/4	✓
fastapi-deprecation-headers	4/4	3/4	3/4	4/4	✓
helm-unified-manifest-stream	4/4	4/4	4/4	4/4	✓
igel-persist-feature-schema	3/4	3/4	0/4	4/4	✓
katex-multicolumn-array-spans	2/4	4/4	3/4	4/4	✓
meriyah-explicit-resource-decl	1/4	0/4	0/4	0/4	✓
query-persist-restored-state	2/4	3/4	1/4	2/4	✓
scc-bounded-memory-spilling	4/4	3/4	4/4	4/4	×
vulture-persistent-analysis-cache	0/4	0/4	1/4	1/4	×
Mean on these 10	65%	62%	52%	62%	80%

视频编码器成为关键证据

Davis的测试从视频编码器、分词器、音频接口和输出风格等多个维度，对ox-alpha进行技术溯源。其中，**视频编码器的高度匹配被认为是最有力的证据。**

测试显示，在四组受控视频中，ox-alpha与GLM-5V-Turbo的video token消耗完全一致，两者均呈现出相同的三项特征：帧率无关的帧采样方式、约每秒147 token的时长缩放比例，以及逐帧分辨率缩放机制。

相比之下，MiMo v2.5、Qwen 3.8 Max和GLM-4.6V等候选模型均表现出明显不同的视频编码特征。

分词器测试同样指向GLM。报告称，对25个不同提示词进行测试后，**ox-alpha的token计数与GLM-5.3完全吻合，仅存在固定的+75 token隐藏封装差异，意味着两者可能共享相同的词汇表。**

此外，ox-alpha拒绝音频输入的行为与GLM-5V一致，而被列为主要竞争候选的MiMo v2.5支持音频输入，这也进一步削弱了后者的可能性。

在输出风格方面，ox-alpha每千字符约使用1.3个emoji，与GLM/Qwen系列较为接近；相比之下，Claude、GPT-5.6和Grok在相同测试环境下的emoji使用率接近于零。

编程能力已超过GLM-5.3?

能力测试方面，报告援引DeepSWE基准数据称，ox-alpha在10个确定性任务中通过8个，Pass@1达到80%。

作为对比，Claude Fable 5的通过率为65%，GLM-5.3和Grok 4.6均为62%，GPT-5.6-sol为52%。不过，由于不同模型的测试次数并不完全一致，且ox-alpha目前样本量较小，这一结果仍需更多独立测试验证。

其中，在“meriyah-explicit-resource-declarations”任务中，ox-alpha一次通过，而GLM-5.3、GPT-5.6-sol和Grok 4.6此前均以0/4告终。同时，ox-alpha保持了51,469项回归测试全部通过。

报告还记录了一次包含69次工具调用的智能体任务。在整个过程中，模型仅出现一次错误，没有发生重试循环，推理开销也较低。**Davis据此认为，ox-alpha的能力表现已经明显强于GLM-5.3，更像是下一代模型检查点，而非简单的变体版本。**

为什么指向智谱？

除了技术指纹，Davis还从模型发布时间和智谱此前的测试方式等方面进行了交叉判断。

智谱于8月14日发布纯文本版GLM-5.3，而统一视觉旗舰模型一直是社区关注的方向。更重要的是，智谱此前已有通过隐身渠道测试模型的先例，Pony Alpha最终便被确认与GLM-5有关。

从模型规模看，报告称ox-alpha的解码速度与GLM-5V-Turbo相差约6%。后者拥有744B总参数、40B激活参数，因此Davis推测，ox-alpha可能采用类似规模的MoE架构。

报告进一步认为，如果模型确实拥有约40B激活参数，那么运营方所声称的每日100万亿token服务能力在技术和成本层面才更具可行性。

与此同时，报告也逐一排除了其他潜在来源。小米MiMo与ox-alpha在视频编码器和音频接口上存在明显差异；DeepSeek此前没有发布视频能力，且分词器不同、模型发布方式也存在差异；谷歌、Qwen、xAI、OpenAI和Anthropic则被认为在分词器、输出风格或视频编码器等方面与ox-alpha不匹配。

免费测试或持续至8月27日

值得关注的是，ox-alpha目前的免费访问窗口可能持续至8月27日。

Davis指出，此前一些类似的隐身模型也曾在免费测试结束后，由相关中国AI实验室正式认领。

目前，智谱尚未就ox-alpha的身份作出官方回应。如果该模型最终确实被证实属于智谱下一代多模态旗舰，那么此次OpenRouter上的“隐身测试”或将成为其正式发布前的一次公开预演。

在官方确认之前，ox-alpha究竟来自何方仍无法盖棺定论，但从视频编码器、分词器到模型行为，多项独立测试目前均将线索指向同一个方向。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

241 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论



Robin
17小时前 中国天津

牛来模型，这名字真应景

0 回复

