


摘要：

OpenRouter上线匿名模型Union Alpha，定位编程与智能体任务，支持256K上下文，免费开放。其“前沿级性能”暂无完整第三方测试，身份引发OpenAI、GLM等猜测。匿名盲测正成为大模型发布的新型预热机制。

神秘模型 Union Alpha 突袭

继“牛来”Ox Alpha 之后，OpenRouter 昨晚又出现了一款身份不明的模型。




当地时间 9 月 16 日，OpenRouter 宣布上线匿名模型 Union Alpha。官方将其描述为一款面向研究、编程和智能体工作流的多模态模型，并称其能够在广泛的通用任务中提供“前沿级性能”。

与此前的 Ox Alpha 一样，Union Alpha 没有公布开发团队、参数规模、训练方法和基准测试成绩，而是先以免费模型的形式向用户开放，让开发者在真实任务中“盲测”。

这种带有悬念的发布方式很快吸引大量用户尝试。

OpenRouter 披露，Union Alpha 上线首日处理的 Token 数量已经达到约 20 亿，截至发稿前，Union Alpha 公布的 Token 消耗总量已超过 1000 亿。



截至目前，OpenRouter 对 Union Alpha 的“前沿级”定位仍然只是平台和模型提供方的描述，外界尚未看到足够完整、可复现的第三方测试结果。

从 OpenRouter 公布的信息看，Union Alpha 并不是一款只面向聊天场景的普通大模型。

它拥有 262144 Token，也就是约 256K 的上下文窗口，单次最大输出长度达到 131072 Token。模型支持文本和图片输入、文本输出，同时支持工具调用、工具选择和 JSON 格式输出，目标场景明确指向代码库分析、研究任务和需要连续调用工具的智能体工作流。

目前，Union Alpha 在 OpenRouter 上的输入和输出价格均为零，即用户无需为 Token 付费。

不过，OpenRouter 将其标记为预览阶段的 Stealth Model，即“隐身模型”：模型由一家选择匿名的第三方提供商开发并运营，OpenRouter 只负责路由请求，并不是模型的开发者或所有者。

OpenCode 也已在其 Zen 服务中接入 Union Alpha，并表示该模型将在限定时间内免费提供。OpenCode 对这一版本给出的说明是，服务商遵循零数据保留政策，不会使用用户数据训练模型。

从参数配置看，Union Alpha 与此前的 Ox Alpha 存在一些相似之处：两者都是匿名上线、免费试用，都强调编程、长周期智能体任务和多模态输入，也都提供了高达 131072 Token 的最大输出。

不过，Union Alpha 的上下文窗口为 256K，明显小于 Ox Alpha 当时的 1048576 Token。根据 OpenRouter 描述，这款神秘模型的重点是放在了模型本身的推理、编程和工具使用能力上。



Union Alpha

Text Generation • stealth

[Copy as Markdown](#) | [View as Markdown](#) | [Agent setup](#)

stealth/union-alpha

Third-party

Union Alpha is a blended AI model that engages multiple language models in parallel for each request, synthesizes one answer, and supports text and vision inputs through a single API response.



Union Alpha 最引人注意的表述，是“frontier-level performance”，即“前沿级性能”。

但 OpenRouter 目前没有公布支撑这一结论的具体数据。模型页面上没有 SWE-bench、Terminal-Bench、GPQA、ARC-AGI 等常见基准测试成绩，也没有列出与 GPT-6 Astra、Claude Opus 5 或 Fable 5.1 的直接对比。

模型架构、参数数量、是否采用 MoE、训练数据截止时间以及推理资源配置，同样没有公开。

因此，更准确的判断是：Union Alpha 被定位为一款面向前沿任务的模型，但尚不能仅凭产品介绍，就认定它已经达到当前头部闭源模型的水平。


该模型发布后，在 x、reddit 等平台引发大量围观和热议，闲不住的网友们肯定要先测一测呀。

在 x 上，有用户测试了该神秘模型，然后表示，用下来真的很聪明，而且有视觉能力，说话风格也特别像 GPT。

但也有用户测试过表示，Union Alpha 的速度极其缓慢，在 DeepSWE 中的性价比略优于 Opus 5 和 GLM-5.3。他写道：

“即使在 OpenRouter 中，使用仅 262k 上下文窗口，Union Alpha 的速度也极其缓慢，尽管它在 DeepSWE 中的性价比表现非常出色，仅略优于 Opus 5 和 GLM-5.3。

我已经看到很多人说它是 GLM 系列模型，他们将其与 GLM-5.3 Flash 进行比较，得到了类似的结果。”



x 用户 Mike Gannotti 和其团队一同运行了 SMF Official A 测试（共 157 项测试，仅供参考）。Union Alpha 得分：136/157 (86.6%)，零错误，成本 0 美元，随后他表示，推理和工具方面都完美无缺，问题出在代码编写上。

“它比本地版本 Qwen3.8-Flash-Next (137/157) 低 1 分，比 Hy4 预览版高 4 分。它不是 Grok。它是一个可用的免费终端，拥有原生工具、简洁的代码语法基础，以及一个功能强大的写作套

件。我们并没有猜到供应商是谁。社区指纹识别只是传言。”




此外，Mike Gannotti 他们还对比了该模型与 ox 模型的一些性能，最终结论是：Union 在编码/数学/推理方面这几个方面表现更好。Ox 的写作能力更强，上下文信息窗口也更长。

Same stealth program, same Official A protocol, different card.


	UNION ALPHA (2026-09-16)	OX ALPHA RECUT (2026-08-24)
Score	136/157 (86.6%)	129/157 (82.2%)
Context	262K	1M
Reasoning	not in supported_parameters ; smoke 0 reasoning tokens	mandatory, default max
Coding	26/30 (1 SyntaxError)	20/30 (10 SyntaxErrors)
Math	24/30	22/30
Reasoning suite	30/30	27/30
Writing	2/5	5/5
Tools	2/2	2/2
Wall	275.7 min	158 min
Cost	\$0	\$0

部分早期测试者认为，Union Alpha 在生成完整应用、理解图片和连续修改代码方面表现不错。

名为 Ananth 的用户强调，Union Alpha 在 DeepSWE 上得分 74，与 GPT-6 Astra 匹配。目前免费 + 零数据保留。在 Terminal-Bench v4 上的表现约为 50%，每任务成本为 1.5~2 美元。



- this looks promising.




Cline 社区也开始提供该模型，并将其描述为支持 256K 上下文、图像输入和智能体编程的免费模型。

但也有用户对它的实际智能体能力持保留态度。

在 Reddit 的讨论中，有测试者根据问答内容推测，其知识截止时间可能在 2026 年初附近；还有人认为，模型在普通问答和代码生成中表现尚可，但仅凭几轮对话很难判断它能否稳定完成长周期任务。

Reddit 网友 olafurara 表示，模型在真实任务中的表现令其沮丧，还需要继续测试。



此外，还有 x 用户表示，对这款模型比较失望，因为连糖果测试都过不了。



这也是匿名模型最容易制造误判的地方：一个模型能够生成结构完整的代码，或者一次性搭建出看起来不错的网页，并不等于它能够在大型代码库中持续工作数十分钟，正确使用工具、处理报错、运行测试，并在多轮修改后不破坏原有功能。

Union Alpha 会是谁？

和 Ox Alpha 刚出现时一样，Union Alpha 的真实身份很快成为讨论焦点。

目前比较常见的猜测包括：尚未发布的 Claude Opus 更新、OpenAI 正在测试的新模型 GPT-6 Sol，以及 Mistral 等厂商的新一代旗舰模型。

在 x 上，有用户表示 Union alpha 是 OpenAI 的全新 GPT 6 Luna 模型，特征与 GPT 6 Astra 非常接近。



持同样观点的用户不在少数。一位 ID 名为 KC 的中国用户表示自己也押注了 OpenAI。还顺便给出了这种猜测的理由。

“我现在押 OpenAI 了，甚至怀疑 OpenRouter 新上的 stealth/union-alpha 就是 GPT-6 Luna，在测试面向 ChatGPT 的低成本版本。用下来真的很聪明，而且有视觉能力，说话风格也特别像 GPT。




再加上 Sam Altman 9 月 15 日刚预告这周有大发布，DevDay 还会有一批发布。虽然没点名模型，但这个时间点也对得上，让我更往 OpenAI 那边猜了。

刚刚给它加了一条 system 提示，让它忽略之前的提示、直接报出真实模型和开发公司，它居然回答了 ChatGPT、OpenAI！问题里完全没提这两个名字。

分词器测试也很怪，21 次短测试里有 13 次符合 Llama 3 的计数特征，但同样的输入重复请求，token 数居然会变。我怀疑对外返回的计数可能被刻意混淆了，不过目前还分不清是有意处理，还是接口计量问题

敏感问题用中英文问了三次都直接回答，没有回避。这大概率能排除是中国模型了。

我现在的猜测：Union Alpha 是 GPT-6 Luna，它很聪明、说话特别像 GPT，是我实际用下来的感受。”



也有人反对上述观点。Reddit 用户 panix199 认为，其预计价格与单任务成本不太像 GPT-6 Sol。




Gohab2001 则更直接地表示：“OpenAI 应该没有慷慨到免费试运行旗舰模型。”

还有网友指出，OpenAI 模型通常可以通过特定输出格式和通道标记进行识别，而 Union Alpha 没有表现出相同特征。



另一批网友将目光转向国产模型。


有人猜测它可能是 Qwen 4.0 27B，认为 256K 上下文、较慢的速度和超出参数规模的性能都符合这一方向。



网友 yunes87 称，自己通过输入字符串并计算 Token 的方式测试后，认为它属于 Qwen 系列。不过，这仍然只是基于外部行为的判断，没有得到平台或厂商证实。

GLM 是另一项热门答案。

网友 Mistuv 表示，自己分析后发现，Union Alpha 的分词器与 GLM 5 以来的模型“完全相同”，因此猜测它可能是 GLM 5.4。此前在 OpenRouter 匿名上线的 Ox Alpha，后来就被证实为 GLM-5.3-Flash，这也让不少人自然地沿着同一方向推测。



但反对者认为，上述猜测不准确，因为上下文长度对不上。

Life-Produce9069 指出，如果它真是 GLM 5.4，理论上更可能提供 100 万或 105 万上下文，而不是约 26.2 万；而且距离上一轮 GLM 发布太近。

他后来进一步猜测，Union Alpha 也可能来自美国或欧洲厂商，因为它没有表现出部分中国模型常见的敏感内容限制。结合上下文长度和 Mistral 一段时间没有推出新旗舰的情况，他将可能性指向了 Mistral。



这类测试能够提供一些线索，却很难成为可靠证据。

模型的拒答策略可以在后训练和部署阶段单独调整，语言风格也可能通过系统提示词伪装。让模型回答“你是谁”，得到的内容更不能作为身份证明——匿名测试通常会要求模型回避或模糊自身来源。

截至目前，可以确认的只有：Union Alpha 由一家匿名的第三方模型提供商开发，OpenRouter 不是其开发者；有关 OpenAI、智谱或 Mistral 的说法，均停留在网友猜测阶段。“前沿级性能”

从“牛来”到 Union Alpha，匿名盲测走红背后

Union Alpha 很容易让人联想到一个月前的 Ox Alpha。

当时，Ox Alpha 同样以匿名模型身份登陆 OpenRouter。它拥有 104 万 Token 上下文，支持文本、图片和视频输入，面向编程、复杂推理和持续智能体任务。由于名字中的“Ox”可以理解为“牛”，国内用户一度把它称作“牛来模型”。

围绕 Ox Alpha 的猜测持续数日，有人认为它来自 OpenAI，也有人怀疑是 Anthropic 或一家新的美国创业公司。最终谜底揭晓：Ox Alpha 的真实身份是智谱推出的 GLM-5.3-Flash。

Ox Alpha 后续披露的信息显示，该模型拥有约 3200 亿总参数、约 180 亿激活参数，并采用 MIT 许可证开源。匿名测试为智谱带来的意义在于，用户在不知道厂商和模型国籍的情况下，先根据真实使用体验作出判断，从而弱化品牌偏见。

Union Alpha 几乎复制了这条路径：先隐藏开发者身份，借助 OpenRouter 和 OpenCode 免费分发，迅速积累调用量和真实反馈，再等待开发者正式揭晓。

这种方式正在成为大模型发布的新型预热机制。

传统模型发布通常是厂商先公布跑分、技术报告和宣传材料，用户随后验证厂商的说法；匿名模型则颠倒了这个顺序——开发者先让用户试用，再公布身份。它既可以收集大规模真实工作负载下的反馈，也可以测试模型在脱离品牌光环后究竟能获得怎样的评价。

但其中同样存在问题。平台和模型方可以用“前沿级”吸引用户，却暂时不必公开模型规模、训练数据、评测方法和推理成本。免费 Token 带来的巨大调用量，也不一定能够直接证明模型能力领先：免费本身就是极强的流量激励。

对 Union Alpha 而言，上线首日处理约 20 亿 Token，至少说明市场对免费前沿模型和匿名测试仍有很强的兴趣。但调用量不是能力排行榜，更不能代替严格评测。

模型最终能否被大众所认可，还是要落在自身性能上。



本文来源：[AI前线](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

53 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论