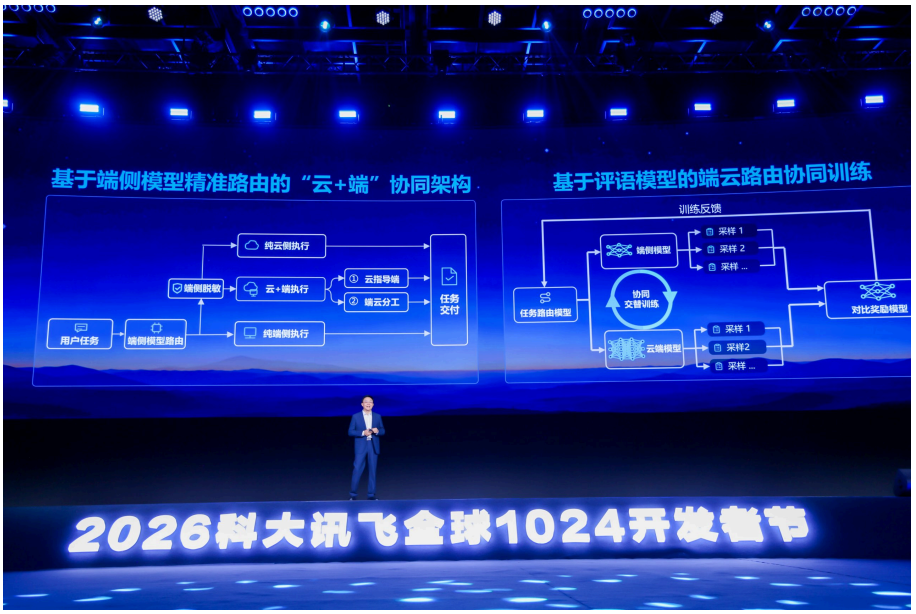
摘要：

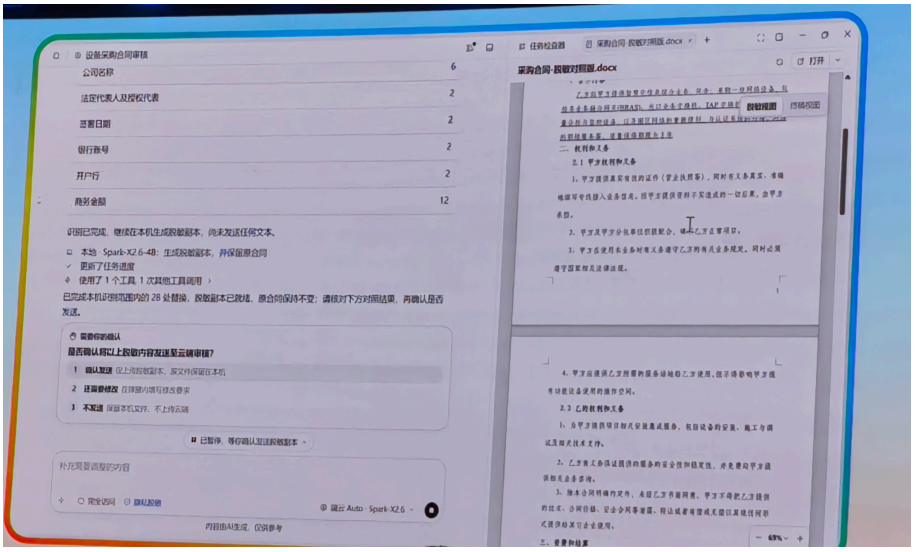
10月22日，在2026科大讯飞全球1024开发者节主论坛上，科大讯飞发布端云一体讯飞星火X2.6大模型，并同步推出端侧模型星火X2.6-4B。此次发布的重点之一是端云一体架构：系统根据用户任务进行路由，分别采用纯端侧执行、纯云侧执行或端云协同的方式完成任务。

10月22日，在2026科大讯飞全球1024开发者节主论坛上，科大讯飞发布端云一体讯飞星火X2.6大模型，并同步推出端侧模型星火X2.6-4B。此次发布的重点之一是端云一体架构：系统根据用户任务进行路由，分别采用纯端侧执行、纯云侧执行或端云协同的方式完成任务。



现场展示的架构图显示，端云协同包含云端指导端侧执行、端云分工两种模式，最终均指向任务交付。主论坛演示环节中，端侧模型在本地处理邮件汇总、合同敏感信息脱敏等任务，再由云端模型进行审核修订，展示了不同处理环节在本地设备与云端之间分工的应用方式。

从合同演示界面看，系统识别并标注了公司名称、法定代表人及授权代表、日期、银行账号、开户行、商务金额等敏感信息，统计了类别及相应数量，并对部分敏感信息字段进行替换。实际应用中的识别准确率、脱敏完整性及数据传输范围，仍需结合具体部署和使用情况判断。



科大讯飞董事长刘庆峰表示，公司预计未来约60%的应用场景可在端侧完成，30%通过端云协同处理，10%需要云端大模型完成。公司还表示，端侧可独立完成的任务占比已从12.8%提升至40%以上，未进一步披露该比例的统计口径。

模型能力方面，星火X2.6采用293B总参数、30B激活参数的混合专家（MoE）架构，与上一代X2.5的参数规模相同。其上下文窗口扩展至100万Tokens。端侧模型X2.6-4B同步开放，官网页面显示限时免费。X2.6与X2.5的发布间隔约45天，本次发布重点强调端云协同，以及代码和智能体等能力的升级。

API定价方面，讯飞星火官网定价页显示，X2.6当前限时6折，输入、输出价格分别为每百万Tokens 0.9元和3.6元。按页面折扣力度反推，折前输出价格约为6元。上一代X2.5当前限时3折，输入、输出价格分别为每百万Tokens 0.96元和3.6元，按折扣反推的折前输出价格约为12元。

两代模型当前促销输出价格相同，缓存命中价格有所差异，X2.6为每百万Tokens 0.08元，X2.5为0.14元。



在国产算力适配方面，科大讯飞称，通过长程任务动态并行训练技术，超长上下文训练效率提升约4倍；通过自适应存算协同推理、四层KV Cache及分布式推理等技术，相关推理效率提升4.5倍。公司称，X2.6训练用时约2至3个月。

4月29日，科大讯飞在2025年度暨2026年第一季度业绩说明会上曾表示，计划于今年10月在昇腾950平台上发布旗舰大模型。此次星火X2.6发布，公司未披露该模型训练所使用的具体芯片型号，目前尚无法确认X2.6是否采用昇腾950平台。

从财务背景看，2026年前三季度，科大讯飞实现营业收入181.87亿元，同比增长7.05%；归母净利润2188.72万元，扣除非经常性损益后的净利润亏损7.63亿元；研发费用38.50亿元，同比增长约20.8%。公司在三季报中表示，第三季度研发投入超过17亿元，较去年同期增加近4亿元，占当季营业收入比重逾25%。

大模型商业化方面，2025年科大讯飞大模型API及MaaS平台服务收入3.85亿元，同比增长263%。2026年上半年，该业务收入同比增长约70%，公司未单独披露同期收入绝对金额。同期，覆盖范围更广的开放平台业务实现收入37.05亿元，同比增长36.01%。两组数据对应的业务口径不同，开放平台整体收入不等同于模型API收入。

新模型将任务路由、端侧处理和云端协同纳入同一架构，试图在任务效果、数据处理方式与使用成本之间进行分工。新模型的端云协同能力、国产算力效率优化及定价策略对API调用需求的影响、后续商业收入增长潜力，仍有待后续经营数据验证。

除星火X2.6外，科大讯飞此次还发布了星火语音基座大模型SparkAudio 1.0、多模交互及具身多模交互技术、讯飞星帆WinWork数字员工平台、星辰TaaS平台，以及基于星火端云大模型和国产操作系统的AIPC系列产品。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限免

23 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论