

摘要：

端侧算力沉寂两年后，真正的“奇点”或藏在机器人身上。国盛证券认为，云端无法克服的“低时延”缺口，正推动割草机器人、人形机器人、无人车成为端侧算力主战场。从YOLO到世界模型的三级跳、NPU架构瓶颈与GPGPU生态降维，芯片、模组、存储三条投资主线随之浮现。

端侧算力的真正爆发可能不在手机和电脑上，而在会动的机器人身上。

5月18日，国盛证券通信行业研究团队（分析师宋嘉吉、黄瀚、邵帅）发布深度研究报告，梳理了端侧算力在需求、模型、芯片三个维度的最新进展，并作出判断：端侧算力正走入“奇点”时刻。

这份报告的起点，是一次坦诚的自我复盘。

两年前，国盛证券曾发布端侧算力深度报告，预判手机、PC等AI设备上的本地算力将迎来高速增长。但现实是——这些设备上的AI功能，大多数仍依赖云端算力，端侧算力并未如期放量。

端侧算力（On-Device Computing / Edge Computing）是指直接在用户终端设备（如智能手机、AI眼镜、PC、智能家居、现在可能包括机器人等）上执行的数据处理和计算能力，无需完全依赖远程云端服务器。

报告用两句话总结了这段历史：“不要低估云端模型的能力边界”，以及“需求不是凭空想象的”。

云端太强，传统端侧需求被“压住了”

过去三年，云端大模型的进化速度远超预期。

报告指出，随着“超节点”、“PD分离”等云端算力架构部署，云端模型在能力快速提升的同时，单位Token成本在加速降低。

以文生图为例：三年前高通还在端侧部署Stable Diffusion，端侧只能生成512×512的底图，逻辑性较差；而云端的GPT-4o、Nano Banana等模型已经可以在10秒内生成4K高分辨率图像，且逻辑细节远胜端侧。

图表1: Nano Banana 将 4K 生成时间压缩至 10 秒以内

NANO BANANA VS NANO BANANA 2		
Feature	Nano Banana	Nano Banana 2
AI Model	Gemini 2.5 Flash	Gemini 3.0 Pro
Text Adherence	Moderate accuracy	3x better prompt understanding
Detail Handling	Struggles with fine text & UI	Sharper text, charts & complex GUI
Resolution	Up to 2K	Native 2K, 4K-ready
Character Consistency	Strong stability	Even more consistent
Editing	Basic background edits	Advanced complex background editing
Aspect Ratios	Standard ratios	More options, incl. 21:9
Speed	10-15s	<10s

资料来源: easemate.ai, 国盛证券研究所


原本支撑端侧算力的三大理由——隐私性、低成本、低时延——也在云端的强势进化下逐一被动摇。报告认为，“隐私性”和“低成本”这两个需求正在被证伪，真正站得住脚的，只剩下“低时延”这一个。

但这里说的低时延，不是指人类等待AI回复的速度。腾讯混元T1模型的吐字速度已达60-80 token/秒，首字秒出，早已低于人类舒适反应区间。

报告所说的低时延，是设备对外部信号的内生处理速度。


人脑处理视觉-运动反应约需180-200毫秒；而一个设备从接收信号、传送云端解析、再传回本地执行，往往需要2-5秒以上——如果是图片等多模态信号，还会更长。

图表2: 膝跳反射链路



资料来源: 《Assessing neuromuscular system via patellar tendon reflex analysis using EMG in healthy individuals》, Khatun Z, Kristinsdóttir S, Thórisdóttir A T, et al., 国盛证券研究所

图表3: 从端到云的数据处理链路



资料来源: 长杨科技, 国盛证券研究所

这就是云端算力无法触及的盲区。报告用了一个类比：把人体神经换成无线信号，把大脑换成云端算力，整个链路的稳定性和延迟就会被无线拉长。

需求在哪里？在会动的机器人上

锁定“低时延”这一核心命题后，真正的需求方向也随之清晰：让“类人终端”更像人。

分析师将当前类人终端按智能程度分为四类：

- 第一类：摄像头等感知硬件，需要处理更多路信号、更精细的识别模型
- 第二类：工具机器人（割草、泳池等），需要识别更多场景——比如割草机器人能识别宠物粪便、石头、积雪、落叶，就能进化为四季可用的“庭院机器人”

- 。第三类：智能车，需要理解异形障碍物和极端复杂场景
- 。第四类：人形机器人，需要实时理解物理世界并产生互动，输入涵盖视觉、听觉、触觉，输出是复杂肢体动作



分析师核心判断是：这一轮端侧需求，不是资本市场的一厢情愿，而是来自“客户需求增长叠加行业能力进化的闭环结果”——割草机器人、送餐机器人、无人汽车的普及，让用户在接受基础功能的同时，也开始提出更高要求。

图表6: 端侧用户需求汇总

	终端类型	更多功能需求
第一类	摄像头等感知硬件	更多路信号，更多解析需求
第二类	工具机器人（割草，泳池等）	更多场景理解，适应更多需求
第三类	智能车	异形障碍识别，极端情况
第四类	人形机器人	物理世界实时理解与互动


资料来源: 国盛证券研究所整理

模型三级跳：从“看图识字”到“预判未来”

需求侧的演进，离不开模型侧的支撑。报告梳理了端侧视觉模型的进化路径，逻辑清晰。

第一代：YOLO模型


大模型时代之前，机器视觉依赖CNN算法下的YOLO模型。其原理是把图像划分为网格，让每个格子负责预测其中的物体——报告打了个比方：就像“一个经验丰富的保安站在高处快速扫视人群，只要某个格子里大概率出现了‘车’或者‘人’的特征，它就立刻画一个框圈出来”。快，但有硬伤：难以处理异形物体和3D画面，也无法理解物品之间的逻辑关联。



第二代：Vision Transformer (ViT)

大模型思路引入视觉领域后，ViT打开了新天花板。它把图像切成小方块，像做阅读理解一样，思考每个碎片与全图其他碎片的关系。报告的描述很形象：“看到左上角的‘猫耳朵’，它会立刻通过逻辑联想到右下角的‘猫尾巴’，即使它们隔得很远。”

图表9: ViT 算法原理



资料来源: GeeksforGeeks, 国盛证券研究所

ViT更消耗算力，这恰恰打通了端侧算力升级的逻辑——更强的算力可以真正转化为更强的能力，而不是“空有算力却无法提升能力”。

第三代：VLM → VLA → 世界模型

智能驾驶加速了这一演进。

- **VLM**（视觉-语言模型）：能看懂图像并翻译成语义信息，相当于“坐在副驾的解说员”，把路况变成机器能听懂的“情报”
- **VLA**（视觉-语言-动作模型）：在VLM基础上加入“动作”维度，直接从视觉感知输出控制指令——“方向盘左打10度”、“油门踩下20%”，实现从眼睛直达手脚的端到端控制。英伟达已于近期发布开源VLA模型Alpamayo
- **世界模型**：更进一步，引入预测机制，在执行动作前预演未来几秒的多种情况，“通过生成未来的视频画面来评估风险，从而在无数个‘平行宇宙’中选出最安全的那一条路去走”

图表11: 世界模型根据当前画面实时预测未来画面



资料来源: 蔚来, 国盛证券研究所

机器人前沿：GEM模型


相比智能驾驶，让机器人理解并与物理世界互动的难度更高一个量级。智能车的目标是“避免与外界互动”，机器人则必须实时与外界产生物理和语言接触。

报告认为，GEM（Grounding Embedding Model）是解决这一难题的可能路径之一。简单说，它能把机器人的感知数据（摄像头画面、激光雷达点云）和高层指令（“把蓝色的杯子递给我”）



映射到同一个特征空间，让机器人即使没见过某个物体，也能通过语义理解完成动作。谷歌的RT-2模型已在探索这一方向，将图像、动作、语言全部token化来实现对齐。

图表12：谷歌 RT-2 模型



资料来源：Deepmind，国盛证券研究所

报告指出，GEM模型当前的主要痛点在于不同模态信号的对齐，以及灾难性遗忘、模态鸿沟等问题，“不仅需要模型工程上的持续优化，在未来执行层面，也需要专门的算力芯片架构进行配合”。


芯片之争：NPU遇到天花板，GPGPU向下渗透

模型需求确定了，芯片是最终落脚点。报告详细分析了NPU与GPGPU两条路线的优劣。

NPU：从YOLO起家，遭遇架构瓶颈

NPU的第一波放量来自YOLO模型——安防摄像头、初级自主移动机器人大量搭载NPU芯片。瑞芯微RK系列凭借性价比和低功耗成为主流选择，其营业收入从2016年的12.98亿元增长至2025年的44.02亿元。

图表13：瑞芯微营业收入高速增长



资料来源：ifind，国盛证券研究所

但进入大模型时代，NPU遇到了架构层面的硬约束：在扫地机器人等低功耗场景下，如果要运行以ViT为基座的模型替代YOLO，算力需求将接近100TFLOPS。更关键的是，NPU缺少CUDA CORE，所有指令由CPU下发，而端侧功耗和成本限制下无法使用高性能CPU——“一旦在较弱的CPU下挂在了过多的NPU核，用于AI任务的指令就会占据CPU所有的通信总线，从而使得设备宕机”。

当前有两条破局路径：

- 高通骁龙IQ10：换装更好的CPU和更大面积的NPU核，并融合部分GPU任务调度结构
- 瑞芯微RK182x：采用3D-DRAM+协处理器双轨并行，通过堆叠封装加大NPU与存储间的带宽，同时将AI推理从主芯片解放出来，缓解总线拥堵

图表16：高通发布基于骁龙 IQ10 的整套物理 AI 方案




资料来源：高通，国盛证券研究所

GPGPU：从云端继承，生态优势放大

相比NPU，GPGPU的端侧路径更顺滑。云端GPGPU本就是全功能芯片，走向端侧只需按需缩减面积和核心数量，不存在NPU面临的架构改造难题。

英伟达智能驾驶业务收入从2021财年的5.36亿美元增长至2026财年的23.49亿美元，Orin、Thor系列已推出覆盖不同价位和算力段的产品线。


图表18：英伟达车载收入增长情况（按财年）



资料来源：ifind，国盛证券研究所

但GPGPU的核心优势不只是硬件，更在于生态。报告指出，大部分端侧模型的预训练和微调都需要借助CUDA生态完成，“如果在端侧使用GPGPU架构的算力，那么无论是部署速度，部署效果都会远超需要转译的NPU环境”。同时，英伟达在FP4等低精度推理方面已有成熟方案，可以直接下放端侧，而NPU则追赶艰难。

图表20: CUDA 正在向物理世界加速延伸



资料来源：英伟达，国盛证券研究所

分析师的结论是：**看好GPGPU架构在端侧渗透率持续提升**。但英伟达高昂的售价注定其不会成为市场唯一选择，这也为高通（通信+计算融合的SOC方案）和国内芯片公司（以性价比切入下沉市场）留出了空间。

投资布局：芯片、模组、存储三条线

分析师将端侧算力的投资机会分为三个环节：

芯片：价值量提升最大的环节。关注NPU迭代与GPGPU向下渗透。报告特别指出，端侧设备中算力成本占比将显著提升，“这一逻辑与云端基建类似”。

模组：报告称之为“旱涝保收的中间商”。端侧算力客户极度分散，模组公司承担连接上游芯片和下游万千用户的桥梁作用。无论哪种芯片路线最终胜出，模组厂商都能受益。在IoT时代已实现全球“东生西落”的中国模组公司，被认为不会缺席这一轮增长。

存储：3D-DRAM是报告重点提及的新方向。端侧芯片的推理能力同样受内存大小和带宽制约，3D-DRAM通过将DRAM与NPU堆叠封装，在低成本、低功耗前提下提升带宽。

图表21: 端侧上市公司整理

代码	公司	市值（亿元人民币）	关键信息
端侧算力公司：GPGPU 与 NPU			
NVDA.O	英伟达	390552	全球 GPGPU 龙头，端侧算力全球领先
QCOM.O	高通	14425	全球端侧高端 NPU 算力龙头
ARM.O	ARM	16630	全球端侧 CPU 架构龙头
9660.HK	地平线	801	中国智驾与具身算力龙头
603893.SH	瑞芯微	737	高性价比端侧算力龙头
000716.SZ	黑芝麻	42	中国智驾与具身算力龙头
300458.SZ	全志科技	360	端侧全品类 SOC
688099.SH	晶晨股份	471	端侧全品类 SOC
端侧配套公司：通信与存储			
603986.SH	兆易创新	2531	中国消费存储龙头
688008.SH	澜起科技	3358	中国存储控制芯片龙头
688220.SH	翱杰科技	458	端侧 SOC 设计与通信芯片龙头
688018.SH	乐鑫科技	293	端侧 Wifi 解决方案龙头
端侧模组公司			
603236.SH	移远通信	212	全球物联网模组龙头
300638.SZ	广和通	197	全球物联网模组龙头
002881.SZ	美格智能	114	全球物联网模组龙头

资料来源：ifind，数据截至 2026-05-14，国盛证券研究所

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

64 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论